

Gemischte Modelle in den Life Sciences

**Für Studierende der
Agrarbiologie und
der Agrarwissenschaften (M. Sc.)**

an der Universität Hohenheim

6./8. Semester

Prof. Dr. Hans-Peter Piepho

Institut für Pflanzenbau und Grünland (340)
FG Bioinformatik
Universität Hohenheim
Email piepho@uni-hohenheim.de

Hohenheim, im März 2003

Inhaltsverzeichnis

Seite

1. Vorbemerkung	1
2. Was sind gemischte Modelle?	1
3. Einfache hierarchische Modelle	4
Beispiel 3.1 Einfache Varianzanalyse	4
Beispiel 3.2 Rübenblätter - Ca-Gehalt - zweistufig	10
Beispiel 3.3 Zuckergehalt Rüben - optimaler Stichprobenplan	15
Beispiel 3.4 Kelchlängen bei Primeln, gewichtetes Mittel	17
Beispiel 3.5 Rübenblätter - Ca-Gehalt - dreistufig	21
Beispiel 3.6 Urinproben - zweistufig	24
Beispiel 3.7 Reizschwellen des Patellarsehnenreflexes - Kreuzklassifikation	26
4. Versuche mit unvollständigen Blöcken	33
Beispiel 4.1 Intra-Block-Information	33
Beispiel 4.2 Balancierte unvollständige Blöcke - Penicillin	38
Beispiel 4.3 α -Design - Hafer	45
5. Split-plots und strip-plots	49
Beispiel 5.1 Spaltanlage - Reis	49
Beispiel 5.2 Streifenanlage - Reis	66
Beispiel 5.3 Streifenanlage - Schnitthäufigkeit Grünland	75
6. Sub-Sampling	78
Beispiel 6.1 Sorghum-Versuch	78
7. Zuchtwertschätzung	86
Beispiel 7.1 Radieschen	86
8. Longitudinale Daten (repeated measurements)	93
Beispiel 8.1 Ascorbinsäure	93
Beispiel 8.2 Alzheimer-Patienten	101
Beispiel 8.3 Grimmdarm Schweine	106
Beispiel 8.4 Ratten - Wachstumsverläufe	135
Beispiel 8.5 $N_{\min}$ -Bodenproben - Messwiederholungen in Raum und Zeit	143
9. Versuchsserien	150
Beispiel 9.1 Haferdaten Bundessortenamt	150
Beispiel 9.2 Krüger-Park - Zebras	163
10. Fehlerfortpflanzung	169
Beispiel 10.1 Viskositätsmessung - Physikpraktikum	169
11. Makros	177
Makro 1: Multiple Vergleiche	177
Makro 2: Daten-Transformationen (Box-Cox und Manly)	180
Anhang 1: Allgemeine Resultate für das lineare gemischte Modell	186
Angang 2: Hinweise zur Nutzung von SAS	190

1. Vorbemerkung

In diesem Skript werden einfache gemischte Modelle anhand von Beispielen vorgestellt. Hierbei steht die Fragestellung der zugrundeliegenden Untersuchung und die sich daraus ergebende Motivation des Modells im Vordergrund. Für jedes Beispiel wird die Auswertung angegeben, wobei die Diskussion der statistischen Theorie sich auf ein Minimum beschränkt. Einige theoretische statistische Grundlagen werden im Anhang beschrieben. Detaillierte Darstellungen der statistischen Theorie finden sich z.B. in Searle et al. (1992) oder Verbeke und Molenberghs (1997). Für den Anwender von Statistikroutinen zur Auswertung gemischter Modelle (z.B. PROC MIXED in SAS) ist die richtige Formulierung des Modells die zentrale Aufgabenstellung bei der Auswertung. Daher liegt das Schwergewicht der Darstellung auf einer Diskussion der Modelle.

Diese Vorlesung wird in der jetzigen Form das erste Mal gehalten. Der Inhalt, und somit auch das vorliegende Skript, werden während der Vorlesung weiterentwickelt. Aktualisierte Fassungen und ergänzendes Material werden auf der homepage des Fachgebietes Bioinformatik zur Verfügung gestellt (<http://www.uni-hohenheim.de/Bioinformatik/Bioinformatik/>).

Die Vorlesung ist Beispiel-zentriert. Dies soll erreichen, dass die vorgestellten Methoden von der Anwendung her und nicht von der Theorie motiviert werden. Dies bietet den Vorteil der starken Anwendungsbezogenheit, hat aber den Nachteil, dass theoretische Grundlagen in den Beispielen versteckt sind. Hierüber sollte sich der Leser des Skriptes bewusst sein. Eine Inhalts-Übersicht über verschiedene theoretische Inhalte ist in Vorbereitung.

Am Semesterende wird es eine gemeinsame Prüfung mit der Veranstaltung "Weiterführende statistische Methoden für die Life Sciences" geben. Es ist noch zu klären, in welcher Form diese Prüfung stattfindet (schriftlich/mündlich, mit oder ohne PC).

Die Vorlesung wird am ersten Termin in HS 20 stattfinden, danach überwiegend im PC Raum 5 in der "Alten Botanik". Details werden in der Vorlesung bekannt gegeben.

2. Was sind gemischte Modelle?

Angenommen, in einer klinischen Studie werden vier verschiedene Behandlungen (Placebo + 3 Medikamente) zur Blutdrucksenkung geprüft (Searle et al., 1992, S. 8). Hierzu wird eine Zufallsauswahl von 15 Kliniken herangezogen. Je Klinik werden pro Medikation fünf Patienten in die Studie einbezogen. Bei jedem Patienten wird vor und nach Verabreichung der Medikation der Blutdruck gemessen. Die Änderung des Blutdrucks (y) wird dann zur Beurteilung der Medikamente herangezogen. Ein lineares Modell für die Auswertung ist wie folgt:

$$E(y_{ijk}) = \mu + \alpha_i + \beta_j + \gamma_{ij} \quad \text{und} \quad y_{ijk} = E(y_{ijk}) + e_{ijk}, \quad \text{wobei}$$

y_{ijk} = Blutdruck-Differenz des k -ten Patienten ($k = 1, \dots, 5$)
in der j -ten Klinik ($j = 1, \dots, 15$) für die i -te Medikation ($i = 1, \dots, 4$)

μ = Gesamteffekt ("Gesamtmittelwert")

α_i = Effekt der i -ten Medikation

β_j = Effekt der j -ten Klinik

γ_{ij} = Wechselwirkung zwischen der i -ten Medikation und der j -ten Klinik

e_{ijk} = Abweichung des k -ten Patienten in der j -ten Klinik für die i -te Medikation

$E(y_{ijk})$ ist der **Erwartungswert** einer Beobachtung bei der i -ten Medikation in der j -ten Klinik. Dies ist der systematische Teil des Modells. Die Zufallsabweichung e_{ijk} , auch als "Fehler" bezeichnet, ist die zufällige oder stochastische Komponente des Modells. Für den Fehler wird oft zusätzlich die Annahme einer Normalverteilung mit Mittelwert Null und Varianz σ^2 gemacht. Dies wird formal wie folgt ausgedrückt:

$$e_{ijk} \sim N(0, \sigma^2)$$

In diesem Modell ist der Effekt e_{ijk} eine Zufallsvariable, während alle anderen Effekte ($\mu, \alpha_i, \beta_j, \gamma_{ij}$) feste Parameter sind. Die **zufälligen Effekte** (e_{ijk}) sind gewissermassen das Hintergrundrauschen ("noise"), dass durch Unterschiede zwischen den Personen in der Disposition für Bluthochdruck zustandekommt, während die **festen Effekte** ($\mu, \alpha_i, \beta_j, \gamma_{ij}$) systematische Unterschiede modellieren, die durch die Faktoren Klinik und Medikation zustandekommen. Unter diesen Modellannahmen kann die Studie klassisch mittels einer zweifaktoriellen Varianzanalyse ausgewertet werden, wobei Mittelwerte mit der Methode der Kleinsten Quadrate geschätzt werden (BLUE = best linear unbiased estimation). Hierbei steht vor allem die Frage der Wechselwirkung Klinik $\times$ Medikation im Vordergrund. Bei signifikanten Wechselwirkungen kann die Wirkung der Medikation nicht einfach für alle Kliniken verallgemeinert werden. Vielmehr schwankt die Wirkung von Klinik zu Klinik, und es stellt sich die Frage, wie es zu Unterschieden in der Wirkung kommt (Personal, Klima, etc.).

Da im vorliegenden Fall die Kliniken zufallsmäßig ausgewählt wurden, kann der Faktor Klinik auch als zufällig betrachtet werden. Bei dieser Sichtweise interessieren die Ergebnisse der einzelnen Kliniken in der Regel wenig. Diese dienen gewissenmassen nur als Wiederholung. Von Interesse ist vor allem der Durchschnitt oder Erwartungswert über eine Zufallsstichprobe von Kliniken hinweg. Wird ein Faktor als zufällig betrachtet, so werden üblicherweise seine Hauptwirkung sowie alle Wechselwirkungen mit anderen Faktoren als zufällig betrachtet. Im vorliegenden Fall bedeutet dies folgendes Modell:

$$E(y_{ijk}) = \mu + \alpha_i$$

$$\beta_j \sim N(0, \sigma_\beta^2)$$

$$\gamma_{ij} \sim N(0, \sigma_\gamma^2)$$

$$e_{ijk} \sim N(0, \sigma^2)$$

Bei der Auswertung steht die Berechnung von Mittelwerten über die Kliniken und deren Vergleich im Vordergrund. Die Wechselwirkungen sind zufällig und gehen als Fehlerterm in den Mittelwertvergleich ein. Um den Fehlerterm berechnen zu können, ist im allgemeinen eine Schätzung der Varianzkomponenten erforderlich. Es ist außerdem möglich, bei Annahme zufälliger Kliniken die Klinikeffekte und Wechselwirkungen zu schätzen (BLUP = best linear unbiased prediction). Die Schätzungen führen zu etwas anderen Ergebnissen als bei Annahme feste Klinikeffekte. In vielen Fällen sind die Schätzungen genauer als bei Annahme fester Effekte.

Da hier in einem Modell sowohl feste Effekte (neben μ) also auch zufällige Effekte (neben dem Resteffekt e_{ijk}) im selben Modell auftreten, spricht man von einem **gemischten Modell** (mixed model). Im weiteren Sinne sind alle linearen Modelle gemischt, da sie immer feste (systematische) und zufällige Komponenten enthalten. Im Agrarbereich ergibt sich übrigens eine ähnliche Modellierung, wenn Sorten über verschiedene Standorte geprüft werden. Sorten entsprechen den Medikationen, Kliniken den Standorten.

Wie das Beispiel zeigt, ist die Frage ob ein Effekt bzw. Faktor als fest oder zufällig zu betrachten ist, zentral bei der Formulierung von gemischten Modellen. Searle et al. (1992, S. 18) geben das folgende Entscheidungsschema für die Frage, ob ein Faktor fest oder zufällig ist, und die Konsequenzen für die Analyse (Abb. 2.1):




Abb.2.1: Entscheidungsschema zur Wahl fester und zufälliger Faktoren (BLUE = Best linear unbiased estimation; BLUP = Best linear unbiased prediction; REML = Restricted maximum likelihood)

3. Einfache hierarchische Modelle

In vielen Anwendungen werden Zufallsstichproben von Untersuchungseinheiten erhoben, die dann zur Berechnung von Mittelwerten herangezogen werden. Oft gebietet es der Untersuchungsgegenstand, dass auf mehreren Stufen eine Zufallsstichprobe gezogen wird, z.B. Pflanzen einer Parzelle auf der ersten und Blätter einer Pflanze auf der zweiten Stufe. Solche mehrstufigen Stichproben können mit hierarchischen gemischten Modellen ausgewertet werden. Hierarchische Modelle haben eine gewisse Ähnlichkeit mit dem Modell der einfachen Varianzanalyse, unterscheiden sich von diesem aber wesentlich durch die Annahme eines Verteilungsmodells für die Effekte. In Beispiel 1 wird zur Grundlegung zunächst das varianzanalytische Modell mit festen Behandlungseffekten vorgestellt. Dort gibt es außer dem "Restfehler" keine zufälligen Effekte. Die Beispiele 2 bis 7 beschäftigen sich dagegen mit Modellen, in denen ausschliesslich zufällige Effekte auftreten, und diese spiegeln jeweils eine mehrstufige Stichprobenstruktur wieder, so dass ein hierarchisches Modell vorliegt. In Beispiel 7 liegt zusätzlich auf der ersten Stufe eine kreuzklassifizierte Struktur vor.

Beispiel 3.1: In einem vollständig randomisierten Feldversuch mit 5 Weizensorten (A, B, C, D, E) und 4 Wiederholungen (also $4 \cdot 5 = 20$ Parzellen = Feldstücke) werden folgende Erträge (dt/ha) ermittelt (**sorten.dat**):

1 B 21	2 D 34	3 D 32	4 E 24
5 C 27	6 E 23	7 A 31	8 B 23
9 A 32	10 C 29	11 E 27	12 A 37
13 D 31	14 D 27	15 A 32	16 B 25
17 B 19	18 C 34	19 E 26	20 C 34

(oben links in jeder Parzelle: Parzellennummer; unten rechts: Ertrag)

Ziel der Auswertung: Vergleich der Mittelwerte der 5 Sorten, Signifikanztests.

Versuche wie der hier beschriebene werden in der Regel basierend auf einem linearen Modell ausgewertet. Im vorliegenden Fall kann das folgende Modell angesetzt werden:

$$y_{ij} = \mu_i + e_{ij}, \quad i = 1, \dots, t; \quad j = 1, \dots, r$$

wobei

y_{ij} = Messwert der j -ten Wiederholung der i -ten Behandlung (Sorte)

μ_i = theoretischer Mittelwert (Erwartungswert) der i -ten Behandlung

e_{ij} = Zufallsabweichung der Beobachtung y_{ij} vom Behandlungsmittel

Eine alternative Schreibweise ergibt sich, wenn wir den Behandlungsmittelwert μ_i ersetzen durch $\mu + \tau_i$, so dass das Modell lautet:

$$y_{ij} = \mu + \tau_i + e_{ij}, \quad i = 1, \dots, t; \quad j = 1, \dots, r,$$

wobei

μ = Konstante

τ_i = Effekt der i -ten Behandlung

In dieser Schreibweise ist $\mu + \tau_i$ der wahre Mittelwert der i -ten Behandlung.

Das hier verwendete Modell ist ein lineares Modell. Lineare Modelle sind häufig gute Annäherungen an die Wirklichkeit. Wegen Ihrer einfachen Handhabbarkeit werden sie oft benutzt.

Da es sich um einen randomisierten Versuch handelt, bei dem die Behandlungen (Sorten) zufällig den Versuchseinheiten (Parzellen) zugeordnet wurden, ist der Fehlereffekt e_{ij} eine Zufallsvariable. Ein wichtiger Aspekt der Modellformulierung ist die Annahme über die Verteilung des Fehlers e_{ij} . Wir nehmen hier an, dass die Fehler stochastisch unabhängig sind und dass sie einer Normalverteilung mit Mittelwert Null und konstanter Varianz σ^2 folgen. Dies wird auch wie folgt ausgedrückt:

$$e_{ij} \sim N(0, \sigma^2)$$

Diese Annahme bedeutet, dass auch die Daten normalverteilt sind, und zwar mit Mittelwert μ_i :

$$y_{ij} \sim N(\mu_i, \sigma^2)$$

Die Annahme der stochastischen Unabhängigkeit ist immer dann gewährleistet, wenn der Versuch richtig randomisiert wurde. Wurde dagegen nicht randomisiert, ist diese Annahme nicht zulässig. Daher ist die Randomisation außerordentlich wichtig.

Die anderen beiden Effekte des Modells, μ und τ_i , sind keine Zufallsvariablen, sondern "feste" Parameter ohne eine Verteilung (es sein denn wir nehmen den Standpunkt eines 'Bayesianers' ein und postulieren eine sog. "*a priori* Verteilung" der Effekte, was wir hier aber nicht tun wollen; später werden wir dies im Beispiel 5 tun). Also sind die Fehler e_{ij} zufällig, während die Effekte μ und τ_i "fest" sind. Das Modell lässt sich graphisch wie folgt darstellen:




Abb. 3.1: Graphische Darstellung des varianzanalytischen Modells: Überlagerung von 5 Normalverteilungen, wobei die Verteilungen der Behandlungen 3 und 4 wegen des gleichen Mittelwertes exakt übereinander liegen.

Jede Behandlung hat eine eigene Normalverteilung. Die Breite der Dichtefunktion und damit die Varianz ("Streuung") ist für jede Behandlung gleich. Wenn Behandlungsunterschiede im mittleren Ertrag bestehen, so ist die Lage der Verteilungskurven auf der x-Achse verschoben. Die Lage der Kurven ist durch den Mittelwert (Erwartungswert) μ_i festgelegt.

Auswertung: Die Erwartungswerte μ_i der Sorten werden mittels des einfachen Stichprobenmittelwertes geschätzt:

$$\hat{\mu}_i = \bar{y}_{i.} = \frac{\sum_{j=1}^r y_{ij}}{r}$$

Dieser Schätzer hat die optimale Eigenschaft, dass er unter allen unverfälschten linearen Schätzern die minimale Varianz hat (engl.: best linear unbiased estimator = BLUE).

Varianzanalyse:

Quelle	FG	MQ	E(MQ)	F _{Vers}
Behandlungen	$t - 1$	$MQ_{Beh} = \frac{SQ_{Beh}}{t - 1}$	$\sigma^2 + \frac{r \sum_{i=1}^t (\tau_i - \bar{\tau})^2}{t - 1}$	$F_{Vers} = \frac{MQ_{Beh}}{MQ_{Fehler}}$
Fehler	$t(r - 1)$	$MQ_{Fehler} = \frac{SQ_{Fehler}}{t(r - 1)}$	σ^2	

Quadratsummen:

$$SQ_{Beh} = r \sum_{i=1}^t (\bar{y}_{i.} - \bar{y}_{..})^2 = \sum_{i=1}^t y_{i.}^2 / r - y_{..}^2 / (rt);$$

$$SQ_{Fehler} = \sum_{i=1}^t \sum_{j=1}^r (y_{ij} - \bar{y}_{i.})^2 = \sum_{i=1}^t \sum_{j=1}^r y_{ij}^2 - \sum_{i=1}^t y_{i.}^2 / r$$

wobei

Beobachtung: y_{ij} = Messwert j -te Wiederholung der i -ten Behandlung

$$(i = 1, \dots, t; j = 1, \dots, r)$$

Behandlungssummen: $y_{i.} = \sum_{j=1}^r y_{ij}$

Gesamtsumme: $y_{..} = \sum_{i=1}^t \sum_{j=1}^r y_{ij}$

Verwerfe die Nullhypothese $H_0: \tau_1 = \tau_2 = \dots = \tau_t$ wenn gilt:

$$F_{Vers} = MQ_{Beh} / MQ_{Fehler} > F_{Tab} = F_{(1-\alpha; t-1, t(r-1))}$$

Hinzu kommt ein multipler Mittelwertvergleich, der hier nicht weiter besprochen wird (siehe SAS Anweisungen und Vorlesung "Statistik für Agrarbiologen" im 3. Sem.).

SAS Anweisungen:

```
data;
input parzelle sorte$ ertrag;
cards;
1 B 21
2 D 34
3 D 32
4 E 24
5 C 27
6 E 23
7 A 31
8 B 23
```

```

9  A 32
10 C 29
11 E 27
12 A 37
13 D 31
14 D 27
15 A 32
16 B 25
17 B 19
18 C 34
19 E 26
20 C 34
;
proc mixed;
class sorte;
model ertrag=sorte/solution;
lsmeans sorte/pdiff adjust=tukey;
run;

```

Output (Auszug):

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
sorte	4	15	11.28	0.0002

Least Squares Means

sorte	Estimate	Standard Error
A	33.0000	1.3904
B	22.0000	1.3904
C	31.0000	1.3904
D	31.0000	1.3904
E	25.0000	1.3904

Differences of Least Squares Means

Effect	sorte	_sorte	Estimate	Standard Error	DF	Adjustment	Adj P
sorte	A	B	11.0000	1.9664	15	Tukey	0.0004
<weitere Vergleiche>							

Beispiel 3.2: Bei Rübenblättern einer Pflanze wurde der Gehalt an Calcium (% der Trockenmasse) bestimmt (Snedecor und Cochran, 1967, S. 281). Pro Blatt wurden 4 Analysen durchgeführt (**rüben.dat**).

Blatt	% Calcium			
1	3,28	3,09	3,03	3,03
2	3,52	3,48	3,38	3,38
3	2,88	2,80	2,81	2,76
4	3,34	3,38	3,23	3,26

Ziel: Bestimmung des durchschnittlichen Calciumgehaltes des Blattapparates der Pflanze.

Modellierung: Wir können hier den einfachen Mittelwert der 16 Beobachtungen berechnen. Dies ist allerdings nur ein Schätzwert des tatsächlichen Calciumgehaltes des Blattapparates der Pflanze, weil wir nur eine Stichprobe von Blättern untersucht haben und weil die Messmethode einen Analysefehler hat, wie durch die Streuung der Messwiederholungen offenbar wird. Daher ist es sinnvoll, den Mittelwerte mit einer Genauigkeitsangabe zu versehen, z.B. dem Standardfehler. Je größer der Standardfehler, desto ungenauer ist der Mittelwert. Der Standardfehler kann auch zur Berechnung eines Vertrauensintervalls herangezogen werden, welches mit vorgegebener Wahrscheinlichkeit den wahren Ca-Gehalt der Pflanze überdeckt. Auch für ein solches Intervall benötigen wir den Standardfehler.

Um den Standardfehler (Quadratwurzel aus der Varianz des Mittelwertes) zu berechnen, könnten wir die einfache Annahme machen, dass die 16 Messwerte eine einfache Zufallsstichprobe aus der Grundgesamtheit "Pflanze" darstellen. Hierfür können wir das folgende lineare Modell aufstellen:

$$y_{ij} = \mu + e_{ij} \quad , \quad i = 1, \dots, t; \quad j = 1, \dots, n$$

wobei

y_{ij} = Ca-Menge der j -ten Messwiederholung für das i -te Blatt

μ = theoretischer Mittelwert (Erwartungswert) der Pflanze; tatsächlicher Ca-Gehalt der gesamten Pflanze

e_{ij} = Zufallsabweichung der Beobachtung y_{ij} vom Erwartungswert

Für die Zufallsabweichung e_{ij} machen wir folgende Verteilungsannahme:

$$e_{ij} \sim N(0, \sigma^2)$$

Nach diesem Modell hat der einfache Mittelwert

$$\hat{\mu} = \bar{y}_{..} = \frac{\sum_{i=1}^t \sum_{j=1}^r y_{ij}}{rt}$$

der Ein Schätzer für μ ist, folgende Varianz:

$$\text{var}(\bar{y}_{..}) = \frac{\sigma^2}{rt}$$




Abb. 3.2: Calziumgehalte der Blätter der vier verschiedenen Pflanzen.

Das Modell impliziert, dass alle 16 Messungen voneinander statistisch unabhängig sind, dass also die Korrelation bzw. die Kovarianz aller Beobachtungspare Null ist. Diese Annahme ist aber nicht vernünftig, denn zwei Messwiederholungen, die von demselben Blatt stammen, sind sich tendentiell ähnlicher als zwei Messwerte von verschiedenen Blättern, wie Abb. 3.2 zeigt. In anderen Worten: zwei Messwerte vom selben Blatt sind positiv miteinander korreliert, die Kovarianz ist positiv. Die positive Kovarianz kann modellseitig einfach berücksichtigt werden, in dem ein Blatteffekt aufgenommen wird:

$$y_{ij} = \mu + b_i + e_{ij}, \quad i = 1, \dots, t, \quad j = 1, \dots, r$$

wobei

b_i = Effekt des i -ten Blatts ($i = 1, \dots, t$)

e_{ij} = Messfehler der Beobachtung y_{ij}

Da eine Zufallsstichprobe von Blättern untersucht wurde, ist der Blatteffekt als zufällig zu betrachten:

$$b_i \sim N(0, \sigma_b^2)$$

Formal hat das lineare Modell dieselbe Form wie in Beispiel 3.1. Der Behandlungseffekt τ_i entspricht hier dem Blatteffekt b_i . Der Unterschied besteht darin, dass wir hier die Blatteffekte als zufällig und nicht als fest betrachten, weil eine Zufallsstichprobe von Blättern vorliegt. Auch sind wir nicht an Mittelwertunterschieden zwischen den Blättern interessiert. Vielmehr soll ja über die Blätter gemittelt werden. Da das Modell mehr als einen zufälligen Effekt hat, spricht man von einem zufälligen Modell (random model).

Die Messwerte des Ca-Gehaltes sind durch den zufälligen Blatteffekt jetzt nicht mehr alle unabhängig. Zwar sind Messwerte von verschiedenen Blättern nachwievor unabhängig, aber Messwerte vom selben Blatt sind korreliert bzw. sie weisen eine positive Kovarianz auf. Die Kovarianz zweier Messwerte vom i -ten Blatt ist gegeben durch:

$$\text{cov}(y_{ij}, y_{ij'}) = \sigma_b^2$$

Die Korrelation zweier Messwerte vom selben Blatt ist

$$\text{corr}(y_{ij}, y_{ij'}) = \frac{\sigma_b^2}{\sigma_b^2 + \sigma^2}$$

Man spricht auch von der sog. "Intraclass-Korrelation". Die positive Korrelation spiegelt die Tatsache wieder, dass sich Messwerte von selben Blatt ähnlicher sind als Messwerte von verschiedenen Blättern. Nach dem um Blatteffekte erweiterten Modell hat der Mittelwert folgende Varianz:

$$\text{var}(\bar{y}_{..}) = \frac{\sigma_b^2}{t} + \frac{\sigma^2}{nt}$$

Die Varianz ist also um den Betrag σ_b^2/t größer als wenn wir Unabhängigkeit aller Beobachtungen annehmen würden! Der Grund ist wie folgt: Bei positiv korrelierten Messwerten bringt jeder zusätzliche Messwert (selbes Blatt) weniger zusätzliche Information als bei unabhängigen Messwerten (neues Blatt). In der extremen Situation einer perfekten Korrelation (Messfehlervarianz $\sigma^2 = 0$; $\text{corr}(y_{ij}, y_{ij'}) = 1$) liefert ein einziger Messwert von einem Blatt dieselbe Information wie 5, 10 oder 1000 Messwerte vom selben Blatt, denn die wiederholten Messwerte sind alle identisch. Wir können also noch so viele Messwiederholungen machen, dadurch wird sich die Genauigkeit des Mittelwertes kein bisschen erhöhen.

Auswertung:

Varianzanalyse-Tabelle:

Quelle	FG	MQ	E(MQ)
Blätter ("Behandlungen")	$t - 1$	$MQ_{Beh} = \frac{SQ_{Beh}}{t - 1}$	$\sigma^2 + r\sigma_b^2$
Fehler	$t(n - 1)$	$MQ_{Fehler} = \frac{SQ_{Fehler}}{t(r - 1)}$	σ^2

Quadratsummen wie in Beispiel 3.1

Schätzung der Varianzkomponenten nach der ANOVA-Methode (Momenten-Methode):

$$\hat{\sigma}^2 = MQ_{Fehler}$$
$$\hat{\sigma}_b^2 = \frac{MQ_{Beh} - MQ_{Fehler}}{r}$$
$$\hat{\text{var}}(\bar{y}_{..}) = \frac{\hat{\sigma}_b^2}{t} + \frac{\hat{\sigma}^2}{rt} = \frac{MQ_{Beh}}{rt}$$

$(1-\alpha)100\%$ Vertrauensintervall für μ :

$$\bar{y}_{..} \pm t_{1-\alpha/2; t-1} \sqrt{\hat{\text{var}}(\bar{y}_{..})}$$

wobei $t_{1-\alpha/2; t-1}$ das $(1-\alpha/2)100\%$ Quantil der t -Verteilung mit $t-1$ Freiheitsgraden ist.

Beispiel:

Quelle	FG	MQ	E(MQ)
Blätter	3	0,296123	$\sigma^2 + 3\sigma_b^2$
Fehler	12	0,006602	σ^2

$$\hat{\sigma}^2 = 0,006602$$

$$\hat{\sigma}_b^2 = \frac{0,296123 - 0,006602}{3} = 0,07238$$

Vertrauensintervall:

$$\bar{y}_{..} = 3,1656$$

$$3,1656 \pm 3,182 \sqrt{\frac{0,29612}{4 \cdot 4}}$$

⇒ Untere Grenze = 2,7327, Obere Grenze = 3,5986

SAS Anweisungen:

```
data ruebe1;
input pflanze probe calzium;
datalines;
  1      1      3.28
  1      2      3.09
  1      3      3.03
  1      4      3.03
  2      1      3.52
  2      2      3.48
  2      3      3.38
  2      4      3.38
  3      1      2.88
  3      2      2.80
  3      3      2.81
  3      4      2.76
  4      1      3.34
  4      2      3.38
  4      3      3.23
  4      4      3.26
;
proc mixed data=ruebe1;
class pflanze;
model calzium=/solution cl;
random pflanze;
run;
```

Output:

Covariance Parameter Estimates

Cov Parm	Estimate
pflanze	0.07238
Residual	0.006602

Solution for Fixed Effects

Effect	Estimate	Standard Error	DF	Lower	Upper
Intercept	3.1656	0.1360	3	2.7327	3.5986

Beispiel 3.3: Snedecor und Cochran (S. 529) beschreiben eine Studie zur Entwicklung eines optimalen Stichprobenplanes zur Ermittlung des Zuckergehaltes bei Zuckerrüben. Auf 100 Parzellen eines Blindversuches wurden je 10 Pflanzen analysiert. Um die Bedingungen eines Blockversuchs zu simulieren, wurde das MQ "zwischen den Parzellen" auf Basis der Streuung zwischen den Parzellen innerhalb von Blöcken à 5 Parzellen berechnet. Je Block gibt es hierbei 4 Freiheitsgrade für die Parzellen. Da 20 Blöcke vorliegen, beträgt die Zahl der Freiheitsgrade für Parzellen insgesamt 80. Die Varianzanalyse war wie folgt:

Ursache	Freiheitsgrade	MQ	E(MQ)
Zwischen den Parzellen	80	2,9254	$\sigma^2 + 10\sigma_b^2$
Innerhalb der Parzellen	900	2,1374	σ^2

Ziel: Bestimmung der optimalen Zahl von Pflanzen je Parzelle.

Modellierung: Da eine zweistufige Stichprobe vorliegt, kann analog zu Beispiel 3.2 folgendes Modell angesetzt werden:

$$y_{ij} = \mu + b_i + e_{ij}, \quad i = 1, \dots, t, \quad j = 1, \dots, r$$

wobei

y_{ij} = Zuckergehalt der j -ten Pflanze auf der i -ten Parzelle

μ = theoretischer Mittelwert (Erwartungswert); durchschnittlicher Zuckergehalt aller Pflanzen im Feld (Grundgesamtheit)

b_i = Effekt der i -ten Parzelle ($i = 1, \dots, t$)

e_{ij} = Fehler der Beobachtung y_{ij}

Verteilungsannahmen:

$$e_{ij} \sim N(0, \sigma^2)$$

$$b_i \sim N(0, \sigma_b^2)$$

Die Varianz des Mittelwertes ist

$$V = \text{var}(\bar{y}_{..}) = \frac{\sigma_b^2}{t} + \frac{\sigma^2}{rt}$$

wobei

t = Zahl der Parzellen

r = Zahl der Pflanzen je Parzelle
 σ_b^2 = Varianz zwischen den Parzellen
 σ^2 = Varianz der Pflanzen innerhalb der Parzellen

Die Gesamtkosten einer Erhebung sind

$$K = k_1 t + k_2 r t$$

wobei

k_1 = Kosten je Parzelle (ohne Pflanzen)

k_2 = Kosten je Pflanze

Bei der Planung des optimalen Stichprobenumfanges gibt es zwei operationalisierbare Ziele:

- (1) Die Kosten K werden minimiert für gegebene Varianz V
- (2) Die Varianz V wird minimiert für ein gegebenes Budget K

ad (1): Da die Varianz fest vorgegeben ist, gilt

$$t = \frac{1}{V} \left(\sigma_b^2 + \frac{\sigma^2}{r} \right)$$

und somit

$$K = t(k_1 + k_2 r) = \frac{1}{V} (k_1 + k_2 r) \left(\sigma_b^2 + \frac{\sigma^2}{r} \right)$$

ad (2): Da die Kosten fest vorgegeben sind, gilt

$$t = \frac{K}{k_1 + k_2 r}$$

und somit

$$V = \frac{1}{t} \left(\sigma_b^2 + \frac{\sigma^2}{r} \right) = \frac{1}{K} (k_1 + k_2 r) \left(\sigma_b^2 + \frac{\sigma^2}{r} \right)$$

In beiden Fällen ist also der Ausdruck

$$F = VK = (k_1 + k_2 r) \left(\sigma_b^2 + \frac{\sigma^2}{r} \right)$$

zu minimieren. Setzt man die erste Ableitung von F nach r gleich Null und löst nach r auf, so erhält man

$$r = \sqrt{\frac{k_1 \sigma^2}{k_2 \sigma_b^2}}$$

Da die zweite Ableitung positiv ist, ist dies der Wert für r , der F minimiert. Dies ist die optimale Allokation bei Gültigkeit des angenommenen linearen Modells. Den Wert für t erhält man durch einsetzen in die Gleichung für V (Varianz) bzw. K (Kosten), je nachdem welche der beiden Größen vorgegeben wurde.

Auswertung: Um diese Allokationsformel praktisch nutzen zu können, müssen Schätzwerte der Varianz eingesetzt werden. In unserem Beispiel ergibt die Varianzkomponentenschätzung mit der ANOVA Methode $\hat{\sigma}_b^2 = 0,0788$ und $\hat{\sigma}^2 = 2,1374$, so dass

$$r = \sqrt{\frac{2,1374}{0,0788}} \sqrt{\frac{k_1}{k_2}} \approx 5,2 \sqrt{\frac{k_1}{k_2}}$$

Die Kosten sind hier nicht bekannt, so dass keine weiteren Berechnungen möglich sind. Bei etwa gleichen Kosten je Parzelle (k_1) und je Pflanze (k_2) ist eine Allokation von ca. 5 Pflanzen je Parzelle optimal.

Beispiel 3.4: Es wurden 42 Messungen der Kelchlänge (mm) einer Primelart (*Primula variabilis* Goupil) gemacht (E. Weber, 1986, Grundriss der biologischen Statistik, Fischer Verlag, S. 252). Hierzu wurde eine Zufallsstichprobe von Pflanzen ausgewählt. An jeder Pflanze wurden mehrere Blüten vermessen (**primel.dat**):

Blüte Nr.	Pflanze Nr.									
	1	2	3	4	5	6	7	8	9	10
1	12,5	13,5	15,0	11,5	12,5	12,0	15,0	15,0	10,5	13,0
2	11,5	14,5	13,5	12,0	12,5	11,0	15,5	13,0	10,5	13,5
3	12,0	13,5	13,5	12,0	12,5	11,5	14,5	15,0	11,0	13,5
4	12,5	13,5	14,5	11,5	12,0	11,5	13,0			
5	11,5	12,5	14,5	12,0	11,5					

Ziel: Schätzung des mittleren Kelchlänge der Primelart.

Modellierung: Wie haben hier prinzipiell diesselbe Situation wie in Beispiel 3.2, da eine zweistufige Stichprobennahme vorliegt. Somit kann das folgende Modell zugrundegelegt werden:

$$y_{ij} = \mu + b_i + e_{ij}, \quad i = 1, \dots, t; \quad j = 1, \dots, r_i$$

wobei

y_{ij} = Kelchlänge der j -ten Blüte für die i -te Pflanze

μ = theoretischer Mittelwert (Erwartungswert); durchschnittliche Kelchlänge der

Population von Primelpflanzen (Grundgesamtheit)
 b_i = Effekt der i -ten Pflanze ($i = 1, \dots, t$)
 e_{ij} = Fehler von y_{ij}

Verteilungsannahmen:

$$e_{ij} \sim N(0, \sigma^2)$$

$$b_i \sim N(0, \sigma_b^2)$$

Auswertung: Ein Unterschied zum Beispiel 3.2 besteht darin, dass die Zahl der Blüten nicht von Pflanze zu Pflanze konstant ist. Daher ist es nicht optimal, den einfachen Mittelwert aller Messwerte zu berechnen. Vielmehr ist ein gewichteter Mittelwert optimal (im Sinne von BLUE). Hierbei kann man ein zweistufiges Vorgehen betrachten, bei dem zunächst die Mittelwerte für jede Pflanze berechnet werden:

$$\bar{y}_{i.} = \frac{\sum_{j=1}^{r_i} y_{ij}}{r_i}$$

Im zweiten Schritt werden die Pflanzenmittelwerte dann über die Pflanzen gemittelt, um einen Schätzwert für μ zu erhalten:

$$\frac{\sum_{i=1}^t \bar{y}_{i.}}{t}$$

Dieser einfache Mittelwert der Pflanzenmittelwerte ist aber nicht optimal, weil die Pflanzenmittelwerte keine konstante Varianz haben. Es gilt:

$$\text{var}(\bar{y}_{i.}) = \sigma_b^2 + \frac{\sigma^2}{r_i}$$

Optimal (BLUE) ist hier ein gewichteter Mittelwert, wobei die Kehrwerte der Varianzen als Gewichte fungieren:

$$\text{BLUE}(\mu) = \frac{\sum_{i=1}^t \frac{\bar{y}_{i.}}{\text{var}(\bar{y}_{i.})}}{\sum_{i=1}^t \frac{1}{\text{var}(\bar{y}_{i.})}}$$

Der gewichtete Mittelwert entspricht auch der Maximum Likelihood Schätzung von μ bei bekannten Varianzkomponenten. Um diesen gewichteten Mittelwert zu berechnen, müssen die Varianzen bekannt sein. In der Praxis ist dies nicht der Fall, so dass Schätzwerte eingesetzt werden. Der resultierende Schätzer hat nicht mehr die Optimalitätseigenschaften von BLUE, kommt diesem aber nahe, falls die Varianzen mit ausreichender Genauigkeit geschätzt werden.

Nebenbemerkung: Im Spezialfall, dass die Zahl der Messwiederholungen konstant ist ($r_i = r$ für alle i), ist auch die Varianz der Pflanzenmittelwerte konstant, und es gilt:

$$\text{BLUE}(\mu) = \frac{\sum_{i=1}^t \frac{\bar{y}_{i.}}{\text{var}(\bar{y}_{i.})}}{\sum_{i=1}^t \frac{1}{\text{var}(\bar{y}_{i.})}} = \frac{\sum_{i=1}^t \bar{y}_{i.}}{t} = \frac{\sum_{i=1}^t \sum_{j=1}^r y_{ij}}{rt} = \bar{y}_{..}$$

Wir erhalten also wieder den einfachen (ungewichteten) Mittelwert, den wir bereits im Beispiel 3.2 verwendet hatten.

Zurück zu den unbalancierten Primel-Daten. Die Varianzkomponenten können wie im balancierten Fall (Beispiel 3.2) auch mit der ANOVA-Methode geschätzt werden. Ein alternatives Verfahren, dass als Voreinstellung in der MIXED Prozedur implementiert ist, ist die REML Methode (Restricted Maximum Likelihood). Im balancierten Fall stimmen REML-Schätzungen und ANOVA-Schätzungen überein, falls die ANOVA-Schätzung aller Varianzkomponenten positiv ist. Im unbalancierten Fall ergeben sich verschiedene Schätzwerte. Auf Details soll hier nicht näher eingegangen werden (siehe Searle et al., 1992). Die REML-Schätzungen der Varianz-Komponenten für das Primel-Beispiel sind (Berechnung mit MIXED):

$$\hat{\sigma}^2 = 0,4037$$

$$\hat{\sigma}_b^2 = 1,6827$$

Die Pflanzen-Mittelwerte und deren geschätzte Varianzen sind:

Pflanze	Mittelwert	r_i	geschätzte Varianz des Mittelwertes
1	12,0	5	$1,6827 + 0,4037/5 = 1,76$
2	13,5	5	$1,6827 + 0,4037/5 = 1,76$
3	14,2	5	$1,6827 + 0,4037/5 = 1,76$
4	11,8	5	$1,6827 + 0,4037/5 = 1,76$
5	12,2	5	$1,6827 + 0,4037/5 = 1,76$
6	11,5	4	$1,6827 + 0,4037/4 = 1,78$
7	14,5	4	$1,6827 + 0,4037/4 = 1,78$
8	14,3	3	$1,6827 + 0,4037/3 = 1,82$
9	10,7	3	$1,6827 + 0,4037/3 = 1,82$
10	13,3	3	$1,6827 + 0,4037/3 = 1,82$

Gewichteter Mittelwert:

$$\hat{\mu} = \frac{\frac{12,0}{1,76} + \frac{13,5}{1,76} + \frac{14,2}{1,76} + \frac{11,8}{1,76} + \frac{12,2}{1,76} + \frac{12,0}{1,78} + \frac{13,5}{1,78} + \frac{14,2}{1,82} + \frac{11,8}{1,82} + \frac{12,2}{1,82}}{\frac{1}{1,76} + \frac{1}{1,76} + \frac{1}{1,76} + \frac{1}{1,76} + \frac{1}{1,76} + \frac{1}{1,78} + \frac{1}{1,78} + \frac{1}{1,82} + \frac{1}{1,82} + \frac{1}{1,82}} = 12,80$$

Zur Berechnung des Vertrauensintervalls muss zunächst die Varianz des gewichteten Mittelwertes berechnet werden. Die Berechnung von (approximativen) Freiheitsgraden für die Berechnung eines Vertrauensintervalls ist nicht einfach, weil die Gewichte berücksichtigt werden müssen. Außerdem ist die Tatsache zu berücksichtigen, dass die Gewichte selbst nur geschätzt sind. Hierfür haben Kenward und Roger (1997) eine Methode vorgeschlagen, die auf einer Erweiterung der sog. Satterthwaite-Methode beruht. Auf Details kann hier nicht eingegangen werden. Es sei lediglich auf die folgenden SAS-Anweisungen verwiesen.

```
data primel;  
input pflanze bluete laenge;  
datalines;  
1      1      12.5  
1      2      11.5  
1      3      12.0  
1      4      12.5  
1      5      11.5  
2      1      13.5  
2      2      14.5  
2      3      13.5  
2      4      13.5  
2      5      12.5  
3      1      15.0  
3      2      13.5  
3      3      13.5  
3      4      14.5  
3      5      14.5  
4      1      11.5  
4      2      12.0  
4      3      12.0  
4      4      11.5  
4      5      12.0  
5      1      12.5  
5      2      12.5  
5      3      12.5  
5      4      12.0  
5      5      11.5  
6      1      12.0  
6      2      11.0  
6      3      11.5  
6      4      11.5  
7      1      15.0  
7      2      15.5  
7      3      14.5  
7      4      13.0  
8      1      15.0  
8      2      13.0  
8      3      15.0  
9      1      10.5  
9      2      10.5
```

```

9      3      11.0
10     1      13.0
10     2      13.5
10     3      13.5
;
proc mixed data=primel;
class pflanze;
model laenge=/solution cl ddfm=satterth;
random pflanze;
run;

```

Output:

Solution for Fixed Effects					
Effect	Estimate	Standard Error	DF	Lower	Upper
Intercept	12.8031	0.4223	8.91	11.8463	13.7599

Man beachte, dass die Freiheitsgrade "krumm" sind (Eigenschaft der Methode von Kenward und Roger).

Beispiel 3.5: An vier zufällig ausgewählten Rübenpflanzen einer Parzelle wurde an jeweils 3 zufällig ausgewählten Blättern der Calciumgehalt zweifach bestimmt (Snedecor und Cochran, 1967, S. 286; **rüben2.dat**).

Pflanze	Blatt	Messungen	
1	1	3,28	3,09
	2	3,52	3,48
	3	2,88	2,80
2	1	2,46	2,44
	2	1,87	1,92
	3	2,19	2,19
3	1	2,77	2,66
	2	3,74	3,44
	3	2,55	2,55
4	1	3,78	3,87
	2	4,07	4,12
	3	3,31	3,31

Ziel: Bestimmung des durchschnittlichen Calciumgehaltes des Blattapparates der Pflanzen auf der Parzelle.




Abb. 3.3: Veranschaulichung der dreistufigen Stichprobe zur Ermittlung des Ca-Gehaltes.

In Erweiterung des Beispiel 3.2 haben wir hier eine dreistufige Stichprobe vorliegen (Abb. 3.3):

Stufe 1: Pflanzen

Stufe 2: Blätter innerhalb der Pflanzen

Stufe 3: Messwiederholungen innerhalb der Blätter innerhalb der Pflanzen

Modell:

$$y_{ijk} = \mu + p_i + b_{ij} + e_{ijk}$$

$$(i = 1, \dots, t; j = 1, \dots, r; k = 1, \dots, m)$$

wobei

y_{ijk} = k -te Messwiederholung auf dem j -ten Blatt der i -ten Pflanze

μ = mittlerer Ca-Gehalt der Population von Rübenpflanzen (Feld)

p_i = Effekt der i -ten Pflanze

b_{ij} = Effekt des j -ten Blattes der i -ten Pflanze

e_{ijk} = Messfehler von y_{ijk}

$$p_i \sim N(0, \sigma_p^2)$$

$$b_{ij} \sim N(0, \sigma_b^2)$$

$$e_{ijk} \sim N(0, \sigma^2)$$

Auswertung: Da die Daten balanciert sind, kann hier zur Schätzung von μ der einfache Mittelwert berechnet werden. Dieser hat folgende Varianz:

$$\text{var}(\bar{y}_{...}) = \frac{\sigma_p^2}{t} + \frac{\sigma_b^2}{tr} + \frac{\sigma^2}{trm}$$

wobei

t = Zahl der Pflanzen

r = Zahl der Blätter pro Pflanze

m = Zahl der Messwiederholungen pro Blatt

Da die Daten balanciert sind, kann hier eine ANOVA-Methode analog zu der in Beispiel 3.2 angewendet werden (nicht gezeigt). Das Ergebnis ist identisch zu einer REML-Analyse, die mit MIXED erhalten werden kann (beachte REML = ANOVA-Methode bei balancierten Daten, falls alle ANOVA-Schätzungen positiv sind).

SAS-Anweisungen:

```
data;
input
  pflanze    blatt    messung    calzium;
datalines;
  1          1        1          3.28
  1          1        2          3.09
  1          2        1          3.52
  1          2        2          3.48
  1          3        1          2.88
  1          3        2          2.80
  2          1        1          2.46
  2          1        2          2.44
  2          2        1          1.87
  2          2        2          1.92
  2          3        1          2.19
  2          3        2          2.19
  3          1        1          2.77
  3          1        2          2.66
  3          2        1          3.74
  3          2        2          3.44
  3          3        1          2.55
  3          3        2          2.55
  4          1        1          3.78
  4          1        2          3.87
  4          2        1          4.07
  4          2        2          4.12
  4          3        1          3.31
  4          3        2          3.31
;
proc mixed;
class pflanze blatt;
model calzium=/solution cl ddfm=kenwardroger;
random pflanze blatt*pflanze;
```

run;

Output:

Covariance Parameter Estimates	
Cov Parm	Estimate
pflanze	0.3652
pflanze*blatt	0.1611
Residual	0.006654

Solution for Fixed Effects

Effect	Estimate	Standard Error	DF	Lower	Upper
Intercept	3.0121	0.3240	3	1.9808	4.0433

Beispiel 3.6: Bei einer Zufallsstichprobe von 16 Frauen wurde der Urin während 24 Stunden gesammelt. Für jede Person wurde für 2 zufällig ausgewählten Probe der Ausscheidungswert der 17-Hydroxy-corticostereoid gemacht (Linder, Statistische Methoden II, S. 100; **cortico.dat**):

Person	Bestimmungen		Person	Bestimmungen	
1	101	91	9	115	111
2	90	86	10	70	81
3	90	103	11	78	89
4	69	80	12	76	79
5	106	110	13	109	115
6	90	94	14	102	88
7	72	74	15	107	109
8	86	86	16	101	101

Ziel: Schätzen des durchschnittlichen Corticostereoid-Wertes der Grundgesamtheit.

Modellierung und Auswertung: Auswertungsziel und zu verwendendes lineares Modell entsprechen Beispiel 3.2.

SAS-Anweisungen:

```
data;  
input  
  person    messung    cortico;  
datalines;  
  1         1        101  
  1         2         91  
  2         1         90  
  2         2         86
```

3	1	90
3	2	103
4	1	69
4	2	80
5	1	106
5	2	110
6	1	90
6	2	94
7	1	72
7	2	74
8	1	86
8	2	86
9	1	115
9	2	111
10	1	70
10	2	81
11	1	78
11	2	89
12	1	76
12	2	79
13	1	109
13	2	115
14	1	102
14	2	88
15	1	107
15	2	109
16	1	101
16	2	101

```

;
proc print;
run;
proc mixed;
class person;
model cortico=/solution ddfm=kenwardroger cl;
random person;
run;

```

Output:

Covariance Parameter Estimates

Cov Parm	Estimate
person	168.55
Residual	29.5313

Solution for Fixed Effects

Effect	Estimate	Standard Error	DF	Lower	Upper
Intercept	92.4688	3.3849	15	85.2541	99.6834

Beispiel 3.7: Reizschwellen des Patellarsehnenreflexes von 5 Personen, gemessen an je 6 Tagen und mit je 3 aufeinanderfolgenden Bestimmungen (Linder und Berchtold, Statistische Methoden II, S. 108; **patellar.dat**). Die Messwerte in cm je g wurden nach

$$y = 100 \log x - 200$$

transformiert, um eine annähernde Normalverteilung zu erhalten. Tage und Personen werden jeweils als Zufallstichprobe betrachtet.

Ziel: Es sollen die verschiedenen Streuungsursachen (Personen, Tage, Personen $\times$ Tage und Fehler) über Varianzkomponenten quantifiziert werden. Sowohl die Personen als auch die Tage sollen dabei als Zufallsstichproben aus einer Grundgesamtheit betrachtet werden. Ziel ist weiterhin eine Schätzung der durchschnittlichen Reizschwellen in der Grundgesamtheit.

Personen					
Tag	A	B	C	D	E
1	76	76	113	76	134
	76	76	100	66	100
	85	85	113	66	134
2	93	76	76	93	113
	85	76	85	100	113
	66	85	76	93	139
3	66	66	100	66	107
	93	66	107	76	113
	76	66	107	54	119
4	25	76	119	5	5
	54	76	130	25	41
	41	76	100	25	54
5	54	85	113	25	66
	66	85	113	41	66
	66	76	113	54	85
6	66	85	113	5	76
	66	76	113	25	66
	66	66	113	5	76

Modellierung:

$$y_{ijk} = \mu + p_i + t_j + (pt)_{ij} + e_{ijk}$$

$$(i = 1, \dots, a; j = 1, \dots, b; k = 1, \dots, r)$$

wobei

y_{ijk} = Reizschwelle (transformiert) der k -ten Messwiederholung der i -ten Person am j -ten Tag
 μ = Erwartungswert
 p_i = Effekt der i -ten Person
 t_j = Effekt des j -ten Tages
 $(pt)_{ij}$ = Wechselwirkung der i -ten Person mit dem j -ten Tag
 e_{ijk} = Messfehler von y_{ijk}

Verteilungsannahmen:

$$p_i \sim N(0, \sigma_p^2)$$

$$t_j \sim N(0, \sigma_t^2)$$

$$(pt)_{ij} \sim N(0, \sigma_{pt}^2)$$

$$e_{ijk} \sim N(0, \sigma^2)$$

Auswertung:

Da balancierte Daten vorliegen, ist der BLUE von μ wieder durch den einfachen Stichprobenmittelwert gegeben:

$$\text{BLUE}(\mu) = \bar{y} \dots$$

Varianzanalyse:

Quelle	FG	MQ	E(MQ)
Personen	$a - 1$	$MQ_{Person} = \frac{SQ_{Person}}{a - 1}$	$\sigma^2 + r\sigma_{pt}^2 + rb\sigma_p^2$
Tage	$b - 1$	$MQ_{Tag} = \frac{SQ_{Tag}}{b - 1}$	$\sigma^2 + r\sigma_{pt}^2 + ra\sigma_t^2$
Personen $\times$ Tage	$(a - 1)(b - 1)$	$MQ_{P \times T} = \frac{SQ_{P \times T}}{(a - 1)(b - 1)}$	$\sigma^2 + r\sigma_{pt}^2$
Fehler	$ab(r - 1)$	$MQ_{Fehler} = \frac{SQ_{Fehler}}{ab(r - 1)}$	σ^2

Quadratsummen:

$$SQ_{Fehler} = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (y_{ijk} - \bar{y}_{ij.})^2$$

$$SQ_{P \times T} = r \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...})^2$$

$$SQ_{Person} = rb \sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...})^2$$

$$SQ_{P \times T} = ra \sum_{j=1}^b (\bar{y}_{.j.} - \bar{y}_{...})^2$$

Schätzung der Varianzkomponenten nach der ANOVA-Methode (Momenten-Methode):

$$\hat{\sigma}_p^2 = \frac{MQ_{Person} - MQ_{P \times T}}{rb}$$

$$\hat{\sigma}_t^2 = \frac{MQ_{Tag} - MQ_{P \times T}}{ra}$$

$$\hat{\sigma}_{pt}^2 = \frac{MQ_{P \times T} - MQ_{Fehler}}{r}$$

$$\hat{\sigma}^2 = MQ_{Fehler}$$

$$\begin{aligned} \wedge \text{var}(\bar{y}_{...}) &= \frac{\hat{\sigma}_p^2}{a} + \frac{\hat{\sigma}_t^2}{b} + \frac{\hat{\sigma}_{P \times T}^2}{ab} + \frac{\hat{\sigma}^2}{rab} \\ &= \frac{MQ_{Person} - MQ_{P \times T}}{rab} + \frac{MQ_{Tag} - MQ_{P \times T}}{rab} + \frac{MQ_{P \times T} - MQ_{Fehler}}{rab} + \frac{MQ_{Fehler}}{rab} \\ &= \frac{MQ_{Person} + MQ_{Tag} - MQ_{P \times T}}{rab} \end{aligned}$$

$(1-\alpha)100\%$ Vertrauensintervall für μ :

$$\bar{y}_{..} \pm t_{1-\alpha/2; v} \sqrt{\wedge \text{var}(\bar{y}_{..})}$$

wobei $t_{1-\alpha/2; v}$ das $(1-\alpha/2)100\%$ Quantil der t-Verteilung mit v Freiheitsgraden ist, wobei die Freiheitsgrade approximativ nach der Satterthwaite-Methode zu bestimmen sind (siehe unten).

Die Freiheitsgrade v müssen hier approximativ mit der sog. **Satterthwaite-Methode** bestimmt werden, da die Varianz des Mittelwertes nicht mittels eines einzigen MQ geschätzt werden kann, sondern aus einer Linearkombination. Die Freiheitsgrade v einer Linearkombination statistisch unabhängiger Mittelquadrate

$$c_1 MQ_1 + c_2 MQ_2 + \dots + c_r MQ_r$$

wobei MQ_i ($i = 1, \dots, r$) die Mittelquadrate und c_i die Koeffizienten der Linearkombination sind, berechnen sich nach folgender Formel:

$$v = \frac{(c_1 MQ_1 + c_2 MQ_2 + \dots + c_r MQ_r)^2}{\frac{(c_1 MQ_1)^2}{FG_1} + \frac{(c_2 MQ_2)^2}{FG_2} + \dots + \frac{(c_r MQ_r)^2}{FG_r}}$$

wobei FG_i die Freiheitsgrade von MQ_i sind.

Im vorliegenden Fall finden wir:

$$c_1 = c_2 = -c_3 = (abr)^{-1}$$

und

$$v = \frac{(MQ_{Person} + MQ_{Tag} - MQ_{P \times T})^2}{\frac{(MQ_{Person})^2}{a-1} + \frac{(MQ_{Tag})^2}{b-1} + \frac{(MQ_{P \times T})^2}{(a-1)(b-1)}}$$

$$\bar{y}_{...} = 77,82$$

Ursache	FG	MQ
Person	4	8055,43
Tag	5	2972,20
Person $\times$ Tag	20	1354,09
Fehler	60	108,64

$$\hat{\sigma}_p^2 = \frac{8055,43 - 1354,09}{18} = 372,30$$

$$\hat{\sigma}_t^2 = \frac{2972,20 - 1354,09}{15} = 107,87$$

$$\hat{\sigma}_{pt}^2 = \frac{1354,09 - 108,64}{3} = 415,15$$

$$\hat{\sigma}^2 = 108,64$$

Die Varianz zwischen den Personen ist hier größer als die Varianz zwischen den Tagen.

$$\hat{\text{var}}(\bar{y}_{...}) = \frac{8055,43 + 2972,20 - 1354,09}{90} = 107,48$$

$$v = \frac{(8055,43 + 2972,20 - 1354,09)^2}{\frac{(8055,43)^2}{4} + \frac{(2972,20)^2}{5} + \frac{(1354,09)^2}{20}} = 5,18$$

Kritische t-Werte mit gebrochenen Freiheitsgraden sind nicht tabelliert. Daher runden wir auf $\nu = 5$ ab und erhalten:

$$77,82 \pm 2,571 \sqrt{108,64}$$

⇒ Untere Grenze = 51,02; Obere Grenze = 104,47

Mit den genaueren Freiheitsgraden von $\nu = 5,18$ ergeben sich die Grenzen 51,44 und 104,2 (mit MIXED berechnet). Diese sind etwas enger.

SAS Anweisungen:

```
data;
input
tag    messung    person    y;
datalines;
1      1          1      76
1      1          2      76
1      1          3     113
1      1          4      76
1      1          5     134
1      2          1      76
1      2          2      76
1      2          3     100
1      2          4      66
1      2          5     100
1      3          1      85
1      3          2      85
1      3          3     113
1      3          4      66
1      3          5     134
2      1          1      93
2      1          2      76
2      1          3      76
2      1          4      93
2      1          5     113
2      2          1      85
2      2          2      76
2      2          3      85
2      2          4     100
2      2          5     113
2      3          1      66
2      3          2      85
2      3          3      76
2      3          4      93
2      3          5     139
3      1          1      66
3      1          2      66
3      1          3     100
```

3	1	4	66
3	1	5	107
3	2	1	93
3	2	2	66
3	2	3	107
3	2	4	76
3	2	5	113
3	3	1	76
3	3	2	66
3	3	3	107
3	3	4	54
3	3	5	119
4	1	1	25
4	1	2	76
4	1	3	119
4	1	4	5
4	1	5	5
4	2	1	54
4	2	2	76
4	2	3	130
4	2	4	25
4	2	5	41
4	3	1	41
4	3	2	76
4	3	3	100
4	3	4	25
4	3	5	54
5	1	1	54
5	1	2	85
5	1	3	113
5	1	4	25
5	1	5	66
5	2	1	66
5	2	2	85
5	2	3	113
5	2	4	41
5	2	5	66
5	3	1	66
5	3	2	76
5	3	3	113
5	3	4	54
5	3	5	85
6	1	1	66
6	1	2	85
6	1	3	113
6	1	4	5
6	1	5	76
6	2	1	66
6	2	2	76

6	2	3	113
6	2	4	25
6	2	5	66
6	3	1	66
6	3	2	66
6	3	3	113
6	3	4	5
6	3	5	76

```

;
proc mixed;
class person tag;
model y=/ddfm=satterth solution cl;
random tag person tag*person;
run;

```

Output:

Covariance Parameter Estimates					
Cov Parm	Estimate				
tag	107.87				
person	372.30				
person*tag	415.15				
Residual	108.64				

Solution for Fixed Effects					
Effect	Estimate	Standard Error	DF	Lower	Upper
Intercept	77.8222	10.3674	5.18	51.4414	104.20

MIXED verwendet die REML Methode. Die Ergebnisse sind identisch mit denen nach der ANOVA-Methode, weil bei balancierten Daten REML = ANOVA, falls die ANOVA Methode alle Varianzen positiv schätzt.

4. Versuche mit unvollständigen Blöcken

Im gartenbau- und agrarwissenschaftlichen Bereich werden viele Versuche in Blockanlagen durchgeführt. Auch in anderen Bereichen wie der Medizin und den Sozialwissenschaften ist das Prinzip der Blockbildung sehr verbreitet. Durch die Blockbildung lässt sich in der Regel ein Gewinn an Genauigkeit erzielen (Dean und Voss, 1999, S. 18). In Abhängigkeit von der Randomisationsstruktur sind in einigen Fällen sind entweder Blockeffekte oder Parzelleneffekte als zufällig zu betrachten, so dass zur Auswertung ein gemischtes Modell in Frage kommt. Hierfür werden in diesem und im Folgenden Kapitel einige Beispiele gegeben. Im aktuellen Kapitel geht es um Anlagen mit unvollständigen Blöcken. Im nächsten Kapitel werden Split-plot und strip-plot Anlagen behandelt.

Beispiel 4.1: Viele landwirtschaftliche Feldversuche werden in einer Blockanlage durchgeführt. Auch in vielen anderen Anwendungsbereichen ist die Blockanlage verbreitet. Das Prinzip sei an einem hypothetischen Beispiel erläutert. Drei Sorten A, B und C werden in 2 Blöcken randomisiert geprüft.

Block 1	C ($y_{31} = 10$)	A ($y_{11} = 20$)	B ($y_{21} = 38$)
Block 2	A ($y_{12} = 35$)	B ($y_{22} = 52$)	C ($y_{32} = 27$)

Block 2 hat gegenüber Block 1 deutlich bessere Wachstumsbedingungen, was an den höheren Erträgen in Block 2 abzulesen ist. Zwischen den Wiederholungen einer Behandlung bestehen große Unterschiede. Bei vollständiger Randomisation ohne Blockbildung würden all diese Unterschiede als Versuchsfehler zu Buche schlagen. Bei einer Blockbildung können dagegen Unterschiede zwischen den Blöcken vom Versuchsfehler abgetrennt werden, was zu einer höheren Genauigkeit führt. Der Gewinn an Genauigkeit rührt daher, dass Vergleiche zwischen den Behandlungen innerhalb der Blöcke durchgeführt werden können. Solange also die Bedingungen innerhalb der Blöcke möglichst konstant sind, werden Behandlungsunterschiede sehr genau geprüft.

Betrachten wir als Beispiel den Vergleich der Sorten A und B. Deren Differenz kann in beiden Blöcken durch einfache Differenzbildung geschätzt werden:

	A	–	B	=	Differenz
Block 1:	20	–	38	=	–18
Block 2:	35	–	52	=	–17
Mittel:					–17,5

Diese Art der Auswertung kann auch mittels des linearen Modells

$$y_{ij} = \mu + b_j + \tau_i + e_{ij}$$

formalisiert werden, wobei

y_{ij} = Ertrag der i -ten Sorte im j -ten Block
 μ = Gesamtmittel
 b_j = Effekt des j -ten Block
 τ_i = Effekt der i -ten Sorte
 e_{ij} = Fehler von y_{ij}

Eine Schätzung der Effekte dieses Modells mit der Methode der Kleinsten Quadrate, wobei b_j und τ_i als feste Effekte betrachtet werden, führt zu den eben beschriebenen Schätzungen für Behandlungsdifferenzen.

Bei der bisherigen Auswertungsmethode beruhten Schätzungen der Behandlungseffekte auf **Differenzen innerhalb der Blöcke**. Bei balancierten Daten wird ausschließlich diese Information genutzt. Wir können auch sagen, dass bei dieser Art der Auswertung lediglich Information innerhalb der Blöcke genutzt wird, die sog. Intra-Block-Information.

Bei einer grossen Zahl von Behandlungen würden vollständige Blöcke so gross, dass das Ziel möglichst homogener Bedingungen innerhalb der Blöcke schwer zu erreichen ist. Aus diesem Grunde gibt es eine große Zahl von Versuchsanlagen mit unvollständigen Blöcken, z.B. Gitteranlagen und α -Designs. Von besonderer Bedeutung ist bei diesen Anlagen die Randomisation. Diese erlaubt es, Blockeffekte als zufällig zu betrachten. Ein Beispiel für die Randomisation einen Versuch in einer **balancierten unvollständigen Blockanlage** (BUB) ist wie folgt:

Schritt 1: Für einen Versuch mit $t = 5$ Behandlungen A, B, C, D und E und Blockgröße $k = 3$ finden wir folgenden Grundplan für eine balancierte unvollständige Blockanlage (10 Blöcke = Zeilen):

```

1 2 3
1 2 4
1 2 5
1 3 4
1 3 5
1 4 5
2 3 4
2 3 5
2 4 5
3 4 5

```

Schritt 2: Randomisiere die Reihenfolge der Blöcke.

Schritt 3: Die Behandlungen werden getrennt für jeden Block randomisiert.

Schritt 4: Zuletzt werden die Behandlung zufällig den Behandlungsnummern zugeordnet.

Bei unbalancierten Daten ist neben der Intra-Block-Information aber immer auch ein gewisse Information zwischen den Blöcken vorhanden, die zum Vergleich zwischen den Behandlungen genutzt werden kann. Voraussetzung dafür, dass diese Inter-

Block-Information genutzt werden kann, ist eine Randomisation, bei der die Blöcke zufällig angeordnet werden. Dies erlaubt es, dass im Modell die Blockeffekte b_j als zufallsverteilt angesehen werden können. In der Regel wird von einer Normalverteilung ausgegangen:

$$b_j \sim N(0, \sigma_b^2)$$

Neben dem Fehler hat dann das Modell einen weiteren zufälligen Effekt. Man spricht auch von gemischten Modellen. Die Auswertung nach diesem gemischten Modell erlaubt die Nutzung der Inter-Block-Information. Hierzu müssen zunächst die Varianzkomponenten geschätzt werden. Danach werden die festen Effekte (μ, τ_i) mit der Methode der gewichteten kleinsten Quadrate geschätzt, wobei die Varianzkomponenten als Gewichte verwendet werden. Die Nutzung der Inter-Block-Information lohnt sich vor allem dann, wenn die Blockvarianz σ_b^2 klein ist und mit großer Genauigkeit geschätzt werden kann. Auf Details soll hier nicht eingegangen werden. Näheres findet sich z.B. bei Fox und Kempton (1996).

Die Nutzung der Inter-Block-Information wird über die Einbeziehung der **Blocksummen** erreicht, während die Intra-Block-Information über Differenzen innerhalb der Blöcke erhalten wird. Die Blocksummen beinhalten Information über den Vergleich der Behandlungen, die in der Intra-Block-Information nicht enthalten sind. Dies soll an einem denkbar einfachen Beispiel deutlich gemacht werden. Drei Behandlungen A, B und C werden in 2 Blöcken mit dem folgenden Ergebnis geprüft (**ibd.dat**):

Block 1	A ($y_{11} = 20$)	B ($y_{21} = 38$)
Block 2	A ($y_{12} = 35$)	C ($y_{32} = 47$)

(y_{ij} = Ertrag der i -ten Behandlung im j -ten Block; A: $i = 1$; B: $i = 2$; C: $i = 3$). Es sollen die Behandlungen B und C verglichen werden, es ist also die Differenz $\delta = \tau_2 - \tau_3$ ("B - C")

zu schätzen. Die **Intra-Block-Information** wird über den **indirekten Vergleich** innerhalb der Blöcke erhalten:

$$d_1 = (\text{"B - A in Block 1"}) - (\text{"C - A in Block 2"})$$

$$= (y_{21} - y_{11}) - (y_{32} - y_{12})$$

$$= (38 - 20) - (47 - 35)$$

$$= 6$$

d_1 ist der Intra-Block-Schätzer für δ , denn es gilt:

$$E(d_1) = E(y_{21} - y_{11}) - E(y_{32} - y_{12}) = (\tau_2 - \tau_1) - (\tau_3 - \tau_1) = \tau_2 - \tau_3 = \delta$$

Eine Auswertung, bei der ausschließlich die Inter-Block-Information genutzt wird, entspricht der Auswertung nach dem Modell mit festen Blockeffekten. Soll dagegen die Inter-Block-Information genutzt werden, müssen Blockeffekte als zufällig betrachtet werden. Da die Blöcke sich durch die Behandlungen B und C unterscheiden, ist die Differenz der **Blocksummen** ein Schätzer für die Differenz von B und C. Man spricht hier von der **Inter-Block-Information**:

$$d_2 = ("B + A \text{ in Block 1}") - ("C + A \text{ in Block 2"})$$

$$= (y_{21} + y_{11}) - (y_{32} + y_{12})$$

$$= (38 + 20) - (47 + 35)$$

$$= -24$$

d_2 ist der Inter-Block-Schätzer für δ , denn es gilt:

$$E(d_2) = E(y_{21} + y_{11}) - E(y_{32} + y_{12}) = 2\mu + \tau_2 + \tau_1 - (2\mu + \tau_3 + \tau_1) = \tau_2 - \tau_3$$

Es sei hier darauf hingewiesen, dass generell eine Inter-Block-Information nur nutzbar ist, wenn die Blöcke unvollständig sind, weil nur dann die Blocksummen Information hinsichtlich der Behandlungsdifferenzen aufweisen.

Ziel der weiteren Auswertung ist es, die beiden Schätzer d_1 und d_2 zu kombinieren. Man spricht von der **kombinierten Inter-Block-Intra-Block Schätzung**. Hierbei werden die Inter-Block- und Intra-Block Schätzungen der Differenz mittels eines **gewichteten Mittelwertes** kombiniert, wobei die Gewichte sich aus der Genauigkeit der beiden Schätzungen ergeben. Zur Ermittlung der Genauigkeit der Inter-Block-Schätzung ist es notwendig, Blockeffekte als zufällig zu betrachten. Diese Annahme ist zulässig, wenn die Blöcke entsprechend randomisiert wurden. Es lässt sich zeigen, dass

$$\text{var}(d_1) = 4\sigma^2$$

$$\text{var}(d_2) = 4\sigma^2 + 8\sigma_b^2$$

$$\text{cov}(d_1, d_2) = 0$$

wobei σ^2 die Fehlervarianz, σ_b^2 die Blockvarianz, $\text{var}(\cdot)$ die Varianz, und $\text{cov}(\cdot, \cdot)$ die Kovarianz ist. Eine Besonderheit besteht darin, dass die Inter-Block Schätzung eine höhere Varianz hat als die Intra-Block-Schätzung, weil in ersterer die Streuung zwischen den Blöcken zu Buche schlägt, während in letzterer die Differenz lediglich innerhalb der Blöcke geschätzt wird.

Nun sind bei beiden Schätzungen d_1 und d_2 zu einer gemeinsamen Schätzung kombinieren. Hierbei kommt vereinfachend hinzu, dass die beiden Schätzungen unkorreliert sind. Daher ist die optimale Schätzung ein gewichtetes Mittel, wobei die Kehrwerte der Varianzen als Gewichte verwendet werden. Die **kombinierte Inter-Block-Intra-Block Schätzung** ist

$$\hat{\delta} = \frac{\frac{d_1}{\text{var}(d_1)} + \frac{d_2}{\text{var}(d_2)}}{\frac{1}{\text{var}(d_1)} + \frac{1}{\text{var}(d_2)}}$$

In der Praxis müssen die Varianzkomponenten geschätzt werden, was mehr Daten als im vorliegenden Beispiel erfordert. Die Varianzkomponentenschätzung kann mit der sog. REML-Methode durchgeführt werden. Hier nehmen wir der Einfachheit halber feste (bekannte) Werte für die Varianzkomponenten an:

$$\sigma^2 = 1$$

$$\sigma_b^2 = 5$$

Hiermit ist

$$\text{var}(d_1) = 4$$

$$\text{var}(d_2) = 44$$

und somit die kombinierte Inter-Block-Intra-Block-Schätzung

$$\hat{\delta} = \frac{\frac{6}{4} + \frac{-24}{44}}{\frac{1}{4} + \frac{1}{44}} = 3,5 \quad . \quad \square$$

SAS Anweisungen

Um das hypothetische Beispiel mit als bekannt angenommen Varianzkomponenten mit MIXED zu rechnen, kann die PARMS Anweisung in Verbindung mit den NOITER und SIGITER Optionen verwendet werden, welche die REML-Iterationen ausschalten, so dass die in der PARMS-Anweisung übergebenen Startwerte der Varianzkomponenten unverändert bleiben. Es muss hier auf jeden Fall mit bekannten Varianzen gerechnet werden, da nicht genügend Freiheitsgrade zur Schätzung der Varianzkomponenten zur Verfügung stehen. In der Praxis haben Anlagen mit unvollständigen Blöcken viele Beobachtungen, so dass die Varianzkomponentenschätzung möglich ist.

```
data;
input block sorte ertrag;
datalines;
1 1 20
1 2 38
2 1 35
2 3 47
;
/*Ohne Nutzung der Inter-Block-Information*/
proc mixed sigiter;
class sorte block;
```

```

model ertrag=block sorte;
estimate 'sorte 1 - sorte 2' sorte 1 -1 0;
estimate 'sorte 1 - sorte 3' sorte 1 0 -1;
estimate 'sorte 2 - sorte 3' sorte 0 1 -1;
parms (1)/noiter;
run;

/*Mit Nutzung der Inter-Block-Information*/
proc mixed sigiter;
class sorte block;
model ertrag=sorte;
random block;
estimate 'sorte 1 - sorte 2' sorte 1 -1 0;
estimate 'sorte 1 - sorte 3' sorte 1 0 -1;
estimate 'sorte 2 - sorte 3' sorte 0 1 -1;
parms (5)(1)/noiter;
run;

```

Beispiel 4.2: Der Grad des Schmerzempfindens für verschiedene Penicillin-Dosen wurde in 10 Gruppen von jeweils drei Patienten geprüft (John und Quenouille, 1977, S. 187). In jeder Gruppe von drei Patienten wurden bei jeder Person jeweils drei Penicillin-Dosen geprüft. Der Versuch wurde in einer balancierten unvollständigen Blockanlage durchgeführt, d.h. jedes Paar von Behandlungen kommt gleich oft in einem Block vor, so dass alle Vergleiche mit derselben Genauigkeit gemessen werden können. Die Randomisation ist so wie in Beispiel 4.1 beschrieben. Der Schmerz wurde auf einer Skala von 0 - 4 gemessen. In jeder Gruppe wurde die Summe der Scores je Dosis berechnet. Das Ergebnis war wie folgt:

Tab. 4.1: Scores (Summe von jeweils drei Patienten) für Schmerzempfinden bei verschiedenen Dosen von Penizillin (**penicillin.dat**).

Gruppe	Dosis von Penizillin (Einheiten pro mg)					
	a 936	b 502	c 175	d 333	e 1127	f 711
1	1	5	4	.	.	.
2	5	10	.	6	.	.
3	2	.	9	.	3	.
4	4	.	.	8	.	6
5	2	.	.	.	4	7
6	.	6	7	.	.	5
7	.	5	.	7	2	.
8	.	7	.	.	2	4
9	.	.	8	4	2	.
10	.	.	10	8	.	7

Die Gruppen sind hierbei als unvollständige Blöcke mit jeweils drei Behandlungen aufzufassen. Es handelt sich um eine balancierte unvollständige Blockanlage, da jedes Behandlungspaar gleich oft im selben Block steht (einmal).

Es kann nach folgendem Modell ausgewertet werden:

$$y_{ij} = \mu + b_j + \tau_i + e_{ij}$$

wobei

y_{ij} = Score der i -ten Penizillin-Dosis im j -ten Block (Gruppe)

μ = Gesamtmittel

b_j = Effekt des j -ten Block (Gruppe)

τ_i = Effekt der i -ten Dosis

e_{ij} = Fehler von y_{ij}

Falls die Inter-Block-Information nicht genutzt wird, ist der Blockeffekt b_j fest. Zur Nutzung der Inter-Block-Information wird der Blockeffekt b_j als zufällig betrachtet.

Da es sich bei dem Behandlungsfaktor um einen quantitativen Faktor handelt, ist eine Regression möglich. Beispielsweise ist der lineare Ansatz wie folgt:

$$y_{ij} = \mu + b_j + \lambda x_i + \delta_i + e_{ij}$$

wobei

λ = Regressionskoeffizient

x_i = Penicillin-Dosis (Einheiten je mg)

δ_i = Systematische Abweichung von der Linearität; Lack-of-fit

Bei der Auswertung ist zu entscheiden, ob die Inter-Block-Information genutzt werden soll (b_j zufällig) oder nicht (b_j fix).

Auswertung mit zufälligen Blockeffekten b_j : Hier wird der Einfachheit halber zunächst der Fall zufälliger Blockeffekte behandelt, wobei folgende Verteilungsannahme getroffen wird:

$$b_j \sim N(0, \sigma_b^2)$$

Da bei der Auswertung gewichtete Mittelwerte berechnet werden, benutzen wir die allgemeine Methode von Kenward und Roger (1997) zur Berechnung der Varianz und der Freiheitsgrade (siehe SAS Anweisungen).

SAS-Anweisungen:

```

data t;
input
gruppe    dosis      x      score;
datalines;
  1        1      936      1
  1        2      502      5
  1        3      175      4
  2        1      936      5
  2        2      502     10
  2        4      333      6
  3        1      936      2
  3        3      175      9
  3        5     1127      3
  4        1      936      4
  4        4      333      8
  4        6      711      6
  5        1      936      2
  5        5     1127      4
  5        6      711      7
  6        2      502      6
  6        3      175      7
  6        6      711      5
  7        2      502      5
  7        4      333      7
  7        5     1127      2
  8        2      502      7
  8        5     1127      2
  8        6      711      4
  9        3      175      8
  9        4      333      4
  9        5     1127      2
 10        3      175     10
 10        4      333      8
 10        6      711      7
;

/*Dosis als qualitativer Faktor*/
proc mixed data=t;
class gruppe dosis;
model score=dosis/ddfm=kenwardroger;
random gruppe;
lsmeans dosis;
run;

/*Dosis als quantitativer Faktor*/
proc mixed data=t;
class gruppe dosis;
model score=x dosis/htype=1 ddfm=kenwardroger;
random gruppe;

```

```

run;

/*Schaetzen der Regressionsgleichung*/
proc mixed data=t;
class gruppe;
model score=x/solution ddfm=kenwardroger;
random gruppe;
run;

```

Output bei Auswertung als qualitativer Faktor:

Covariance Parameter
Estimates

Cov Parm	Estimate
gruppe	1.5627
Residual	1.3975

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
dosis	5	16.6	14.17	<.0001

Effect	dosis	Estimate	x
dosis	3	7.9521	175
dosis	4	6.1022	333
dosis	2	7.0735	502
dosis	6	5.4600	711
dosis	1	2.5814	936
dosis	5	2.8307	1127




Abb 4.1: Plot der Mittelwerte gegen die Dosis, mit angepasster Regressionslinie (MIXED; zufällige Blöcke).

Die Blockvarianz ("gruppe") ist nicht zu vernachlässigen. Es bestehen signifikante Unterschiede zwischen den Behandlungen (Dosen). Die Mittelwerte deuten einen linear abfallenden Trend mit der Dosis an (Abb. 4.1).

Auswertung als quantitativer Faktor:

Type 1 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
x	1	16.6	61.10	<.0001
dosis	4	16.6	2.43	0.0881

Die Regression ist signifikant, der Lack-of-fit Test (dosis) ist nicht signifikant. Es kann daher von einer annähernd linearen Beziehung zwischen Score für Schmerzempfinden und Dosis ausgegangen werden.

Schätzen der Regressionsgleichung:

Effect	Estimate	Standard Error	DF	t Value	Pr > t
Intercept	8.8792	0.6570	26.5	13.51	<.0001
x	-0.00562	0.000826	22.8	-6.81	<.0001

Geschätzte Regressionsgleichung:

$$\text{SCORE} = 8,8792 - 0,00562 \cdot X$$

Auswertung mit festen Blockeffekten b_j : Der Gruppeneffekt muss von der RANDOM- un die MODEL-Anweisung verschoben werden. Ansonsten sind die Anweisungen identisch.

SAS-Anweisungen:

```
/*Dosis als qualitativer Faktor*/
proc mixed data=t;
class gruppe dosis;
model score=gruppe dosis;
lsmeans dosis;
run;
```

```
/*Dosis als quantitativer Faktor*/
proc mixed data=t;
class gruppe dosis;
model score=gruppe x dosis/htype=1;
run;
```

```
/*Schaetzen der Regressionsgleichung*/
proc mixed data=t;
class gruppe;
model score=gruppe x/solution;
run;
```

Output für Schätzung der Regression:

Effect	gruppe	Estimate	Standard Error	DF	t Value	Pr > t
Intercept		10.6387	0.8880	19	11.98	<.0001
gruppe	1	-4.2549	1.1579	19	-3.67	0.0016
gruppe	2	-0.2894	1.1633	19	-0.25	0.8062
gruppe	3	-1.7395	1.1894	19	-1.46	0.1600
gruppe	4	-0.8941	1.1731	19	-0.76	0.4553
gruppe	5	-1.0592	1.2372	19	-0.86	0.4026
gruppe	6	-2.0137	1.1533	19	-1.75	0.0969
gruppe	7	-2.2615	1.1722	19	-1.93	0.0688
gruppe	8	-1.8799	1.1971	19	-1.57	0.1328
gruppe	9	-2.8799	1.1585	19	-2.49	0.0224
gruppe	10	0	.	.	.	.
x		-0.00567	0.000869	19	-6.53	<.0001

Die Schätzung der festen Effekte umfasst jetzt die Blockeffekte. Die Schätzungen sind so nicht für eine graphische Darstellung geeignet. Wegen des festen Blockeffektes haben wir hier für jeden Block eine eigene Regressionsgleichung der Form

$$\mu + b_j + \lambda x_i$$

Jeder Block (Gruppe) hat also einen eigenen Achsenabschnitt ($\mu + b_j$), aber die Steigung (λ) ist in allen Blöcken dieselbe. Dies ist anhand der obigen Parameterschätzungen in Abb. 4.2 graphisch dargestellt.




Abb 4.2: Angepasste Regressionslinien (MIXED; feste Blöcke; gestrichelt: Regressionslinien für die Blöcke; fett: Durchschnitt der Regressionen der Blöcke).

Es ist sinnvoll, anstelle von 10 parallelen Regressionskurven für jede Gruppe die durchschnittliche Regressionsgerade über die Gruppen zu berechnen. Dies führt zu folgender Regressionsgleichung:

$$\mu + \bar{b}_\cdot + \lambda x_i$$

Um den durchschnittlichen Achsenabschnitt $\mu + \bar{b}_\cdot$ zu schätzen, ist eine ESTIMATE Anweisung erforderlich:

```
proc mixed data=t;
class gruppe;
model score=gruppe x/solution;
estimate 'intercept' intercept 10 gruppe 1 1 1 1 1 1 1 1 1 1/divisor=10;
estimate 'slope' x 1;
```

run;

Output:

Label	Estimate	Standard Error	DF	t Value	Pr > t
intercept	8.9115	0.6058	19	14.71	<.0001
slope	-0.00567	0.000869	19	-6.53	<.0001

Die geschätzte Regressionsgleichung lautet somit:

$$\text{SCORE} = 8,9115 - 0,00567 \cdot X$$

Dies unterscheidet sich nur unwesentlich von der Inter-Block-Analyse (Blöcke = Gruppen zufällig).

Beispiel 4.3: Ein α -Design ist eine Versuchsanlage in unvollständigen Blöcken, bei der die Blöcke zu **vollständigen Wiederholungen** gruppiert werden können. Ansonsten ist die Randomisation so wie bei allen Anlagen mit unvollständigen Blöcken (siehe Beispiel 4.1). Viele Sortenversuche werden in solchen Anlagen durchgeführt. Ein Versuch mit $t = 24$ Hafersorten wurde als α -Design angelegt. Die Anlage hatte $r = 3$ vollständige Wiederholungen, $m = 6$ Blöcke je Wiederholung und $k = 4$ Parzellen je Block.

Der Versuchsplan war:

Wiederholung 1						Wiederholung 2						Wiederholung 3						Block Nr.
1	2	3	4	5	6	1	2	3	4	5	6	1	2	3	4	5	6	
11	21	23	13	17	6	8	24	12	5	2	19	11	2	17	12	21	3	
4	10	14	3	15	12	20	15	11	9	18	7	1	15	18	13	22	5	
5	20	16	19	7	24	14	3	21	10	13	6	14	9	4	10	16	20	
22	2	18	8	1	9	4	23	17	1	22	16	19	8	6	23	24	7	

Die Erträge in t/ha waren (**alpha.dat**):

Wiederholung 1					
Block 1	Block 2	Block 3	Block 4	Block 5	Block 6
4,1172	4,6540	4,2323	4,2530	4,7876	4,7085
4,4461	4,1736	4,7572	3,3420	5,0902	5,2560
5,8757	4,0141	4,4906	4,7269	4,1505	4,9577
4,5784	4,3350	3,9737	4,9989	5,1202	3,3986

Wiederholung 2

Block 1	Block 2	Block 3	Block 4	Block 5	Block 6
3,9926	3,9039	5,3127	5,1202	5,1566	5,3148
3,6056	4,9114	5,1163	4,2955	5,0988	4,6297
4,5294	3,7999	5,3802	4,9057	5,4840	5,1751
4,3599	4,3042	5,0744	5,7161	5,0969	5,3024

Wiederholung 3

Block 1	Block 2	Block 3	Block 4	Block 5	Block 6
3,9205	4,0510	4,3234	4,1746	4,4130	2,8873
4,6512	4,6783	4,2486	4,7512	4,2397	4,1972
4,3887	3,1407	4,3960	4,0875	4,3852	3,7349
4,5552	3,9821	4,2474	3,8721	3,5655	3,6096

Die Auswertung erfolgt nach folgendem Modell:

$$y_{ijh} = \mu + \gamma_j + b_{jh} + \tau_i + e_{ijh}$$

$$(i = 1, \dots, t; j = 1, \dots, r; h = 1, \dots, m)$$

wobei

y_{ijh} = Beobachtung der i -ten Behandlung im h -ten Block innerhalb der j -ten Wiederholung

μ = Gesamteffekt

γ_j = Effekt der j -ten Wiederholung

b_{jh} = Effekt des h -ten Blocks innerhalb der j -ten Wiederholung

τ_i = Effekt der i -ten Behandlung

e_{ijh} = Fehler der Beobachtung y_{ijh}

Wegen der Randomisation (zufällige Anordnung der Blöcke innerhalb der Wiederholungen, zufällige Zuordnung der Behandlungen zu den Behandlungsnummern) kann der Blockeffekt als zufällig betrachtet werden:

$$b_j \sim N(0, \sigma_b^2)$$

Bei einer Auswertung unter dieser Annahme wird die Inter-Block-Information genutzt, während bei Annahme fester Blockeffekte die Inter-Block-Information nicht genutzt wird.

SAS Anweisungen

```
data alpha;
input rep block trt y;
datalines;
```

1	1	11	4.1172
1	1	4	4.4461
1	1	5	5.8757
1	1	22	4.5784
1	2	21	4.6540
1	2	10	4.1736
1	2	20	4.0141
1	2	2	4.3350
1	3	23	4.2323
1	3	14	4.7572
1	3	16	4.4906
1	3	18	3.9737
1	4	13	4.2530
1	4	3	3.3420
1	4	19	4.7269
1	4	8	4.9989
1	5	17	4.7876
1	5	15	5.0902
1	5	7	4.1505
1	5	1	5.1202
1	6	6	4.7085
1	6	12	5.2560
1	6	24	4.9577
1	6	9	3.3986
2	1	8	3.9926
2	1	20	3.6056
2	1	14	4.5294
2	1	4	4.3599
2	2	24	3.9039
2	2	15	4.9114
2	2	3	3.7999
2	2	23	4.3042
2	3	12	5.3127
2	3	11	5.1163
2	3	21	5.3802
2	3	17	5.0744
2	4	5	5.1202
2	4	9	4.2955
2	4	10	4.9057
2	4	1	5.7161
2	5	2	5.1566
2	5	18	5.0988
2	5	13	5.4840
2	5	22	5.0969
2	6	19	5.3148
2	6	7	4.6297
2	6	6	5.1751
2	6	16	5.3024
3	1	11	3.9205

3	1	1	4.6512
3	1	14	4.3887
3	1	19	4.5552
3	2	2	4.0510
3	2	15	4.6783
3	2	9	3.1407
3	2	8	3.9821
3	3	17	4.3234
3	3	18	4.2486
3	3	4	4.3960
3	3	6	4.2474
3	4	12	4.1746
3	4	13	4.7512
3	4	10	4.0875
3	4	23	3.8721
3	5	21	4.4130
3	5	22	4.2397
3	5	16	4.3852
3	5	24	3.5655
3	6	3	2.8873
3	6	5	4.1972
3	6	20	3.7349
3	6	7	3.6096

```

;
/*ohne Nutzung der Inter-Block-Information*/
proc mixed data=alpha;
class rep block trt;
model y=rep block(rep) trt;
lsmeans trt/adjust=sim pdiff cl;
make 'diffs' out=intra;
run;

/*mit Nutzung der Inter-Block-Information*/
proc mixed data=alpha;
class rep block trt;
model y=rep trt/ddfm=kenwardroger;
random block(rep);
lsmeans trt/adjust=sim pdiff cl;
make 'diffs' out=inter;
run;

title 'mittlerer Standardfehler einer Differenz;
      Intra-Block-Analyse';
proc means data=intra mean;
var StdErr;
run;

title 'mittlerer Standardfehler einer Differenz;
      kombinierte Inter-Intra-Block-Analyse';

```

```
proc means data=inter mean;
var StdErr;
run;
```

Mittlerer Standardfehler einer Differenz;
Intra-Block-Analyse

Mean
0.2766288

Mittlerer Standardfehler einer Differenz;
kombinierte Inter-Intra-Block-Analyse

Mean
0.2707963

Die Nutzung der Inter-Block-Information hat hier nur einen geringen Gewinn an Genauigkeit erbracht, was der etwas kleinere Standardfehler anzeigt.

5. Split-plots und strip-plots

Beispiel 5.1: Es wurde ein Versuch mit sechs N-Düngerstufen (N1, N2, N3, N4, N5, N6) und vier Reissorten (V1, V2, V3, V4) durchgeführt. Der Versuch wurde in einer Spaltanlage mit drei Wiederholungen (Blöcken) angelegt, wobei wie folgt randomisiert wurde:

Schritt 1: Jeder Block wurde unterteilt in sechs sog. Großteilstücke. Für jeden Block gesondert wurden die sechs N-Stufen zufällig auf die Großteilstücke verteilt.

N1	N2	N4	N6	N3	N5
----	----	----	----	----	----

Block I

N3	N2	N5	N1	N6	N4
----	----	----	----	----	----

Block II

N4	N6	N3	N1	N2	N5
----	----	----	----	----	----

Block III

Schritt 2: Jedes Großteilstück wurde in vier sog. Kleinteilstücke unterteilt. Für jedes Großteilstück wurden die vier Sorten zufällig auf die vier Kleinteilstücke verteilt.

N1V3	N2V4	N4V1	N6V3	N3V2	N5V1
N1V2	N2V1	N4V4	N6V1	N3V1	N5V4
N1V4	N2V3	N4V2	N6V4	N3V3	N5V2
N1V1	N2V2	N4V3	N6V2	N3V4	N5V3

Block I

N3V2	N2V2	N5V2	N1V4	N6V3	N4V1
N3V1	N2V4	N5V3	N1V3	N6V1	N4V3
N3V4	N2V3	N5V4	N1V1	N6V4	N4V4
N3V3	N2V1	N5V1	N1V2	N6V2	N4V2

Block II

N4V1	N6V1	N3V4	N1V1	N2V1	N5V3
N4V4	N6V2	N3V3	N1V3	N2V4	N5V1
N4V2	N6V4	N3V2	N1V4	N2V2	N5V4
N4V3	N6V3	N3V1	N1V2	N2V3	N5V2

Block III

Ziel: 2-faktorielle varianzanalytische Auswertung (Sorte $\times$ Dünger); multiple Mittelwertvergleiche.

Modellierung: Bei Spaltanlagen haben wir zwei verschiedene Randomisationseinheiten: die Großteilstücke und die Kleinteilstücke. Es ist ein generelles Prinzip der Modellbildung für geplante Versuche, dass jede Randomisationseinheit einen eigenen Fehlerterm erhält. Somit müssen wir bei der Spaltanlage zwei Fehlerterme im Modell haben, einen sog. Großteilstückfehler und einen sog. Kleinteilstückfehler.

In unserem Beispiel muß das Modell einen Blockeffekt sowie den faktoriell aufgespaltenen Behandlungseffekt enthalten. Es sei y_{ijh} die Beobachtung der i -ten N-Stufe und der j -ten Sorte in Block h .

Blöcke: $h = 1, \dots, r$
 N: $i = 1, \dots, a$ (Großteilstückfaktor)
 Sorte: $j = 1, \dots, b$ (Kleinteilstückfaktor)

Dann ist der Erwartungswert

$$E(y_{ijh}) = \eta_{ijh} = \mu + b_h + \tau_{ij}$$

wobei

μ = Gesamteffekt
 b_h = Effekt des h -ten Blocks
 τ_{ij} = Effekt der ij -ten Behandlung

Der Behandlungseffekt τ_{ij} kann wie üblich faktoriell aufgespalten werden. Betrachten wir N-Stufe und Sorte als qualitative Faktoren, so können wir schreiben:

$$\tau_{ij} = \alpha_i + \beta_j + (\alpha\beta)_{ij}$$


wobei

α_i = Haupteffekt der i -ten N-Stufe

β_j = Haupteffekt der j -ten Sorte

$(\alpha\beta)_{ij}$ = Wechselwirkung

Kommen wir nun zu den zufälligen Effekten für Großteilstückfehler und Kleinteilstückfehler. Jede Kombination von Block und Großteilstückfaktor (N-Stufe) entspricht einem eigenen Großteilstück.



Großteilstück für $i = 4$ (4. N-Stufe) und
 $h = 1$ (Block 1)

Daher müssen wir für jede Block $\times$ N-Stufe Kombination einen eigenen Effekte im Modell haben. Dies erreichen wir durch Hinzunahme eines Effektes f , den wir nach Block und Faktor N-Stufe indizieren. Also schreiben wir den Großteilstückfehler als

f_{ih} = Großteilstückfehler
= Fehler für Großteilstück in Block h mit N-Stufe i

Wir nehmen an, der Großteilstückfehler f_{ih} sei normalverteilt mit Mittelwert 0 und Varianz σ_f^2 . Dies schreiben wir auch kurz als

$$f_{ih} \sim N(0, \sigma_f^2)$$

Außerdem entspricht jede Block $\times$ N-Stufe $\times$ Sorte Kombination einem Kleinteilstück.

N1V3	N2V4	N4V1	N6V3	N3V2	N5V1
N1V2	N2V1	N4V4	N6V1	N3V1	N5V4
N1V4	N2V3	N4V2	N6V4	N3V3	N5V2
N1V1	N2V2	N4V3	N6V2	N3V4	N5V3

Block I

Kleinteilstück für $i = 4$ (4. N-Stufe),
 $j = 3$ (Sorte 3), und
 $h = 1$ (Block 1) □

Also wird der Kleinteilstückfehler nach Block, N-Stufe und Sorte indiziert:

e_{ijh} = Kleinteilstückfehler
= Effekt von Kleinteilstück in Block h mit i -ter N-Stufe und j -ter Sorte

Der Fehler wird als normalverteilt mit Mittelwert Null und Varianz σ^2 betrachtet:

$$e_{ijh} \sim N(0, \sigma^2)$$

Das vollständige Modell für die Daten lautet demnach

$$\begin{aligned} y_{ijh} &= E(y_{ijh}) + f_{ih} + e_{ijh} \\ &= \eta_{ijh} + f_{ih} + e_{ijh} \\ &= \mu + b_h + \tau_{ij} + f_{ih} + e_{ijh} \end{aligned}$$

Falls wir beide Faktoren als qualitativ betrachtet werden, können wir schreiben:

$$y_{ijh} = \mu + b_h + \alpha_i + \beta_j + (\alpha\beta)_{ij} + f_{ih} + e_{ijh}$$

Auswertung: Die Besonderheit der statistischen Auswertung einer Spaltanlage gegenüber einer gewöhnlichen Blockanlage liegt darin, dass das lineare Modell zwei zufällige Fehlerterme hat. Dies ist bei der Durchführung von Mittelwertvergleichen und bei F-Tests zu berücksichtigen.

Für vollständige Daten berechnet sich die Varianzanalyse einer Spaltenanlage mit Großteilstückfaktor in vollständigen Blöcken wie folgt:

Ursache	FG	SQ	MQ
Blöcke	$(r-1)$	$SQ_{\text{Blöcke}}$	
Faktor A (Großteilstückfaktor)	$(a-1)$	SQ_A	
Fehler (A) Großteilstückfehler	$(a-1)(r-1)$	$SQ_{\text{Fehler(A)}}$	E_a
Faktor B (Kleinteilstückfaktor)	$(b-1)$	SQ_B	
Wechselwirkung	$(a-1)(b-1)$	SQ_{AB}	
Fehler (B) Kleinteilstückfehler	$a(b-1)(r-1)$	$SQ_{\text{Fehler(B)}}$	E_b

(E_a und E_b sind Abkürzungen für die MQ von Großteilstück- und Kleinteilstückfehler). Die Rechenformeln für die SQ werden hier weggelassen.

Betrachten wir die Großteilstückmittelwerte, so können wir diese wie bei einer Blockanlage auswerten. Der Fehlerterm für den Großteilstückfaktor in einer entsprechenden Varianzanalyse muß daher formal dem Fehlerterm einer Blockanlage entsprechen. Dagegen werden der Kleinteilstückfaktor sowie die Wechselwirkungen gegen einen anderen Fehlerterm, den Kleinteilstückfehler geprüft. Um die Notwendigkeit der Verwendung verschiedener Fehlerterme genau nachvollziehen zu können, müssen wir uns mit dem Prinzip der Varianzanalyse für gemischte Modelle beschäftigen. Bei Auswertung nach Modellen mit nur einem Fehlerterm werden alle Streuungsursachen gegen einen einzigen Fehlerterm getestet. Bei gemischten Modellen gibt es dagegen mehrere Fehlerterme und die Wahl des adäquaten Fehlerterms für die verschiedenen Streuungsursachen ist ein zusätzlicher Schritt der Analyse. Eine Möglichkeit, den richtigen Fehlerterm zu ermitteln, besteht darin, die Erwartungswerte der verschiedenen MQ der Streuungszerlegung zu berechnen. Für eine Spaltanlage mit Großteilstücken in vollständigen Blöcken finden wir (Dufner et al., 1992):

Ursache	FG	E(MQ)
Blöcke	$(r-1)$	$\sigma^2 + b\sigma_f^2 + \frac{ab}{r-1} \sum_{h=1}^r (b_h - \bar{b})^2$
Faktor A	$(a-1)$	$\sigma^2 + b\sigma_f^2 + \frac{br}{a-1} \sum_{i=1}^a (\alpha_i - \bar{\alpha})^2 \quad (*)$
Fehler (A)	$(a-1)(r-1)$	$\sigma^2 + b\sigma_f^2$
Faktor B	$(b-1)$	$\sigma^2 + \frac{ar}{b-1} \sum_{j=1}^b (\beta_j - \bar{\beta})^2 \quad (*)$
Wechselwirkung	$(a-1)(b-1)$	$\sigma^2 + \frac{r}{(a-1)(b-1)} \sum_{i=1}^a \sum_{j=1}^b [(\alpha\beta)_{ij} - \overline{(\alpha\beta)}_{i.} - \overline{(\alpha\beta)}_{.j} + \overline{(\alpha\beta)}_{..}]^2$
Fehler (B)	$a(b-1)(r-1)$	σ^2

(*) Unter der Annahme, dass keine Wechselwirkungen vorliegen!

Den richtigen Nenner für den F-Test eines Effektes findet man, indem man den Erwartungswert des MQ des zu testenden Effektes unter der Nullhypothese bildet und dasjenige MQ in der Varianzanalyse-Tabelle sucht, welches denselben Erwartungswert hat. Wir sehen auf diese Weise leicht, dass Faktor A gegen Fehler(A) zu testen ist, während Faktor B und die Wechselwirkungen gegen den Fehler (B) getestet werden müssen:

$$F_{Vers}^{(A)} = \frac{SQ_A / (a-1)}{SQ_{Fehler(A)} / [(a-1)(r-1)]}$$

$$F_{Vers}^{(B)} = \frac{SQ_B / (b-1)}{SQ_{Fehler(B)} / [a(b-1)(r-1)]}$$

$$F_{Vers}^{(AB)} = \frac{SQ_{AB} / [(a-1)(b-1)]}{SQ_{Fehler(B)} / [a(b-1)(r-1)]}$$

Die Daten des Reisversuchs (kg/ha) sind im folgenden wiedergegeben (**reis.dat**):

		Block		
		1	2	3
N1	V1	4430	4478	3850
	V2	3944	5314	3660
	V3	3464	2944	3124
	V4	4126	4482	4836
N2	V1	5418	5166	6432
	V2	6502	5858	5586
	V3	4768	6004	5556
	V4	5192	4604	4652
N3	V1	6076	6420	6704
	V2	6008	6127	6642
	V3	6244	5724	6014
	V4	4546	5744	4146
N4	V1	6462	7056	6680
	V2	7139	6982	6564
	V3	5792	5880	6370
	V4	2774	5036	3638
N5	V1	7290	7848	7552
	V2	7682	6594	6576
	V3	7080	6662	6320
	V4	1414	1960	2766
N6	V1	8452	8832	8818
	V2	6228	7387	6006
	V3	5594	7122	5480
	V4	2248	1380	2014

Die Varianzanalyse-Tabelle ist wie folgt:

Ursache	FG	SQ	MQ	F	p-Wert
Blöcke	2	1084820	542410		
N	5	30480453	6096091	42,81	<0,0001
Fehler (A)	10	1424107	142411	$= E_a$	
Sorte	3	89885035	29961678	85,74	<0,0001
Wechselwirkung	15	69378044	4625203	13,24	<0,0001
Fehler (B)	36	12579905	349442	$= E_b$	

Sowohl die beiden Hauptwirkungen als auch die Wechselwirkungen sind signifikant.

Hinweis für Verwendung von SAS: Die SAS Prozedur GLM berechnet die Erwartungswerte der MQ automatisch bei Verwendung der Option /TEST in der RANDOM Anweisung. Auf diese Weise lassen sich für beliebige Spaltanlagen die adäquaten F-Tests erhalten. Mit MIXED werden ebenfalls automatisch die richtigen F-Tests erhalten.

Bei Mittelwertvergleichen müssen ebenfalls die beiden Fehlerterme berücksichtigt werden.

Vergleich	Standardfehler einer Mittelwertdifferenz ($s_{\bar{d}}$)	Freiheitsgrade
A Mittel über Stufen von B	$s_{\bar{d}}^{(1)} = \sqrt{\frac{2E_a}{rb}}$	$FG^{(1)} = (a-1)(r-1)$
B Mittel über Stufen von A	$s_{\bar{d}}^{(2)} = \sqrt{\frac{2E_b}{ra}}$	$FG^{(2)} = a(b-1)(r-1)$
AB Mittel bei gleicher Stufe von A	$s_{\bar{d}}^{(3)} = \sqrt{\frac{2E_b}{r}}$	$FG^{(3)} = a(b-1)(r-1)$
AB Mittel bei gleicher Stufe von B	$s_{\bar{d}}^{(4)} = \sqrt{\frac{2[(b-1)E_b + E_a]}{rb}}$	$FG^{(4)}$ siehe Text

Grenzdifferenz: $t_{1-\alpha/2; FG} s_{\bar{d}}$

Für den Vergleich der AB Mittelwerte auf gleicher Stufe von B (Kleinteilstückfaktor) berechnet sich die Varianz einer Differenz als Linearkombination zweier MQ (E_a und E_b). Daher muss hier wie in Beispiel 7 die Satterthwaite-Methode zur Berechnung der Freiheitsgrade $FG^{(4)}$ angewendet werden.

Satterthwaite-Methode

Berechnet sich der Standardfehler einer Differenz nur aus einem MQ, so folgt das Quadrat des Standardfehlers dem Vielfachen einer χ^2 -verteilten Zufallsvariable mit den Freiheitsgraden des MQ. Sind mehr als ein MQ an der Berechnung des Standardfehlers beteiligt, so ist das Quadrat des Standardfehlers verteilt wie eine Linearkombination aus χ^2 -verteilten Zufallsvariablen mit unterschiedlichen Freiheitsgraden.

Diese Verteilung kann lediglich approximiert werden. Satterthwaite (1946) hat vorgeschlagen, die Verteilung durch eine χ^2 -Verteilung mit gewichteten Freiheitsgraden zu approximieren. Dazu wird ein gewichtetes Mittel der Freiheitsgrade der einzelnen MQ berechnet, wobei die Gewichte von den MQ selbst abhängen. Allgemein berechnen sich die approximativen Freiheitsgrade für eine Linearkombination von MQ

$$Q = q_1MQ_1 + q_2MQ_2 + \dots$$

als

$$FG = \frac{Q^2}{(q_1MQ_1)^2/FG_1 + (q_2MQ_2)^2/FG_2 + \dots}$$

wobei FG_i die Freiheitsgrade von MQ_i sind.

Im Falle einer Spaltanlage mit Großteilstücken in vollständigen Blöcken lauten die approximativen Freiheitsgrade für den Standardfehler $s_d^{(4)} = \sqrt{\frac{2[(b-1)E_b + E_a]}{rb}}$:

$$FG^{(4)} = \frac{[(b-1)E_b + E_a]^2}{[(b-1)E_b]^2/[a(b-1)(r-1)] + [E_a]^2/[(a-1)(r-1)]}$$

Im oben beschriebenen Reisversuch haben wir

$$E_a = 142411 \quad E_b = 349442 \\ a = 6; b = 4; r = 3$$

Somit ist

$$s_d^{(4)} = \sqrt{\frac{2[(b-1)E_b + E_a]}{rb}} = \sqrt{\frac{2[3 \times 349442 + 142411]}{12}} = 445,48 \quad \text{und}$$

$$FG^{(4)} = \frac{[(b-1)E_b + E_a]^2}{[(b-1)E_b]^2/[a(b-1)(r-1)] + [E_a]^2/[(a-1)(r-1)]} \\ = \frac{[3 \times 349442 + 142411]^2}{[3 \times 349442]^2/36 + 142411^2/10} = 43,55$$

SAS Anweisungen:

```
data;
input
  n    v    block    y;
datalines;
  1    1     1    4430
  1    1     2    4478
  1    1     3    3850
  1    2     1    3944
```

1	2	2	5314
1	2	3	3660
1	3	1	3464
1	3	2	2944
1	3	3	3124
1	4	1	4126
1	4	2	4482
1	4	3	4836
2	1	1	5418
2	1	2	5166
2	1	3	6432
<mehr Daten>			
5	4	3	2766
6	1	1	8452
6	1	2	8832
6	1	3	8818
6	2	1	6228
6	2	2	7387
6	2	3	6006
6	3	1	5594
6	3	2	7122
6	3	3	5480
6	4	1	2248
6	4	2	1380
6	4	3	2014
;			

```

proc mixed method=reml nobound data=reis;
class block n v;
model y=block n v n*v/ddfm=satterth;
random block*n;
lsmeans n*v/pdiff;
run;

```

Die Option NOBOUND bewirkt, dass die REML Schätzungen negativ werden können. Hierdurch wird bei balancierten Daten Übereinstimmung mit der ANOVA Methode erzielt für den Fall, dass die ANOVA Methode negative Schätzwerte liefert (Piepho und Spilke, 1999).

Output (Auszug):

Covariance Parameter Estimates

Cov Parm	Estimate
block*n	-51758
Residual	349442

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
block	2	10	3.81	0.0589
n	5	10	42.81	<.0001
v	3	36	85.74	<.0001
n*v	15	36	13.24	<.0001

Die hier erhaltenen Tests sind sog. Wald-Tests (siehe Anhang), die im Falle balancierter Daten identisch mit den F-Tests der Varianzanalyse sind (Piepho und Spilke, 1999). Sowohl die Wechselwirkungen als auch die Hauptwirkungen sind signifikant. Daher vergleichen wir AB Mittelwerte. Hier einige Beispiele:

Least Squares Means

Effect	n	v	Estimate	Standard Error
n*v	1	1	4252.67	315.00
n*v	1	2	4306.00	315.00
n*v	1	3	3177.33	315.00
n*v	1	4	4481.33	315.00
n*v	2	1	5672.00	315.00
n*v	2	2	5982.00	315.00
n*v	2	3	5442.67	315.00
n*v	2	4	4816.00	315.00
n*v	3	1	6400.00	315.00
n*v	3	2	6259.00	315.00
n*v	3	3	5994.00	315.00
n*v	3	4	4812.00	315.00
n*v	4	1	6732.67	315.00
n*v	4	2	6895.00	315.00
n*v	4	3	6014.00	315.00
n*v	4	4	3816.00	315.00
n*v	5	1	7563.33	315.00
n*v	5	2	6950.67	315.00
n*v	5	3	6687.33	315.00
n*v	5	4	2046.67	315.00
n*v	6	1	8700.67	315.00
n*v	6	2	6540.33	315.00
n*v	6	3	6065.33	315.00
n*v	6	4	1880.67	315.00

Differences of Least Squares Means

Effect	n	v	_n	_v	Estimate	Standard Error	DF	t Value	Pr > t
n*v	1	1	1	2	-53.3333	482.66	36	-0.11	0.9126
n*v	1	1	2	1	-1419.33	445.48	43.6	-3.19	0.0027

<weitere Vergleiche>

Anhand des Outputs, der sehr viele paarweise Differenzen umfasst und damit praktisch nicht leicht interpretierbar ist, kann die Grenzdifferenz in einem Datenschnitt (dataset) leicht berechnet werden. Wir müssen lediglich den "Standard error" ($s_{\bar{d}}$) mit dem kritischen t-Wert multiplizieren, wobei die Freiheitsgrade nach Satterthwaite direkt unter DF abzulesen sind. Der kritische t-Wert kann mittels der TINV Funktion berechnet werden. Die Berechnungen werden mit folgenden Anweisungen erhalten, welche die beiden verschiedenen Grenzdifferenzen mittels der MEANS Prozedur ausgeben:

```
proc mixed method=reml nobound data=reis;
class block n v;
model y=block n v n*v/ddfm=satterth;
random block*n;
lsmeans n*v/pdiff;
make 'Diffs' out=diffs;
```

```
data diffs;
set diffs;
LSD=tinv(0.975, DF)*StdErr;
```

```
proc sort data=diffs out=diffs;
by StdErr DF;
```

```
proc means data=diffs mean;
by StdErr DF;
var LSD;
run;
```

Output:

--- Standard Error=445.48 DF=43.6 ---

The MEANS Procedure

Analysis Variable : LSD

Mean
898.0750670

----- Standard Error=482.66 DF=36 -----

Analysis Variable : LSD

Mean
978.8809665

Die Mittelwert Tabelle für den Versuch ist wie folgt:

	N1 (0)	N2 (60)	N3 (90)	N4 (120)	N5 (150)	N6 (180)
V1	4253	5672	6400	6733	7563	8701
V2	4306	5982	6259	6895	6951	6540
V3	3177	5443	5994	6014	6687	6065
V4	4481	4816	4812	3816	2047	1881

LSD($\alpha = 5\%$) = 898,1 (Vergleiche in derselben Zeile)

LSD($\alpha = 5\%$) = 978,8 (Vergleiche in derselben Spalte)

Zusätzlich können die Mittelwerte noch mit Buchstaben versehen werden, um signifikante Mittelwerteunterschiede kenntlich zu machen, was aber hier der Kürze halber unterbleiben soll.

Bisher haben wir die N-Stufe als qualitativen Faktor behandelt, obwohl es sich um einen quantitativen Faktor handelt, für den eine Regression in Frage kommt. Dies soll im folgenden besprochen werden. Wir machen für den Haupteffekt der N-Stufe (α_i) und die Interaktionen $[(\alpha\beta)_{ij}]$ einen Polynomansatz:

$$\alpha_i = \theta_1 z_i + \lambda_i \quad (\text{Hauptwirkung N-Stufen})$$

$$(\alpha\beta)_{ij} = \delta_{1j} z_i + \lambda_{ij} \quad (\text{Wechselwirkungen})$$

wobei

z_i = N-Menge

θ_1 = gemeinsamer Regressionskoeffizient für die Hauptwirkung N

δ_{1j} = Regressionskoeffizient für die Wechselwirkung (einer für jede Sorte j)

λ_i = Lack-of-fit Effekt für die Hauptwirkung N

λ_{ij} = Lack-of-fit Effekt für die Wechselwirkung

Dieser Ansatz impliziert eine lineare Wirkung der N-Stufe auf den Ertrag, wobei jede Sorte eine eigene Steigung hat. Eine graphische Abtragung der Erträge gegen die N-Menge für die einzelnen Sorten legt allerdings bereits nahe, daß die Wirkung nichtlinear ist, so daß wir einen quadratischen Term benötigen.

$$\alpha_i = \theta_1 z_i + \theta_2 z_i^2 + \lambda_i \quad (\text{Hauptwirkung N-Stufen})$$

$$(\alpha\beta)_{ij} = \delta_{1j} z_i + \delta_{2j} z_i^2 + \lambda_{ij} \quad (\text{Wechselwirkungen})$$

Mit diesem Modellansatz lautet das vollständige Modell für die Daten:


$$y_{ijh} = \mu + b_h + \theta_1 z_i + \theta_2 z_i^2 + \lambda_i + \beta_j + \delta_{1j} z_i + \delta_{2j} z_i^2 + \lambda_{ij} + f_{ih} + e_{ijh}$$

Wir demonstrieren nun die Umsetzung mit der SAS Prozedur GLM. Zunächst erzeugen wir einen Datensatz der folgenden Struktur:

BLOCK	N	V	N2	LACKFIT	Y
1	0	1	0	0	4430
2	0	1	0	0	4478
3	0	1	0	0	3850
1	0	2	0	0	3944
2	0	2	0	0	5314
.					
. < mehr Daten >					
.					
1	180	3	32400	180	5594
2	180	3	32400	180	7122
3	180	3	32400	180	5480
1	180	4	32400	180	2248
2	180	4	32400	180	1380
3	180	4	32400	180	2014

BLOCK, N und V sind die Variablen für Blöcke, N-Stufe und Sorte, wobei wir für N den quantitativen Wert der N-Menge eingetragen haben, da eine Regression durchgeführt werden soll. Um den quadratischen Term anpassen zu können, benötigen wir außerdem das Quadrat der N-Menge (N2). Die Variable LACKFIT hat dieselbe Kodierung wie N. Wir benötigen sie zur Anpassung der Lack-of-fit Effekte. In der Prozedur GLM geben wir das Modell wie folgt an:

MODEL = BLOCK N N2 LACKFIT BLOCK*LACKFIT V N*V N2*V LACKFIT*V;



Außerdem müssen die Variablen BLOCK, LACKFIT und V als Klassifizierungsvariablen kenntlich gemacht werden, was über die CLASS Anweisung erfolgt. Klassifizierungsvariablen sind solche Variablen, für die jede Stufe der Variablen einen eigenen Effekt im Modell zugewiesen bekommt. Der Term BLOCK in der Modell Anweisung von GLM (siehe unten) muß beispielsweise für jeden Block (1, 2, 3) einen eigenen Effekt erzeugen (b_1, b_2, b_3). Dies wird erreicht, indem BLOCK in der CLASS Anweisung aufgeführt wird. Der Term N dagegen soll den Regressionsterm $\theta_1 z_i$ erzeugen,

welcher nur einen Parameter hat, nämlich θ_1 . Verschiedene N-Stufen (0, 60, 90, 120, 150, 180) haben hier nur einen Parameter, nämlich θ_1 . Dagegen muß der Lack-of-fit Term λ_j für jede N-Stufe einen eigenen Parameter haben ($\lambda_1, \dots, \lambda_6$). Die Prozedur wird wie folgt aufgerufen:

```
proc glm;
class block lackfit v;
model y=block n n2 lackfit block*lackfit v n*v n2*v
      lackfit*v/ss1 e1;
random block*lackfit/test;
run;
```

Der Großteilstückfehler BLOCK*LACKFIT ist ein zufälliger Effekt, was in der RANDOM Anweisung spezifiziert wird. Durch die Option /TEST der RANDOM Anweisung wird die Prozedur veranlaßt, Erwartungswerte der MQ zu berechnen, mit deren Hilfe dann F-Tests konstruiert werden. Die Erwartungswerte werden wie folgt ausgegeben:

Source	Type I Expected Mean Square
BLOCK	Var(Error) + 4 Var(BLOCK*LACKFIT) + Q(BLOCK)
N	Var(Error) + 4 Var(BLOCK*LACKFIT) + Q(N,N2,LACKFIT,N*V,N2*V,LACKFIT*V)
N2	Var(Error) + 4 Var(BLOCK*LACKFIT) + Q(N2,LACKFIT,N2*V,LACKFIT*V)
LACKFIT	Var(Error) + 4 Var(BLOCK*LACKFIT) + Q(LACKFIT,LACKFIT*V)
BLOCK*LACKFIT	Var(Error) + 4 Var(BLOCK*LACKFIT)
V	Var(Error) + Q(V,N*V,N2*V,LACKFIT*V)
N*V	Var(Error) + Q(N*V,N2*V,LACKFIT*V)
N2*V	Var(Error) + Q(N2*V,LACKFIT*V)
LACKFIT*V	Var(Error) + Q(LACKFIT*V)
Error	Var(Error)

Aufgrund der Erwartungswerte ergibt sich, daß N, N2 und LACKFIT gegen BLOCK*LACKFIT (f_{ijh} ; Großteilstückfehler) getestet werden müssen, während V, N*V, N2*V und LACKFIT*V gegen "Error" getestet werden müssen (e_{ijh} ; Kleinteilstückfehler). Aus dem Output der Prozedur GLM entnehmen wir folgende Varianzanalyse-Tabelle:

Ursache	FG	SQ	F	p-Wert
Großteilstückfaktor-Analyse (Test gegen BLOCK*LACKFIT):				
BLOCK	2	542410	3,8088	0,0589
N	1	20283862	142,4321	0,0001
N2	1	969338	68,0664	0,0001
LACKFIT	3	167737	1,1778	0,3665
BLOCK*LACKFIT	10	142411		

Kleinteilstückfaktor-Analyse (Test gegen "Error"):

V	3	29961678	85,7415	0,0001
N*V	3	20247407	57,9421	0,0001
N2*V	3	1743106	4,9883	0,0054
LACKFIT*V	9	378500	1,0832	0,3986
Error	36	349442		

Die Varianzanalyse zeigt, daß wir einen quadratischen Term in der Regression auf die N-Menge benötigen, da N und N2 sowie N*V und N2*V signifikant sind. Terme höherer Ordnung werden nicht benötigt, da die beiden Lack-of-fit Terme LACKFIT und LACKFIT*V nicht signifikant sind.

Kommen wir nun zur Schätzung der Regressionskurven. Hierzu lassen wir alle nicht signifikanten Terme aus dem Modell und betrachten zunächst den Erwartungswert einer Beobachtung

$$\eta_{ijh} = E(y_{ijh}) = \mu + b_h + \theta_1 z_i + \theta_2 z_i^2 + \beta_j + \delta_{1j} z_i + \delta_{2j} z_i^2$$

Diesen Erwartungswert mitteln wir über die Blöcke:

$$\bar{\eta}_{ij.} = \mu + \bar{b}_{.} + \theta_1 z_i + \theta_2 z_i^2 + \beta_j + \delta_{1j} z_i + \delta_{2j} z_i^2$$

Umstellen der Terme liefert:

$$\begin{aligned} \bar{\eta}_{ij.} &= (\mu + \bar{b}_{.} + \beta_j) + (\theta_1 + \delta_{1j}) z_i + (\theta_2 + \delta_{2j}) z_i^2 \\ &= \mu_j + \delta'_{1j} z_i + \delta'_{2j} z_i^2 \end{aligned}$$

mit

$$\mu_j = \mu + \bar{b}_{.} + \beta_j$$

$$\delta'_{1j} = \theta_1 + \delta_{1j}$$

$$\delta'_{2j} = \theta_2 + \delta_{2j}$$

Dies ist ein Polynom 2. Grades in z_i , wobei jede Sorte j eigene Werte der Parameter hat. Um die Parameter dieser Polynome zu schätzen, verwenden wir die ESTIMATE Anweisung der Prozedur MIXED. Diese Prozedur liefert im Gegensatz zur Prozedur GLM auch die adäquaten Standardfehler der Schätzungen. Diese Anweisung erlaubt

es, aus den Kleinstquadratschätzungen der Parameter beliebige schätzbare Funktionen zu berechnen. Die Parameter des Polynoms sind schätzbare Funktionen der Parameter des ursprünglichen Modells! Wir rufen die Prozedur GLM wie folgt auf:

```
proc mixed method=reml nobound data=temp;
class block v lackfit;
model y=block v n n2 n*v n2*v/ddfm=satterth;
random lackfit*block;
estimate 'Achsenabschnitt 1' intercept 3 block 1 1 1 v 3 0 0 0/divisor=3;
estimate 'Achsenabschnitt 2' intercept 3 block 1 1 1 v 0 3 0 0/divisor=3;
estimate 'Achsenabschnitt 3' intercept 3 block 1 1 1 v 0 0 3 0/divisor=3;
estimate 'Achsenabschnitt 4' intercept 3 block 1 1 1 v 0 0 0 3/divisor=3;
estimate 'Linear      1'      ' n  1 v*n  1 0 0 0;
estimate 'Linear      2'      ' n  1 v*n  0 1 0 0;
estimate 'Linear      3'      ' n  1 v*n  0 0 1 0;
estimate 'Linear      4'      ' n  1 v*n  0 0 0 1;
estimate 'Quadratisch 1'      ' n2 1 v*n2 1 0 0 0;
estimate 'Quadratisch 2'      ' n2 1 v*n2 0 1 0 0;
estimate 'Quadratisch 3'      ' n2 1 v*n2 0 0 1 0;
estimate 'Quadratisch 4'      ' n2 1 v*n2 0 0 0 1; run;
```

Wir haben in der Modell-Anweisung neben den nicht-signifikanten Termen den zufälligen Term BLOCK*FACKFIT wegelassen, da andernfalls die Parameter nicht eindeutig schätzbar sind.

Zur Berechnung der Koeffizienten für die ESTIMATE Anweisung zur Berechnung des Achsenabschnittes: Diesen können wir schreiben als

$$\mu_j = \mu + \bar{b}_j + \beta_j = \frac{3\mu + b_1 + b_2 + b_3 + 3\beta_j}{3}$$

woraus sich die Koeffizienten in der ESTIMATE Anweisung ergeben. Die Division durch 3 wird durch die Option DIVISOR=3 erreicht.

Output:

ESTIMATE Statement Results

Parameter	Estimate	Std Error	DF	t	Pr > t
Achsenabschnitt 1	4323.4682540	308.45757673	54.7	14.02	0.0001
Achsenabschnitt 2	4278.6825397	308.45757673	54.7	13.87	0.0001
Achsenabschnitt 3	3200.8174603	308.45757673	54.7	10.38	0.0001
Achsenabschnitt 4	4561.6904762	308.45757673	54.7	14.79	0.0001
Linear 1	18.81396825	7.27961205	54.7	2.58	0.0125
Linear 2	35.61698413	7.27961205	54.7	4.89	0.0001
Linear 3	45.29174603	7.27961205	54.7	6.22	0.0001
Linear 4	14.61492063	7.27961205	54.7	2.01	0.0496
Quadratisch 1	0.02582892	0.03856021	54.7	0.67	0.5058
Quadratisch 2	-0.12480600	0.03856021	54.7	-3.24	0.0021

Quadratisch 3	-0.16048501	0.03856021	54.7	-4.16	0.0001
Quadratisch 4	-0.17637566	0.03856021	54.7	-4.57	0.0001

Somit lauten die geschätzten Regressionsgleichungen:


Sorte V1: $ERTRAG = 4323 + 18,81 \times N + 0,02583 \times N^2$

Sorte V2: $ERTRAG = 4279 + 35,62 \times N - 0,12481 \times N^2$

Sorte V3: $ERTRAG = 3201 + 45,29 \times N - 0,16049 \times N^2$

Sorte V4: $ERTRAG = 4462 + 14,61 \times N - 0,17638 \times N^2$

Die t-Tests zeigen an, daß für alle Sorten der lineare Term signifikant ist. Außerdem ist für alle Sorten außer V1 der quadratische Term signifikant. Abschließend stellen wir die Regressionslinien graphisch dar.



□

Beispiel 5.2 (Gomez und Gomez, S. 110): Ein Versuch mit sechs Reissorten (V1 bis V6) und drei Düngerstufen (N1 bis N3) wurde in einer Streifenanlage (strip-plot) durchgeführt (siehe Plan; Daten in **reis strip plot.dat**).

	N ₁	N ₃	N ₂	
V ₆				Block I
V ₅				
V ₃				
V ₂				
V ₄				
V ₁				

	N ₃	N ₂	N ₁	
V ₄				Block II
V ₂				
V ₆				
V ₃				
V ₁				
V ₅				

	N ₃	N ₁	N ₂	
V ₅				Block III
V ₂				
V ₃				
V ₄				
V ₆				
V ₁				

Die Erträge waren wie folgt:

Dünger, kg/ha	Ertrag, kg/ha		
	Block I	Block II	Block III
		IR8 (V ₁)	
0 (N ₁)	2373	3958	4384
60 (N ₂)	4076	6431	4889
120 (N ₃)	7254	6808	8582
		IR127-80 (V ₂)	
0	4007	5795	5001
60	5630	7334	7177
120	7053	8284	6297
		IR305-4-12 (V ₃)	
0	2620	4508	5621
60	4676	6672	7019
120	7666	7328	8611
		IR400-2-5 (V ₄)	
0	2726	5630	3821
60	4838	7007	4816
120	6881	7735	6667

IR665-58 (V_5)			
0	4447	3276	4582
60	5549	5340	6011
120	6880	5080	6076

Peta (V_6)			
0	2572	3724	3326
60	3896	2822	4425
120	1556	2706	3214

Die Modellierung kann man getrennt für die Behandlungen und die Versuchseinheiten vornehmen.

Behandlungen:

$$\alpha_i + \beta_j + (\alpha\beta)_{ij}$$

α_i = Haupteffekt der i -ten Sorte

β_j = Haupteffekt der j -ten Düngerstufe

$(\alpha\beta)_{ij}$ = Wechselwirkung Dünger $\times$ Sorte

Versuchseinheiten:

$$b_k + e_{jk} + f_{ik} + g_{ijk}$$

wobei

b_k = Effekt des k -ten Blocks

e_{jk} = Effekt der j -ten Spalte (Dünger) im k -ten Block; $e_{jk} \sim N(0, \sigma_e^2)$

f_{ik} = Effekt der i -ten Zeile (Sorte) im k -ten Block; $f_{ik} \sim N(0, \sigma_f^2)$

g_{ijk} = Restfehler; $g_{ijk} \sim N(0, \sigma_g^2)$

Der Auswertungsgang nach diesem gemischten Modell ist ähnlich wie bei einer Spaltanlage, d.h., es gibt in der Varianzanalyse verschiedene Fehlerterme im Nenner der F-Statistik, und bei Mittelwertvergleichen sind die Grenzdifferenzen aus verschiedenen Fehler-MQs zu berechnen. Man erhält die "richtige" Auswertung automatisch, wenn man nach einem gemischten Modell mit MIXED auswertet.

Die Varianzanalyse-Tabelle hat die folgende Struktur:

Tabelle 5.1: Varianzanalyse-Tabelle einer zweifaktoriellen Streifenanlage.

Ursache	Freiheitsgrade (FG)	MQ	E(MQ) [§]
Blöcke	$(r - 1)$		$\sigma_g^2 + b\sigma_e^2 + br \frac{\sum_{i=1}^a [\alpha_i]^2}{(a - 1)}$
A (Sorte)	$(a - 1)$	E_a	$\sigma_g^2 + b\sigma_e^2$
Fehler(A)	$(a - 1)(r - 1)$		
B (Dünger)	$(b - 1)$	E_b	$\sigma_g^2 + a\sigma_f^2 + ar \frac{\sum_{j=1}^b [\beta_j]^2}{(b - 1)}$
Fehler(B)	$(b - 1)(r - 1)$		
A x B	$(a - 1)(b - 1)$	E_c	$\sigma_g^2 + r \frac{\sum_{i=1}^a \sum_{j=1}^b [(\alpha\beta)_{ij}]^2}{(a - 1)(b - 1)}$
Fehler(C)	$(a - 1)(b - 1)(r - 1)$		

r = Zahl der Blöcke, a = Zahl der Stufen des Faktors A (Sorte), b = Zahl der Stufen des Faktors B (Dünger)

§ Für Haupteffekte gelten E(MQ) für den Fall das keine Wechselwirkung vorliegt. Ausserdem wird hier mit der folgenden Reistrktion gearbeitet:

$$\sum_{i=1}^a \alpha_i = \sum_{j=1}^b \beta_j = \sum_{i=1}^a \sum_{j=1}^b [(\alpha\beta)_{ij}]^2$$

Aus den Erwartungswerten der MQ ergibt sich, dass Sorte gegen Fehler(A), Dünger gegen Fehler (B) und Sorte × Dünger gegen Fehler(C) zu testen ist.

Wir verwenden folgende SAS Anweisungen, um die Varianzanalyse mit GLM zu erhalten.

```
data;
do sorte=1 to 6;
do n=0 to 120 by 60;
do block=1 to 3;
input y@@; output;
end;
end;
end;
datalines;
2373 3958 4384
4076 6431 4889
7254 6808 8582
4007 5795 5001
5630 7334 7177
```

```

7053 8284 6297
2620 4508 5621
4676 6672 7019
7666 7328 8611
2726 5630 3821
4838 7007 4816
6881 7735 6667
4447 3276 4582
5549 5340 6011
6880 5080 6076
2572 3724 3326
3896 2822 4425
1556 2706 3214
;
proc glm;
class block n sorte;
model y=block n sorte n*sorte n*block sorte*block;
random n*block sorte*block/test;
run;

```

Ergebnis:

The GLM Procedure

Source	Type III Expected Mean Square
block	Var(Error) + 3 Var(block*sorte) + 6 Var(block*n) + Q(block)
n	Var(Error) + 6 Var(block*n) + Q(n,n*sorte)
sorte	Var(Error) + 3 Var(block*sorte) + Q(sorte,n*sorte)
n*sorte	Var(Error) + Q(n*sorte)
block*n	Var(Error) + 6 Var(block*n)
block*sorte	Var(Error) + 3 Var(block*sorte)

Die Erwartungswerte der *MQ* zeigen, dass "SORTE" gegen den Fehler "BLOCK*SORTE" [Fehler(A)] zu prüfen ist, "N" gegen BLOCK*N [Fehler(B)] und "SORTE*N" gegen den Rest ["Error"; Fehler(C)]. Die F-Tests sind wie folgt:

The GLM Procedure

Tests of Hypotheses for Mixed Model Analysis of Variance

Dependent Variable: y

Source	DF	Type III SS	Mean Square	F Value	Pr > F
block	2	9220962	4610481	2.53	0.1345
Error	9.0089	16435239	1824343		
Error: MS(block*n) + MS(block*sorte) - MS(Error)					

Source	DF	Type III SS	Mean Square	F Value	Pr > F
* n	2	50676061	25338031	34.07	0.0031
Error: MS(block*n)	4	2974908	743727		
* This test assumes one or more other fixed effects are zero.					

Source	DF	Type III SS	Mean Square	F Value	Pr > F
* sorte	5	57100201	11420040	7.65	0.0034
Error	10	14922619	1492262		
Error: MS(block*sorte)					
* This test assumes one or more other fixed effects are zero.					

Source	DF	Type III SS	Mean Square	F Value	Pr > F
n*sorte	10	23877979	2387798	5.80	0.0004
block*n	4	2974908	743727	1.81	0.1672
block*sorte	10	14922619	1492262	3.63	0.0069
Error: MS(Error)	20	8232917	411646		

Die Wechswleirungen sind signifikant, also müssen SORTE*N Mittelwerte verglichen werden. Dieselbe Varianzanalyse erhalten wir mit MIXED:

```
proc mixed;
class block n sorte;
model y=block n sorte n*sorte/ddfm=kr;
random n sorte/sub=block;
run;
```

Ergebnis:

Covariance Parameter Estimates

Cov Parm	Subject	Estimate
n	block	55347
sorte	block	360205
Residual		411646

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
block	2	9.01	2.53	0.1345
n	2	4	34.07	0.0031
sorte	5	10	7.65	0.0034
n*sorte	10	20	5.80	0.0004

Die Mittelwertvergleiche führt man mit MIXED durch, da nur hier die richtigen Standardfehler/Varianzen einer Differenz gefunden werden. Die Varianz einer Differenz berechnet sich wie folgt:

Tabelle 5.2: Varianzen von Mittelwertdifferenzen in einer zweifaktoriellen Streifenanlage.

Vergleich	Varianz der Differenz (V)*
A Mittelwerte (Sorte)	$2E_a/(br)$
B Mittelwerte (Dünger)	$2E_b/(ar)$
A x B Mittelwerte auf gleicher Stufe von B	$2[(b-1)E_c + E_a]/(br)$
A x B Mittelwerte auf gleicher Stufe von A	$2[(a-1)E_c + E_b]/(ar)$

*: Standardfehler der Differenz ergibt sich aus der Quadratwurzel der Varianz V.

Die Varianzen einer Differenz für die verschiedenen Typen von Mittelwertvergleichen berechnen sich wie in Tab. 5.2 gezeigt (Gomez und Gomez, 1984, S. 203). In die Berechnung der ersten beiden Vergleiche in Tab. 5.2 geht nur ein MQ ein, so dass exakte Tests resultieren. Zur Berechnung der Freiheitsgrade für die beiden letzten Vergleiche kann die Methode von Satterthwaite (1941, 1946) angewendet werden (Milliken und Johnson, 1984, S.281). Hier soll exemplarisch der Vergleich der A-Mittelwerte (Sorte) auf gleicher Stufe von B (Dünger) betrachtet werden. Die Varianz einer Differenz (V) berechnet sich als Linearkombination der MQs E_a und E_c :

$$V = h_a E_a + h_c E_c,$$

wobei $h_c = 2(b-1)/(br)$ und $h_a = 2/(br)$ ist. Die approximativen Satterthwaite-Freiheitsgrade ($FG_{Satterth}$) berechnen sich zu

$$FG_{Satterth} = \frac{V^2}{(h_a E_a)^2 / FG_a + (h_c E_c)^2 / FG_c},$$

wobei $FG_a = (a-1)(r-1)$ und $FG_c = (a-1)(b-1)(r-1)$ ist. Wir führen zunächst die Varianzanalyse mit der Prozedur GLM durch, um E_a und E_c zu erhalten und daraus die Freiheitsgrade von Hand zu berechnen. Wir finden $E_a = 1492262$ und $E_c = 411646$. Hiermit berechnen sich $V = 514562$ und $FG_{Satterth} = 20,9$ (Standardfehler der Differenz = $\sqrt{V} = 717,33$). Exakt dieselben Ergebnisse werden mit der Prozedur MIXED unter Angabe der SATTERTH Option (oder KR) erhalten. Auch für die anderen Vergleiche werden die adäquaten Standardfehler und Freiheitsgrade berechnet.

SAS Anweisungen:

```
ods output diffs=diffs;
proc mixed;
class block n sorte;
model y=block n sorte n*sorte/ddfm=kr;
random n sorte/sub=block;
lsmeans sorte*n/pdiff;
```

```
run;

data diffs;
set diffs;
lsd=StdErr*tinv(0.975,DF);

proc print data=diffs;
run;
```

Ergebnis:

Least Squares Means

Effect	n	sorte	Estimate
n*sorte	0	1	3571.67
n*sorte	0	2	4934.33
n*sorte	0	3	4249.67
n*sorte	0	4	4059.00
n*sorte	0	5	4101.67
n*sorte	0	6	3207.33
n*sorte	60	1	5132.00
n*sorte	60	2	6713.67
n*sorte	60	3	6122.33
n*sorte	60	4	5553.67
n*sorte	60	5	5633.33
n*sorte	60	6	3714.33
n*sorte	120	1	7548.00
n*sorte	120	2	7211.33
n*sorte	120	3	7868.33
n*sorte	120	4	7094.33
n*sorte	120	5	6012.00
n*sorte	120	6	2492.00

Obs	Effect	n	sorte	_n	_sorte	Estimate	StdErr	DF	tValue	Probt	lsd
1	n*sorte	0	1	0	2	-1362.67	717.33	20.9	-1.90	0.0714	1492.22
2	n*sorte	0	1	0	3	-678.00	717.33	20.9	-0.95	0.3554	1492.22
3	n*sorte	0	1	0	4	-487.33	717.33	20.9	-0.68	0.5044	1492.22
4	n*sorte	0	1	0	5	-530.00	717.33	20.9	-0.74	0.4682	1492.22
5	n*sorte	0	1	0	6	364.33	717.33	20.9	0.51	0.6168	1492.22
6	n*sorte	0	1	60	1	-1560.33	557.97	22.4	-2.80	0.0104	1155.88
7	n*sorte	0	1	60	2	-3142.00	742.61	22.3	-4.23	0.0003	1538.92
8	n*sorte	0	1	60	3	-2550.67	742.61	22.3	-3.43	0.0023	1538.92
9	n*sorte	0	1	60	4	-1982.00	742.61	22.3	-2.67	0.0139	1538.92
10	n*sorte	0	1	60	5	-2061.67	742.61	22.3	-2.78	0.0109	1538.92
11	n*sorte	0	1	60	6	-142.67	742.61	22.3	-0.19	0.8494	1538.92
.											
.											
.											
151	n*sorte	120	4	120	5	1082.33	717.33	20.9	1.51	0.1463	1492.22
152	n*sorte	120	4	120	6	4602.33	717.33	20.9	6.42	<.0001	1492.22
153	n*sorte	120	5	120	6	3520.00	717.33	20.9	4.91	<.0001	1492.22

Wir sehen, dass alle Vergleiche, die dieselbe Düngerstufen, aber verschiedene Sorten umfassen, den Standardfehler s.e.d. = 717,33 sowie die Satterthwaite-Freiheitsgrade 20,9 haben. Multiplikation des s.e.d. mit den t-Wert für die entsprechende Satterthwaite-Freiheitsgrade liefert die Grenzdifferenz, die wir hier in einem Datenschnitt berechnet haben. Für Vergleiche verschiedener Sorten bei derselben Düngerstufe finden wir LSD = 1492,22.

Das ganze fassen wir in einer Mittelwert-Tabelle zusammen.

Sorte	Dünger		
	N ₁	N ₂	N ₃
V ₁	3571,67 ^{ab}	5132,00 ^{ac}	7548,00 ^b
V ₂	4934,33 ^b	6713,67 ^b	7211,33 ^{bc}
V ₃	4249,67 ^{ab}	6122,33 ^{bc}	7868,33 ^b
V ₄	4059,00 ^{ab}	5553,67 ^{bc}	7094,33 ^{bc}
V ₅	4101,67 ^{ab}	5633,33 ^{bc}	6012,00 ^c
V ₆	3207,33 ^a	3714,33 ^a	2492,00 ^a

Vergleich der Sorten bei derselben N-Stufe: LSD = 1492,22

Für Vergleiche der N-Stufen bei derselben Sorte erstellen wir folgende Tabelle:

Sorte	Dünger		
	N ₁	N ₂	N ₃
V ₁	3571,67 ^b	5132,00 ^c	7548,00 ^a
V ₂	4934,33 ^b	6713,67 ^a	7211,33 ^a
V ₃	4249,67 ^b	6122,33 ^c	7868,33 ^a
V ₄	4059,00 ^b	5553,67 ^c	7094,33 ^a
V ₅	4101,67 ^b	5633,33 ^a	6012,00 ^a
V ₆	3207,33 ^{ab}	3714,33 ^b	2492,00 ^a

Vergleich der N-Stufen bei derselben Sorte: LSD = 1155,88

Die Buchstabendarstellungen wird mit den folgenden Anweisungen erhalten:

```
ods output diffs=diffs;
ods output lsmeans=lsmeans;

proc mixed;
class block n sorte;
model y=block n sorte n*sorte/ddfm=kr;
random n sorte/sub=block;
lsmeans sorte*n/pdiff;
run;

%mult(trt=sorte, by=n, level=0);
%mult(trt=sorte, by=n, level=60);
%mult(trt=sorte, by=n, level=120);
```

```
%mult(trt=n,      by=sorte, level=1);
%mult(trt=n,      by=sorte, level=2);
%mult(trt=n,      by=sorte, level=3);
%mult(trt=n,      by=sorte, level=4);
%mult(trt=n,      by=sorte, level=5);
%mult(trt=n,      by=sorte, level=6);
```

Beispiel 5.3: Streifenanlage - Schnitthäufigkeitsversuch (V116) (**schnitte.dat**)


Versuchsfrage: Langfristige Auswirkung von 2-, 3-, 4-, und 5 Schnittnutzung auf Pflanzenbestandszusammen-setzung, TM-Ertrag und Futterinhaltsstoffe eines aus einer einheitlichen Saatmischung hervorgegangenen Grünlandfläche

Faktoren:

Nutzungshäufigkeit: (nutz_h)	4 Stufen:	S2	2 Schnitte/Jahr
		S3	3 Schnitte/Jahr
		S4	4 Schnitte/Jahr
		S5	5 Schnitte/Jahr
N- Düngung: (n_stufe)	2 N-Stufen:	N1	30 kg N/ha pro Aufwuchs
		N2	60 kg N pro Aufwuchs
Wiederholungen: (block)	4		
Versuchsanordnung:	Streifenanlage		
Standort:	Hohenheim (Goldener Acker)		
Anlagetermin:	September 1993		
Parzellengröße:	6.5 m * 6 m = 39 m ²		

Die Ertragserfassung erfolgt mit einem HALDRUP-Grünfuttervollernter. Daher wurden die Varianten mit gleicher Nutzungshäufigkeit, die also stets gleichzeitig geschnitten werden, hintereinander angeordnet (in Streifen). Ansonsten wären zwischen allen Parzellen breite Zwischenwege erforderlich, soviel Versuchsfläche stand jedoch nicht zur Verfügung.

Düngung erfolgt mit einem Kastendüngerstreuer. Diese Geräte brauchen immer eine Anlaufstrecke (ca. 1-2m) bis gleichmäßig Dünger ausgebracht wird. Durch die Anordnung in Streifen kann auf mehreren Parzellen hintereinander eine einheitliche Düngermenge ohne Unterbrechung ausgestreut werden.



Randomisation:

- Je Block 2 Zeilen für Faktor N und 4 Zeilen für S
- Je Block N1 und N2 zufällig auf Zeilen verteilen
- Je Block S2 bis S5 zufällig auf Spalten verteilen

Eigenschaften der Streifenanlage:

- Wechselwirkungen werden genauer geprüft als Hauptwirkungen

Die Daten sind nach den einzelnen Schnitten (**aufwuchs**) aufgeschlüsselt. Zunächst müssen die Aufwüchse auf derselben Parzelle summiert werden, um den Gesamtertrag der Vegetationsperiode zu ermitteln.

SAS-Anweisungen:

```

proc sort data=a out=a;
by block n_stufe nutz_h;

proc means data=a noprint;
var dt_ha;
by block n_stufe nutz_h;
output out=sum sum=;

proc mixed data=sum nobound;
class block n_stufe nutz_h;
model dt_ha= block n_stufe nutz_h n_stufe*nutz_h/ddfm=kr;
random block*n_stufe block*nutz_h;
lsmeans n_stufe nutz_h/pdiff;
run;

```

Ergebnis:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
Block	3	3	1.42	0.3905
N_Stufe	1	3	91.40	0.0024
Nutz_h	3	9	13.64	0.0011
N_Stufe*Nutz_h	3	9	2.59	0.1171

Least Squares Means

Effect	N_Stufe	Nutz_h	Estimate	Standard Error	DF	t Value	Pr > t
N_Stufe	1		75.8992	1.3923	3.31	54.51	<.0001
N_Stufe	2		88.7036	1.3923	3.31	63.71	<.0001
Nutz_h		2	96.1107	2.9609	7.16	32.46	<.0001
Nutz_h		3	82.3425	2.9609	7.16	27.81	<.0001
Nutz_h		4	82.8094	2.9609	7.16	27.97	<.0001
Nutz_h		5	67.9430	2.9609	7.16	22.95	<.0001

The Mixed Procedure

Differences of Least Squares Means

Effect	N_Stufe	Nutz_h	_N_Stufe	_Nutz_h	Estimate	Standard Error	DF	t Value	Pr > t
N_Stufe	1		2		-12.8044	1.3393	3	-9.56	0.0024
Nutz_h		2		3	13.7682	4.4051	9	3.13	0.0122
Nutz_h		2		4	13.3013	4.4051	9	3.02	0.0145
Nutz_h		2		5	28.1676	4.4051	9	6.39	0.0001
Nutz_h		3		4	-0.4669	4.4051	9	-0.11	0.9179
Nutz_h		3		5	14.3994	4.4051	9	3.27	0.0097
Nutz_h		4		5	14.8663	4.4051	9	3.37	0.0082

6. Sub-sampling


Beispiel 6.1: In einem Gewächshausversuch mit Sorghum wurden verschiedene Intensitäten der Doppelnutzung untersucht: (1) Kontrolle; (2) Entfernung aller Blätter ausser dem obersten; (3) Entfernung aller Blätter ausser den 6 obersten (Piepho, 1997). Die Blätter wurden zu vier Zeitpunkten innerhalb von drei Wochen entfernt. Die Versuchsanlage war eine randomisierte vollständige Blockanlage mit vier Wiederholungen. Die Sorghumpflanzen wurden einzeln in Gefäße gepflanzt (eine Pflanze je Gefäß). Eine Wiederholung umfaßte 10 Gefäße/Pflanzen je Behandlung, die auf einem Tablett aufgestellt wurden. Drei Tablett bildeten somit einen vollständigen Block. Die Messungen wurden an den Einzelpflanzen durchgeführt. Hier wird das Tausendkorngewicht (g) betrachtet (siehe Tab. 6.1). Bevor die ersten Blätter entfernt wurden, starben einige Pflanzen. Das Fehlen der Pflanzen hat daher nichts mit der Behandlung zu tun, so dass hier die missing-at-random Annahme erfüllt ist. Wegen der fehlenden Werte haben wir es mit unbalancierten Daten zu tun. Die Unbalanciertheit muss bei der Auswertung berücksichtigt werden. Wie wir sehen werden, geschieht die Berücksichtigung der Unbalanciertheit über eine Gewichtung.

Tab. 6.1: Tausendkorngewicht von Sorghum in Gewächshausexperiment zur Doppelnutzung (Futter und Samenproduktion; **sorghum.dat**).

Behandlung	Block	Laufende Pflanzennummer									
		1	2	3	4	5	6	7	8	9	10
1	1	41,89	29,97	27,82	29,68	27,84	33,93	34,77	30,00	27,71	32,66
	2	28,21	34,80	31,25	34,35	37,50	36,74	32,23	38,35	29,50	
	3	41,54	44,19	40,44	35,20	26,76	32,37	31,18	34,23	34,22	25,01
	4	35,26	26,65	35,47	29,84	34,38	26,79	41,39	40,60	28,16	28,11
2	1	41,28	32,86	35,15		21,76	34,60	19,36	46,22	41,64	32,91
	2	27,55	40,89	33,14	29,62		48,43	25,39	35,45	27,73	29,45
	3	32,27	38,62	24,18	29,34	22,77		23,87	28,01	24,70	23,70
	4	42,36	35,61	17,47	23,55	18,21	33,21	32,76	26,47	21,68	
3	1	27,40	32,66	24,15	27,98	35,43		31,94	32,24	29,87	
	2	44,37	30,01		36,49	40,40	29,48	24,69	35,03	27,48	
	3	35,98	32,82	27,16	29,81	33,91	28,28	29,67	33,66		29,50
	4	36,58	27,64	27,53	26,23		31,00	31,36	29,67	30,12	27,33

Ziel: Varianzanalyse mit Mittelwertvergleichen der drei Behandlungen

Modellierung: Die nachstehende Graphik zeigt exemplarisch den Lageplan für einen Block.



Wir haben es hier mit einer Anlage zu tun, bei der Messwiederholungen auftreten. Die Tablettts sind die eigentlichen Versuchseinheiten (Randomisationseinheiten), während die Pflanzen Messwiederholungen sind. Diese Struktur der Daten muss bei der Modellierung zum tragen kommen. Insbesondere haben wir hier mehr als eine zufällige Streuungskomponente, nämlich die Streuung innerhalb der Tablettts (zwischen den Pflanzen) und die Streuung zwischen den Tablettts. Ein lineare Modell für diese Datenstruktur ist wie folgt:

$$y_{ijk} = \mu + \tau_i + \beta_j + u_{ij} + e_{ijk}$$

wobei

y_{ijk} = Messwert der k -ten Pflanze für i -te Behandlung im j -ten Block

μ = Gesamtmittel

τ_i = Effekt der i -ten Behandlung

β_j = Effekt des j -ten Blocks

u_{ij} = Effekt des ij -ten Tablettts

e_{ijk} = Fehler der ijk -ten Pflanze

Wir haben jetzt hier die Besonderheit, dass das Modell zwei zufällige Effekte hat, nämlich den Tablett-Effekt u_{ij} und den Pflanzeneffekt e_{ijk} . Wir machen die üblichen Verteilungsannahmen

$$u_{ij} \sim N(0, \sigma_u^2)$$

$$e_{ijk} \sim N(0, \sigma_e^2)$$

wobei $N(0, \cdot)$ für die Normalverteilung mit Mittelwert Null und entsprechender Varianz steht.

Auswertung: Wir könnten der Einfachheit halber daran denken, die Mittelwerte je Tablett ($\bar{y}_{ij\cdot}$) einer einfachen Varianzanalyse für eine Blockanlage zu unterwerfen.

Tatsächlich führt dieser Ansatz zu vernünftigen Resultaten, sofern das Maß der Unbalanciertheit nicht zu groß ist. Das potentielle Problem dieser Art der Auswertung besteht in der Tatsache, dass die Mittelwerte bei Unbalanciertheit Varianzheterogenität aufweisen. Denn es gilt:

$$\text{var}(\bar{y}_{ij\bullet}) = \sigma_u^2 + \frac{\sigma_e^2}{r_{ij}}$$

wobei r_{ij} die Zahl der Pflanzen im ij -ten Tablett ist. Somit hängt die Varianz eines Mittelwertes vom Stichprobenumfang n_{ij} ab, und die Varianzen der Mittelwerte sind heterogen, falls r_{ij} nicht konstant ist. Eine einfache varianzanalytische Auswertung verletzt somit die Voraussetzungen der Varianzanalyse! Eine adäquate Modellierung berücksichtigt die Varianzheterogenität durch eine Gewichtung. Hierbei erhalten Mittelwerte ein umso größeres Gewicht, je kleiner ihre Varianzen sind (siehe Beispiel 3). Es lässt sich zeigen, dass die optimale Gewichtung durch den Kehrwert der Varianz gegeben ist.

Die sich nach der Methode der gewichteten kleinsten Quadrate (siehe Anhang) ergebenden gewichteten Mittelwerte haben allerdings keine einfache algebraische Form. Die optimale Gewichtung ergibt sich jedoch automatisch, wenn wir die Daten mit der SAS Prozedur MIXED auswerten. Da gewichtete Mittelwerte berechnet werden, verwenden wir die Kenward-Roger (1997) Methode zur Schätzung der Varianz und der Freiheitsgrade.

SAS Anweisungen:

```
data;
input
treat    block    plant    TKG;
datalines;
1        1        1        41.89
1        1        2        29.97
1        1        3        27.82
1        1        4        29.68
1        1        5        27.84
1        1        6        33.93
1        1        7        34.77
1        1        8        30.00
1        1        9        27.71
1        1        10       32.66
2        1        1        41.28
2        1        2        32.86
2        1        3        35.15
2        1        4        .
2        1        5        21.76
2        1        6        34.60
2        1        7        19.36
2        1        8        46.22
2        1        9        41.64
2        1        10       32.91
3        1        1        27.40
3        1        2        32.66
```

3	1	3	24.15
3	1	4	27.98
3	1	5	35.43
3	1	6	.
3	1	7	31.94
3	1	8	32.24
3	1	9	29.87
3	1	10	.
1	2	1	28.21
1	2	2	34.80
1	2	3	31.25
1	2	4	34.35
1	2	5	37.50
1	2	6	36.74
1	2	7	32.23
1	2	8	38.35
1	2	9	29.50
1	2	10	.
2	2	1	27.55
2	2	2	40.89
2	2	3	33.14
2	2	4	29.62
2	2	5	.
2	2	6	48.43
2	2	7	25.39
2	2	8	35.45
2	2	9	27.73
2	2	10	29.45
3	2	1	44.37
3	2	2	30.01
3	2	3	.
3	2	4	36.49
3	2	5	40.40
3	2	6	29.48
3	2	7	24.69
3	2	8	35.03
3	2	9	27.48
3	2	10	.
1	3	1	41.54
1	3	2	44.19
1	3	3	40.44
1	3	4	35.20
1	3	5	26.76
1	3	6	32.37
1	3	7	31.18
1	3	8	34.23
1	3	9	34.22
1	3	10	25.01
2	3	1	32.27

2	3	2	38.62
2	3	3	24.18
2	3	4	29.34
2	3	5	22.77
2	3	6	.
2	3	7	23.87
2	3	8	28.01
2	3	9	24.70
2	3	10	23.70
3	3	1	35.98
3	3	2	32.82
3	3	3	27.16
3	3	4	29.81
3	3	5	33.91
3	3	6	28.28
3	3	7	29.67
3	3	8	33.66
3	3	9	.
3	3	10	29.50
1	4	1	35.26
1	4	2	26.65
1	4	3	35.47
1	4	4	29.84
1	4	5	34.38
1	4	6	26.79
1	4	7	41.39
1	4	8	40.60
1	4	9	28.16
1	4	10	28.11
2	4	1	42.36
2	4	2	35.61
2	4	3	17.47
2	4	4	23.55
2	4	5	18.21
2	4	6	33.21
2	4	7	32.76
2	4	8	26.47
2	4	9	21.68
2	4	10	.
3	4	1	36.58
3	4	2	27.64
3	4	3	27.53
3	4	4	26.23
3	4	5	.
3	4	6	31.00
3	4	7	31.36
3	4	8	29.67
3	4	9	30.12
3	4	10	27.33

```

;
proc mixed;
class treat block;
model tkg=treat block/ddfm=kenwardroger;
lsmeans treat/pdiff;
random block*treat;
run;

```

Output:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
treat	2	6.15	1.43	0.3097
block	3	6.13	1.11	0.4136

Least Squares Means

Effect	treat	Estimate	Standard Error
treat	1	33.1393	1.0965
treat	2	30.6169	1.1288
treat	3	31.1691	1.1546

Differences of Least Squares Means

Effect	treat	_treat	Estimate	Standard Error	DF	t Value	Pr > t
treat	1	2	2.5223	1.5737	5.87	1.60	0.1611
treat	1	3	1.9702	1.5922	6.14	1.24	0.2612
treat	2	3	-0.5521	1.6147	6.5	-0.34	0.7432

Der Wald-F-Wert für Behandlungsunterschiede beträgt 1,43 und ist nicht signifikant. Auch die Mittelwertvergleiche sind nicht signifikant. Man beachte, dass die Standardfehler der Mittelwerte und Ihrer Differenzen nicht konstant sind. Dies ist Folge der Unbalanciertheit. Außerdem sind die Freiheitsgrade "krumm", weil hier die Kenward-Roger-Methode angewendet wurde.

Zum Vergleich nun die Auswertung mit der Prozedur GLM. Hier können wir auch ein gemischtes Modell angeben, und zwar über die RANDOM Anweisung wie bei MIXED. Die F-Tests werden etwas anders berechnet als bei MIXED, nämlich unter Zuhilfenahme der Erwartungswerte der SQ der Varianzanalyse. Auf Details kann hier nicht eingegangen werden. Der wesentliche Nachteil von GLM ist, dass lediglich einfache, d.h. ungewichtete Kleinstquadratmittelwerte nach der allgemeinen Formel

$\hat{\beta} = (X'X)^{-1}X'y$ berechnet werden, und nicht gewichtet nach $\hat{\beta} = (X'V^{-1}X)^{-1}X'V^{-1}y$ (siehe Anhang). Außerdem werden die Standardfehler der Mittelwerte und Kontraste falsch berechnet, nämlich lediglich unter Berücksichtigung der Restvarianz. Dies führt in der Regel zu einer Unterschätzung der tatsächlichen Standardfehler und bedingt damit zu liberale Testentscheidungen.

```
proc glm;
class treat block;
model tkg=treat block treat*block;
random treat*block/test;
lsmeans treat/pdiff;
run;
```

Output:

Source	Type III Expected Mean Square
treat	Var(Error) + 9.0521 Var(treat*block) + Q(treat)
block	Var(Error) + 9.0436 Var(treat*block) + Q(block)
treat*block	Var(Error) + 9.0607 Var(treat*block)

SAS Berechnet die Erwartungswerte der Mittelquadrate der Varianzanalyse. Diese werden zur anschließenden Konstruktion von F-Test benötigt. Ziel ist dabei, dass sich die Erwartungswerte von Zähler und Nenner lediglich um eine quadratische Form der zu testenden Effekte unterscheiden $[Q(TREAT)]$, so dass die Verteilung der F-Statistik unter der Nullhypothese näherungsweise einer F-Verteilung folgt. Die Freiheitsgrade werden dabei mit der Satterthwaite-Methode bestimmt. Das Prinzip der Konstruktion von F-Tests ist hier ein anderes als bei MIXED. Nun weiter mit der Varianzanalyse:

Tests of Hypotheses for Mixed Model Analysis of Variance

Dependent Variable: TKG

Source	DF	Type III SS	Mean Square	F Value	Pr > F
treat	2	130.308498	65.154249	1.43	0.3104
Error	6.0086	273.658769	45.544254		

Error: 0.999*MS(treat*block) + 0.001*MS(Error)

Source	DF	Type III SS	Mean Square	F Value	Pr > F
block	3	158.297992	52.765997	1.16	0.3996
Error	6.0171	273.981689	45.533838		

Error: 0.9981*MS(treat*block) + 0.0019*MS(Error)

Source	DF	Type III SS	Mean Square	F Value	Pr > F
treat*block	6	273.329423	45.554904	1.33	0.2533
Error: MS(Error)	97	3334.149331	34.372674		

Least Squares Means for effect treat
Pr > |t| for H0: LSMean(i)=LSMean(j)

Dependent Variable: TKG

i/j	1	2	3
1		0.0683	0.1577
2	0.0683		0.7024
3	0.1577	0.7024	

Die Unterschiede des F-Tests sowie der adjustierten Mittelwerte ist marginal, aber die Ergebnisse der t-Tests sind bei GLM auch in diesem Beispiel zu liberal. Aus diesem Grunde muß generell von einer Auswertung gemischter Modelle mittels der Prozedur GLM abgeraten werden.

7. Zuchtwertschätzung

In züchterischen Anwendungen werden die Effekte der Genotypen als zufällig betrachtet. Dies erlaubt eine effiziente Schätzung der genetischen Effekte und eine Abschätzung des Selektionserfolges (Bos und Caligari, 1995).

Beispiel 7.1: In einem Zuchtprogramm mit Radieschen wurden 26 Stämme in einer Blockanlage mit 2 Wiederholungen geprüft (S. Schmiegel, Universität-Gesamthochschule Kassel, pers. Mitteilung, 2001). Unter anderem wurde an einer Stichprobe von Pflanzen je Parzelle erfasst, ob die Radieschen holzig waren oder nicht. Hieraus kann der Anteil holziger Pflanzen berechnet werden (**radieschen.dat**).

Anzahl Pflanzen				Anzahl Pflanzen			
Block	Stamm	Holzig z	Gesamt m	Block	Stamm	Holzig z	Gesamt m
1	1	18	41	1	14	12	44
2	1	19	41	2	14	25	50
1	2	18	35	1	15	12	40
2	2	19	37	2	15	18	37
1	3	22	42	1	16	8	44
2	3	28	47	2	16	16	45
1	4	9	32	1	17	12	47
2	4	12	41	2	17	12	45
1	5	13	45	1	18	14	44
2	5	14	44	2	18	21	38
1	6	6	46	1	19	24	50
2	6	8	40	2	19	27	45
1	7	11	38	1	20	7	43
2	7	8	39	2	20	5	39
1	8	8	37	1	21	33	45
2	8	17	41	2	21	19	32
1	9	2	40	1	22	12	44
2	9	5	45	2	22	24	40
1	10	10	37	1	23	17	36
2	10	7	46	2	23	29	42
1	11	21	37	1	24	6	43
2	11	17	33	2	24	17	47
1	12	3	34	1	25	7	33
2	12	8	40	2	25	8	36
1	13	19	38	1	26	5	40
2	13	18	44	2	26	12	45

Ziel: Schätzung der Heritabilität des Merkmales "Anteil befallener Pflanzen" und des Zuchtwertes der Stämme.

Modellierung und Auswertung: Modell für den Anteil befallener Pflanzen ($y = z/m$):

$$y_{ij} = \mu + \beta_j + s_i + e_{ij} \quad (i = 1, \dots, t; j = 1, \dots, r)$$

wobei

y_{ij} = Anteil befallener Pflanzen des i -ten Stammes im j -ten Block

μ = Gesamtmittelwert

β_j = Effekt des j -ten Blocks (fester Effekt)

s_i = Effekt des i -ten Stamms

e_{ij} = Fehler von y_{ij}

$$e_{ij} \sim N(0, \sigma^2)$$

Ziel der Auswertung ist es, die Stammeffekte s_i bzw. die Erwartungswerte ("Zuchtwerte", "genotypische Werte der Stämme") der Stämme, also

$$\theta_i = \mu + \frac{\beta_1 + \beta_2}{2} + s_i$$

möglichst genau zu schätzen. Wenn wir feste Stammeffekte s_i annehmen, ist die beste Schätzung gegeben durch

$$\text{BLUE}(\theta_i) = \bar{y}_i.$$

Dieser Schätzer ist erwartungstreu in dem Sinne, dass

$$E[\text{BLUE}(\theta_i)] = \theta_i$$

wobei $E[.]$ der Erwartungswert ist. Wiederholt über viele Experimente wird also der genetische Wert θ_i genau getroffen; es liegt keine Verzerrung (bias) vor.

Nun können wir im vorliegenden Fall die Stammeffekte auch als zufällig betrachten, da die Stämme sich als Nachkommenschaften einer einzigen Kreuzung ergeben haben. Die genetischen Unterschiede zwischen den Stämmen sind daher durch Aufspaltung nach den Mendelschen Gesetzen bedingt. Wenn angenommen wird, dass das interessierende Merkmal durch viele Gene bedingt ist, kann man von einer Zufallsverteilung, insbesondere einer Normalverteilung, der Stammeffekte ausgehen:

$$s_i \sim N(0, \sigma_s^2)$$

Bei zufälligen Stammeffekten liegt ein gemischtes Modell vor, weil sowohl feste Effekte (β_j) also auch zufällige Effekte außer dem Fehler (s_i) im linearen Modell "gemischt" auftreten.

Wenn die Stammeffekte zufällig sind, so sind die genetischen Effekte und somit auch θ_i keine Parameter mehr, sondern Zufallsvariablen. Zunächst ist daran zu denken, dass auch bei der Annahme zufälliger Effekte der Stamm-Mittelwert $\bar{y}_i$ als Schätzer von θ_i zu verwenden. Es gibt aber einen alternative, in der Regel besseren Schätzer. Dieser alternative Schätzer ergibt sich als Antwort auf die Frage, welches der erwartete Wert für θ_i bei gegebenem $\bar{y}_i$ ist:

$$E(\theta_i | \bar{y}_{i.})$$

Nun folgen θ_i und $\bar{y}_{i.}$ einer bivariaten Normalverteilung, falls s_i normalverteilt ist. Aus Resultaten für die bivariate Normalverteilung folgt, dass

$$E(\theta_i | \bar{y}_{i.}) = \text{BLUP}(\theta_i) = \bar{y}_{..} + h^2(\bar{y}_{i.} - \bar{y}_{..})$$

wobei

$$h^2 = \frac{\sigma_s^2}{\sigma_s^2 + \sigma^2 / r} \quad (0 \leq h^2 \leq 1)$$

BLUP steht für "best linear unbiased prediction". Die Schätzung oder "Vorhersage" (prediction) ist wie BLUE ebenfalls unverzerrt, aber in einem anderen Sinne, nämlich in dem Sinne, dass $\text{BLUP}(\theta_i)$ und θ_i denselben Erwartungswert haben:

$$E[\text{BLUP}(\theta_i)] = E[\theta_i] = \mu$$

Dagegen meint "Unverzerrtheit" bei BLUE, dass

$$E[\text{BLUE}(\theta_i)] = \theta_i$$

ist. h^2 wird unter Züchtern als Heritabilität (im weiteren Sinne) bezeichnet. Es ist der Anteil der Varianz des phänotypischen Mittelwertes $\bar{y}_{i.}$, der genetisch bedingt ist. Für die phänotypische Varianz gilt:

$$\text{var}(\bar{y}_{i.}) = \sigma_s^2 + \sigma^2 / r$$

Der Nenner von h^2 entspricht also gerade der phänotypischen Varianz, während die genetische Varianz σ_s^2 im Zähler steht.

BLUPs haben, angewendet auf unser Beispiel, u.a. folgende Eigenschaften:

- Sie maximieren die Wahrscheinlichkeit, die Genotypen in die richtige Reihenfolge (bezogen auf θ_i) zu bringen
- Sie minimieren die durchschnittliche quadratische Abweichung $(\text{BLUP}(\theta_i) - \theta_i)^2$

BLUPs des genetischen Wertes sind gegenüber dem BLUE zum Gesamtmittelwert hin geschrumpft ("shrinkage"). Diese Schrumpfung deckt sich mit der Erfahrung von Züchtern und Genetikern, dass die Nachkommen selektierter Individuen zum Gesamtmittel hin tendieren (regression to the mean). Insofern ist BLUP, salopp gesagt, die Abschätzung dessen, was von den Nachkommen zu erwarten ist, und das ist näher am Mittel als das, was bei den Eltern phänotypisch zu sehen ist.

Falls $h^2 = 1$ ist, der Fehler also gleich Null, so ist

$$\text{BLUP}(\theta_i) = \bar{y}_{..} + (\bar{y}_{i.} - \bar{y}_{..}) = \bar{y}_{i.} = \text{BLUE}(\theta_i)$$

Falls $h^2 = 0$ ist, es also keine genetische Varianz (und somit keine Unterschiede zwischen den Stämmen) gibt, so ist

$$\text{BLUP}(\theta_i) = \bar{y}_{..} + 0(\bar{y}_{i.} - \bar{y}_{..}) = \bar{y}_{..}$$

Alle Sortenmittel werden also vollständig zum Gesamtmittel "geschrumpft".

Die Heritabilität wird von Züchtern benutzt, um den Selektionserfolg abzuschätzen. Es gilt (Bos und Caligari, 1995):

$$R = h^2 S$$

wobei S die durchschnittliche Abweichung der selektierten Stämme vom Gesamtmittel ist (Selektionsdifferential) und R die (geschätzte) durchschnittliche Abweichung der Nachkommenschaften der selektierten Stämme (Selektionserfolg) ist. Wenn $h^2 = 0$ ist, ist der Selektionserfolg also immer gleich Null!

Um die BLUP Formel in der Praxis nutzen zu können, müssen geschätzte Varianzkomponenten eingesetzt werden. Man spricht dann von empirischen BLUP oder eBLUP. eBLUP verliert gegenüber BLUP mit bekannten Varianzen die optimalen Eigenschaften (minimale Varianz, etc.), ist aber annähernd optimal, falls die Varianzen mit ausreichender Genauigkeit geschätzt werden.

Die Ergebnisse für den Radieschenversuch finden sich in Tab. 7.1. BLUE und eBLUP sind in der Abb. 7.1 gegenübergestellt. Man sieht hier anschaulich die Schrumpfung zum Gesamtmittel.

Tab. 7.1: BLUE und BLUP Schätzungen für den Radieschenversuch.

Stamm	eBLUP(θ)	BLUE(θ)	eBLUP(s_i) = $\hat{h}^2(\bar{y}_{i.} - \bar{y}_{..})$	BLUE(s_i) = $\bar{y}_{i.} - \bar{y}_{..}$
1	0,4353	0,4512	0,08725	0,10313
2	0,4884	0,5139	0,1403	0,16581
3	0,5272	0,5598	0,1791	0,21169
4	0,2964	0,2870	-0,05171	-0,06112
5	0,3104	0,3035	-0,03769	-0,04455
6	0,1934	0,1652	-0,1547	-0,18287
7	0,2628	0,2473	-0,08526	-0,10078
8	0,3205	0,3154	-0,02763	-0,03266
9	0,1218	0,0806	-0,2263	-0,26753
10	0,2323	0,2112	-0,1158	-0,13686
11	0,5116	0,5414	0,1635	0,19327
12	0,1755	0,1441	-0,1726	-0,20397
13	0,4382	0,4545	0,09007	0,10646
14	0,3805	0,3864	0,03238	0,03828
15	0,3863	0,3932	0,03820	0,04516
16	0,2809	0,2687	-0,06717	-0,07940

17	0,2744	0,2610	-0,07368	-0,08709
18	0,4220	0,4354	0,07387	0,08732
19	0,5104	0,5400	0,1624	0,19191
20	0,1767	0,1455	-0,1714	-0,20259
21	0,6150	0,6635	0,2669	0,31546
22	0,4228	0,4364	0,07468	0,08828
23	0,5454	0,5813	0,1973	0,23326
24	0,2656	0,2506	-0,08246	-0,09747
25	0,2373	0,2172	-0,1108	-0,13091
26	0,2193	0,1958	-0,1288	-0,15225




Abb. 7.1: eBLUP versus BLUP für 26 Stämme der Radieschen-Daten. $h^2 = 0,846$.

SAS-Anweisungen:

```
data t;
input block stamm z m;
y=z/m;
datalines;
1 1 18 41
2 1 19 41
1 2 18 35
2 2 19 37
1 3 22 42
2 3 28 47
1 4 9 32
2 4 12 41
1 5 13 45
```

```

2 5 14 44
1 6 6 46
2 6 8 40
1 7 11 38
2 7 8 39
1 8 8 37
2 8 17 41
1 9 2 40
2 9 5 45
1 10 10 37
2 10 7 46
1 11 21 37
2 11 17 33
1 12 3 34
2 12 8 40
1 13 19 38
2 13 18 44
1 14 12 44
2 14 25 50
1 15 12 40
2 15 18 37
1 16 8 44
2 16 16 45
1 17 12 47
2 17 12 45
1 18 14 44
2 18 21 38
1 19 24 50
2 19 27 45
1 20 7 43
2 20 5 39
1 21 33 45
2 21 19 32
1 22 12 44
2 22 24 40
1 23 17 36
2 23 29 42
1 24 6 43
2 24 17 47
1 25 7 33
2 25 8 36
1 26 5 40
2 26 12 45
;
proc mixed data=t;
class block stamm;
model y=block;
random stamm/solution;
estimate 'Stamm1 ' int 2 block 1 1 | stamm 2/divisor=2;

```

```
estimate 'Stamm2 ' int 2 block 1 1 | stamm 0 2/divisor=2;  
<etc>  
run;
```

8. Longitudinale Daten (repeated measurements)

Gemischte Modelle erlauben eine Berücksichtigung von Korrelationen. Bei den bisherigen Beispielen wurden Korrelationen modelliert, die sich entweder durch die Mehrstufigkeit der Stichprobe ergaben, oder durch die Randomisationsstruktur der Versuchsanlage (räumliche Abhängigkeiten). Ein weiterer Typ von Korrelation entsteht durch die zeitliche Abfolge von Messungen an der selben Untersuchungseinheit. Man spricht von Messwiederholungen (repeated measures) und von longitudinalen Daten. Gemischte Modelle eignen sich ausgezeichnet, um zeitliche Abhängigkeiten zu modellieren.

Beispiel 8.1: (Crowder and Hand, 1996, S. 8) Ascorbinsäure im Plasma wurde bei 12 Patienten zu sieben Zeitpunkten gemessen (**plasma ascorbic acid.dat**).

Wochen						
1	2	6	10	14	15	16
0,22	0,00	1,03	0,67	0,75	0,65	0,59
0,18	0,00	0,96	0,96	0,98	1,03	0,70
0,73	0,37	1,18	0,76	1,07	0,80	1,10
0,30	0,25	0,74	1,10	1,48	0,39	0,36
0,54	0,42	1,33	1,32	1,30	0,74	0,56
0,16	0,30	1,27	1,06	1,39	0,63	0,40
0,30	1,09	1,17	0,90	1,17	0,75	0,88
0,70	1,30	1,80	1,80	1,60	1,23	0,41
0,31	0,54	1,24	0,56	0,77	0,28	0,40
1,40	1,40	1,64	1,28	1,12	0,66	0,77
0,60	0,80	1,02	1,28	1,16	1,01	0,67
0,73	0,50	1,08	1,26	1,17	0,91	0,87




Abb. 8.1: Ascorbinsäure im Plasma bei 12 Patienten zu sieben Zeitpunkten.

Ziel: Beantwortung folgender Fragen: Gibt es signifikante Unterschiede zwischen den Zeitpunkten? Gibt es einen Zeittrend? Wie kann dieser modelliert werden?

Modellierung: Da der Faktor Zeit hier von Interesse ist und es dem Anschein nach (Abb. 8.1) Unterschiede zwischen den Zeitpunkten gibt, ist es sinnvoll, einen Zeiteffekt in das Modell auszunehmen. Außerdem ist mit systematischen Unterschieden zwischen den Personen zu rechnen, so dass ein Personeneffekt in das Modell aufgenommen werden sollte. In gewisser Weise spielen die Personen die Rolle von Blöcken und die Zeitpunkte die von Behandlungen bei einer Blockanlage. Daher kann zunächst folgendes Modell aufgestellt werden:

$$y_{ij} = \mu + b_j + \tau_i + e_{ij} \\ (i = 1, \dots, t; j = 1, \dots, r)$$

wobei

y_{ij} = Ascorbinsäurewert zum i -ten Zeitpunkt bei der j -ten Person

μ = Gesamtmittel

b_j = Effekt der j -ten Person

τ_i = Effekt des i -ten Zeitpunktes

e_{ij} = Fehler von y_{ij}

In Analogie zur Blockanlage könnte man annehmen, dass die Fehler normalverteilt sind:

$$e_{ij} \sim N(0, \sigma^2)$$

Bisher hatten wir immer stillschweigend angenommen, dass zufällige Effekte stochastisch unabhängig, also unkorreliert sind. Diese Annahme kann wie folgt ausgedrückt werden:

$$\text{cov}(e_{ij}, e_{i'j}) = 0 \quad \text{für alle } i \neq i'$$

(i, i' : Index für die Zeitpunkte). Dies ist in vielen Fällen eine realistische Annahme. Insbesondere stellt eine zufällsmäßige Auswahl der Untersuchungseinheiten und/oder eine Randomisation sicher, dass diese Annahme zulässig ist. Im vorliegenden Fall haben wir dagegen aber eine Zeitreihe. Für eine Person liegen wiederholte Messungen vor (repeated measures), ohne dass diese in irgend einer Weise randomisiert werden könnten. Es ist damit zu rechnen, dass zeitlich direkt aufeinanderfolgende Beobachtungen bei der selben Person eine gewisse Ähnlichkeit zeigen. Ist beispielsweise bei einer Person zu einem Zeitpunkt der Ascorbinsäurewert gross, so ist er es zu einem darauffolgenden Zeitpunkt wahrscheinlich auch noch. Je weiter zwei Zeitpunkte nun auseinander liegen, umso geringer wird die zu erwartende Korrelation. Bei sehr weit auseinander liegenden Zeitpunkten kann dann Unabhängigkeit angenommen werden.

Es gibt sehr viele Möglichkeiten, die zeitliche Abhängigkeit in Zeitreihen zu modellieren. Hier werden nur zwei angesprochen, die sich im Rahmen von gemischten Modellen umsetzen lassen.

AR(1)-Modell:

$$\text{cov}(e_{ij}, e_{lj}) = \sigma^2 \rho^{|j-i|} \quad (0 \leq \rho \leq 1)$$

Hierbei ist ρ ein Korrelationsparameter. "AR" steht für "autoregressiv". Es wird hier angenommen, dass der Index i die Zeitpunkte chronologisch ordnet. $i = 1$ ist der erste Zeitpunkt, $i = 2$ ist der zweite, etc. Also ist z.B.

$$\text{cov}(e_{1j}, e_{1j}) = \sigma^2 \rho^{|1-1|} = \sigma^2 = \text{var}(e_{1j}) \quad (\rho^0 = 1!)$$

$$\text{cov}(e_{1j}, e_{2j}) = \sigma^2 \rho^{|1-2|} = \sigma^2 \rho$$

$$\text{cov}(e_{1j}, e_{3j}) = \sigma^2 \rho^{|1-3|} = \sigma^2 \rho^2$$

$$\text{cov}(e_{1j}, e_{4j}) = \sigma^2 \rho^{|1-4|} = \sigma^2 \rho^3$$

etc.

Je größer der zeitliche Abstand ist, umso kleiner wird die Korrelation. Dies zeigt auch Abb. 8.2 für einige Werte von ρ .

Korrelation




Abb. 8.2: Abhängigkeit der Korrelation vom zeitlichen Abstand beim AR(1)-Modell.

Dieses Korrelationsmodell ist sinnvoll, wenn die Spannen zwischen den verschiedenen Zeitpunkten gleich gross sind. Im vorliegenden Fall ist dies jedoch nicht der Fall. Es bietet sich daher eine Modifikation der AR(1) Modells an, bei der die Korrelation von der zeitlichen Distanz zwischen zwei Zeitpunkten abhängt:

Modifiziertes AR-Modell:

$$\text{cov}(e_{ij}, e_{lj}) = \sigma^2 \rho^{d(ij)} \quad (0 \leq \rho \leq 1)$$

wobei

$d(i, i') =$ Zeitspanne zwischen den Zeitpunkten i und i' .

Es ist zur Veranschaulichung des Modells für manchen Leser hilfreich, die Varianz-Kovarianz-Struktur in Matrix-Form zu formulieren. Hierzu werden die Fehler (sowie die Beobachtungen) einer Person j in einen Vektor geschrieben:

$$\mathbf{e}_j = \begin{pmatrix} e_{1j} \\ e_{2j} \\ e_{3j} \\ e_{4j} \\ e_{5j} \\ e_{6j} \\ e_{7j} \end{pmatrix}; \mathbf{y}_j = \begin{pmatrix} y_{1j} \\ y_{2j} \\ y_{3j} \\ y_{4j} \\ y_{5j} \\ y_{6j} \\ y_{7j} \end{pmatrix}$$

Die Varianz-Kovarianz-Struktur bei unabhängigen Fehlern lautet (Unabhängiges Modell):

$$\text{var} \begin{pmatrix} e_{1j} \\ e_{2j} \\ e_{3j} \\ e_{4j} \\ e_{5j} \\ e_{6j} \\ e_{7j} \end{pmatrix} = \begin{pmatrix} \sigma^2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma^2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma^2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma^2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \sigma^2 \end{pmatrix}$$

Die Varianzen stehen auf der Diagonalen, die Kovarianzen der Zeitpunkte jenseits der Diagonalen. Wegen der Unabhängigkeitsannahme sind hier alle Kovarianzen gleich Null.

AR(1) Modell:

$$\text{var} \begin{pmatrix} e_{1j} \\ e_{2j} \\ e_{3j} \\ e_{4j} \\ e_{5j} \\ e_{6j} \\ e_{7j} \end{pmatrix} = \begin{pmatrix} \sigma^2 & \sigma^2 \rho & \sigma^2 \rho^2 & \sigma^2 \rho^3 & \sigma^2 \rho^4 & \sigma^2 \rho^5 & \sigma^2 \rho^6 \\ \sigma^2 \rho & \sigma^2 & \sigma^2 \rho & \sigma^2 \rho^2 & \sigma^2 \rho^3 & \sigma^2 \rho^4 & \sigma^2 \rho^5 \\ \sigma^2 \rho^2 & \sigma^2 \rho & \sigma^2 & \sigma^2 \rho & \sigma^2 \rho^2 & \sigma^2 \rho^3 & \sigma^2 \rho^4 \\ \sigma^2 \rho^3 & \sigma^2 \rho^2 & \sigma^2 \rho & \sigma^2 & \sigma^2 \rho & \sigma^2 \rho^2 & \sigma^2 \rho^3 \\ \sigma^2 \rho^4 & \sigma^2 \rho^3 & \sigma^2 \rho^2 & \sigma^2 \rho & \sigma^2 & \sigma^2 \rho & \sigma^2 \rho^2 \\ \sigma^2 \rho^5 & \sigma^2 \rho^4 & \sigma^2 \rho^3 & \sigma^2 \rho^2 & \sigma^2 \rho & \sigma^2 & \sigma^2 \rho \\ \sigma^2 \rho^6 & \sigma^2 \rho^5 & \sigma^2 \rho^4 & \sigma^2 \rho^3 & \sigma^2 \rho^2 & \sigma^2 \rho & \sigma^2 \end{pmatrix}$$

Die Kovarianz zwischen dem ersten und dem vierten Zeitpunkt ist beispielsweise $\sigma^2 \rho^3$.

Modifiziertes AR-Modell:

$$\text{var} \begin{pmatrix} e_{1j} \\ e_{2j} \\ e_{3j} \\ e_{4j} \\ e_{5j} \\ e_{6j} \\ e_{7j} \end{pmatrix} = \begin{pmatrix} \sigma^2 & \sigma^2 \rho^1 & \sigma^2 \rho^5 & \sigma^2 \rho^9 & \sigma^2 \rho^{13} & \sigma^2 \rho^{14} & \sigma^2 \rho^{15} \\ \sigma^2 \rho^1 & \sigma^2 & \sigma^2 \rho^4 & \sigma^2 \rho^8 & \sigma^2 \rho^{12} & \sigma^2 \rho^{13} & \sigma^2 \rho^{14} \\ \sigma^2 \rho^5 & \sigma^2 \rho^4 & \sigma^2 & \sigma^2 \rho^4 & \sigma^2 \rho^8 & \sigma^2 \rho^9 & \sigma^2 \rho^{10} \\ \sigma^2 \rho^9 & \sigma^2 \rho^8 & \sigma^2 \rho^4 & \sigma^2 & \sigma^2 \rho^4 & \sigma^2 \rho^5 & \sigma^2 \rho^6 \\ \sigma^2 \rho^{13} & \sigma^2 \rho^{12} & \sigma^2 \rho^8 & \sigma^2 \rho^4 & \sigma^2 & \sigma^2 \rho^1 & \sigma^2 \rho^2 \\ \sigma^2 \rho^{14} & \sigma^2 \rho^{13} & \sigma^2 \rho^9 & \sigma^2 \rho^5 & \sigma^2 \rho^1 & \sigma^2 & \sigma^2 \rho \\ \sigma^2 \rho^{15} & \sigma^2 \rho^{14} & \sigma^2 \rho^{10} & \sigma^2 \rho^6 & \sigma^2 \rho^2 & \sigma^2 \rho^1 & \sigma^2 \end{pmatrix}$$

Die Bedeutung des Parameters ρ unterscheidet sich hier von der beim AR(1)-Modell, obwohl dasselbe Symbol verwendet wird.

Auswertung: Die AR-Modelle haben zwei Varianzparameter, die mit der REML-Methode geschätzt werden können (ρ , σ^2). Eine Auswertung "von Hand" ist nicht ohne weiteres möglich. Die Kenward-Roger-Methode kann zur Berechnung von Teststatistiken und Freiheitsgraden verwendet werden.

Der erste Schritt der Auswertung liegt zunächst in der Wahl der Varianz-Kovarianz-Struktur. Hierzu gibt es verschiedene Ansätze. Wir benutzen hier das sog. Akaike'sche Informations-Kriterium (AIC). Dieses berechnet sich aus der maximierten REML Log-Likelihood (LL_R):

$$AIC = -2LL_R + 2p$$

wobei p die Zahl der Varianzparameter ist. Wichtig beim Vergleich verschiedener Modelle ist, dass die festen Effekte jeweils dieselben sind. Je kleiner der AIC, umso besser das Modell. Wir finden mittels SAS (siehe SAS-Anweisungen) folgendes:

Modell	AIC
Unabhängig	47,6
AR(1)	40,1
Mod. AR	45,8

Die autoregressiven Modelle passen also eindeutig besser als das unabhängige Modell, weil sie einen kleineren AIC-Wert haben. Dies bestätigt die Annahme, dass die Unabhängigkeit der Fehler e_{ij} verletzt ist. Das AR(1) Modell paßt zwar besser nach AIC, es ist aber weniger plausibel, weil die Zeitabstände nicht gleich sind, wie beim AR(1) Modell vorausgesetzt werden muss. Daher wird im folgenden das modifizierte AR-Modell zum Test der fixen Effekte (Personen, Zeit) verwendet (siehe SAS-Anweisungen - Output).

SAS-Anweisungen:

```
data;
input
person    time    t    y;
datalines;
    1      1      1    0.22
    1      2      2    0.00
    1      3      6    1.03
    1      4     10    0.67
    1      5     14    0.75
    1      6     15    0.65
    1      7     16    0.59
    2      1      1    0.18
<mehr Daten>
    11     4     10    1.28
    11     5     14    1.16
    11     6     15    1.01
    11     7     16    0.67
    12     1      1    0.73
    12     2      2    0.50
    12     3      6    1.08
    12     4     10    1.26
    12     5     14    1.17
    12     6     15    0.91
    12     7     16    0.87
;
/*unabhaengiges Modell*/
proc mixed data=t;
class person time;
model y=person time/ddfm=kenwardroger;
run;

/*AR(1) Modell*/
proc mixed data=t;
class person time;
model y=person time/ddfm=kenwardroger;
repeated time/sub=person type=ar(1);
run;

/*modifiziertes AR Modell*/
proc mixed data=t;
class person time;
model y=person time/ddfm=kenwardroger;
repeated time/sub=person type=sp(pow) (t);
run;
```

Output:

Unabhängiges Modell:

**Covariance Parameter
Estimates**

Cov Parm	Estimate
Residual	0.06741

Fit Statistics

-2 Res Log Likelihood	45.6
AIC (smaller is better)	47.6
AICC (smaller is better)	47.7
BIC (smaller is better)	49.8

AR(1)-Modell:

Covariance Parameter Estimates

Cov Parm	Subject	Estimate
AR(1)	person	0.4781
Residual		0.08658

The Mixed Procedure

Fit Statistics

-2 Res Log Likelihood	36.1
AIC (smaller is better)	40.1
AICC (smaller is better)	40.3
BIC (smaller is better)	41.1

Modifiziertes AR-Modell:

Covariance Parameter Estimates

Cov Parm	Subject	Estimate
SP(POW)	person	0.3627
Residual		0.07147

Fit Statistics

-2 Res Log Likelihood	41.8
AIC (smaller is better)	45.8
AICC (smaller is better)	45.9
BIC (smaller is better)	46.7

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
person	11	22	3.90	0.0032
time	6	49.1	13.25	<.0001

Least Squares Means

Effect	time	Estimate	Standard Error
time	1	0.5142	0.07717
time	2	0.5808	0.07717
time	3	1.2050	0.07717
time	4	1.0792	0.07717
time	5	1.1633	0.07717
time	6	0.7567	0.07717
time	7	0.6425	0.07717

Differences of Least Squares Means

Effect	time	_time	Estimate	Standard Error	DF	t Value	Pr > t
time	1	2	-0.06667	0.08834	31.7	-0.75	0.4560
time	1	3	-0.6908	0.1097	53.5	-6.30	<.0001
time	1	4	-0.5650	0.1092	49.8	-5.17	<.0001
time	1	5	-0.6492	0.1091	49.7	-5.95	<.0001
time	1	6	-0.2425	0.1091	49.7	-2.22	0.0309
time	1	7	-0.1283	0.1091	49.7	-1.18	0.2453
time	2	3	-0.6242	0.1098	57.9	-5.69	<.0001
time	2	4	-0.4983	0.1092	50	-4.56	<.0001
time	2	5	-0.5825	0.1091	49.7	-5.34	<.0001
time	2	6	-0.1758	0.1091	49.7	-1.61	0.1135
time	2	7	-0.06167	0.1091	49.7	-0.57	0.5746
time	3	4	0.1258	0.1098	57.9	1.15	0.2563
time	3	5	0.04167	0.1092	50	0.38	0.7045
time	3	6	0.4483	0.1092	49.8	4.11	0.0001
time	3	7	0.5625	0.1092	49.7	5.15	<.0001
time	4	5	-0.08417	0.1098	57.9	-0.77	0.4463

time	4	6	0.3225	0.1097	53.5	2.94	0.0048
time	4	7	0.4367	0.1095	51.3	3.99	0.0002
time	5	6	0.4067	0.08834	31.7	4.60	<.0001
time	5	7	0.5208	0.1043	61	4.99	<.0001
time	6	7	0.1142	0.08834	31.7	1.29	0.2056

Die Wald-F-Tests (siehe Anhang) für Personen und Zeit sind signifikant. Es gibt signifikante paarweise Unterschiede zwischen den Zeitpunkten nach dem approximativen t-Test.

Beispiel 8.2: An zwei Patientengruppen wurde die Wirkung von Lezithin gegen die Alzheimerkrankheit untersucht (Hand und Crowder, 1996, S. 44 und S. 176). Die erste Gruppe erhielt einen Pazebo und die zweite Lezithin. Die Zielvariable ist die Zahl der richtig behaltenen Wörter. Die Untersuchung wurde zu fünf Terminen wiederholt, die zu Zeitpunkten 0, 1, 2, 4 und 6 durchgeführt wurden (**alzheimer.dat**).

Gruppe	0	1	2	4	6	Gruppe	0	1	2	4	6
1	20	19	20	20	18	2	9	11	14	11	14
1	14	15	16	9	6	2	6	7	9	12	16
1	7	5	8	8	5	2	13	18	14	20	14
1	6	10	9	10	10	2	9	10	9	8	7
1	9	7	9	4	6	2	6	7	4	5	4
1	9	10	9	11	11	2	11	11	5	10	12
1	7	3	7	6	3	2	7	10	11	8	5
1	18	20	20	23	21	2	8	18	19	15	14
1	6	10	10	13	14	2	3	3	3	1	3
1	10	15	15	15	14	2	4	10	9	17	10
1	5	9	7	3	12	2	11	10	5	15	16
1	11	11	8	10	9	2	1	3	2	2	5
1	10	2	9	3	2	2	6	7	7	6	7
1	17	12	14	15	13	2	0	3	2	0	0
1	16	15	13	7	9	2	18	19	15	17	20
1	7	10	4	10	5	2	15	15	15	14	12
1	5	0	5	0	0	2	14	11	8	10	8
1	16	7	7	6	10	2	6	6	5	5	8
1	5	6	9	5	6	2	10	10	6	10	9
1	2	1	1	2	2	2	4	6	6	4	2
1	7	11	7	5	11	2	4	13	9	8	7
1	9	16	17	10	6	2	14	7	8	10	6
1	2	5	6	7	6						
1	7	3	5	5	5						
1	19	13	19	17	17						
1	7	5	8	8	6						

Zahl behaltener Wörter




Abb. 8.3: Zahl der behaltenen Wörter für Personen aus zwei Gruppen (gestrichelt = Lezithin; durchgezogen = Plazebo) zu fünf verschiedenen Zeitpunkten.

Ziel: Beantwortung folgende Fragen: Gibt es Unterschiede zwischen Plazebo und Lecithin? Gibt es Unterschiede im Zeitprofil?

Modellierung: Man kann davon ausgehen, dass jede Gruppe ein durchschnittliches Zeitprofil aufweist. Dieses lässt sich durch ein zweifaktorielles Modell mit Faktoren Zeit und Gruppe modellieren. Wir können postulieren, dass der Erwartungswert einer zufällig bestimmten Person einer Gruppe gegeben ist durch

$$E(y_{ijk}) = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij}$$

wobei

y_{ijk} = Zahl behaltener Wörter bei der k -ten Person zum j -ten Zeitpunkt für das i -te Medikament

μ = Gesamtmittel

α_i = Effekt des i -ten Medikaments

β_j = Effekt des j -ten Zeitpunktes

$(\alpha\beta)_{ij}$ = Wechselwirkung

Hieraus ließe sich das einfache varianzanalytische Modell

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ijk}$$

ableiten, wobei

$$e_{ijk} \sim N(0, \sigma^2)$$

ein Fehlerterm ist. Dieses Modell ist unrealistisch, weil mehrere Beobachtungen pro Person vorliegen (repeated measurements). Die sich hieraus ergebende Korrelation kann einfach modelliert werden, indem ein zufälliger Personeneffekt in das Modell aufgenommen wird:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + p_k + e_{ijk}$$

wobei

$$p_k \sim N(0, \sigma_p^2)$$

Durch diesen Effekt wird die Kovarianz zwischen Beobachtungen bei derselben Person gleich

$$\text{cov}(y_{ijk}, y_{ij'k}) = \sigma_p^2 \quad (j \neq j')$$

Diese Kovarianz gilt unabhängig vom zeitlichen Abstand. Das Modell impliziert eine Struktur, die als **compound symmetry** (CS) bezeichnet wird.

Zusätzlich kann für jede Person ein autoregressives Modell für die Fehler e_{ijk} angenommen werden, wobei wie in Beispiel 14 hier zwei Alternativen betrachtet werden:

$$\begin{aligned} \text{cov}(e_{ijk}, e_{ij'k}) &= \sigma^2 \rho^{|j-j'|} \quad (0 \leq \rho \leq 1) \quad [\text{AR}(1)\text{-Modell}] \\ \text{cov}(e_{ijk}, e_{ij'k}) &= \sigma^2 \rho^{d(ij', j)} \quad (0 \leq \rho \leq 1) \quad [\text{modifiziertes AR-Modell}] \end{aligned}$$

wobei

$d(j, j')$ = Zeitspanne zwischen den Zeitpunkten j und j' (vgl. Beispiel 14).

Alternativ hierzu können wir schließlich eine völlig unstrukturierte Kovarianz zwischen den verschiedenen Zeitpunkten annehmen:

$$\text{cov}(e_{ijk}, e_{ij'k}) = \sigma_{jj'}$$

wobei $\sigma_{jj'}$ frei wählbare Parameter sind (mit der einzigen Einschränkung, dass die resultierende Varianz-Kovarianz-Matrix positiv-definit sein muss). In diesem Fall muss allerdings der Personeneffekt aus dem Modell genommen werden, da die Varianz-Kovarianz-Struktur sonst überparametrisiert ist.

Auswertung: Zunächst ist wieder die Varianz-Kovarianz-Struktur zu selektieren. Hierzu werden die Modelle mit der REML-Methode angepaßt.

Modell	AIC
Unabhängig	1440,4
Personeneffekt (CS)	1254,6
Personeneffekt+AR(1)	1250,2
Personeneffekt+Mod. AR	1253,6
Unstrukturiert	1256,7

Das AR(1)-Modell passt am besten, so dass wir es zur Beurteilung der festen Effekte verwenden (obschon die Zeitabstände nicht identisch sind). Die Wald-Tests (siehe SAS-Anweisungen; Output) zeigen keine signifikanten Hauptwirkungen, was sich mit dem Eindruck aus Abb. 8.3 deckt. Dafür gibt es aber signifikante Wechselwirkungen. Die Wechselwirkungen sind allerdings nicht sehr stark, wie die Darstellung der Gruppen $\times$ Zeit Mittelwerte in Abb. 8.4 zeigt, und zu keinem Zeitpunkt ist die Differenz zwischen Lezithin und Placebo signifikant (Output SAS Anweisungen).




Abb. 8.4: Gruppen $\times$ Zeit Mittelwerte.

SAS-Anweisungen:

```
data;
input
group    person    time    t    y;
datalines;
  1        1        1        0    20
  1        1        2        1    19
  1        1        3        2    20
<mehr Daten>
  2        48        3        2     8
  2        48        4        4    10
  2        48        5        6     6
;
/*Unabhaengiges Modell*/
proc mixed data=t;
class group time person;
model y=group time group*time/ddfm=kenwardroger;
run;

/*Personeneffekt*/
proc mixed data=t;
class group time person;
model y=group time group*time/ddfm=kenwardroger;
```

```

random person;
run;

/*Personeneffekt + AR(1)*/
proc mixed data=t;
class group time person;
model y=group time group*time/ddfm=kenwardroger;
random person;
repeated time/sub=person type=ar(1);
run;

/*Personeneffekt + mod. AR*/
proc mixed data=t;
class group time person;
model y=group time group*time/ddfm=kenwardroger;
random person;
repeated time/sub=person type=sp(pow) (t);
run;

/*Unstrukturiert*/
proc mixed data=t;
class group time person;
model y=group time group*time/ddfm=kenwardroger;
repeated time/sub=person type=un;
run;

```

Varianzanalyse und Mittelwertvergleiche (Personeneffekt + mod. AR):

```

proc mixed data=t;
class group time person;
model y=group time group*time/ddfm=kenwardroger;
random person;
repeated time/sub=person type=ar(1);
lsmeans group*time/pdiff;
make 'Diffs' out=diffs;
run;

data diffs;
set diffs;
if time=_time;

proc print;
run;

```

Output:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
group	1	46.2	0.07	0.7867
time	4	130	0.49	0.7436
group*time	4	130	2.79	0.0290

Differences of Least Squares Means

Effect	group	time	_group	_time	Estimate	StdErr	DF	tValue	Probt
group*time	1	1	2	1	1.5175	1.4877	72.2	1.02	0.3111
group*time	1	2	2	2	-0.5420	1.4877	72.2	-0.36	0.7167
group*time	1	3	2	3	1.6678	1.4877	72.2	1.12	0.2660
group*time	1	4	2	4	-0.5315	1.4877	72.2	-0.36	0.7219
group*time	1	5	2	5	-0.3147	1.4877	72.2	-0.21	0.8331

Beispiel 8.3: (J. Mentschel, FG Tierhaltung und Leistungsphysiologie, Institut Tierhaltung und Tierzüchtung, Universität Hohenheim - description of investigation partly verbatim from Claus et al., 2002): Der Grimmdarm bei Schweinen hat eine feine Mikrostruktur, wie in Abb. 16.1 angedeutet. Das Darmepithel wird von sog. Krypten bedeckt. Es handelt sich um kleine Einstülpungen, die bestimmte Zellen (Enterozyten) produzieren. Die Kryptenzellen haben verschiedene Funktionen, z.B. Absorption von Nährstoffen und Produktion von Schleim für den besseren Transport von Kot durch den Darm. Die Zellen entstehen durch Mitose an der Basis der Krypten (Stammzellregion), wonach sie sich sukzessive differenzieren und zum luminalen Ende der Krypte wandern, wo sie nach programmiertem Zelltod (= Apoptosis) in das Lumen des Darms abgeschieden werden.

Es gibt Hinweise, dass Butyrat den Zelltod (Apoptosis) von Grimmdarmzellen in vivo reduziert, so dass weniger Tryptophan zur Skatolbildung durch Mikroben zur Verfügung steht. Der Zelltod findet vornehmlich am luminalen Ausgang der Krypten statt. Ein Ziel der vorliegenden Untersuchung war es, die Wirkung von zwei verschiedenen Stärkeformen auf die Überlebensrate von Kryptenzellen zu untersuchen. Kartoffelstärke mit einem hohen Anteil sog. resistenter Stärke (wird langsamer abgebaut) sowie normale Stärke wurden an je eine Gruppe von Tieren verfüttert, um die Hypothese zu prüfen, dass eine erhöhte Butyratbildung im Grimmdarm den Zelltod von Kryptenzellen reduzieren kann, wodurch wiederum die Skatolbildung und -absorption verringert wird. Zwei Gruppen à sechs Ferkel wurden jeweils mit normaler Stärke und resistenter Stärke als Hauptkohlehydratlieferant gefüttert. Nach dem Ende der Fütterungsperiode wurden die Tiere getötet und Probem vom Darmgewebe genommen. Bei jedem Tier wurden je drei Gewebeproben (Segmente) vom vorderen (proximalen) und von hinteren (distalen) Darmabschnitt genommen. Zellen im Stadium der Apoptosis wurden mittels sog. TUNEL Assay erfasst, welches auf einer Färbung von Apoptosis-spezifischen DNA-Fragmenten beruht. Für jede der drei Segmente einer Region wurden 30 Krypten identifiziert. Für jedes Tier und jede Region wurde die mittlere Zahl apoptotischer Zellen pro Krypte berechnet.




Abb. 8.5: Graphische Darstellung der Epithelmorphologie im Grimmdarm (Colon), mit zwei Krypten (Potten, 1992).

Es wurden die folgenden Daten erfasst (**colon.dat**):

group = Gruppe (1 = Kontrolle, 3 = resistente Stärke = RS)
region = Region des Grimmdarm (1 = proximal, 2 = distal)
animal = Tiernummer
avcount = Mittlere Zahl apoptotischer Zellen je Krypte, ermittelt aus mindestens 30 Krypten je Segment, gemittelt über drei Segmente je Tier und Region

group	region	animal	avcount
1	1	1	0.93667
1	1	2	1.18000
1	1	3	0.85667
1	1	4	0.77667
1	1	5	0.49667
1	1	6	0.89000
1	2	1	1.34000
1	2	2	1.17000
1	2	3	1.26667
1	2	4	0.78000
1	2	5	0.71000
1	2	6	0.96333
3	1	12	0.37000
3	1	13	0.54000
3	1	14	0.36333
3	1	15	0.54333
3	1	16	0.40000
3	1	17	0.44333

3	2	12	0.36333
3	2	13	0.30667
3	2	14	0.46000
3	2	15	1.13000
3	2	16	0.61000
3	2	17	1.07667

Das Hauptziel der Untersuchung ist es, die beiden Gruppen (Kontrolle vs. RS) zu vergleichen und so den Effekt der resistenten Stärke auf den Zelltod zu erfassen. Ausserdem soll geprüft werden, ob Unterschiede zwischen den beiden Regionen (proximal versus distal) vorliegen. Es liegt also eine zweifaktorielle Behandlungsstruktur vor, wobei jeder Faktor zwei Stufen hat. Es handelt sich um ein Problem mit Messwiederholungen, bei dem Messungen von verschiedenen Regionen am selben Tier korreliert sein können. Im folgenden wird der Datensatz Schritt für Schritt mit verschiedenen Verfahren analysiert.

(1) Gruppen - der unverbundene t-Test: Die beiden Gruppen können getrennt für die beiden Regionen verglichen werden, wobei der einfache t-Test für unverbundene Stichproben verwendet wird. Dieser ist identisch zur einfachen Varianzanalyse zum Vergleich von zwei Gruppen (Behandlungen; Beispiel 1). Die t-Statistik berechnet sich wie folgt:

$$t_{vers} = \frac{|\bar{y}_1 - \bar{y}_2|}{s \sqrt{\frac{2}{r}}}$$

wobei

r = Zahl der Wiederholungen (Tiere!) je Gruppe

$\bar{y}_1, \bar{y}_2$ = Mittelwerte in den Gruppen 1 und 2

$$s^2 = \frac{s_1^2 + s_2^2}{2}$$

s_1^2, s_2^2 = Stichprobenvarianzen der Gruppen 1 und 2

Der berechnete t-Wert wird gegen eine t-Verteilung mit $2(r-1)$ Freiheitsgraden verglichen (kritischer t-Wert: t_{tab}). Obige Formel ist gültig für balancierte Daten.

Region	Gruppe	Mittel ($\bar{y}_j$)	Varianz (s_j^2)	t_{vers}	t_{tab}
Proximal	Kontrolle	0.856	0.0496	4.26	2.228
	RS	0.443	0.0066		
Distal	Kontrolle	1.038	0.0681	2.09	2.228
	RS	0.658	0.1300		

Der Vergleich ist signifikant für die proximale Region, wobei der Zelltod für die resistente Stärke (RS) reduziert ist. In der distalen Region gibt es keinen

signifikanten Unterschied. Der Grund hierfür ist v.a. die höhere Varianz in der distalen Region.

(2) Regionen - der gepaarte t-Test: Auf ähnliche Weise können die Regionen getrennt für beide Gruppen verglichen werden. Je Gruppe liegen sechs Messungen für die proximale Region und sechs Messungen für die distale Region vor. Man könnte geneigt sein, denselben t-Test zu verwenden, wie für den Vergleich der Gruppen, aber dies ist aus einem wichtigen Grund nicht zulässig: Die zwölf Messungen sind nicht statistisch unabhängig, da Messungen am selbem Tier korreliert sind. Es gibt sechs Messwertpaare, eines für jedes Tier. Die Paarung der Stichproben bedingt, dass der oben verwendete t-Test nicht anwendbar ist. Stattdessen muss der "gepaarte" oder "verbundene" t-Test verwendet werden. Dieses ist wie folgt zu berechnen:

Verbundener t-Test:

- Berechne die Differenzen beider Werte (distal und proximal), d_i , für jedes Tier
- Berechne das Mittel der Differenzen, $\bar{d}$, und die Standardabweichung, s_d , der
-
- Vergleiche t_{vers} mit einer t-Verteilung mit $r-1$ Freiheitsgraden (FG)

Dies wird für die Kontrollgruppe erläutert:

Proximal	distal	Differenz (d_i)
0,93667	1,34000	-0,40333
1,18000	1,17000	0,01000
0,85667	1,26667	-0,41000
0,77667	0,78000	-0,00333
0,49667	0,71000	-0,21333
0,89000	0,96333	-0,07333

$$\bar{d} = -0,1822$$

$$s_d = 0,1911$$

$$t_{vers} = 2,336$$

$$t_{vers} = 2,571 \quad (r = 6, FG = 5)$$

Der Mittelwert der Differenzen ist identisch mit der Differenz der beiden Mittelwerte (proximal und distal):

$$\bar{d} = 0,856 - 1,038 = -0,182$$

Die beiden Regionen sind nicht signifikant verschieden. Für die zweite Gruppe ergibt sich $t_{vers} = 1,55$, was ebenfalls nicht signifikant ist.

(3) Unverbundener t-test für Gruppen und einfache Varianzanalyse: Anstelle eines t-Tests kann eine Varianzanalyse nach dem folgenden Modell durchgeführt werden (Beispiel 1):

$$y_{ik} = \mu + \alpha_i + e_{ik}$$

wobei

y_{ik} = Mittlere Zahl toter Zellen für k -tes Tier in der i -ten Gruppe

μ = Allgemeiner Effekt

α_i = Effekt der i -ten Gruppe

e_{ik} = Fehler

F-test und t-Test sind äquivalent, weil es nur zwei Gruppen gibt.

SAS Anweisungen: Die Varianzanalyse kann mit GLM oder MIXED durchgeführt werden.

```
data;
input
group    region    animal    avcount;
datalines;
  1        1         1        0.93667
  1        1         2        1.18000
  1        1         3        0.85667
  1        1         4        0.77667
  1        1         5        0.49667
  1        1         6        0.89000
  1        2         1        1.34000
  1        2         2        1.17000
  1        2         3        1.26667
  1        2         4        0.78000
  1        2         5        0.71000
  1        2         6        0.96333
  3        1        12        0.37000
  3        1        13        0.54000
  3        1        14        0.36333
  3        1        15        0.54333
  3        1        16        0.40000
  3        1        17        0.44333
  3        2        12        0.36333
  3        2        13        0.30667
  3        2        14        0.46000
  3        2        15        1.13000
  3        2        16        0.61000
  3        2        17        1.07667
;
proc sort;
by region group;
```

```

proc mixed;
class group;
model avcount=group;
lsmeans group/pdiff;
by region;
run;

```

Output:

----- region=1 -----

The Mixed Procedure

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
group	1	10	18.19	0.0017

Least Squares Means

Effect	group	Estimate	Standard Error	DF	t Value	Pr > t
group	1	0.8561	0.06844	10	12.51	<.0001
group	3	0.4433	0.06844	10	6.48	<.0001

Differences of Least Squares Means

Effect	group	_group	Estimate	Standard Error	DF	t Value	Pr > t
group	1	3	0.4128	0.09679	10	4.26	0.0017

----- region=2 -----

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
group	1	10	4.39	0.0627

Least Squares Means

Effect	group	Estimate	Standard Error	DF	t Value	Pr > t
group	1	1.0383	0.1285	10	8.08	<.0001
group	3	0.6578	0.1285	10	5.12	0.0005

Differences of Least Squares Means

Effect	group	_group	Estimate	Standard Error	DF	t Value	Pr > t
group	1	3	0.3806	0.1817	10	2.09	0.0627

Man beachte, dass die p-Werte von F- und t-Test identisch sind. Ausserdem ist $F_{vers} = (t_{vers})^2$, wie erwartet, woei F_{vers} der aus den Daten berechnete F-Wert ist. Die t-Werte sind dieselben die unter (1) berechnet wurden.

(4) Gepaarter t-Test für Regionen und ANOVA für Blockanlage: Anstelle eines t-Tests kann eine Varianzanalyse durchgeführt werden nach dem Modell

$$y_{jk} = \mu + f_k + \beta_j + e_{jk}$$

wobei

y_{jk} = Mittlere Zellzahl für j -te Region beim k -ten Tier

μ = Allgemeiner Effekt

β_j = Effekt der j -ten Region

f_k = Effekt des k -ten Tieres

e_{jk} = Fehler

Dieses entspricht dem Modell für eine Blockanlage, wenn wir Tiere mit Blöcken gleichsetzen. In der Tat entspricht jedes Tier einem vollständigen Block mit den Behandlungen "proximal" und "distal". Der Unterschied zu einer echten Blockanlage besteht jedoch darin, dass die Regionen innerhalb eines Tieres nicht randomisiert werden können. Trotzdem kann dieses Modell im vorliegenden Fall verwendet werden.

Wenn Tiere als eine Zufallsstichprobe aus einer Grundgesamtheit ausgefasst werden, dann kann der Tiereffekt als zufällig mit Mittelwert Null und Varianz σ_f^2 betrachtet werden. Der zufällige Tiereffekt modelliert hier eine positive Korrelation der Messungen am selben Tier. Es ist sinnvoll, eine solche Korrelation anzunehmen. Die Korrelation ist gegeben durch

$$\rho = \frac{\sigma_f^2}{\sigma_f^2 + \sigma^2} \quad (\text{Intra-Class-Korrelation}),$$

wobei σ^2 die Fehlervarianz (von e_{jk}) ist. Je grösser die Varianz der Tiereffekte, desto grösser ist die Korrelation.

Obwohl die Tiereffekte nach dem Design zufällig sind, ändert sich die Analyse nicht, wenn Tiereffekte formal als fix betrachtet werden. Die Analyse mit festen Tiereffekten ist vorzuziehen, da sie einfacher ist. F- und t-Test sind auch hier äquivalent, da nur zwei Regionen verglichen werden.

SAS Anweisungen: Die Varianzanalyse kann mit GLM oder MIXED durchgeführt werden.

```
proc sort;  
by group region;
```

```

proc mixed;
class region animal;
model avcount=animal region;
lsmeans region/pdiff;
by group; run;

```

Output:

----- group=1 -----

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
animal	5	5	5.45	0.0431
region	1	5	5.46	0.0667

Least Squares Means

Effect	region	Estimate	Standard Error	DF	t Value	Pr > t
region	1	0.8561	0.05516	5	15.52	<.0001
region	2	1.0383	0.05516	5	18.82	<.0001

Differences of Least Squares Means

Effect	region	_region	Estimate	Standard Error	DF	t Value	Pr > t
region	1	2	-0.1822	0.07801	5	-2.34	0.0667

----- group=3 -----

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
animal	5	5	1.37	0.3704
region	1	5	2.39	0.1828

Least Squares Means

Effect	region	Estimate	Standard Error	DF	t Value	Pr > t
region	1	0.4433	0.09809	5	4.52	0.0063
region	2	0.6578	0.09809	5	6.71	0.0011

Differences of Least Squares Means

Effect	region	_region	Estimate	Standard Error	DF	t Value	Pr > t
region	1	2	-0.2144	0.1387	5	-1.55	0.1828

Auch hier sind die p-Werte von F-test und t-Test identisch, und es ist $F_{vers} = (t_{vers})^2$. Die t-Werte sind identisch mit den in (2) berechneten Werten.

(5) Ein t-Test auf Interaktion: Wie weiter unten besprochen wird, kann eine zweifaktorielle Varianzanalyse zum Test der Wechselwirkungen (Interaktionen) zwischen Gruppen und Regionen durchgeführt werden. Hier wird derselbe Test mit einem t-Test realisiert, was möglich ist, da jeder Faktor nur zwei Stufen aufweist.

Eine Interaktion tritt dann auf, wenn die Differenz zwischen distaler und proximaler Region nicht identisch für beide Gruppen ist. Wir können daher für jede Gruppe die Differenz zwischen den Regionen berechnen und hieraus dann die **Differenz der Differenzen** ermitteln.

Region	Gruppe	Mittel ($\bar{y}_j$)	Varianz (s_j^2)	t_{vers}	t_{tab}
Proximal	Kontrolle	0,856	0,0496	4,26	2,228
	RS	0,443	0,0066		
Distal	Kontrolle	1,038	0,0681	2,09	2,228
	RS	0,658	0,1300		

Die Differenz der Gruppen ist 0,413 für die proximale Region und 0,380 für die distale Region. Die beiden Differenzen sind sehr ähnlich. Ihre Differenz beträgt 0,033, so dass nur geringe Anzeichen für eine Wechselwirkung bestehen. Formal kann die Wechselwirkung geprüft werden, in dem die Differenz der Differenzen auf einen signifikanten Unterschied von Null geprüft wird.

Man kann das ganze auch andersherum betrachten. Die Differenz der Regionen ist 0,182 für Gruppe 1 und 0,215 für Gruppe 3. Auch hier ist die Differenz der Differenzen natürlich 0,033.

Wie kann man nun die Interaktionen testen? Zunächst betrachten wir die Differenzen der beiden Regionen beim selben Tier.

Gruppe (i)	proximal	distal	Differenz (d_{ik})
Control	0,93667	1,34000	-0,40333
	1,18000	1,17000	0,01000
	0,85667	1,26667	-0,41000
	0,77667	0,78000	-0,00333
	0,49667	0,71000	-0,21333
	0,89000	0,96333	-0,07333
			$\bar{d}_1$
			$s_{d1}^2 = 0,0365$

RS	0,37000	0,36333	0,00667
	0,54000	0,30667	0,23333
	0,36333	0,46000	-0,09667
	0,54333	1,13000	-0,58667
	0,40000	0,61000	-0,21000
	0,44333	1,07667	-0,63334
	$\bar{y}_1 = 0,4433$	$\bar{y}_2 = 0,6578$	$\bar{d}_2 = -0,2144$
			$s_{d2}^2 = 0,1155$

Die Differenz der Zellmittelwerte für die proximale und die distale Region in einer Gruppe entspricht dem Mittel der Differenzen d_{ik} . Das Modell für eine Differenz d_{ik} vom k -ten Tier in der i -ten Gruppe kann geschrieben werden als

$$d_{ik} = \delta_i + e_{ik},$$

wobei

d_{ik} = Differenz zwischen proximaler und distaler Zellzahl

δ_i = Erwartete Differenz zwischen proximaler und distaler Zellzahl bei der i -ten Gruppe

e_{ik} = Fehler von d_{ik}

Wenn keine Wechselwirkung besteht, so sind die erwarteten Differenzen in beiden Gruppen gleich, es gilt also

$$H_0: \delta_1 = \delta_2$$

Diese Hypothese kann mittels der unverbundenen t-Tests der Differenzen geprüft werden. Wir finden

$$t_{\text{vers}} = \frac{|\bar{d}_1 - \bar{d}_2|}{s \sqrt{\frac{2}{n}}} = \frac{|-0,1822 + 0,2144|}{\sqrt{\frac{0,0365 + 0,1155}{2}} \sqrt{\frac{2}{6}}} = 0,20$$

mit $2(r-1) = 10$ FG (Die gepoolte Varianz wurde verwendet, also $s^2 = (s_{d1}^2 + s_{d2}^2)/2$).

Dies ist nicht signifikant, da $t_{\text{tab}} = 2,228$ ($p = 0,8436$). Also liegen keine signifikanten Interaktionen vor.

(6) Vergleich der Randmittelwerte für Gruppen mit dem unverbundenen t-Test (Annahme: keine Wechselwirkungen):

Da keine Wechselwirkungen vorliegen, ist es angebracht, die Randmittelwerte sowohl für Gruppen als auch für Regionen zu vergleichen. Zunächst zu den Gruppenmittelwerten. Für jedes Tier kann der Mittelwert für aus dem Wert für die proximale Region und dem Wert für die distale Region berechnet werden (Mittelung über die beiden Regionen). Somit erhält man sechs Mittelwerte je Gruppe. Das Gruppenmittel dieser Mittelwerte je Tier ist der **Randmittelwert** für die betreffende Gruppe. The Randmittelwerte der beiden Gruppen können mit dem unverbundenen t-Test verglichen werden.

Gruppe (i)	proximal	distal	Mittel (m_{ik})
Kontrolle	0,93667	1,34000	1,13834
	1,18000	1,17000	1,17500
	0,85667	1,26667	1,06167
	0,77667	0,78000	0,77834
	0,49667	0,71000	0,60334
	0,89000	0,96333	0,92667
			$\bar{m}_1 = 0,9472$
			$s_{m1}^2 = 0,04974$
RS	0,37000	0,36333	0,36667
	0,54000	0,30667	0,42334
	0,36333	0,46000	0,41167
	0,54333	1,13000	0,83667
	0,40000	0,61000	0,50500
	0,44333	1,07667	0,76000
			$\bar{m}_2 = 0,5506$
			$s_{m2}^2 = 0,03942$

Hiermit finden wir:

$$t_{\text{vers}} = \frac{|\bar{m}_1 - \bar{m}_2|}{s \sqrt{\frac{2}{n}}} = \frac{|0,9472 - 0,5506|}{\sqrt{\frac{0,04974 + 0,03942}{2}} \sqrt{\frac{2}{6}}} = 3,25$$

Dies ist zu vergleichen gegen t_{tab} mit $2(r-1) = 10$ Freiheitsgraden: $t_{\text{tab}} = 2,228$ (p-Wert = 0,0087) (Die gepoolte Varianzschätzung wurde hier verwendet: $s^2 = (s_{m1}^2 + s_{m2}^2)/2$).

Es liegt somit eine signifikante Differenz der Randmittelwerte der beiden Gruppen vor. Die Zelltodrate ist reduziert für resistente Stärke (RS). Man beachte, dass der Fehlerterm des t-Tests von der **Varianz zwischen den Tieren** abhängt. Dies steht im Gegensatz zum Fehlerterm für den Vergleich der Randmittel für die Regionen (siehe unten).

(7) Vergleich der Randmittelwerte der Regionen mit dem verbundenen t-Test (Annahme: Keine Wechselwirkungen): Man kann die beiden Regionen auf jedem Tier vergleichen. Falls keine Wechselwirkungen vorliegen, hat die beobachtete Differenz d_{ik} für das k -te Tier in der i -ten Gruppe denselben Erwartungswert für beide Gruppen. Daher kann man die Differenzen d_{ik} über alle 12 Tiere mitteln. Dieser Mittelwert ist identisch mit der Differenz der Randmittelwerte für die beiden Regionen. Die Differenz kann mit dem verbundenen t-Test geprüft werden.

Gruppe (i)	proximal	distal	Differenz (d_{ik})
Kontrolle	0,93667	1,34000	-0,40333
	1,18000	1,17000	0,01000
	0,85667	1,26667	-0,41000
	0,77667	0,78000	-0,00333
	0,49667	0,71000	-0,21333
	0,89000	0,96333	-0,07333
RS	0,37000	0,36333	0,00667
	0,54000	0,30667	0,23333
	0,36333	0,46000	-0,09667
	0,54333	1,13000	-0,58667
	0,40000	0,61000	-0,21000
	0,44333	1,07667	-0,63334
	$\bar{y}_1 = 0,6497$	$\bar{y}_2 = 0,8481$	$\bar{d} = -0,1984$
			$s_d^2 = 0,06936$

Die hier geschätzte Differenz entspricht der Differenz der Randmittelwerte für die distale und proximale Region:

$$\bar{y}_1 - \bar{y}_2 = 0,6497 - 0,8481 = -0,1984 = \bar{d}$$

Die t-Statistik für den gepaarten t-Test der Differenzen d_{ik} ist

$$t_{\text{vers}} = \frac{|-0,1984|}{\sqrt{0,06936}} \sqrt{2r-1} = 2,609$$

Dies ist signifikant, da $t_{\text{tab}} = 2.201$ bei $2r-1 = 11$ Freiheitsgraden (p-Wert = 0,0243). Es sei nochmals darauf hingewiesen, dass dieser Test die Abwesenheit von Wechselwirkungen voraussetzt. Der Fehlerterm für den t-Test umfasst lediglich die **Varianz innerhalb der Tiere**. In dem (hypothetischen) Extremfall, dass es keine Varianz innerhalb der Tiere gibt, ist die Differenz dieselbe bei jedem Tier, und zwar auch dann, wenn die Varianz zwischen den Tieren gross ist! Hier kommt es nur darauf an, wie variabel die Differenzen der Zellzahlen sind, nicht wie variabel die Zellzahlen selber sind. Dies steht im Gegensatz zum Vergleich der Gruppenmittelwerte, bei dem die Varianz zwischen den Tieren einen Einfluss auf die Genauigkeit des Vergleiches hat.

(8) Ein lineares Modell für die zweifaktorielle Auswertung: Bisher wurden fast alle Analysen für das Grimmdarmbeispiel mit t-Tests durchgeführt, da dies sehr anschaulich ist. Diese Analyse ist hier möglich, weil beide Faktoren (Gruppe, Region) nur zwei Stufen haben. Wenn mindestens einer der Faktoren mehr als zwei Stufen hat, ist die Auswertung am besten in einer zweifaktoriellen Varianzanalyse durchzuführen. Das bekannte Standardmodell für eine zweifaktorielle Varianzanalyse lautet für dieses Beispiel:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ijk}$$

wobei

y_{ijk} = Mittlere Zellzahl in der j -ten Region beim k -ten Tier innerhalb der i -ten Gruppe

μ = Allgemeiner Effekt

α_i = Haupteffekt der i -ten Gruppe

β_j = Haupteffekt der j -ten Region

$(\alpha\beta)_{ij}$ = Interaktion Gruppe $\times$ Region

e_{ijk} = Fehler

Dieses Modell nimmt an, dass alle Beobachtungen unabhängig sind. Diese Annahme ist in unserem Fall jedoch nicht zutreffend, da Messwiederholungen je Tier vorliegen (distal, proximal). Die Korrelation kann durch einen Tiereffekt wie folgt modelliert werden (vergleiche Abschnitt 4: "Gepaarter t-Test für Regionen und ANOVA für Blockanlage"):

$$y_{ijk} = \mu + \alpha_i + f_{ik} + \beta_j + (\alpha\beta)_{ij} + e_{ijk}$$

wobei

f_{ik} = Effekt des k -ten Tieres in der i -ten Gruppe.

Dieses Modell hat zwei zufällige Effekte, f_{ik} und e_{ijk} . Für diese kann eine Normalverteilung angenommen werden:

$$f_{ik} \sim N(0, \sigma_f^2)$$

$$e_{ijk} \sim N(0, \sigma^2)$$

Bevor wir zur Varianzanalyse auf Basis dieses Modells kommen, ist es hilfreich die in den vorangegangenen Abschnitten verwendeten Mittelwerte und Differenzen zu betrachten. Die "Zutaten" waren Summen (Mittelwerte) und Differenzen der Messwerte für proximale und distale Region bei jedem Tier. Die Differenz der beiden Regionen für das ik -te Tier ist

$$\begin{aligned} d_{ik} &= y_{i1k} - y_{i2k} = \mu + \alpha_i + f_{ik} + \beta_1 + (\alpha\beta)_{i1} + e_{i1k} \\ &\quad - [\mu + \alpha_i + f_{ik} + \beta_2 + (\alpha\beta)_{i2} + e_{i2k}] \\ &= \beta_1 + (\alpha\beta)_{i1} + e_{i1k} - [\beta_2 + (\alpha\beta)_{i2} + e_{i2k}] \end{aligned}$$

Ein wichtiges Merkmal dieser Differenz ist, dass der Tiereffekt f_{ik} herausfällt. Daher hängt die Varianz von d_{ik} nur von den Fehlereffekten e_{ijk} ab, welche die Varianz innerhalb der Tiere widerspiegeln. Die Varianz von d_{ik} ist frei von der Varianz zwischen den Tieren, die durch die Tiereffekte f_{ik} modelliert wird. Man beachte, dass die t-Tests für Interaktionen und für die Randmittelwerte der Regionen aus den Differenzen d_{ik} berechnet werden. Daher hängt der Fehlerterm zur Prüfung der Interaktionen und der Randmittel der Regionen nur vom Fehler (e_{ijk}) ab.

Der Mittelwert über beide Regionen für das ik -te Tier ist

$$m_{ik} = \frac{y_{i1j} + y_{i2j}}{2} = [\mu + \alpha_i + f_{ik} + \beta_1 + (\alpha\beta)_{i1} + e_{i1k} + \mu + \alpha_i + f_{ik} + \beta_2 + (\alpha\beta)_{i2} + e_{i2k}]/2$$

Dieser Ausdruck kann nicht weiter vereinfacht werden, da keine Effekte herausfallen. Insbesondere fällt der Tiereffekt nicht heraus. Daher hängt der Fehlerterm zum Vergleich der Randmittel der Gruppen, die aus den Tiermittelwerten m_{ik} berechnet werden, sowohl vom Tiereffekt (f_{ik}) als auch vom Fehler (e_{ijk}) ab, also sowohl von der Varianz zwischen als auch von der Varianz innerhalb der Tiere.

(9) Zweifaktorielle Varianzanalyse: Die Varianzanalyse basiert auf der folgenden Sequenz von Modellen

Model	Fehler SQ	Reduktion der Fehler SQ (RSQ) im Vergleich zum vorhergehenden Modell
$y_{ijk} = \mu + e_{ijk}$	$SQ(\mu)$	
$y_{ijk} = \mu + \alpha_i + e_{ijk}$	$SQ(\alpha_i, \mu)$	$RSQ(\alpha_i \mu)$
$y_{ijk} = \mu + \alpha_i + f_{ik} + e_{ijk}$	$SQ(f_{ik}, \alpha_i, \mu)$	$RSQ(f_{ik} \alpha_i, \mu)$
$y_{ijk} = \mu + \alpha_i + f_{ik} + \beta_j + e_{ijk}$	$SQ(\beta_j, f_{ik}, \alpha_i, \mu)$	$RSQ(\beta_j f_{ik}, \alpha_i, \mu)$
$y_{ijk} = \mu + \alpha_i + f_{ik} + \beta_j + (\alpha\beta)_{ij} + e_{ijk}$	$SQ[(\alpha\beta)_{ij}, \beta_j, f_{ik}, \alpha_i, \mu]$	$RSQ[(\alpha\beta)_{ij} \beta_j, f_{ik}, \alpha_i, \mu]$

Die Reduktionen (RSQ) der Fehler-Summe-der Quadrate (SS) berechnet sich wie gewöhnlich, also z.B.

$$RSQ(\beta_j|f_{ik}, \alpha_i, \mu) = SQ(f_{ik}, \alpha_i, \mu) - SQ(\beta_j, f_{ik}, \alpha_i, \mu)$$

Die Reduktion (RSS) des Fehler SS durch Hinzunahme eines Terms entspricht der Quadratsumme für diesen Term in der Varianzanalyse-Tabelle.

Ursache	Freiheitsgrade	QS
Gruppen (Haupteffekt α_i)	$(a-1)$	$RSQ(\alpha_i \mu)$
Tiere innerhalb Gruppen (f_{ik})	$(p-a)$	$RSQ(f_{ik} \alpha_i, \mu)$
Regionen (Haupteffekt β_j)	$(b-1)$	$RSQ(\beta_j f_{ik}, \alpha_i, \mu)$
Gruppe $\times$ Region Interaktion $[(\alpha\beta)_{ij}]$	$(a-1)(b-1)$	$RSQ[(\alpha\beta)_{ij} \beta_j, f_{ik}, \alpha_i, \mu]$
Fehler (e_{ijk})	$(n-p-ab+a)$	$SQ[(\alpha\beta)_{ij}, \beta_j, f_{ik}, \alpha_i, \mu]$

a = Zahl der Gruppen

b = Zahl der Regionen

p = Gesamtanzahl der Tiere

n = Gesamtzahl an Beobachtungen

Division einer Quadratsumme (SQ) durch ihre Freiheitsgrade liefert das Mittel-Quadrat (MQ). Die oben angegebenen Freiheitsgrade treffen zu für den Fall, dass alle Faktorkombinationen (Gruppe $\times$ Region) beobachtet wurden. Da es sich um ein

gemischtes Modell handelt, werden nicht alle Mittelquadrate (MQ) gegen den Restfehler (e_{ijk}) geprüft. Um die korrekten F-Tests zu erhalten, müssen die Erwartungswerte der MQ berechnet werden. Diese haben bei balancierten Daten eine einfache Form (gleiche Zahl von Tieren je Gruppe, keine fehlenden Werte). Bei unbalancierten Daten ist die Situation etwas komplizierter (wie weiter unten besprochen). Für balancierte Daten sind die Erwartungswerte in Tab. 16.1 angegeben. Die Erwartungswerte zeigen, die Haupteffekte für Gruppen gegen das MQ für "Tiere innerhalb Gruppen" geprüft werden müssen, weil diese beiden MQ unter der Nullhypothese denselben Erwartungswert haben. Dagegen sind Interaktionen und Haupteffekte der Regionen gegen den Restfehler zu prüfen. Diese Struktur ist im wesentlichen dieselbe wie bei einer Spaltanlage, in welcher die Grossteilstücke nach einer vollständig randomisierten Anlage angeordnet sind (in Feldeversuchen ist der Grossteilstückfaktor meist in vollständigen Blöcken randomisiert). Die Analogie zu Feldversuchen ist wie folgt:

Grossteilstücke (main plots)	= Tiere
Kleinteilstücke (subplots, split plots)	= Regionen innerhalb eines Tieres

Der einzige Unterschied besteht darin, dass Regionen ("Kleinteilstücke") nicht innerhalb der Tiere (Grossteilstücke) randomisiert werden können. Dieser Unterschied wird vor allem dann relevant, wenn der Kleinteilstückfaktor mehr als zwei Stufen hat. Dann können spezielle Modelle, z.B. autoregressive und geostatistische Modelle, verwendet werden, um die Korrelationsstruktur zu modellieren. Bei nur zwei Stufen des Kleinteilstückfaktors kann immer das Modell der Spaltanlage verwendet werden. Auch bei mehr als zwei Stufen ist das Modell der Spaltanlage oft gut anwendbar.

Tab. 8.1: Erwartungswerte der Mittelquadrate (MS) in Varianzanalyse für Spaltanlage bei balancierten Daten.

Ursache	Freiheitsgrade	Erwartungswert $MQ = E(MQ)$	Durch MQ getestete H_0	Erwartungswert $MQ = E(MQ)$ unter H_0
Gruppen	$(a-1)$	$\sigma^2 + b\sigma_f^2 + \frac{br}{a-1} \sum_{i=1}^a (\alpha_i - \bar{\alpha}_{\cdot})^2 \quad (*)$	$\alpha_1 = \alpha_2 = \dots$	$\sigma^2 + b\sigma_f^2$
Tiere	$a(r-1)$	$\sigma^2 + b\sigma_f^2$	Keine	$\sigma^2 + b\sigma_f^2$
Regionen	$(b-1)$	$\sigma^2 + \frac{ar}{(b-1)} \sum_{j=1}^b (\beta_j - \bar{\beta}_{\cdot})^2 \quad (*)$	$\beta_1 = \beta_2 = \dots$	σ^2
Interaktionen	$(a-1)(b-1)$	$\sigma^2 + \frac{r}{(a-1)(b-1)} \sum_{i=1}^a \sum_{j=1}^b [(\alpha\beta)_{ij} - (\alpha\beta)_{i\cdot} - (\alpha\beta)_{\cdot j} + (\alpha\beta)_{\cdot\cdot}]^2$	$(\alpha\beta)_{11} = (\alpha\beta)_{12} = \dots$	σ^2
Fehler	$a(b-1)(r-1)$	σ^2	Keine	σ^2

(*) Annahme: Keine Interaktionen!

r = Zahl der Tiere je Gruppe

```
proc glm;
class region animal group;
model avcount=group animal*group region region*group;
random animal*group/test;
run;

proc mixed nobound;
class region animal group;
model avcount=region group region*group/ddfm=satterth;
random animal*group;
run;
```

GLM und MIXED liefern dieselbe Varianzanalyse, mit der Ausnahme, dass MIXED keinen F-test für Tiere liefert, da der betreffende Effekt zufällig ist.

Output (GLM):

Dependent Variable: avcount

	Source	DF	Type III SS	Mean Square	F Value	Pr > F
*	group	1	0.944075	0.944075	10.59	0.0087
	Error	10	0.891603	0.089160		

Error: MS(animal*group)

* This test assumes one or more other fixed effects are zero.

	Source	DF	Type III SS	Mean Square	F Value	Pr > F
	animal*group	10	0.891603	0.089160	2.35	0.0973
*	region	1	0.236017	0.236017	6.21	0.0319
	region*group	1	0.001558	0.001558	0.04	0.8436

Error: MS(Error)

10 0.379929 0.037993

* This test assumes one or more other fixed effects are zero.

Der F-Test für Interaktionen ist nicht signifikant. Der p-Wert der F-Statistik ist derselbe wie der des t-Tests für Interaktionen im Abschnitt (5), und $F_{vers} = 0,04 = (t_{vers})^2 = (0,20)^2$. Wegen der nicht-signifikanten Interaktionen können wir zum Test der Haupteffekte übergehen. Der p-Wert für die Gruppenhaupteffekte ist derselbe wie beim entsprechenden t-Test in Abschnitt (6), und man findet, dass $F_{vers} = 10,59 = (t_{vers})^2 = (3,25)^2$. Der F-Test der Randmittelwerte der Regionen unterscheidet sich etwas vom t-Test in Abschnitt (7), obwohl beide signifikant sind ($p = 0,243$ für t-Test in (7) und $p = 0,0319$ für F-Test). Der t-Test in (7) hatte 11 Fehler-Freiheitsgrade, während der F-Test nur 10 Freiheitsgrade aufweist. Wenn jedoch der Wechselwirkungsterm aus dem Modell genommen wird, so ist der F-Test der Haupteffekte der Regionen äquivalent zum t-Test in (7). Das Weglassen des Interaktionsterms ist gerechtfertigt, da dieser nicht signifikant war. Man beachte ausserdem, dass für die t-Tests der Randmittelwerte in (6) und (7) die Abwesenheit von Interaktionen vorausgesetzt wurde. Die Varianzanalyse für das um die Interaktionen reduzierte Modell wird wie folgt erhalten:

Dependent Variable: avcount

Source	DF	Type III SS	Mean Square	F Value	Pr > F
group	1	0.944075	0.944075	10.59	0.0087
Error	10	0.891603	0.089160		
Error: MS(animals*group)					

Source	DF	Type III SS	Mean Square	F Value	Pr > F
animals*group	10	0.891603	0.089160	2.57	0.0685
region	1	0.236017	0.236017	6.81	0.0243
Error: MS(Error)	11	0.381487	0.034681		

Der F-Test der Regionen hat jetzt 11 Fehler-Freiheitsgrade, und der p-Wert ist derselbe wie beim t-Test in (7). Desweiteren ist $F_{vers} = 6,81 = (t_{vers})^2 = (2,609)^2$. Der F-Test für Gruppen ist unverändert im Vergleich zum Modell mit Interaktionen.

Output (MIXED):

Covariance Parameter Estimates

Cov Parm	Estimate	
animals*group	0.02558	→ σ_f^2
Residual	0.03799	→ σ^2

Der Output liefert Schätzungen der Varianzkomponenten mit der Restricted Maximum Likelihood (REML) Methode. Die Varianz zwischen den Tieren (σ_f^2) ist etwas kleiner also die Varianz innerhalb der Tiere (σ^2).

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
region	1	10	6.21	0.0319
group	1	10	10.59	0.0087
region*group	1	10	0.04	0.8436

Die F-Tests sind dieselben wie sie mit GLM erhalten wurden. Ein Test für ANIMAL*GROUP (f_{ik}) wird nicht erhalten, da dieser Effekt zufällig ist und eine entsprechende Varianzkomponente geschätzt wird. Die Varianzanalyse für das reduzierte Modell (ohne Interaktionen) ist wie folgt:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
region	1	11	6.81	0.0243
group	1	10	10.59	0.0087

Auch hier sind die Resultate identisch zu denen der Prozedur GLM.

(10) Mittelwertvergleiche (balancierte Daten): Mittelwertvergleiche werden wie bei einer Spaltanlage durchgeführt. Details finden sich in Tab. 16.2.

Tab. 16.2: Standardfehler einer Differenz (s.e.d.) und dazugehörige Fehler-Freiheitsgrade (FG) für balancierte Spaltanlage mit Grossteilstückfaktor A (Gruppen) und Kleinteilstückfaktor B (Regionen).

Vergleich	Standardfehler einer Differenz (s.e.d.)	Fehler-Freiheits- grade (FG)
Randmittel Gruppen (A)	$s_a \sqrt{\frac{2}{rb}}$	$a(r-1)$
Randmittel Regionen (B)	$s_b \sqrt{\frac{2}{ra}}$	$a(b-1)(r-1)$
Zellmittel (AB Mittel) bei derselben Gruppe (A-Stufe)	$s_b \sqrt{\frac{2}{r}}$	$a(b-1)(r-1)$
Zellmittel (AB Mittel) bei derselben Region (B-Stufe)	$\sqrt{\frac{2[(b-1)s_b^2 + s_a^2]}{rb}}$	$FG_{\text{satterth}} (*)$

a (b) = Zahl der Stufen von A (B); r = Zahl der Tiere je Gruppe;
 s_a^2 = Grossteilstückfehler MQ (Tiere innerhalb Gruppe); s_b^2 = Kleinteilstückfehler MQ (Fehler); (*) siehe Text.

Die Standardfehler einer Differenz (s.e.d.) hängen von der Art des Vergleiches ab. Für jede Art von Vergleich wird die Grenzdifferenz (LSD) berechnet nach

$$LSD = t_{\text{tab}} \times \text{s.e.d.}$$

Der s.e.d.-Wert zum Vergleich der Zellmittelwerte für dieselbe Region (B) werden aus einer Linearkombination von zwei MS aus der Varianzanalyse berechnet: s_a^2 und s_b^2 . Daher sind die Fehler-FG für diesen Vergleich ein gewichtetes Mittel der FG der betreffenden MS. Nach der sog. **Satterthwaite Methode** berechnen sich die FG einer Linearkombination von Mittelquadraten der Form

$$c_1MQ_1 + c_2MQ_2 + \dots$$

nach

$$FG_{satterth} = \frac{(c_1MQ_1 + c_2MQ_2 + \dots)^2}{\frac{(c_1MQ_1)^2}{FG_1} + \frac{(c_2MQ_2)^2}{FG_2} + \dots}$$

wobei c_i die Koeffizienten von MQ_i und FG_i die zugehörigen Fehler-FG von MQ_i . Für den Vergleich der Zellmittel bei derselben Region (B-Stufe) finden wir:

$$FG_{satterth} = \frac{\left(\frac{2s_a^2}{rb} + \frac{2(b-1)s_b^2}{rb} \right)^2}{\frac{\left(\frac{2s_a^2}{rb} \right)^2}{a(r-1)} + \frac{\left(\frac{2(b-1)s_b^2}{rb} \right)^2}{a(b-1)(r-1)}}$$

SAS Anweisungen

Warnung: PROC GLM berechnet nicht die richtigen s.e.d.-Werte! Daher sollte zur Auswertung durchweg PROC MIXED verwendet werden. Für balancierte Daten muss die NOBOUND Option verwendet werden, um immer dieselben Ergebnisse wie mit GLM zu erhalten (Die NOBOUND lässt negative Varianzkomponentenschätzungen zu).

Im vorliegenden Fall waren die Interaktionen nicht signifikant, so dass sie für die Mittelwertvergleiche (Randmittel) aus dem Modell genommen werden:

```
proc mixed nobound;
class region animal group;
model avcount=region group/noint solution ddfm=satterth;
random animal*group;
lsmeans group/pdiff;
lsmeans region/pdiff;
run;
```

Output:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
region	1	11	6.81	0.0243
group	1	10	10.59	0.0087

Least Squares Means								
Effect	region	group	Estimate	Standard Error	DF	t Value	Pr > t	
group		1	0.9472	0.08620	10	10.99	<.0001	
group		3	0.5506	0.08620	10	6.39	<.0001	
region	1		0.6497	0.07183	17	9.04	<.0001	
region	2		0.8481	0.07183	17	11.81	<.0001	

Differences of Least Squares Means									
Effect	region	group	_region	_group	Estimate	Standard Error	DF	t Value	Pr > t
group		1		3	0.3967	0.1219	10	3.25	0.0087
region	1		2		-0.1983	0.07603	11	-2.61	0.0243

Gruppen und Regionen sind signifikant verschieden, wie wir bereits mit dem F-Test gefunden hatten. Zur Illustration schauen wir uns auch die Anweisungen zum Vergleich der Zellmittel an (praktisch nicht relevant hier, da die Interaktionen nicht signifikant waren):

```
proc mixed nobound;
class region animal group;
model avcount=region group region*group/ddfm=satterth;
random animal*group;
lsmeans group*region/pdiff;
run;
```

Output:

Least Squares Means									
Effect	region	group	Estimate	Standard Error	DF	t Value	Pr > t		
region*group	1	1	0.8561	0.1029	17.2	8.32	<.0001		
region*group	1	3	0.4433	0.1029	17.2	4.31	0.0005		
region*group	2	1	1.0383	0.1029	17.2	10.09	<.0001		
region*group	2	3	0.6578	0.1029	17.2	6.39	<.0001		

Differences of Least Squares Means									
Effect	region	group	_region	_group	Estimate	Standard Error	DF	t Value	Pr > t
region*group	1	1	1	3	0.4128	0.1456	17.2	2.84	0.0113
region*group	1	1	2	1	-0.1822	0.1125	10	-1.62	0.1365
region*group	1	1	2	3	0.1983	0.1456	17.2	1.36	0.1906
region*group	1	3	2	1	-0.5950	0.1456	17.2	-4.09	0.0008
region*group	1	3	2	3	-0.2144	0.1125	10	-1.91	0.0858
region*group	2	1	2	3	0.3806	0.1456	17.2	2.61	0.0180

Der Hauptvorteil einer varianzanalytischen Auswertung im Vergleich zu den t-Tests in den Abschnitten (1) und (2) besteht darin, dass alle Daten verwendet werden, um

die Fehlerterme zu schätzen. Daher haben die t-Tests zum Vergleich der Gruppen bei derselben Region mehr Freiheitsgrade (17,2 Satterthwaite-FG, Im Vergleich zu 10 FG für die einfachen t-Tests). Somit ist ein Gewinn an Teststärke zu erwarten.

(11) Der t-Test für Interaktionen - neue Betrachtungsweise: Der t-Test auf Interaktion in Abschnitt (5) basierte auf der Differenz von Mittelwertdifferenzen und umfasste somit vier verschiedene (Zell-) Mittelwerte. Die "Differenz einer Differenz" entspricht einem linearen Kontrast mit vier Mittelwerten:

$\bar{y}_{11}$ = Mittel für Gruppe 1 (Kontrolle), proximale Region = 0,856

$\bar{y}_{12}$ = Mittel für Gruppe 1 (Kontrolle), distale Region = 1,038

$\bar{y}_{21}$ = Mittel für Gruppe 3 (RS), proximale Region = 0,443

$\bar{y}_{22}$ = Mittel für Gruppe 3 (RS), distale Region = 0,658

Die Differenz der Gruppen für die proximale Region ist

$$\bar{y}_{11} - \bar{y}_{21} = 0,856 - 0,443 = 0,413$$

Die Differenz der Gruppen für die distale Region ist

$$\bar{y}_{12} - \bar{y}_{22} = 1,038 - 0,658 = 0,380$$

Die Differenz der Differenzen ist

$$L = \bar{y}_{11} - \bar{y}_{21} - (\bar{y}_{12} - \bar{y}_{22}) = 0,413 - 0,380 = 0,033$$

Dies ist ein Kontrast der Form

$$L = c_{11}\bar{y}_{11} - c_{12}\bar{y}_{12} - c_{21}\bar{y}_{21} + c_{22}\bar{y}_{22}$$

mit

$$c_{11} = 1$$

$$c_{12} = -1$$

$$c_{21} = -1$$

$$c_{22} = 1$$

SAS Anweisungen

```
proc mixed;
class region animal group;
model avcount=region group region*group;
random animal*group;
estimate 'interaction' region*group 1 -1 -1 1;
run;
```

Output:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
region	1	10	6.21	0.0319
group	1	10	10.59	0.0087
region*group	1	10	0.04	0.8436

Estimates

Label	Estimate	Standard Error	DF	t Value	Pr > t
interaction	0.03223	0.1591	10	0.20	0.8436

Der p-Wert für diesen Interaktionskontrast ist derselbe wie für den F-Test auf Interaktionen in Abschnitt (9) und den t-Test auf Interaktionen in Abschnitt (5).

(12) Analyse für drei Gruppen (unbalanciert): Bisher umfasste die Analyse nur zwei Gruppen. Das vollständige Experiment wurde mit drei Gruppen durchgeführt (**colon2.dat**). Die zweite Gruppe wurde mit derselben resistenten Stärke gefüttert wie Gruppe 2. Im Unterschied zu Gruppe 3 wurde bei Gruppe 2 eine Hungerperiode vor der Fütterung der resistenten Stärke vorgeschaltet. Die drei Gruppen können wie folgt charakterisiert werden:

Gruppe	Behandlung	Zahl der Tiere
1	Kontrolle	6
2	RS+ (mit Hungerperiode)	5
3	RS– (ohne Hungerperiode)	6

Die Varianzanalyse ist im wesentlichen analog zur Auswertung bei zwei Gruppen. Allerdings kann hier eine vollständige Analyse nicht ausschliesslich auf Basis von t-Tests implementiert werden, wie es bei nur zwei Gruppen der Fall war. Ausserdem sind die Daten hier unbalanciert, da Gruppe 2 nur 5 Tiere hatte. Daher können Mittelwerte nicht mit den *s.e.d.* -Werten in Tab. 16.2 durchgeführt werden. Es werden allgemeinere Methoden zur Berechnung von Mittelwerten, F-Werten, t-Werten und Freiheitsgraden benötigt (siehe Anhang). Wir verwenden hier die Kenward-Roger-Methode, eine Erweiterung der Satterthwaite Methode. Diese ist verfügbar in MIXED mit der Option DDFM = KR option.

SAS Anweisungen

```
data;
input
group    region    animal    avcount;
datalines;
    1      1        1        0.93667
```

1	1	2	1.18000
1	1	3	0.85667
1	1	4	0.77667
1	1	5	0.49667
1	1	6	0.89000
1	2	1	1.34000
1	2	2	1.17000
1	2	3	1.26667
1	2	4	0.78000
1	2	5	0.71000
1	2	6	0.96333
2	1	18	0.43000
2	1	19	0.66667
2	1	20	0.31667
2	1	21	0.53000
2	1	22	0.37333
2	2	18	0.36667
2	2	19	0.19667
2	2	20	0.53333
2	2	21	0.50333
2	2	22	0.66667
3	1	12	0.37000
3	1	13	0.54000
3	1	14	0.36333
3	1	15	0.54333
3	1	16	0.40000
3	1	17	0.44333
3	2	12	0.36333
3	2	13	0.30667
3	2	14	0.46000
3	2	15	1.13000
3	2	16	0.61000
3	2	17	1.07667

```

;
proc mixed;
class group region animal;
model avcount=group region group*region/ddfm=kr;
random animal(group);
run;

```

Output:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
group	2	14	11.76	0.0010
region	1	14	3.51	0.0820
group*region	2	14	0.98	0.4001

Die Interaktionen sind weiterhin nicht signifikant, aber die signifikanten Unterschiede der Regionen sind "verschwunden". Es kann daher gut sein, dass der signifikante Regioneneffekt ein Fehler 1. Art war. Der p-Wert ist jedoch nahe bei der konventionellen 5% Schwelle, so dass es nach wie vor einen deutlichen Hinweis auf Regioneneffekte gibt. Randmittelwerte (gewichtete Kleinstquadratschätzungen) werden wie folgt berechnet und verglichen:

```
proc mixed;
class group region animal;
model avcount=group region/ddfm=kr;
random animal(group);
lsmeans group region/pdiff;
run;
```

Output:

Least Squares Means								
Effect	group	region	Estimate	Standard Error	DF	t Value	Pr > t	
group	1		0.9472	0.07387	14	12.82	<.0001	
group	2		0.4583	0.08093	14	5.66	<.0001	
group	3		0.5506	0.07387	14	7.45	<.0001	
region		1	0.5835	0.05578	27.3	10.46	<.0001	
region		2	0.7206	0.05578	27.3	12.92	<.0001	

Differences of Least Squares Means									
Effect	group	region	_group	_region	Estimate	Standard Error	DF	t Value	Pr > t
group	1		2		0.4889	0.1096	14	4.46	0.0005
group	1		3		0.3967	0.1045	14	3.80	0.0020
group	2		3		-0.09222	0.1096	14	-0.84	0.4141
region		1		2	-0.1371	0.06845	16	-2.00	0.0625

Gruppen 2 und 3 sind nicht signifikant verschieden, so dass die Hungerperiode keinen Einfluss auf die Zellzahlen hatte. Beide RS Behandlungen (Gruppen 2 und 3) sind signifikant verschieden von der Kontrolle. Man beachte, dass die *s.e.d.*-Werte nicht konstant sind, so dass keine gemeinsame Grenzdifferenz berechnet werden kann. Die Regionen sind nicht signifikant verschieden.

(13) Analyse der Einzelwerte der Segmente (unbalanciert): Die mittleren Zellzahlen einer Region für ein Tier wurden aus drei verschiedenen Proben (Segmenten) berechnet. Für einige Tiere lagen allerdings nur zwei oder nur ein Wert vor (in manchen Proben wurden keine Krypten gefunden oder die Krypten konnten in den Präparaten nicht ausreichend sichtbar gemacht werden). Die Einzelwerte sind unten angegeben (**colon3.dat**). Die ersten sechs Beobachtungen stammen von den Tieren mit den Nummern 1, 2 und 3. Für Tier 1 waren nur zwei Segmente verfügbar, und für Tier 2 nur ein Segment. Für Tier 3 wurden drei Segmente ausgezählt. Dies zeigt exemplarisch, wie unbalanciert die Daten waren.

slide	group	region	grureg	animal	avcount	
632	1	2	11	1	1.57	}
633	1	2	11	1	1.11	
644	1	2	11	2	1.17	→
655	1	2	11	3	0.89	}
656	1	2	11	3	1	
657	1	2	11	3	1.91	
667	1	2	11	4	0.38	
668	1	2	11	4	1.1	
669	1	2	11	4	0.86	
679	1	2	11	5	0.67	
680	1	2	11	5	0.6	
681	1	2	11	5	0.86	
703	1	2	11	6	0.7	
704	1	2	11	6	0.6	
705	1	2	11	6	1.59	
634	1	1	12	1	1	
635	1	1	12	1	1.31	
636	1	1	12	1	0.5	
646	1	1	12	2	1.32	
647	1	1	12	2	0.75	
648	1	1	12	2	1.47	
658	1	1	12	3	1.07	
659	1	1	12	3	0.5	
660	1	1	12	3	1	
670	1	1	12	4	1	
671	1	1	12	4	0.33	
672	1	1	12	4	1	
682	1	1	12	5	0	
683	1	1	12	5	0.82	
684	1	1	12	5	0.67	
706	1	1	12	6	0.67	
707	1	1	12	6	0.6	
708	1	1	12	6	1.4	
607	2	2	41	18	0.42	
608	2	2	41	18	0.43	
609	2	2	41	18	0.25	
619	2	2	41	19	0.46	
620	2	2	41	19	0	
621	2	2	41	19	0.13	
437	2	2	41	20	0.6	
438	2	2	41	20	0.29	
439	2	2	41	20	0.71	
449	2	2	41	21	0.58	
450	2	2	41	21	0.5	
451	2	2	41	21	0.43	
461	2	2	41	22	1	
462	2	2	41	22	0.5	
463	2	2	41	22	0.5	
610	2	1	42	18	0.5	
611	2	1	42	18	0.5	
612	2	1	42	18	0.29	
622	2	1	42	19	1	

nur 2 Segmente

nur 1 Segment

3 Segmente, wie geplant

623	2	1	42	19	0.5
624	2	1	42	19	0.5
440	2	1	42	20	0.5
441	2	1	42	20	0.36
442	2	1	42	20	0.09
452	2	1	42	21	0.5
453	2	1	42	21	0.52
454	2	1	42	21	0.57
464	2	1	42	22	0.25
465	2	1	42	22	0.67
466	2	1	42	22	0.2
571	3	2	51	12	0.71
572	3	2	51	12	0.25
573	3	2	51	12	0.13
583	3	2	51	13	0.42
584	3	2	51	13	0.33
585	3	2	51	13	0.17
595	3	2	51	14	0.56
596	3	2	51	14	0.44
597	3	2	51	14	0.38
401	3	2	51	15	1.56
403	3	2	51	15	0.7
413	3	2	51	16	0.83
414	3	2	51	16	0.67
415	3	2	51	16	0.33
425	3	2	51	17	0.83
426	3	2	51	17	0.9
427	3	2	51	17	1.5
575	3	1	52	12	0.55
576	3	1	52	12	0.19
587	3	1	52	13	0.33
588	3	1	52	13	0.75
598	3	1	52	14	0.67
599	3	1	52	14	0.22
600	3	1	52	14	0.2
404	3	1	52	15	0.6
405	3	1	52	15	0.43
406	3	1	52	15	0.6
416	3	1	52	16	0.2
417	3	1	52	16	1
418	3	1	52	16	0
428	3	1	52	17	0.4
429	3	1	52	17	0.43
430	3	1	52	17	0.5

;

slide = laufende Nummer des Objektträgers, entspricht einem Segment (Probe)
grureg = gekreuzte Variable zwischen Gruppe und Region (hier nicht verwendet)

Die Unbalanciertheit der Daten bedingt, dass die Genauigkeit der Mittelwerte von der Zahl der Wiederholungen abhängt. Ein Zellzahlmittelwert aus drei Segmenten ist z.B. genauer als einer aus nur zwei Segmenten. Um dies bei der Auswertung zu berücksichtigen, muss eine gewichtete Analyse durchgeführt werden, bei der Mittelwerte ein umso höheres Gewicht erhalten, aus je mehr Einzelwerten sie

berechnet wurden (vgl. Beispiel 12 - Sorghum-Daten). Die gewichtete Analyse wird automatisch erhalten, wenn ein dem Design entsprechendes gemischtes Modell für die Einzelwerte in MIXED angepasst wird. Das Modell lautet

$$y_{ijkh} = \mu + \alpha_i + f_{ik} + \beta_j + (\alpha\beta)_{ij} + e_{ijk} + g_{ijkh}$$

wobei

y_{ijkh} = Zellzahl der h -ten Probe (Segment) für die j -te Region beim k -ten Tier in der i -ten Gruppe

μ = Allgemeiner Effekt

α_i = Haupteffekt der i -ten Gruppe

β_j = Haupteffekt der j -ten Region

$(\alpha\beta)_{ij}$ = Gruppe $\times$ Region Interaktion

f_{ik} = Zufälliger Effekt des ik -ten Tiers (Effekt "zwischen" den Tieren)

e_{ijk} = Zufälliger Effekt der j -ten Region beim ik -ten Tier ("innerhalb" der Tiere)

g_{ijkh} = Restfehler (Stichprobenfehler)

SAS Anweisungen

```
proc mixed data=t;
class group region animal;
model avcount=group region group*region/ddfm=kr;
random animal(group) group*animal*region;
run;
```

f_{ik}

e_{ijk}

Output:

Covariance Parameter Estimates

Cov Parm	Estimate	
animal(group)	0.01152	σ_f^2
group*region*animal	0.004166	σ_e^2
Residual	0.1005	σ_g^2

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
group	2	13	11.82	0.0012
region	1	13.2	2.91	0.1115
group*region	2	13.2	0.86	0.4439

Die Interaktionen und die Hauptwirkungen der Regionen sind nicht signifikant. Da dies die effizienteste Analyse ist, würde ich schliessen, dass es nur schwache Hinweise auf Unterschiede zwischen den Regionen (proximal, distal) gibt, während die Unterschiede zwischen den Gruppen hoch signifikant sind. Die gewichteten Kleinstquadratmittelwerte für die Gruppen sind:

```
proc mixed data=t;
class group region animal;
model avcount=group/ddfm=kr;
random animal(group) group*animal*region;
lsmeans group/pdiff;
run;
```

Output:

Least Squares Means							
Effect	group	Estimate	Standard Error	DF	t Value	Pr > t	
group	1	0.9281	0.07029	13.6	13.20	<.0001	
group	2	0.4583	0.07434	12.3	6.17	<.0001	
group	3	0.5404	0.07001	13.7	7.72	<.0001	

Differences of Least Squares Means							
Effect	group	_group	Estimate	Standard Error	DF	t Value	Pr > t
group	1	2	0.4697	0.1023	12.9	4.59	0.0005
group	1	3	0.3877	0.09920	13.7	3.91	0.0016
group	2	3	-0.08204	0.1021	12.9	-0.80	0.4363

(14) Zusammenfassung Beispiel 16: Es wurde gezeigt, wie ein zweifaktorielles Experiment mit Messwiederholungen mit verschiedenen Methoden analysiert werden kann. Einfache verbundene und unverbundene t-Tests waren dabei der Startpunkt. Eine ausgefeiltere Auswertung mit gemischten Modellen, die die höchste Effizienz erwarten lässt und auch bei unbalancierte Daten anwendbar ist, liefert ähnliche Ergebnisse wie die einfachen t-Tests. Die effizientere Auswertung nach einem gemischten Modell mit PROC MIXED ist relativ einfach, sofern das richtige gemischte Modell aufgestellt werden kann.

Wir haben hier ausschließlich Modelle für Messwiederholungen verwendet, die denen für die Spaltanlage gebräuchlichen entsprechen, welche wiederum eine "Compound Symmetry" Struktur (CS) implizieren. Dies ist hier sinnvoll, weil der "wiederholte Faktor" (Region) nur zwei Stufen hat. Daher ist CS identisch mit einem AR(1) Modell (es gibt nur einen Abstand zwischen zwei wiederholten Messungen).

Abschließend noch einmal eine Zusammenstellung der drei verschiedenen Datensätze:

colon.dat : Zwei Gruppen, Mittlere Zellzahlen je Region colon2.dat : Drei Gruppen, Mittlere Zellzahlen je Region colon3.dat : Drei Gruppen, Mittlere Zellzahlen je Probe (Segment, Objektträger)

Beispiel 8.4: Drei Behandlungen (eine Kontrolle und zwei Chemikalien) wurden jeweils 10, 7 und 10 Ratten verabreicht. Die Anlage wurde vollständig randomisiert, d.h. die Ratten wurden zufällig den Behandlungen zugewiesen (**rat repeated.dat**). Die Gewichte der Tiere wurden zu fünf aufeinander folgenden Zeitpunkten gemessen (zu Beginn sowie 1, 2, 3 und 4 Wochen nach Beginn). Ziel der Untersuchung ist es, mögliche Unterschiede der Behandlungen hinsichtlich der Gewichtsentwicklung der Ratten zu ermitteln.

Tab. 8.3: Gewichtsdaten für Ratten bei 3 verschiedenen Behandlungen

	0	Woche		3	4	Differenz "4-0"	Regression <i>b</i>
Kontrolle		1	2				
Ratte 1	57	86	114	139	172	115	28,3
Ratte 2	60	93	123	146	177	117	28,7
Ratte 3	52	77	111	144	185	133	33,3
Ratte 4	49	67	100	129	164	115	29,2
Ratte 5	56	81	104	121	151	95	23,0
Ratte 6	46	70	102	131	153	107	27,5
Ratte 7	51	71	94	110	141	90	21,9
Ratte 8	63	91	112	130	154	91	22,1
Ratte 9	49	67	90	112	140	91	22,7
Ratte 10	57	82	110	139	169	112	28,1
	0	Woche		3	4	Differenz "4-0"	Regression <i>b</i>
Tyroxin		1	2				
Ratte 1	59	85	121	156	191	132	33,5
Ratte 2	54	71	90	110	138	84	20,7
Ratte 3	56	75	108	151	189	133	34,2
Ratte 4	59	85	116	148	177	118	29,9
Ratte 5	57	72	97	120	144	87	22,2
Ratte 6	52	73	97	116	140	88	21,9
Ratte 7	52	70	105	138	171	119	30,6
Thiouracil							
Ratte 1	61	86	109	120	129	68	17,0
Ratte 2	59	80	101	111	126	67	16,5
Ratte 3	53	79	100	106	133	80	18,7
Ratte 4	59	88	100	111	122	63	14,9
Ratte 5	51	75	101	123	140	89	22,6
Ratte 6	51	75	92	100	119	68	16,1
Ratte 7	56	78	95	103	108	52	12,9
Ratte 8	58	69	93	114	138	80	20,5
Ratte 9	46	61	78	90	107	61	15,1
Ratte 10	53	72	89	104	122	69	17,0




Abb. 8.6: Zeitliche Gewichtsverläufe für 27 Ratten bei drei verschiedenen Behandlungen. — Kontrolle Tyroxin - - - Thiouracil

Die Verlaufskurven in Abb. 8.6 zeigen, dass zu Beginn keine Unterschiede zu verzeichnen sind, während im späteren Verlauf deutlichere Unterschiede zu Tage treten. In der Vorlesung "Biometrie" (Kap. 13) haben wir bereits einfache Auswertungsansätze für diesen Datensatz betrachtet, die auf der Berechnung von zusammenfassenden Maßzahlen je Ratte beruhten. Wir wollen nun die Einzeldaten direkt modellieren. Hierbei ist die Korrelation der Messwerte für dieselbe Ratte zu modellieren.

Ein zweifaktorielles Modell hat die Form

$$y_{ijk} = \mu_{ij} + e_{ijk}$$

wobei

μ_{ij} = Erwartungswert der i -ten Behandlung in der j -ten Woche und

e_{ijk} = Zufallsabweichung des k -ten Tiers bei der i -ten Behandlung in der j -ten Woche

Das Problem der Messwiederholungen besteht darin, dass die Fehler e_{ijk} beim selben Tier für verschiedene Zeitpunkte (j) korreliert sind. Für eine einfache Varianzanalyse müsste für die Fehler des ik -ten Tieres zu den fünf verschiedenen Zeitpunkten ($e_{i1k}, e_{i2k}, e_{i3k}, e_{i4k}, e_{i5k}$) Unabhängigkeit und Varianzhomogenität gelten, also:

$$\text{var} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \begin{pmatrix} \sigma^2 & 0 & 0 & 0 & 0 \\ 0 & \sigma^2 & 0 & 0 & 0 \\ 0 & 0 & \sigma^2 & 0 & 0 \\ 0 & 0 & 0 & \sigma^2 & 0 \\ 0 & 0 & 0 & 0 & \sigma^2 \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} = \sigma^2 \mathbf{I}$$

Obenstehender Ausdruck ist die Varianz-Kovarianz-Matrix der Fehler. Auf der Diagonalen stehen die Varianzen, jenseits der Diagonalen die Kovarianzen. Bei Unabhängigkeit sind die Kovarianzen Null. Bei Varianzhomogenität sind die Varianzen auf der Diagonale alle gleich, was bedeutet, dass zu jedem Zeitpunkt dieselbe Varianz gilt. Um zu untersuchen, wie sinnvoll diese Annahme ist, lassen wir nun von Null verschiedene Kovarianzen sowie Varianzheterogenität zu und betrachten das erweiterte Modell

$$\text{var} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \sigma_{21} & \sigma_{31} & \sigma_{41} & \sigma_{51} \\ \sigma_{12} & \sigma_2^2 & \sigma_{32} & \sigma_{42} & \sigma_{52} \\ \sigma_{13} & \sigma_{23} & \sigma_3^2 & \sigma_{43} & \sigma_{53} \\ \sigma_{14} & \sigma_{24} & \sigma_{34} & \sigma_4^2 & \sigma_{54} \\ \sigma_{15} & \sigma_{25} & \sigma_{35} & \sigma_{45} & \sigma_5^2 \end{pmatrix}$$

wobei

$\sigma_j^2 = \text{var}(e_{ijk}) = E[e_{ijk}^2] = \text{Varianz zum } j\text{-ten Zeitpunkt}$

$\sigma_{jj'} = \text{cov}(e_{ijk}, e_{ij'k}) = E[e_{ijk} e_{ij'k}] = \text{Kovarianz der Zeitpunkte } j \text{ und } j'$

Bei Unabhängigkeit gilt $\sigma_{jj'} = 0$ für alle $j \neq j'$. Bei Varianzhomogenität gilt $\sigma_j^2 = \sigma^2$ für alle j . Die Korrelation ist definiert als standardisierte Kovarianz:

$$\rho_{jj'} = \text{corr}(e_{ijk}, e_{ij'k}) = \frac{\sigma_{jj'}}{\sqrt{\sigma_j^2 \sigma_{j'}^2}} = \frac{\sigma_{jj'}}{\sigma_j \sigma_{j'}}$$

Im Zusammenhang mit Messwiederholungen und Zeitreihendaten spricht man auch von **Autokorrelation**, weil hier ein Merkmal gewissermaßen mit sich selber korreliert ist, nämlich zu verschiedenen Zeitpunkten. Mit der obigen Definition der Korrelation kann die Kovarianz wie folgt ausgedrückt werden:

$$\sigma_{jj'} = \rho_{jj'} \sigma_j \sigma_{j'}$$

Anstelle der Varianz-Kovarianz-Matrix können wir auch die Korrelationsmatrix berechnen:

$$\text{corr} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \begin{pmatrix} 1 & \rho_{21} & \rho_{31} & \rho_{41} & \rho_{51} \\ \rho_{12} & 1 & \rho_{32} & \rho_{42} & \rho_{52} \\ \rho_{13} & \rho_{23} & 1 & \rho_{43} & \rho_{53} \\ \rho_{14} & \rho_{24} & \rho_{34} & 1 & \rho_{54} \\ \rho_{15} & \rho_{25} & \rho_{35} & \rho_{45} & 1 \end{pmatrix}$$

Die Parameter dieses Modells lassen sich leicht mit Hilfe einer Prozedur für gemischte Modelle schätzen, z.B. SAS PROC MIXED. Die geschätzte Korrelation zwischen zwei Zeitpunkten j und j' , $\rho_{jj'} = \text{corr}(e_{ijk}, e_{ij'k})$, sowie die Varianzen, $\sigma_j^2 = \text{var}(e_{ijk})$, wurde wie folgt geschätzt (Korrelationsmatrix und Varianzen):

Woche	0	1	Woche 2	3	4	
0	1,0000	0,8575	0,6984	0,4694	0,3335	} Korrelationen
1	0,8575	1,0000	0,8557	0,5778	0,4222	
2	0,6984	0,8557	1,0000	0,8871	0,7760	
3	0,4694	0,5778	0,8871	1,0000	0,9409	
4	0,3335	0,4222	0,7760	0,9409	1,0000	
Varianzen	21,58	68,73	94,77	181,56	268,34	

Es bestehen deutliche Korrelationen zwischen den verschiedenen Zeitpunkten. Offensichtlich ist die Annahme der statistischen Unabhängigkeit der Fehler verletzt. Man sieht außerdem, dass die Korrelation umso enger ist, je näher die Zeitpunkte benachbart sind. Dieses Muster ist typisch für Zeitreihendaten. Außerdem steigt die Varianz von den frühen zu den späteren Zeitpunkten deutlich an, so dass auch die Annahme homogener Varianzen verletzt ist.

Das bisher verwendete Modell ist unstrukturiert (UN), weil für die Kovarianzen und Varianzen keine besondere Struktur vorgegeben wird. Wir wollen nun verschiedene Modelle anstelle des unstrukturierten Modells, z.B.

CS:

$$\text{var} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & \rho & \rho & \rho & \rho \\ \rho & 1 & \rho & \rho & \rho \\ \rho & \rho & 1 & \rho & \rho \\ \rho & \rho & \rho & 1 & \rho \\ \rho & \rho & \rho & \rho & 1 \end{pmatrix}$$

AR(1):

$$\text{var} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & \rho & \rho^2 & \rho^3 & \rho^4 \\ \rho & 1 & \rho & \rho^2 & \rho^3 \\ \rho^2 & \rho & 1 & \rho & \rho^2 \\ \rho^3 & \rho^2 & \rho & 1 & \rho \\ \rho^4 & \rho^3 & \rho^2 & \rho & 1 \end{pmatrix}$$

CSH:

$$\text{var} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \sigma_2 \sigma_1 \rho & \sigma_3 \sigma_1 \rho & \sigma_4 \sigma_1 \rho & \sigma_5 \sigma_1 \rho \\ \sigma_1 \sigma_2 \rho & \sigma_2^2 & \sigma_3 \sigma_2 \rho & \sigma_4 \sigma_2 \rho & \sigma_5 \sigma_2 \rho \\ \sigma_1 \sigma_3 \rho & \sigma_2 \sigma_3 \rho & \sigma_3^2 & \sigma_4 \sigma_3 \rho & \sigma_5 \sigma_3 \rho \\ \sigma_1 \sigma_4 \rho & \sigma_2 \sigma_4 \rho & \sigma_3 \sigma_4 \rho & \sigma_4^2 & \sigma_5 \sigma_4 \rho \\ \sigma_1 \sigma_5 \rho & \sigma_2 \sigma_5 \rho & \sigma_3 \sigma_5 \rho & \sigma_4 \sigma_5 \rho & \sigma_5^2 \end{pmatrix}$$

ARH(1):

$$\text{var} \begin{pmatrix} e_{i1k} \\ e_{i2k} \\ e_{i3k} \\ e_{i4k} \\ e_{i5k} \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \sigma_2 \sigma_1 \rho & \sigma_3 \sigma_1 \rho^2 & \sigma_4 \sigma_1 \rho^3 & \sigma_5 \sigma_1 \rho^4 \\ \sigma_1 \sigma_2 \rho & \sigma_2^2 & \sigma_3 \sigma_2 \rho & \sigma_4 \sigma_2 \rho^2 & \sigma_5 \sigma_2 \rho^3 \\ \sigma_1 \sigma_3 \rho^2 & \sigma_2 \sigma_3 \rho & \sigma_3^2 & \sigma_4 \sigma_3 \rho & \sigma_5 \sigma_3 \rho^2 \\ \sigma_1 \sigma_4 \rho^3 & \sigma_2 \sigma_4 \rho^2 & \sigma_3 \sigma_4 \rho & \sigma_4^2 & \sigma_5 \sigma_4 \rho \\ \sigma_1 \sigma_5 \rho^4 & \sigma_2 \sigma_5 \rho^3 & \sigma_3 \sigma_5 \rho^2 & \sigma_4 \sigma_5 \rho & \sigma_5^2 \end{pmatrix}$$

Wir finden folgende AIC-Werte:

Modell	AIC
$I\sigma^2$	956,6
UN	767,3
CS	900,6
AR(1)	822,9
CSH	849,5
ARH(1)	780,6

Das unstrukturierte Modell passt am besten, gefolgt von ARH(1) und AR(1). Daher machen wir die folgenden Analysen mit der Struktur UN. Wir finden:

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
Behandlung	2	24	7.63	0.0027
Woche	4	21	294.07	<.0001
Beh*Woche	8	28.2	5.65	0.0003

Da die Wechselwirkungen signifikant sind, unterscheiden sich die Zeitprofile der drei Behandlungen. Daher berechnen wir die Behandlung x Woche Mittelwerte und die dazugehörigen Standardfehler/Vertrauensgrenzen:

```
proc mixed data=a;
class beh woche;
model y=beh woche beh*woche/ddfm=kr;
repeated woche/sub=behrat type=un;
lsmeans beh*woche/cl;
run;
```

Ergebnis:

The Mixed Procedure

Least Squares Means

Beh	Woche	Estimate	Error	Standard		
				DF	Lower	Upper
1	1	54.0000	1.4689	24	50.9684	57.0316
1	2	78.5000	2.6216	24	73.0893	83.9107
1	3	106.00	3.0785	24	99.6464	112.35
1	4	130.10	4.2609	24	121.31	138.89
1	5	160.60	5.1802	24	149.91	171.29
2	1	55.5714	1.7556	24	51.9480	59.1949
2	2	75.8571	3.1334	24	69.3901	82.3242
2	3	104.86	3.6795	24	97.2631	112.45
2	4	134.14	5.0928	24	123.63	144.65
2	5	164.29	6.1915	24	151.51	177.06
3	1	54.7000	1.4689	24	51.6684	57.7316
3	2	76.3000	2.6216	24	70.8893	81.7107
3	3	95.8000	3.0785	24	89.4464	102.15
3	4	108.20	4.2609	24	99.4058	116.99
3	5	124.40	5.1802	24	113.71	135.09




Abb. 8.7: Zeitliche mittlere Gewichtsverläufe (LSMEANS) bei drei verschiedenen Behandlungen. — Kontrolle Tyroxin - - - Thiouracil (mit 95% Vertrauensgrenzen)

Wir stellen fest, dass die Zeitverläufe ab der 3. Woche auseinanderdriften. Man beachte die im Zeitverlauf breiter werdenden Vertrauensintervalle. Zum Schluss untersuchen wir die Signifikanz der Mittelwertvergleiche:

```
quit;
ods output diffs=diffs;
proc mixed data=a;
class beh woche;
model y=beh*woche/ddfm=kr;
lsmeans beh*woche/pdiff;
repeated woche/sub=behrat type=un;
run;
```

```
data diffs;
set diffs;
if woche=_woche;
```

```
proc sort data=diffs out=diffs;
by woche;
```

```
proc print data=diffs;
run;
```

Ergebnis:

Obs	Effect	beh	woche	_beh	_woche	Estimate	StdErr	DF	tValue	Prob>
1	beh*woche	1	1	2	1	-1.5714	2.2891	24	-0.69	0.4990
2	beh*woche	1	1	3	1	-0.7000	2.0773	24	-0.34	0.7391
3	beh*woche	2	1	3	1	0.8714	2.2891	24	0.38	0.7068
4	beh*woche	1	2	2	2	2.6429	4.0855	24	0.65	0.5238
5	beh*woche	1	2	3	2	2.2000	3.7075	24	0.59	0.5585
6	beh*woche	2	2	3	2	-0.4429	4.0855	24	-0.11	0.9146
7	beh*woche	1	3	2	3	1.1429	4.7974	24	0.24	0.8137
8	beh*woche	1	3	3	3	10.2000	4.3536	24	2.34	0.0278
9	beh*woche	2	3	3	3	9.0571	4.7974	24	1.89	0.0712
10	beh*woche	1	4	2	4	-4.0429	6.6402	24	-0.61	0.5483
11	beh*woche	1	4	3	4	21.9000	6.0259	24	3.63	0.0013
12	beh*woche	2	4	3	4	25.9429	6.6402	24	3.91	0.0007
13	beh*woche	1	5	2	5	-3.6857	8.0727	24	-0.46	0.6521
14	beh*woche	1	5	3	5	36.2000	7.3259	24	4.94	<.0001
15	beh*woche	2	5	3	5	39.8857	8.0727	24	4.94	<.0001

Ab der 3. Woche ist Behandlung 3 (Thiouracil) signifikant verschieden von der Kontrolle (1) und Tyroxin (2).

SAS Anweisungen:

```

data a;
array z z1-z5;
input beh rat z1-z5;
behrat=100*beh+rat;
do woche=1 to 5;
    t=woche;
    y=z[woche];
    output;
end;
datalines;
1 1      57      86      114      139      172
1 2      60      93      123      146      177
1 3      52      77      111      144      185
1 4      49      67      100      129      164
1 5      56      81      104      121      151
1 6      46      70      102      131      153
1 7      51      71      94       110      141
1 8      63      91      112      130      154
1 9      49      67      90       112      140
1 10     57      82      110      139      169

2 1      59      85      121      156      191
2 2      54      71      90       110      138
2 3      56      75      108      151      189
2 4      59      85      116      148      177
2 5      57      72      97       120      144
2 6      52      73      97       116      140
2 7      52      70      105      138      171

3 1      61      86      109      120      129

```

3	2	59	80	101	111	126
3	3	53	79	100	106	133
3	4	59	88	100	111	122
3	5	51	75	101	123	140
3	6	51	75	92	100	119
3	7	56	78	95	103	108
3	8	58	69	93	114	138
3	9	46	61	78	90	107
3	10	53	72	89	104	122

```
;
ods output lsmeans=lsmeans;
proc mixed data=a;
class beh woche;
model y=beh woche beh*woche/ddfm=kr;
repeated woche/sub=behrat type=un;
lsmeans beh*woche/cl;
run;
```

Beispiel 8.5 (Fabian Wald, Institut für Pflanzenbau, Uni Hohenheim; **nmin.dat**): Leguminosen-Grasgemenge sind als N-Quelle in Fruchtfolgen des Organischen Landbaus von zentraler Bedeutung. Nach meist mehrjährigem Anbau wird der von den Leguminosen assimilierte Stickstoff mit dem Umbruch der Narbe durch die Mineralisation der organischen Substanz wieder freigesetzt. In der Praxis steht für eine Steuerung der Mineralisierung ausschließlich das Instrument der Bodenbearbeitung zur Verfügung. Ziel dieser Untersuchungen war es, die Beeinflussbarkeit der N-Mineralisierung durch eine Variation des Narbenumbruchs zu quantifizieren, um so eine Datengrundlage für die Modellierung der N-Dynamik in Abhängigkeit von der Bodenbearbeitung zu schaffen.

Nach dem Umbruch eines 3-jährigen Klee-Luzernegrasgemenges auf einem Versuchsstandort der Universität Hohenheim (407 m ü. NN, 8,5 °C, 687 mm, Pseudogley-Parabraunerde, uL) wurde im Herbst 2000 Weizen (cv. Rektor) etabliert. Die Bodenbearbeitung zum Umbruch der Narbe wurde in drei Stufen in einer Blockanlage variiert (**Variante 1**: zweifache Rotortillerbearbeitung (RT, 10 cm tief) in etwa zweiwöchigem Abstand, abschließend Pflugfurche (Pflug, 25 cm tief); **Variante 2**: RT einmal und abschließend Pflugeinsatz; **Variante 3**: ausschließlicher Pflugumbruch. Die Stickstoffgehalte des Bodens wurden durch wiederholtes Beprobieren in den Tiefen 0-10, 10-20, 20-30 und 30-60 cm ermittelt. Zur Erfassung von Nitratausträgen über Winter wurden Monitoringboxen im ungestörten Bodenkörper für den Zeitraum September 2000 bis April 2001 in 1 m Tiefe installiert. Die Messungen erfolgten zu drei verschiedenen Zeitpunkten (09.08.99, 08.09.99, 27.09.99).

Für die Behandlungsstruktur kann ein gewöhnliches dreifaktorielles Modell angesetzt werden:

$$\eta_{ijk} = \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk}$$

wobei die Indizierung wie folgt ist:

$i = 1, 2, 3$ (Bodenbearbeitung)

$j = 1, 2, 3$ (Termine)

$k = 1, 2, 3, 4$ (Tiefe)

Um die Blockstruktur zu berücksichtigen, benötigen wir ausserdem einen Blockeffekt

b_m = Effekt des m -ten Blocks

Der Erwartungswert des Modells ist dann

$$\eta_{ijkm} = b_m + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk}$$

Das Modell der beobachteten Daten kann geschrieben werden als

$$y_{ijkm} = \eta_{ijkm} + r_{ijkm}$$

wobei y_{ijkm} der Wert für die i -te Bodenbearbeitung zum j -ten Termin in der k -ten Bodentiefe im m -ten Block ist und r_{ijkm} eine entsprechende Zufallsabweichung vom Erwartungswert η_{ijkm} .

Die Schwierigkeit der Modellierung besteht nun darin, dass zwei wiederholte Behandlungsfaktoren vorliegen: Termine (3 Stufen) und Bodentiefen (4 Stufen). Je Parzelle liegen als 12 Messwerte vor, die korreliert sind.

Tab. 8.4: Vier verschiedene Arten von Beobachtungspaare bei Design mit zwei wiederholten Faktoren.

Fall	Paar von Beobachtungen auf einer Parzelle
(1)	Selbe Tiefe, selber Zeitpunkt
(2)	Selbe Tiefe, verschiedene Zeitpunkte
(3)	Selber Zeitpunkt, verschiedene Tiefen
(4)	Verschiedene Zeitpunkte, verschiedene Tiefen

Bezüglich der zu erwartenden Kovarianzen lässt sich folgendes erwarten:

$$(1) > (2) > (4)$$

$$(1) > (3) > (4)$$

Ein solches Modell lässt sich einfach formulieren, sofern die **Compound Symmetry** Struktur angenommen werden kann. In diesem Fall kann folgendes Modell angesetzt werden:

$$r_{ijkm} = f_{im} + g_{ijm} + h_{ikm} + e_{ijkm}$$

$f_{im} \sim N(0, \sigma_f^2)$, Effekt der Parzelle im m -ten Block, auf welcher die i -te Variante geprüft wird

$g_{ijm} \sim N(0, \sigma_g^2)$,	Abweichung in des j -ten Termin auf der im -ten Parzelle
$h_{ikm} \sim N(0, \sigma_h^2)$,	Abweichung der k -ten Tiefe auf der im -ten Parzelle
$e_{ijkm} \sim N(0, \sigma_e^2)$,	Restfehler

Das Modell ähnelt dem für ein Strip-plot Design, sofern man dort die Blockeffekte als zufällig betrachtet.

Tab. 8.5: Implikation des Strip-plot Modells für Kovarianzen verschiedener Beobachtungspaare auf derselben Parzelle.

Paar von Beobachtungen	Kovarianz
Selbe Tiefe, selber Zeitpunkt	$\sigma_f^2 + \sigma_g^2 + \sigma_h^2$
Selbe Tiefe, verschiedene Zeitpunkte	$\sigma_f^2 + \sigma_h^2$
Selber Zeitpunkt, verschiedene Tiefen	$\sigma_f^2 + \sigma_g^2$
Verschiedene Zeitpunkte, verschiedene Tiefen	σ_f^2

Selbe Beobachtung (Varianz einer Beobachtung)	$\sigma_f^2 + \sigma_g^2 + \sigma_h^2 + \sigma_e^2$

Ein alternatives Modell ist wie folgt:

$$r_{ijkm} = g_{ijm} + h_{ikm} + e_{ijkm}$$

Hierbei ist der Parzelleneffekt f_{im} weggefallen. Die Effekte g_{ijm} und h_{ikm} können nun mit einem autokorrelativen Struktur modelliert werden (UN, CS, AR(1), etc.), während der Rest weiterhin unaghängig verteilt ist nach $e_{ijkm} \sim N(0, \sigma_e^2)$.

Mittel f_{im}	Parzellenspezifischer Effekt			AIC
	Termin g_{ijm}	Tiefe h_{ikm}	Termin $\times$ Tiefe e_{ijkm}	
unabh.	unabh.	unabh.	unabh.	562,0
-	UN	CS	unabh.	566,1
-	CS	UN	unabh.	545,6
-	AR(1)	UN	unabh.	545,7
-	AR(1)	AR(1)	unabh.	559,3
-	CS	CS	unabh.	564,0

Mit dem am besten passenden Modell führen wir die Tests für die festen Effekte durch:

The Mixed Procedure

Type 3 Tests of Fixed Effects

Effect	Num DF	Den DF	F Value	Pr > F
block	3	6	0.73	0.5700
termin	2	18	51.51	<.0001
tiefe	3	7	62.53	<.0001
termin*tiefe	6	54	62.13	<.0001
boden	2	8.29	23.01	0.0004
termin*boden	4	18	28.12	<.0001
tiefe*boden	6	8.09	9.28	0.0029
termin*tiefe*boden	12	54	32.09	<.0001

Die sich anschließenden Mittelwertvergleiche werden hier nicht besprochen.

SAS Anweisungen

```

data nmin;
input termin block tiefe boden Nmin;
datalines;
1      1      1      1      8.48
1      1      2      1      5.74
1      1      3      1      6.49
1      1      4      1      7.18
1      1      1      2      20.61
1      1      2      2      5.16
1      1      3      2      4.35
1      1      4      2      4.41
1      1      1      3      9.10
1      1      2      3      5.86
1      1      3      3      3.45
1      1      4      3      4.65
1      2      1      2      4.95
1      2      2      2      3.23
1      2      3      2      2.91
1      2      4      2      2.14
1      2      1      1      7.35
1      2      2      1      3.81
1      2      3      1      2.88
1      2      4      1      2.37
1      2      1      3      10.56
1      2      2      3      4.55
1      2      3      3      2.94
1      2      4      3      4.28
1      3      1      1      5.41
1      3      2      1      3.23

```

1	3	3	1	2.63
1	3	4	1	2.93
1	3	1	3	13.66
1	3	2	3	7.90
1	3	3	3	4.88
1	3	4	3	9.15
1	3	1	2	7.13
1	3	2	2	5.14
1	3	3	2	2.76
1	3	4	2	2.35
1	4	1	2	6.85
1	4	2	2	4.43
1	4	3	2	2.87
1	4	4	2	1.94
1	4	1	3	6.78
1	4	2	3	3.83
1	4	3	3	2.98
1	4	4	3	2.51
1	4	1	1	8.26
1	4	2	1	3.39
1	4	3	1	2.91
1	4	4	1	4.05
2	1	1	1	29.57
2	1	2	1	1.18
2	1	3	1	5.65
2	1	4	1	8.74
2	1	1	2	9.68
2	1	2	2	4.14
2	1	3	2	3.07
2	1	4	2	4.31
2	1	1	3	4.45
2	1	2	3	3.27
2	1	3	3	2.04
2	1	4	3	2.91
2	2	1	2	5.75
2	2	2	2	4.22
2	2	3	2	2.29
2	2	4	2	4.38
2	2	1	1	36.47
2	2	2	1	8.84
2	2	3	1	3.96
2	2	4	1	6.02
2	2	1	3	7.71
2	2	2	3	6.26
2	2	3	3	3.94
2	2	4	3	4.03
2	3	1	1	23.82
2	3	2	1	6.53
2	3	3	1	5.89

2	3	4	1	14.93
2	3	1	3	4.95
2	3	2	3	4.64
2	3	3	3	4.17
2	3	4	3	4.29
2	3	1	2	6.04
2	3	2	2	3.04
2	3	3	2	2.10
2	3	4	2	2.31
2	4	1	2	10.61
2	4	2	2	2.87
2	4	3	2	2.26
2	4	4	2	2.85
2	4	1	3	4.61
2	4	2	3	2.46
2	4	3	3	2.02
2	4	4	3	2.41
2	4	1	1	37.06
2	4	2	1	9.26
2	4	3	1	5.30
2	4	4	1	7.09
3	1	1	1	39.36
3	1	2	1	17.49
3	1	3	1	6.89
3	1	4	1	6.54
3	1	1	2	44.82
3	1	2	2	11.75
3	1	3	2	5.54
3	1	4	2	9.49
3	1	1	3	6.01
3	1	2	3	5.08
3	1	3	3	2.28
3	1	4	3	2.04
3	2	1	2	43.72
3	2	2	2	12.63
3	2	3	2	4.62
3	2	4	2	4.33
3	2	1	1	45.92
3	2	2	1	26.49
3	2	3	1	8.51
3	2	4	1	8.65
3	2	1	3	7.35
3	2	2	3	4.92
3	2	3	3	2.97
3	2	4	3	2.71
3	3	1	1	34.04
3	3	2	1	13.80
3	3	3	1	5.90
3	3	4	1	6.00

3	3	1	3	4.43
3	3	2	3	5.06
3	3	3	3	2.67
3	3	4	3	1.86
3	3	1	2	31.28
3	3	2	2	6.43
3	3	3	2	2.81
3	3	4	2	2.93
3	4	1	2	32.87
3	4	2	2	8.96
3	4	3	2	4.05
3	4	4	2	3.69
3	4	1	3	4.90
3	4	2	3	3.06
3	4	3	3	2.23
3	4	4	3	2.36
3	4	1	1	43.66
3	4	2	1	21.06
3	4	3	1	8.53
3	4	4	1	8.69

```

;
proc mixed data=nmin scoring=100;
class termin block tiefe boden;
model Nmin=block termin|tiefe|boden/ddfm=kr;
random termin/sub=block*boden type=cs;
random tiefe/sub=block*boden type=un;
run;

```

9. Versuchsserien

Beispiel 9.1: Das Bundessortenamt prüft neue Sorten an einer Reihe von Standorten, um deren Leistungspotential einschätzen zu können (Wertprüfungen). Versuchsergebnisse werden in der sog. Beschreibenden Sortenliste veröffentlicht. Hierbei werden Mittelwerte über die Standorte zugrundegelegt. Diese Berechnung von Mittelwerten über die Standorte basiert auf der Annahme, dass die Standorte eine repräsentative Stichprobe aus einer definierten Grundgesamtheit von Standorten darstellen. Strenggenommen sind die Versuchsstandorte zwar keine echte Zufallsstichprobe, da Logistik, Gleichmässigkeit der Verteilung, etc. bei der Auswahl eine Rolle spielen. Trotzdem werden Sortenversuche in der Regel unter der Annahme zufälliger Orts- bzw. Umwelteffekte ausgewertet. Wir vollziehen dies hier anhand eines Datensatzes für Hafer nach, bei dem die echte Zufallsauswahl der Standorte sicher nicht streng erfüllt ist, weisen aber darauf hin, dass die Zufallsauswahl der Standorte eine Voraussetzung für die Gültigkeit der Analyse ist. Es wurden 14 Hafersorten an 18 Standorten geprüft. An jedem Ort wurde der Versuch in einer randomisierten vollständigen Blockanlage ausgewertet (**hafer.dat**).

Ziel: Berechnung von Mittelwerten über die Standorte; dabei adäquate Berücksichtigung der Varianz-Kovarianz-Struktur durch Gewichtung.

Modellierung: Ein einfaches varianzanalytisches Modell kann basierend auf dem Modell für einen Einzelversuch entwickelt werden. Dieses ist gegeben durch

$$y_{ik} = \mu + \tau_i + b_k + e_{ik}$$

wobei

y_{ik} = Ertrag der i -ten Sorte im k -ten Block

μ = Gesamtmittel

τ_i = Effekt der i -ten Sorte

b_k = Effekt des k -ten Block

e_{ik} = Versuchsfehler von y_{ik}

Eine Erweiterung auf eine Versuchsserie über mehrere Orte erreicht man formal einfach durch Hinzunahme eines Index (j) für die Orte:

$$y_{ijk} = \mu_j + \tau_{ij} + b_{jk} + e_{ijk}$$

wobei

y_{ijk} = Ertrag der i -ten Sorte im k -ten Block am j -ten Ort

μ_j = Gesamtmittel am j -ten Ort

τ_{ij} = Effekt der i -ten Sorte am j -ten Ort

b_{jk} = Effekt des k -ten Block am j -ten Ort

e_{ijk} = Versuchsfehler von y_{ijk}

Die Effekte μ_j und τ_{ij} sind in diesem Modell vermengt. Sie spiegeln die Effekte der Faktoren Sorten und Ort wieder. Diese Effekte können durch ein zweifaktorielles Modell für Sorte und Ort ersetzt werden:

$$\mu + \alpha_i + \beta_j + (\alpha\beta)_{ij}$$

wobei

μ = Gesamtmittel

α_i = (Haupt-) Effekt der i -ten Sorte

β_j = (Haupt-) Effekt des j -ten Ortes

$(\alpha\beta)_{ij}$ = Wechselwirkung der i -ten Sorte und des j -ten Ortes

Einsetzen in das Gesamtmodell anstelle der Effekte μ_j und τ_{ij} liefert:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + b_{jk} + e_{ijk}$$

Wenn nun der Faktor Ort als zufällig betrachtet wird, so sind der Ortshaupteffekt sowie die Wechselwirkung Sorte $\times$ Ort zufällig. Ausserdem ist der Blockeffekt zufällig, da er hierarchisch innerhalb der Orte geschachtelt ist. Also sind folgende Verteilungsannahmen sinnvoll:

$$\beta_j \sim N(0, \sigma_\beta^2)$$

$$(\alpha\beta)_{ij} \sim N(0, \sigma_{\alpha\beta}^2)$$

$$b_{jk} \sim N(0, \sigma_b^2)$$

$$e_{ijk} \sim N(0, \sigma^2)$$

Varianzheterogenität: Dieses Modell impliziert, dass die Fehlervarianzen in jedem Versuch gleich gross sind. Dies stellt eine starke Annahme dar. In der Praxis werden oft grosse Unterschiede in der Genauigkeit von Versuchen festgestellt. Das Modell mit homogenen Varianzen sollte daher gegen ein Modell mit heterogenen Varianzen geprüft werden, bei dem jeder Ort eine eigene Fehlervarianz aufweist:

$$e_{ijk} \sim N(0, \sigma_j^2)$$

Für jedes Modell kann die Restricted Log-Likelihood (LL_R) basierend auf der REML Methode berechnet werden. Unter der Nullhypothese der Varianzhomogenität folgt die Teststatistik

$$T = -2 [LL_R(\text{homogen}) - LL_R(\text{heterogen})]$$

einer χ^2 -Verteilung mit $(J-1)$ Freiheitsgraden, wobei J die Zahl der Orte ist. Dieses Test ist ein sog. **Likelihood-Quotienten-Test** (Likelihood-Ratio-Test; LRT). LRT sind generell anwendbar zum Vergleich zweier Modelle, bei denen das eine ein Spezialfall eines allgemeineren Modells ist. Man sagt auch, das als Spezialfall betrachtete Modell ist das **reduzierte Modell**, während das allgemeinere Modell das **volle Modell** ist. In unserem Fall ist das Modell mit heterogenen Fehlervarianzen das

volle Modell und das Modell mit homogenen Varianzen das reduzierte Modell, also ein Spezialfall des vollen Modells mit der Restriktion

$$\sigma_1^2 = \sigma_2^2 = \dots = \sigma_J^2$$

Für die Haferdaten finden wir (mit MIXED):

Modell	$-2LL_R$
homogene Varianzen	3808,8
heterogene Varianzen	3644,5
$T = 164,3$	

Die Likelihood-Quotienten-Statistik hat den Wert $T = 164,3$ und gegenüber einer χ^2 -Verteilung mit $(J - 1) = 17$ Freiheitsgraden (kritischer Wert bei $\alpha = 5\%$: 27,59) deutlich signifikant. Es besteht also Varianzheterogenität, was bei der Auswertung zu berücksichtigen ist.

Auswertung: Für die Berechnung von Mittelwerten über die Orte arbeiten wir aufgrund der signifikanten Varianzheterogenität mit einem Modell, welches heterogene Fehlervarianzen umfasst, wobei nun alle Effekte ausser dem Sorteneffekten aus zufällig zu betrachten sind. Die REML Analyse basierend auf diesem Modell liefert gewichtete Mittelwerte, wobei die geschätzten Varianzkomponenten in die Berechnung der Gewichte eingehen. Freiheitsgrade und approximative Varianzen der Mittelwerte können nach der allgemeinen Methode von Kenward und Roger (1997) berechnet werden. In der Tabelle 16.1 sind die gewichteten Mittelwerte sowie die dazugehörigen Standardfehler eines Mittelwertes und einer Mittelwertdifferenz angegeben. Die bisher beschriebene Analyse findet sich unter "1-Schritt", "alle außer α_i " und "heterogen": Im Modell sind die Fehlervarianzen heterogen, alle Effekte außer α_i sind zufällig, und es handelt sich um eine sog. 1-Schrittanalyse, bei der die Originaldaten (Einzelwerte je Parzelle) im Gegensatz zur sog. 2-Schritt-Analyse (siehe unten) in einem Schritt analysiert werden. Die Varianzkomponentenschätzungen sind in Tabelle 16.2 angegeben. Man sieht, dass es deutliche numerische Unterschiede in den Fehlervarianzen gibt. Zum Vergleich wurden die Daten unter Annahme homogener Fehlervarianzen analysiert (Tab. 16.1). Die Unterschiede sind gering, und der Standardfehler einer Differenz (SED) ist etwas größer, was für eine etwas höhere Effizienz der gewichteten Analyse spricht. Allerdings sind die Unterschiede der Mittelwertschätzungen relativ gering.

Ort und Block fest: Eine Alternative Auswertung ist möglich, wenn die Ortshaupteffekte (β_j) und die Blockeffekte (b_{jk}) formal als fest betrachtet werden. Dies ist dann zulässig, wenn lediglich die Mittelwertdifferenzen (Kontraste) von Interesse sind und mit einem Standardfehler versehen werden sollen. Generell können in einem gemischten Modell alle zufälligen Effekte, die mit den zu analysierenden festen Effekten (hier: Sorteneffekte) keinen Index gemeinsam haben, also weder mit diesen gekreuzt noch innerhalb dieser hierarchisch geschachtelt sind, formal als fest betrachtet werden. Die einzige Einschränkung ist, dass lediglich Kontraste der betreffenden festen Effekte von Interesse sind (hier: Sortendifferenzen). Dies trifft für

den Block- und den Ortshaupteffekt zu, nicht aber für die Wechselwirkungen $[(\alpha\beta)_{ij}]$ und die Fehler (e_{ijk}), die den Index i mit dem Sorteneffekt α_i gemeinsam haben und daher in jedem Fall als zufällig betrachtet werden müssen. Man betrachte als Vergleich die Analyse geplanter unvollständiger Blockanlagen, bei der die Blockeffekte wahlweise als fest oder zufällig betrachtet werden können, je nachdem ob die Interblockinformation genutzt werden soll oder nicht. Dort hat im Modell $y_{ij} = \mu + \tau_i + b_j + e_{ij}$ der Blockeffekt (b_j) keinen Index mit dem Behandlungseffekt (τ_i) gemeinsam. Die Schätzungen für die 1-Schritt-Analyse mit festen Ortshaupt- und Blockeffekten finden sich in Tab. 16.1 unter "nur $(\alpha\beta)_{ij}$ und e_{ijk} ". Die Mittelwertschätzungen sind im Fall homogener Varianzen wegen der Balanziertheit der Daten identisch mit denen bei Annahme zufälliger Ortshaupt- und Blockeffekte, bei heterogenen Varianzen sind die Unterschiede minimal. Die Standardfehler einer Differenz sind ebenfalls identisch bzw. nahezu identisch, während der Standardfehler eines Mittelwertes hier viel zu klein und inadäquat ist, weil die Varianz der Ortshaupt und Blockeffekte ignoriert wird.

Dies soll am Beispiel der Auswertung unter Annahme homogener Varianzen erläutert werden. Wegen der Balanciertheit der Daten entsprechen gewichtete den einfachen ungewichteten Mittelwerten (Piepho und Spilke, 1999). Wenn wir für die beobachtungen y_{ijk} das lineare Modell $[y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + b_{jk} + e_{ijk}]$ einsetzen, so ergibt sich:

$$\bar{y}_{i..} = \mu + \alpha_i + \bar{\beta}_{.} + \overline{(\alpha\beta)}_{i.} + \bar{b}_{..} + \bar{e}_{i..}$$

Für die Differenz zweier Mittelwerte finden wir:

$$\bar{y}_{i..} - \bar{y}_{i'..} = \alpha_i - \alpha_{i'} + \overline{(\alpha\beta)}_{i.} - \overline{(\alpha\beta)}_{i'.} + \bar{e}_{i..} - \bar{e}_{i'..}$$

Die Differenz ist frei von Block- und Ortshaupteffekten. Aus diesem Grunde ist bei der Analyse von Mittelwertdifferenzen unerheblich, ob diese Effekte als fest oder zufällig betrachtet werden. Allerdings wird aus der Formel für $\bar{y}_{i..}$ auch deutlich, dass für die Beurteilung der Genauigkeit der Mittelwerte selber diese Effekte zu berücksichtigen und als zufällig zu betrachten sind.

2-Schritt-Analyse: Die Berechnung der 1-Schrittanalyse mit SAS ist schon bei mittleren Datenumfängen (ca. 1000 Beobachtungen) äußerst rechenzeitintensiv. Daher ist eine approximative 2-Schritt-Analyse zu erwägen, bei der im ersten Schritt Mittelwerte der Sorten je Versuch berechnet werden, die dann im 2. Schritt einer Sorte $\times$ Ort Serienauswertung unterzogen werden (FRENSHAM et al., 1997; PIEPHO, 1999a). Das Modell für die Mittelwerte lautet:

$$y_{ij} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + e_{ij}$$

Hierbei ist

y_{ij} = Mittelwert der i -ten Sorte am j -ten Ort

e_{ij} = Fehler des Mittelwertes e_{ij}

Im ersten Schritt lässt sich die Varianz des Mittelwertes y_{ij} schätzen, wobei hier zur Berechnung der Varianz der Einfachheit halber die Blöcke als feste Effekte betrachten. Im zweiten Schritt der Analyse werden dann Blöcke als implizit als zufällige Effekte berücksichtigt, weil der Umwelthaupteffekt den mittleren Blockeffekt je Versuch subsumiert. Das Ergebnis der 2-Schrittanalyse findet sich in den letzten beiden Spalten der Tab. 9.1. Die numerischen Unterschiede zur Einschrittanalyse sind minimal. Da die 2-Schrittanalyse erheblich weniger Rechenzeit benötigt, wird diese im folgenden bei der Entwicklung verschiedener Modelle für die Sorte $\times$ Ort Wechselwirkungen zugrundegelegt.

Tabelle 9.1: Mittelwerte mit Standardfehlern basierend auf der Auswertung nach verschiedenen gemischten Modellen.

Analyse	1-Schritt				2-Schritt	
Zufällige Effekte	alle außer α_i		nur $(\alpha\beta)_{ij}$ und e_{ijk}		alle außer α_i	nur $(\alpha\beta)_{ij}$ und e_{ijk}
Fehler-varianzen	homogen	heterogen	homogen	heterogen	heterogen	heterogen
1	53,65	53,70	53,65	53,71	53,70	53,70
2	51,07	51,05	51,07	51,05	51,06	51,06
3	55,67	55,69	55,67	55,69	55,72	55,72
4	56,24	56,54	56,24	56,54	56,53	56,53
5	55,98	55,86	55,98	55,86	55,85	55,85
6	53,61	53,58	53,61	53,58	53,59	53,59
7	53,81	53,82	53,81	53,83	53,82	53,82
8	52,37	52,19	52,37	52,19	52,16	52,16
9	58,47	58,58	58,47	58,58	58,59	58,59
10	56,58	56,54	56,58	56,54	56,56	56,56
11	53,86	53,90	53,86	53,90	53,88	53,88
12	57,24	56,96	57,24	56,97	56,97	56,97
13	54,72	54,84	54,72	54,84	54,83	54,83
14	53,77	53,78	53,77	53,78	53,79	53,79
Standardfehler	2,27	2,27	0,68	0,67	2,27	0,68
SED [§]	0,96	0,95	0,96	0,95	0,96	0,96

§ SED = Standardfehler einer Differenz

Tabelle 9.1: Varianzkomponentenschätzungen für die Haferdaten.

Effekt	Varianzkomponente	Schätzwert
Haupteffekt Ort	σ_{β}^2	82,34
Sorte $\times$ Ort Wechselwirkung	$\sigma_{\alpha\beta}^2$	6,07
Block innerhalb Ort	σ_b^2	7,74
Fehler Ort 1	σ_1^2	3,29
Fehler Ort 2	σ_2^2	5,39
Fehler Ort 3	σ_3^2	11,04
Fehler Ort 4	σ_4^2	6,00
Fehler Ort 5	σ_5^2	3,55
Fehler Ort 6	σ_6^2	9,76
Fehler Ort 7	σ_7^2	5,95
Fehler Ort 8	σ_8^2	4,73
Fehler Ort 9	σ_9^2	9,71
Fehler Ort 10	σ_{10}^2	15,21
Fehler Ort 11	σ_{11}^2	6,35
Fehler Ort 12	σ_{12}^2	5,36
Fehler Ort 13	σ_{13}^2	7,20
Fehler Ort 14	σ_{14}^2	7,95
Fehler Ort 15	σ_{15}^2	44,07
Fehler Ort 16	σ_{16}^2	4,90
Fehler Ort 17	σ_{17}^2	7,64
Fehler Ort 18	σ_{18}^2	11,11

SAS-Anweisungen:

Hier werden lediglich Anweisungen für die 2-Schritt-Analyse gegeben, da die 1-Schritt-Analyse aufgrund des hohen Rechenaufwandes mit SAS nicht praktikabel ist. Alle 1-Schritt-Analyse wurden mit ASREML (<ftp://ftp.res.bbsrc.ac.uk/pub/aar/>) durchgeführt.

```
data t;
input sorte ort block ertrag;
datalines;
  1  1  1  58.1300
  1  1  2  60.8000
<mehr Daten>
 14 18  2  71.5000
```

```

14 18 3 60.0000
14 18 4 60.0000
;
/*Zweischrittanalyse*/

proc sort data=t out=t;
by ort;
run;

/*Berechnen der Mittelwerte und Standardfehler*/
proc mixed data=t;
class sorte block;
model ertrag=sorte block;
lsmeans sorte;
make 'LsMeans' out=lsm;
by ort;

data lsm;
set lsm;
ertrag=estimate;
var_mean=StdErr**2;
w=1/var_mean;

/*2-Schritt, ort zufaellig*/
proc mixed data=lsm;
class sorte ort;
weight w;
model ertrag=sorte/ddfm=kenwardroger;
random int sorte/sub=ort;
parms (1)(1)(1)/eqcons=3;
lsmeans sorte/pdiff;
repeated;
run;

/*2-Schritt, ort fest*/
proc mixed data=lsm;
class sorte ort;
weight w;
model ertrag=sorte ort/ddfm=kenwardroger;
random int/sub=ort*sorte;
parms (1)(1)/eqcons=2;
lsmeans sorte/pdiff;
repeated;
run;

```

Hier wird die REPEATED Anweisung ohne Optionen aufgerufen. In Kombination mit der PARMS Anweisung, welche Startwerte für die Varianzkomponenten übergibt und mittels der EQCONS-Option die Restvarianz gleich 1 setzt, sowie der Übergabe der Gewichte mittels der WEIGHT-Anweisungen wird die Restvarianz jeder Beobachtung mit dem Kehrwert der in der WEIGHT-Anweisung übergebenen Gewichtvariable

(hier: Kehrwert der Varianz) multipliziert. In den REML-Iterationen wird die Restvarianz durch die EQCONS-Option beim vorgegebenen Wert festgehalten und als bekannter Parameter betrachtet.

Modellierung der Sorte $\times$ Ort Wechselwirkungen:

Zur Fokussierung auf die Sorte $\times$ Ort Wechselwirkungen betrachten wir im folgenden das Modell für den Erwartungswert der i -ten Sorte in der j -ten Umwelt:

$$\eta_{ij} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij}$$

Hierin ist η_{ij} der bedingte Erwartungswert der i -ten Sorte am j -ten Ort. Bisher wurde die Annahme getroffen, dass

$$\beta_j \sim N(0, \sigma_\beta^2)$$

$$(\alpha\beta)_{ij} \sim N(0, \sigma_{\alpha\beta}^2)$$

Dies impliziert eine relativ einfache Varianz-Kovarianz-Struktur für die Erwartungswerte η_{ij} . Im Englischen läuft diese unter der Bezeichnung

"Compound Symmetry":

$$\text{var}(\eta_{ij}) = \sigma_\beta^2 + \sigma_{\alpha\beta}^2$$

$$\text{cov}(\eta_{ij}, \eta_{i'j}) = \sigma_\beta^2$$

(var = Varianz, cov = Kovarianz). In Matrizenschreibweise (exemplarisch für nur 4 Sorten; für 18 Sorten ist eine 18×18 Matrix anzusetzen):

$$\text{var} \begin{pmatrix} \eta_{1j} \\ \eta_{2j} \\ \eta_{3j} \\ \eta_{4j} \end{pmatrix} = \begin{pmatrix} \sigma_\beta^2 + \sigma_{\alpha\beta}^2 & \sigma_\beta^2 & \sigma_\beta^2 & \sigma_\beta^2 \\ \sigma_\beta^2 & \sigma_\beta^2 + \sigma_{\alpha\beta}^2 & \sigma_\beta^2 & \sigma_\beta^2 \\ \sigma_\beta^2 & \sigma_\beta^2 & \sigma_\beta^2 + \sigma_{\alpha\beta}^2 & \sigma_\beta^2 \\ \sigma_\beta^2 & \sigma_\beta^2 & \sigma_\beta^2 & \sigma_\beta^2 + \sigma_{\alpha\beta}^2 \end{pmatrix}$$

Insbesondere hat hier jede Sorte dieselbe Varianz über die Orte, und jedes Paar von Sorten hat dieselbe Korrelation bzw. Kovarianz. Nun kann es sein, dass manche Sorten eine grössere Streuung über die Orte aufweisen als andere. Man kann auch sagen, solche Sorten weisen eine grössere Instabilität auf. Das "Compound Symmetry" Modell lässt diese Varianzheterogenität nicht zu. Eine Erweiterung, die auf Vorschlägen von Wricke (1962) und Shukla (1972) beruht, beinhaltet die Annahme heterogener Interaktionsvarianzen.

Wricke-Shukla Modell:

$$\beta_j \sim N(0, \sigma_\beta^2)$$

$$(\alpha\beta)_{ij} \sim N(0, \sigma_{\alpha\beta(i)}^2)$$

$$\text{var}(\eta_{ij}) = \sigma_{\beta}^2 + \sigma_{\alpha\beta(i)}^2$$

$$\text{cov}(\eta_{ij}, \eta_{i'j}) = \sigma_{\beta}^2$$

Hierbei ist

$$\sigma_{\alpha\beta(i)}^2 = \text{Stabilitätsvarianz der } i\text{-ten Sorte}$$

In Matrizenschreibweise (exemplarisch für nur 4 Sorten; für 18 Sorten ist eine 18×18 Matrix anzusetzen):

$$\text{var} \begin{pmatrix} \eta_{1j} \\ \eta_{2j} \\ \eta_{3j} \\ \eta_{4j} \end{pmatrix} = \begin{pmatrix} \sigma_{\beta}^2 + \sigma_{\alpha\beta(1)}^2 & \sigma_{\beta}^2 & \sigma_{\beta}^2 & \sigma_{\beta}^2 \\ \sigma_{\beta}^2 & \sigma_{\beta}^2 + \sigma_{\alpha\beta(2)}^2 & \sigma_{\beta}^2 & \sigma_{\beta}^2 \\ \sigma_{\beta}^2 & \sigma_{\beta}^2 & \sigma_{\beta}^2 + \sigma_{\alpha\beta(3)}^2 & \sigma_{\beta}^2 \\ \sigma_{\beta}^2 & \sigma_{\beta}^2 & \sigma_{\beta}^2 & \sigma_{\beta}^2 + \sigma_{\alpha\beta(4)}^2 \end{pmatrix}$$

Durch die von der Sorte abhängige Stabilitätsvarianz wird eine Varianzheterogenität zwischen den Sorten induziert. Allerdings wird wie beim "Compound Symmetry" Modell davon ausgegangen, dass die Kovarianz für alle Paare von Sorten dieselbe ist. Dies kann beispielsweise dann eine unrealistische Annahme sein, wenn zwei Sorten A und B dieselbe Resistenzeigenschaft gegen einen Krankheitserreger aufweisen, während eine Sorte C diese Resistenz nicht aufweist. Es ist dann zu erwarten, dass die Sorten A und B über Orte mit verschiedenem Krankheitsdruck eine größere Kovarianz aufweisen als die Sorten A und C oder die Sorten B und C. Das realistischste Modell ist daher sicher das unstrukturierte Modell, bei dem Varianzen und Kovarianzen frei wählbar sind. In diesem Modell entfällt die Unterscheidung zwischen Haupteffekt für Orte β_j und Wechselwirkung $(\alpha\beta)_{ij}$.

Unstrukturiert:

$$\eta_{ij} = \mu + \alpha_i + \gamma_{ij}$$

wobei

γ_{ij} = Für den j -ten Ort spezifische Abweichung des bedingten Erwartungswertes η_{ij} der i -ten Sorte vom Erwartungswert der i -ten Sorte $(\mu + \alpha_i)$.

$$\text{var}(\eta_{ij}) = \text{var}(\gamma_{ij}) = \sigma_{\gamma(i)}^2 = \sigma_{\gamma(ii)}$$

$$\text{cov}(\eta_{ij}, \eta_{i'j}) = \text{cov}(\gamma_{ij}, \gamma_{i'j}) = \sigma_{\gamma(ii')}$$

In Matrix-Schreibweise:

$$\text{var} \begin{pmatrix} \eta_{1j} \\ \eta_{2j} \\ \eta_{3j} \\ \eta_{4j} \end{pmatrix} = \begin{pmatrix} \sigma_{\gamma(11)} & \sigma_{\gamma(12)} & \sigma_{\gamma(13)} & \sigma_{\gamma(14)} \\ \sigma_{\gamma(21)} & \sigma_{\gamma(22)} & \sigma_{\gamma(23)} & \sigma_{\gamma(24)} \\ \sigma_{\gamma(31)} & \sigma_{\gamma(32)} & \sigma_{\gamma(33)} & \sigma_{\gamma(34)} \\ \sigma_{\gamma(41)} & \sigma_{\gamma(42)} & \sigma_{\gamma(43)} & \sigma_{\gamma(44)} \end{pmatrix}$$

Dieses Modell hat allerdings sehr viele Parameter: I Varianzen und $I(I-1)/2$ Kovarianzen, wobei I die Zahl der Sorten ist.

Ein weiteres sehr beliebtes Modell beinhaltet eine Regression auf eine hypothetische Umweltkovariable u_j , auch als Faktor bezeichnet, die das Ertragspotential der Umwelt charakterisiert. Wir bezeichnen es hier nach einer der relevanten Arbeiten als

Finlay-Wilkinson Modell:

$$\eta_{ij} = \mu + \alpha_i + \lambda_i u_j + \delta_{ij}$$

wobei

λ_i = Steigung der i -ten Sorte

u_j = Wert der latenten Variable am j -ten Ort

δ_{ij} = Abweichung von der Regression für die i -te Sorte am j -ten Ort

$$u_j \sim N(0, \sigma_u^2)$$

$$\delta_{ij} \sim N(0, \sigma_\delta^2)$$

$$\text{var}(\eta_{ij}) = \lambda_i^2 \sigma_u^2 + \sigma_\delta^2$$

$$\text{cov}(\eta_{ij}, \eta_{i'j}) = \lambda_i \lambda_{i'} \sigma_u^2$$

Das Modell ist überparametrisiert. Um alle Modellparameter identifizieren, wird ohne Beschränkung der Allgemeinheit folgende Restriktion eingeführt:

$$\sigma_u^2 = 1$$

In Matrizenschreibweise (exemplarisch für nur 4 Sorten; für 18 Sorten ist eine 18×18 Matrix anzusetzen):

$$\text{var} \begin{pmatrix} \eta_{1j} \\ \eta_{2j} \\ \eta_{3j} \\ \eta_{4j} \end{pmatrix} = \begin{pmatrix} \lambda_1^2 + \sigma_\delta^2 & \lambda_1 \lambda_2 & \lambda_1 \lambda_3 & \lambda_1 \lambda_4 \\ \lambda_2 \lambda_1 & \lambda_2^2 + \sigma_\delta^2 & \lambda_2 \lambda_3 & \lambda_2 \lambda_4 \\ \lambda_3 \lambda_1 & \lambda_3 \lambda_2 & \lambda_3^2 + \sigma_\delta^2 & \lambda_3 \lambda_4 \\ \lambda_4 \lambda_1 & \lambda_4 \lambda_2 & \lambda_4 \lambda_3 & \lambda_4^2 + \sigma_\delta^2 \end{pmatrix}$$

Das Modell lässt sowohl heterogene Varianzen als auch heterogene Kovarianzen zu. Da die latente Variable nicht direkt zu beobachten ist, ist dieses kein eigentliches Regressionsmodell, sondern ein sog. faktoranalytisches Modell.

Das faktoranalytische Modell steht in Beziehung zu einer einfachen und populären graphischen Technik, die auf Finlay und Wilkson (1963) zurückgeht:

- (1) Für jeden Ort wird der Mittelwert über die Sorten berechnet ($\bar{y}_{.j.}$). Dieses stellt ein Maß für das Ertragspotential des Standortes dar.
- (2) Die Ertragsmittel der Sorten je Ort ($\bar{y}_{ij.}$) werden gegen das Ortsmittel ($\bar{y}_{.j.}$) abgetragen. Es wird eine Regressionsgerade durch die Punkte gelegt.

Sorten, die stark auf verbesserte Umweltbedingungen reagieren (Intensivsorten), zeigen eine höhere Steigung der Regressionsgeraden als Sorten, die weniger stark reagieren (Extensivsorten). Ein Beispiel ist in Abb. 9.1 gegeben. Dort hat die Sorte 3 eine etwas geringere Steigung als Sorte 4.




Abb. 9.1: Regression gegen das Ortsmittel für die Sorten 3 und 4. Haferdaten.

Eberhart-Russell (1966) Modell:

$$u_j \sim N(0, \sigma_u^2)$$

$$\delta_{ij} \sim N(0, \sigma_{\delta(i)}^2)$$

$$\text{var}(\eta_{ij}) = \lambda_i^2 \sigma_u^2 + \sigma_{\delta(i)}^2$$

$$\text{cov}(\eta_{ij}, \eta_{i'j}) = \lambda_i \lambda_{i'} \sigma_u^2$$

In Matrixschreibweise (exemplarisch für nur 4 Sorten; für 18 Sorten ist eine 18×18 Matrix anzusetzen):

$$\text{var} \begin{pmatrix} \eta_{1j} \\ \eta_{2j} \\ \eta_{3j} \\ \eta_{4j} \end{pmatrix} = \begin{pmatrix} \lambda_1^2 + \sigma_{\delta(1)}^2 & \lambda_1 \lambda_2 & \lambda_1 \lambda_3 & \lambda_1 \lambda_4 \\ \lambda_2 \lambda_1 & \lambda_2^2 + \sigma_{\delta(2)}^2 & \lambda_2 \lambda_3 & \lambda_2 \lambda_4 \\ \lambda_3 \lambda_1 & \lambda_3 \lambda_2 & \lambda_3^2 + \sigma_{\delta(3)}^2 & \lambda_3 \lambda_4 \\ \lambda_4 \lambda_1 & \lambda_4 \lambda_2 & \lambda_4 \lambda_3 & \lambda_4^2 + \sigma_{\delta(4)}^2 \end{pmatrix}$$

Dieses Modell unterscheidet sich von der Finlay-Wilkinson-Regression dadurch, dass die Varianzen der Abweichungen von der Regression sortenabhängig sind.

Die Resultate für die verschiedenen Modelle sind in Tab. 9.2 wiedergegeben. Das Wricke-Shukla-Modell paßt hier nach dem AIC-Wert am besten. Auch der Vergleich geschachtelter Modelle mittels Likelihood-Quotienten Test (Tab. 9.3) ergibt, dass das Wricke-Shukla-Modell gegen das Compound-Symmetry Modell signifikant ist, während das Finlay-Wilkinson-Modell nicht signifikant ist gegen das Compound-Symmetry Modell. Das unstrukturierte Modell konvergierte nicht, was an der hohen Zahl der Parameter liegt.

Tab. 9.2: Anpassung verschiedener Modelle für die Sorte $\times$ Umwelt Wechselwirkung.

Modell	AIC	$-2LL_R$	Zahl der Varianzparameter
Compound-Symmetry	1307,6	1303,6	2
Wricke-Shukla	1297,8	1267,8	$I + 1 = 15$
Finlay-Wilkinson	1323,8	1293,8	$I + 1 = 15$
Eberhart-Russell	1311,5	1255,5	$2I = 28$
Unstrukturiert	keine Konvergenz		$I(I + 1)/2 = 105$

Tab. 9.3: Vergleich geschachtelter Modelle mittels Likelihood-Quotienten-Test:

Volles Modell	Reduziertes Modell	T	Differenz der Zahl der Parameter	Kritischer χ^2 -Wert $\alpha = 5\%$
Wricke-Shukla	Compound Symmetry	*44,2	13	22,36
Finlay-Wilkinson	Compound Symmetry	10,2	13	22,36
Eberhart-Russell	Wricke-Shukla	12,3	13	22,36

*signifikant

Für die weitere Analyse ist es daher sinnvoll, das Wricke-Shukla Modell zu verwenden. Die Varianzkomponentenschätzungen für das Wricke-Shukla-Modell sind wie folgt (SAS-Output):

Tabelle 9.4: Varianzkomponentenschätzungen für die Haferdaten - 2-Schritt-Analyse für Wricke-Shukla-Modell.

Effekt	Varianzkomponente		Schätzwert
Haupteffekt Ort		σ_{β}^2	86,31
Stabilitätsvarianzen	Sorte 1	$\sigma_{\alpha\beta}^2 (1)$	4,61
	Sorte 2	$\sigma_{\alpha\beta}^2 (2)$	14,70
	Sorte 3	$\sigma_{\alpha\beta}^2 (3)$	8,26
	Sorte 4	$\sigma_{\alpha\beta}^2 (4)$	10,51
	Sorte 5	$\sigma_{\alpha\beta}^2 (5)$	2,10
	Sorte 6	$\sigma_{\alpha\beta}^2 (6)$	0,38
	Sorte 7	$\sigma_{\alpha\beta}^2 (7)$	0,89
	Sorte 8	$\sigma_{\alpha\beta}^2 (8)$	8,26
	Sorte 9	$\sigma_{\alpha\beta}^2 (9)$	10,48
	Sorte 10	$\sigma_{\alpha\beta}^2 (10)$	3,58
	Sorte 11	$\sigma_{\alpha\beta}^2 (11)$	12,13
	Sorte 12	$\sigma_{\alpha\beta}^2 (12)$	0,97
	Sorte 13	$\sigma_{\alpha\beta}^2 (13)$	3,43
	Sorte 14	$\sigma_{\alpha\beta}^2 (14)$	5,76

Die Stabilitätsvarianzen reichen von 0,38 (Sorte 6; relativ stabil) bis 14,69 (Sorte 2; relativ instabil). Diese Unterschiede sind relativ klein im Vergleich zur Varianz des Orthsaupteffektes (86,3), so dass die Stabilitätsunterschiede relativ gering sind. Zum einen können die Varianzkomponenten hier direkt zur Beurteilung der Stabilität herangezogen werden, andererseits beeinflussen die heterogenen Varianzen die Berechnung von Mittelwerten bzw. Mittelwertdifferenzen sowie deren Standardfehlern. Dies soll beispielhaft für den Vergleich der Sorten 5 und 11 mit der Kenward-Roger-Methode verdeutlicht werden. Nach dem Compound Symmetry Modell sind die beiden Sorten bei $\alpha = 5\%$ signifikant verschieden, während dies nach dem Wricke-Shukla Modell nicht der Fall ist. Die Wahl der Varianz-Kovarianz-Struktur ist also nicht unerheblich.

Compound Symmetry:

Differences of Least Squares Means							
Effect	sorte	_sorte	Estimate	Standard Error	DF	t Value	Pr > t
sorte	5	11	1.9701	0.9552	217	2.06	0.0403

Wricke-Shukla:

Differences of Least Squares Means

Effect	sorte	_sorte	Estimate	Standard Error	DF	t Value	Pr > t
sorte	5	11	1.9523	1.0081	20.8	1.94	0.0665

SAS-Anweisungen:

*/*2-Schritt, ort zufaellig, Wricke-Shukla*/*

```
proc mixed data=lsn;
class sorte ort;
weight w;
model ertrag=sorte/ddfm=kenwardroger;
random int/sub=ort;
random int/sub=ort group=sorte;
parms (1)(1)(1)(1)(1)(1)(1)(1)
      (1)(1)(1)(1)(1)(1)(1)(1)/eqcons=16;
lsmeans sorte/pdiff;
repeated;
run;
```

*/*2-Schritt, ort zufaellig, Finlay-Wilkinson*/*

```
proc mixed data=lsn;
class sorte ort;
weight w;
model ertrag=sorte/ddfm=kenwardroger;
random sorte/subject=ort type=fa1(1);
parms (1)(1)(1)(1)(1)(1)(1)(1)
      (1)(1)(1)(1)(1)(1)(1)(1)/eqcons=16;
lsmeans sorte/pdiff;
repeated;
run;
```

*/*2-Schritt, ort zufaellig, Eberhart-Russell*/*

```
proc mixed data=lsn;
class sorte ort;
weight w;
model ertrag=sorte/ddfm=kenwardroger;
random sorte/subject=ort type=fa(1);
parms (1)(1)(1)(1)(1)(1)(1)(1)
      (1)(1)(1)(1)(1)(1)(1)(1)
      (1)(1)(1)(1)(1)(1)(1)(1)
      (1)(1)(1)(1)(1)/eqcons=29;
lsmeans sorte/pdiff;
repeated;
run;
```

Beispiel 9.2: Im Krüger-Nationalpark (Südafrika) werden seit vielen Jahren Zählungen der verschiedenen Tierarten durchgeführt. Hierzu werden in zufällig ausgewählten Regionen die Tiere nach einem definierten Verfahren erhoben. Die Tierarten sind:

Art	Name
1	Eland (A)
2	Giraffe
3	Kudu (A)
4	Roan (A)
5	Sable (A)
6	Tsessebe (A)
7	Zebra
8	Impala (A)
9	Warzenschwein
10	Wasserbüffel
11	Wildebeest (A)

(A = Antilopenart)

Die vorliegenden Daten (**krueger.dat**) weisen eine dreifache Klassifikation auf von Art $\times$ Region $\times$ Jahr. Die Daten wurden logarithmisch transformiert, um eine annähernde Normalverteilung zu erhalten.

Ziel: Ermittlung von Korrelationen zwischen den Arten, um die Wechselbeziehungen der Arten zu studieren. Ermittlung eines Zeittrends für jede Arten.

Modellierung: Für eine einzelne Art kann man das folgende zweifaktorielle Modell ansetzen:

$$y_{ij} = \mu + \alpha_i + \beta_j + e_{ij}$$

wobei

y_{ij} = Tierdichte in der i -ten Region im j -ten Jahr

μ = Gesamtmittel

α_i = Effekt der i -ten Region

β_j = Effekt des j -ten Jahres

e_{ij} = Zufallsabweichung von y_{ij} (Stichprobenfehler + Art $\times$ Umwelt Interaktion)

Verteilungsannahmen:

$$e_{ij} \sim N(0, \sigma^2)$$

Wir können außerdem α_i und β_j als zufällig betrachten, da Regionen zufällig ausgewählt wurden und Jahreseffekte als nicht vorhersehbar sind. Hier wird das Schwergewicht der Analyse auf e_{ij} liegen. Daher ist es möglich, α_i und β_j bei der Analyse formal als fest zu betrachten. Dies ist vergleichbar der Analyse einer unvollständigen Blockanlage ohne Nutzung der Inter-Block-Information, also unter

Annahme fester Blockeffekte, obwohl die Randomisation eine Analyse mit zufälligen Blockeffekten zulassen würde.

Das Interesse der Analyse liegt nun bei den Korrelationen zwischen den Arten. Um diese zu studieren, muß das Modell um den Faktor Arten erweitert werden. Korrelationen können auf der Ebene der Effekte e_{ij} studiert werden. Wir können fragen, ob die Effekte e_{ij} zwischen den Arten korreliert sind. Also muss das erweiterte Modell Korrelationen zwischen den e_{ij} zulassen. Außerdem ist davon auszugehen, dass die Varianzen von e_{ij} zwischen den Arten schwanken.

Wir können das zweifaktorielle Modell für unseren Zweck einfach um den Faktor Art erweitern:

$$y_{ijk} = \mu_k + \alpha_{ik} + \beta_{jk} + e_{ijk}$$

$$(i = 1, \dots, I; j = 1, \dots, J; k = 1, \dots, K)$$

where

y_{ijk} = Tierdichte der k -ten Art in der i -ten Region im j -ten Jahr

μ_k = Gesamtmittel

α_{ik} = Effekt der k -ten Art in der i -ten Region

β_{jk} = Effekt der k -ten Art im j -ten Jahr

e_{ijk} = "Resteffekt" von y_{ijk} ; (2-fach-Wechselwirkung der k -ten Art und Stichprobenfehler

Die Analyse ist nun fokussiert auf die Varianz-Kovarianz-Struktur

$$\text{var}(\mathbf{e}_{ij}) = \text{var}(\mathbf{e}_{ij1}, \mathbf{e}_{ij2}, \dots, \mathbf{e}_{ijK})'$$

Da die Korrelationen sich zwischen den Artpaaren unterscheiden können und Varianzheterogenität zwischen den Arten zu erwarten ist, bietet sich eine unstrukturierte Varianz-Kovarianz-Matrix als Modell an. Daneben gibt es eine Reihe anderer, reduzierter Modelle für die Varianz-Kovarianz-Struktur, von denen hier einige beschrieben und mittels des AIC-Kriteriums geprüft werden.

Unstrukturiertes Modell:

Heterogeneous Compound Symmetry: Die Arten haben verschiedene Varianzen (σ_i^2) und dieselbe Korrelation (ρ).

"Compound Symmetry": Alle Arten haben dieselbe Varianz (σ^2) und dieselbe Korrelation (ρ).

165

Diagonal, heterogen: Die Arten haben verschiedene Varianzen (σ_i^2) und sind unkorreliert.

$$\text{var}(\mathbf{e}_{ij}) = \begin{pmatrix} \sigma_1^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_3^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma_4^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_5^2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma_6^2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \sigma_7^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_8^2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_9^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{10}^2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{11}^2 \end{pmatrix}$$

Diagonal, homogen: Die Arten haben dieselbe Varianz (σ^2) und sind unkorreliert.

$$\text{var}(\mathbf{e}_{ij}) = \begin{pmatrix} \sigma^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma^2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma^2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \sigma^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma^2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma^2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma^2 \end{pmatrix}$$

Tab. 9.5: AIC-Werte für verschiedene Varianz-Kovarianz-Strukturen.

Modell	REPEATED TYPE=	AIC
Unstrukturiert	UN	860,1
Heterogeneous Compound Symmetry	CSH	895,4
Compound Symmetry	CS	1350,6
Diagonal, heterogen	UN(1)	944,9
Diagonal, homogen	-	1362,2

Das unstrukturierte Modell passt nach dem AIC-Wert am besten. Wir verwenden dieses Modell, um die paarweisen Korrelationen zu schätzen:

	1	2	3	4	5	6	7	8	9	10	11
1	1.00	0.04	0.29	-0.05	0.09	0.01	0.24	0.16	0.18	0.09	0.27
2	0.04	1.00	-0.22	-0.11	-0.00	-0.16	<u>0.41</u>	<u>0.56</u>	0.17	0.04	0.04
3	0.29	-0.22	1.00	0.26	0.20	0.10	<u>0.15</u>	0.09	0.04	<u>0.41</u>	0.26
4	-0.05	0.11	0.26	1.00	0.10	-0.01	0.01	-0.10	-0.04	0.16	0.14
5	0.09	-0.00	0.20	0.10	1.00	-0.03	0.35	0.03	0.02	0.08	0.32
6	0.01	-0.16	0.10	-0.01	-0.03	1.00	-0.13	0.02	0.02	0.13	-0.16
7	0.24	0.41	0.15	0.01	0.35	-0.13	1.00	<u>0.44</u>	0.30	0.28	<u>0.59</u>
8	0.16	0.56	0.09	-0.10	0.03	0.02	0.44	1.00	0.35	0.27	0.32
9	0.18	0.17	0.04	-0.04	0.02	0.02	0.30	0.35	1.00	0.21	0.24
10	0.09	0.04	0.41	0.16	0.08	0.13	0.28	0.27	0.21	1.00	0.30
11	0.27	0.04	0.26	0.14	0.32	-0.16	0.59	0.32	0.24	0.30	1.00

Auffällig sind einige Korrelationen über 0,40. Diese können ein Hinweis sein auf Belegung gemeinsamer ökologischer Nischen. Es gibt wenige negative Korrelationen, und die Korrelationen weichen nur schwach von der Null ab, so dass offenbar kaum Konkurrenzbeziehungen vorliegen. Vielmehr scheinen sich die meisten Arten tendentiell an denselben Orten aufzuhalten. Die weitere biologische Interpretation soll hier nicht vertieft werden.

Ein Signifikanztest der Korrelationen ist am einfachsten möglich durch paarweise Auswertung der Daten nach zwei Modellen für die Varianz-Kovarianzstruktur: Unstrukturiert und Diagonal (heterogen). Die 2-fache Differenz der log-likelihood Werte liefert unter der Nullhypothese eine asymptotisch χ^2 -verteilte Zufallsvariable mit einem Freiheitsgrad. Dies soll am Beispiel von Zebra (Art 7) und Wildebeest (Art 11) erläutert werden. die Paarweise Analyse liefert folgende Werte für $-2LL_R$, wobei LL_R die Restricted Log-Likelihood ist (aus Output von MIXED ablesbar):

Modell	REPEATED TYPE=	$-2LL_R$
Unstrukturiert	UN	30,5
Diagonal, heterogen	UN(1)	64,6

Die Differenz beträgt 34,1 und ist signifikant gegen den kritischen Wert der χ^2 -Verteilung mit einem Freiheitsgrad (3,84; $\alpha = 5\%$). Die Korrelation zwischen Zebra und Wildebeest ist also signifikant.

SAS Anweisungen:

```
data;
input
region $    species $    year    logcount;
datalines;
  CDE      Eland      1980      -7.70066
  CDE      Giraffe     1980      -0.70398
  CDE      Kudu       1980      -0.23673
```

CDE	Roan	1980	-7.70066
CDE	Sable	1980	-3.91647
CDE	Tsessebe	1980	-7.70066
CDE	Zebra	1980	0.80385
CDE	impala	1980	1.96215
CDE	wart	1980	-1.46234
CDE	waterb	1980	-1.35328
CDE	wildebee	1980	0.49577
CDE	Eland	1981	-7.70066
.			
.			
.			
SDW	waterb	1992	-2.62128
SDW	wildebee	1992	-1.08084
SDW	Eland	1993	-5.53227
SDW	Giraffe	1993	-1.70092
SDW	Kudu	1993	-1.11948
SDW	Roan	1993	-7.61172
SDW	Sable	1993	-2.11455
SDW	Tsessebe	1993	-5.12681
SDW	Zebra	1993	-0.49208
SDW	impala	1993	1.86429
SDW	wart	1993	-3.25501
SDW	waterb	1993	-2.77543
SDW	wildebee	1993	-1.29275

```

;
proc mixed;
class year region species;
model logcount=species species*year species*region;
repeated species/sub=region*year type=unr rcorr;
run;

```

10. Fehlerfortpflanzung

Beispiel 10.1: Versuch M2 - Viskosität (Physikalisches Praktikum, Universität Hohenheim, Haas und Wizemann, pers. Mitt., August 2002; **physik.dat**): Strömende Flüssigkeiten oder Gase setzen der Fließbewegung einen Widerstand entgegen; sie besitzen eine bestimmte Viskosität. Die Viskosität ist temperaturabhängig. Bei Flüssigkeiten nimmt die Viskosität mit steigender Temperatur ab. Es gilt näherungsweise:

$$\eta = A \cdot e^{\frac{B}{T}} \quad (10.1)$$

wobei

η = Viskosität

T = Temperatur (°K = Grad Kelvin)

A, B = Konstanten

Die Temperaturabhängigkeit der Viskosität soll für eine Salzlösung bestimmt werden, indem die Viskosität bei sieben verschiedenen Temperaturen gemessen wird (jeweils 5 Messwiederholungen). Das Ziel des Versuches ist die Schätzung der Konstanten A und B des Modells (10.1) sowie die Angabe eines Vertrauensintervalls für die geschätzte Regressionsfunktion.

Für die Viskositätsmessung wird die Fließgeschwindigkeit durch eine Kapillare herangezogen. Nach dem Hagen-Poiseuille'schen Gesetz hängen die Durchflusszeit und die Viskosität einer Flüssigkeit linear zusammen nach der Gleichung

$$\eta = c \cdot \rho \cdot t \quad (10.2)$$

wobei

c = Gerätekonstante

ρ = Dichte

t = Durchflusszeit

Um die Viskosität messen zu können, muss zunächst anhand einer Flüssigkeit bekannter Viskosität und Dichte (destilliertes Wasser) die Gerätekonstante c geschätzt werden. Ist diese dann bekannt, so kann für eine neue Flüssigkeit nach der Gleichung $\eta = c \cdot \rho \cdot t$ die Viskosität η bestimmt werden, wobei zuvor die Dichte ρ mit Hilfe eines Aräometers geschätzt werden muss. Hierbei wird die Temperaturabhängigkeit der Dichte ignoriert. Außerdem wurde im vorliegenden Versuch die Dichte nur einmal gemessen und als bekannt vorausgesetzt, was eine Näherung darstellt. Mit Hilfe der Schätzungen von c und dem Wert für ρ kann für vorgegebene Durchflussgeschwindigkeit t die Viskosität η geschätzt werden. Mit den so bestimmten Viskositätswerten wird dann eine nichtlineare Regression nach der Gleichung (10.1) durchgeführt. Problem: Da bei der Berechnung der Viskosität η aus der Durchflusszeit immer derselbe Schätzwert von c verwendet werden, entsteht ein systematischer Schätzfehler, der in der Fehlerrechnung zu berücksichtigen ist.

Anders betrachtet kann man auch sagen, dass Schätzwerte der Viskosität bei verschiedenen Temperaturen korreliert sind, weil immer derselbe Schätzwert von c verwendet wird. Aus diesem Grunde ist die naive Auswertung durch Regression von berechneter Viskosität auf die Zeit bei Annahme unabhängiger Fehler nicht empfehlenswert. Dies wird zwar zu einer konsistenten Schätzung der Regressionskurve führen, aber nicht zu realistischen Vertrauensintervallen. Im folgenden wird ein vielleicht etwas unorthodoxer, jedenfalls in der Physik nicht gebräuchlicher Ansatz auf der Basis eines gemischten Modell vorgestellt, der zu realistischen Vertrauensintervallen führt.

Es liegen die folgenden Daten vor:

(1) Bestimmung von c :

Durchflusszeiten (in sec) von destilliertem Wasser durch Messapparatur:

t	$c = \eta/\rho \cdot t (\times 10^{-8})$
25.4	3.9219
27.0	3.7185
25.8	3.8915
26.5	3.7887
26.2	3.8321
26.2	3.8321

Mittel = 3.8308

Die Viskosität von destilliertem Wasser bei 20 °C beträgt $\eta = 1.002 \cdot 10^{-3} \text{ Pa} \cdot \text{s}$. Die Dichte von destilliertem Wasser beträgt $\rho = 0.998 \cdot 10^3 \text{ kg} \cdot \text{m}^{-3}$. Nach der Gleichung $\eta = c \cdot \rho \cdot t$ kann hieraus nach $c = \eta/\rho \cdot t$ für jede Beobachtung die Gerätekonstante geschätzt werden, wie in der obigen Tabelle angegeben.

(2) Bestimmung der Dichte der zu untersuchenden Salzlösung:

$$\rho = 1.102 \cdot 10^3 \text{ kg} \cdot \text{m}^{-3}$$

Dieser Wert beruht auf einer einmaligen Messung, so dass hier kein Messfehler berechnet werden kann und der Wert als "wahrer" Wert betrachtet werden muss. Dies ist vertretbar, wenn der Messfehler sehr klein ist.

(3) Messung der Durchflussgeschwindigkeit (t ; in s) der Salzlösung bei sieben verschiedenen Temperaturen (T ; in °K), mit jeweils 5 Messwiederholungen:

Temperatur (°K)	Messwiederholung (in s)				
	1	2	3	4	5
294	30.8	30.3	30.4	31.0	30.1
300	27.3	26.8	27.1	27.5	26.9
306	24.1	23.8	24.0	24.6	24.2
311	22.3	22.1	22.2	22.3	22.5
316	20.7	20.3	20.5	21.0	20.8
321	18.6	19.1	19.5	19.3	19.3
325	17.2	17.9	17.7	17.5	17.7

Der folgende Auswertungsansatz beruht auf der Tatsache, dass die Einzelmessungen von c und von t als stochastisch unabhängig betrachtet werden können. Daher werden die (transformierten) Einzel-Messwerte für c und t in einem gemeinsamen Modell verrechnet, wobei Unabhängigkeit der Fehler vorausgesetzt wird. Aus den Parameterschätzungen wird dann die Funktion (10.1) geschätzt.

Der Ansatz geht von folgender Gleichung aus, die sich aus 10.1 sowie der Beziehung (17.2) ergibt:

$$\eta = c \cdot \rho \cdot t = A \cdot e^{B/T}$$

$$\Leftrightarrow \log(\eta) = \log(c) + \log(\rho) + \log(t) = \log(A) + B/T$$

$$\Leftrightarrow \log(t) = D + B/T$$

wobei

$$D = \log(A) - \log(c) - \log(\rho) \Leftrightarrow \log(A) = D + \log(c) + \log(\rho).$$

Diese Betrachtung legt eine Regression von $\log(t)$ auf $1/T$ nahe, wodurch D und B geschätzt werden können. Außerdem kann $\log(c)$ [genauer gesagt der Erwartungswert von $\log(c)$] aus dem Mittelwert der logarithmierten c -Werte geschätzt werden. Addition der Schätzungen von D und $\log(c)$ sowie der bekannten Konstante für $\log(\rho)$ ergeben einen Schätzwert für $\log(A)$. Nehmen wir für $\log(t)$ und $\log(c)$ eine Normalverteilung an, so kann ein Vertrauensintervall für $\log(\eta)$ mit Hilfe von linearen Kontrasten berechnet werden. Hierzu müssen $\log(t)$ und $\log(c)$ in einem gemeinsamen Modell verrechnet werden, welches die Parameter D , B sowie den Erwartungswert von $\log(c)$ hat. Diesen bezeichne ich im folgenden mit

$$E = \log(c)$$

Somit ist

$$\log(A) = D + E + \log(\rho)$$

In der üblichen Schreibweise lautet das lineare Modell

$$y_{ij} = D + Bx_i + e_{ij} \quad (i = 1, \dots, 5)$$

$$y_{6j} = E + e_{6j}$$

wobei

y_{ij} = Wert für $\log(t)$ bei der i -ten Temperatur und der j -ten Messwiederholung
 $(i = 1, \dots, 5)$
 x_i = i -ter Wert von $1/T_i$
 y_{6j} = j -te Messwiederholung von $\log(c)$

Dies kann wie folgt in einem einzigen Modell geschrieben werden:

$$y_{ijk} = \mu_k + Bx_{ik} + e_{ijk}$$

wobei

y_{ijk} = j -te Messwiederholung für die i -te Stufe der k -ten Variable
 $[k=1: \log(t), k=2: \log(c)]$
 μ_k = Achsenabschnitt für die k -te Variable [$\mu_1 = D, \mu_2 = E$]
 x_i = i -ter Wert von $1/T_i$; setze $x_{ik} = 0$ für $k = 2$!!

Da es sich um zwei verschiedene Variablen handelt, muss Varianzheterogenität zwischen den beiden Variablen zugelassen werden, was im Rahmen von PROC MIXED leicht möglich ist (GROUP option).

SAS Anweisungen: Wir benötigen die Daten in der folgenden Form:

Variable	Definition
var	Dummy-Variable zur Unterscheidung von $\log(c)$ und $\log(t)$; Stufen 'T' und 'C'
temp	Temperatur T; wird transformiert zu $x = 1/T$; $x=0$ für $\text{var}='C'$
m	Messwert, c oder t ; werden logarithmiert nach $y = \log(m)$

Die Werte für 'C' im unten stehenden Datenschnitt müssen noch mit 10^{-8} multipliziert werden, was im Datenschnitt realisiert ist. Die Varianzheterogenität zwischen den beiden Variablen wird mit der GROUP Option modelliert.

```
data s;
input var$ temp m;
if var='c' then m=m*1e-8;
x=1/temp;if var='c' then x=0;
y=log(m);
datalines;
c    0 3.9219
c    0 3.7185
c    0 3.8915
c    0 3.7887
c    0 3.8321
c    0 3.8321
```

```

t 294 30.8
t 294 30.3
t 294 30.4
t 294 31.0
t 294 30.1
t 300 27.3
t 300 26.8
t 300 27.1
t 300 27.5
t 300 26.9
t 306 24.1
t 306 23.8
t 306 24.0
t 306 24.6
t 306 24.2
t 311 22.3
t 311 22.1
t 311 22.2
t 311 22.3
t 311 22.5
t 316 20.7
t 316 20.3
t 316 20.5
t 316 21.0
t 316 20.8
t 321 18.6
t 321 19.1
t 321 19.5
t 321 19.3
t 321 19.3
t 325 17.2
t 325 17.9
t 325 17.7
t 325 17.5
t 325 17.7
;
proc mixed data=s;
class var;
model y=var x/solution noint ddfm=kr;
repeated/group=var;
run;

```

Output:

Covariance Parameter Estimates

Cov Parm	Group	Estimate
Residual	var c	0.000361
Residual	var t	0.000201

Solution for Fixed Effects

Effect	var	Estimate	Standard Error	DF	t Value	Pr > t
var	c	-17.0778	0.007761	5	-2200.5	<.0001
var	t	-2.2121	0.07132	33	-31.02	<.0001
x		1654.04	22.1026	33	74.83	<.0001

Die Varianz von $\log(c)$ ist fast doppelt so groß wie die von $\log(t)$. Außerdem finden wir:

$$\hat{D} = -17.08, \hat{E} = -2.21, \hat{B} = 1654.04$$

Somit ist

$$\log(\hat{A}) = \hat{D} + \hat{E} + \log(\rho)$$

und

$$\hat{A} = \rho \cdot \exp(\hat{D} + \hat{E}) = 1.102 \cdot 10^3 \exp(-17.08 - 2.21) = 0.000004620$$

so dass

$$\hat{\eta} = \hat{A} \exp(\hat{B}/T) = \rho \cdot \exp(\hat{D} + \hat{E}) \exp(\hat{B}/T) = 0.000004620 \exp(1654/T)$$

Außerdem ist

$$\hat{\eta} = \hat{A} \exp(\hat{B}/T) = \rho \cdot \exp(\hat{D} + \hat{E}) \exp(\hat{B}/T) = \rho \cdot \exp(\hat{D} + \hat{E} + \hat{B}/T)$$

Dies zeigt, dass man für gegeben Temperatur T ein Vertrauensintervall für $\hat{D} + \hat{E} + \hat{B}/T$ berechnen und dieses dann in die obige Gleichung einsetzen kann, um ein Intervall für $\hat{\eta}$ zu erhalten. Das Intervall ist dann wegen der Rücktransformation bei Annahme der Normalverteilung für die logarithmierten Daten eines für den Median von η , nicht aber für den Erwartungswert. Das Intervall wird man für verschiedene Werte von $x = 1/T$ berechnen und dann die Intervallgrenzen zu einem Vertrauensband verbinden. Der beobachtete Wertebereich von x liegt zwischen 0,0030 und 0,0034. Die Anweisungen für die Berechnung der Intervalle, die nachfolgende Rücktransformation und die graphische Darstellung sind wie folgt:

```
ods output estimates=estimates;
proc mixed data=s;
class var;
model y=var x/solution noint ddfm=kr;
estimate 'log(eta/rho) at x=0.0030' var 1 1 x 0.0030/cl;
estimate 'log(eta/rho) at x=0.0031' var 1 1 x 0.0031/cl;
estimate 'log(eta/rho) at x=0.0032' var 1 1 x 0.0032/cl;
```

```

estimate 'log(eta/rho) at x=0.0033' var 1 1 x 0.0033/c1;
estimate 'log(eta/rho) at x=0.0034' var 1 1 x 0.0034/c1;
repeated/group=var;
run;

```

```

data estimates2;
set estimates;
rho=1.102*1000;
estimate=rho*exp(estimate);
lower=rho*exp(lower);
upper=rho*exp(upper);

```

```

data t;
input x;
t=1/x;
datalines;
0.0030
0.0031
0.0032
0.0033
0.0034
;

```

```

data final;
merge estimates2 t;

```

```

symbol1 i=spline line=3 c=black;
symbol2 i=spline line=1 c=black;
symbol3 i=spline line=3 c=black;

```

```

proc gplot data=final;
plot lower*t estimate*t upper*t/overlay;
run;

```

Die Kurve mit Intervallgrenzen findet sich in Abb. 10.1. Zum Vergleich die naive Auswertung (Abb. 10.2): Man erhält dieselbe Schätzung für die Kurve, aber viel engere Intervallgrenzen. Die Genauigkeit der Schätzung wird also bei der naiven Auswertung deutlich überschätzt.




Abb. 10.1: Vertrauensintervall für $\eta = A \cdot e^{\frac{B}{T}}$ nach gemischtem Modell.




Abb. 10.2: Naives Vertrauensintervall für $\eta = A \cdot e^{\frac{B}{T}}$.

11. Makros

Makro 1 (Multiple Mittelwertvergleiche): In vielen statistischen Auswertungen besteht das wesentliche Ergebnis in einem multiplen paarweisen Vergleich aller Behandlungen, so z.B. bei der Varianzanalyse von Feldversuchen. Nutzer der Varianzanalyse sind es gewohnt, Mittelwertvergleiche mit Hilfe einer Buchstabendarstellung wiederzugeben, bei der Mittelwerte, die nicht signifikant voneinander verschieden sind, mit demselben Buchstaben versehen werden. Die Buchstabendarstellung ist bisher jedoch beschränkt auf den Fall balanzierter Daten, wobei der Standardfehler einer Differenz konstant sein muss. In vielen Anwendungen sind diese Voraussetzungen allerdings nicht erfüllt, so z.B. für:

- adjustierte Mittelwerte in Anlagen mit unvollständigen Blöcken (Gitter, α -Designs, vollständige Blöcke mit fehlenden Werten)
- korrigierte Mittelwerte in der Kovarianzanalyse
- gewichtete Mittelwerte in der räumlich-statistischen Analyse eines großen Feldversuches
- Behandlungseffekte in generalisierten linearen oder nichtlinearen (gemischten) Modellen
- multiple Vergleiche bei nichtparametrischen Verfahren (Kruskal-Wallis, etc.)

In jedem dieser Fälle liegen p-Werte für $t(t-1)/2$ paarweise Vergleiche vor, wobei t die Zahl der Behandlungen ist. Ich habe eine allgemeine Methode entwickelt, mit der eine solche Liste von paarweisen p-Werten in eine Buchstabendarstellung umgewandelt werden kann (Piepho, 2002). Die wesentliche Idee wird im folgenden kurz umrissen.

Angenommen, vier Behandlungen T1, T2, T3 und T4 werden verglichen. Die Behandlungen T1 und T4 sind signifikant verschieden, während alle anderen Vergleiche nicht signifikant sind. Um eine Buchstabendarstellung zu erhalten, kann man von einer Darstellung ausgehen, bei der jede Behandlung denselben Buchstaben trägt:

T1	a
T2	a
T3	a
T4	a

Diese Darstellung impliziert, dass kein Vergleich signifikant ist, auch nicht der zwischen T1 und T4. Um einen Fehler dieser Art zu beseitigen, kann man wie folgt vorgehen:

- (1) Dupliziere die Spalte mit Buchstaben, die zu der falschen Aussage über die Nichtsignifikanz eines Vergleiches führt (hier die a-Spalte).
- (2) In der ersten der beiden Spalten lösche den Buchstaben, der sich auf die eine Behandlung des Vergleiches bezieht (hier: T1).
- (3) In der zweiten der beiden Spalten lösche den Buchstaben, der sich auf die andere Behandlung des Vergleiches bezieht (hier: T4).

T1	ab		T1	b
T2	ab		T2	ab
T3	ab	→	T3	ab
T4	ab		T4	a

Diese Methode, die ich als Insertion bezeichne, kann auf beliebig viele Vergleiche erweitert werden. Nach mehreren Insertionen entstehen oft redundante Spalten, die weggelassen werden können (Piepho, 2002).

Das Makro ist auf Verwendung der Prozedur MIXED abgestimmt, aber es kann auch mit einer entsprechend formatierten Liste von paarweisen p-Werten umgehen, die auf andere Weise erzeugt wurde. Das Makro verwendet zwei Datensätze:

(1) LSMEANS (mit MIXED durch ODS Table LSMEANS) mit folgenden Variablen:

- TRT = CLASS Variable für Behandlungen
- ESTIMATE = Mittelwert oder sonstige Parameterschätzung

(2) DIFFS (mit MIXED durch ODS Table DIFFS) mit folgenden Variablen:

- P = p-Wert der paarweisen Vergleiche, möglicherweise adjustiert

Folgende Parameter sind an das Makro zu übergeben:

TRT = Label für Behandlungen (LSMEANS)

P = Label für Variable, die die p-Werte bezeichnet (DIFFS);
Voreinstellung P = PROBT (p-Werte für paarweise t-Tests in DIFFS;
Alternativ z.B. P = ADJP, wenn adjustierte p-Werte in MIXED berechnet werden)

ALPHA = Gewünschter Fehler 1. Art (Voreinstellung P = 0.05)

Bei mehrfaktoriellen Versuchen sind die Variablen BY, BY2, BY3, LEVEL, LEVEL2, LEVEL3 hilfreich, um vergleiche für einen Faktor getrennt für die Stufen der anderen Faktoren durchführen zu können (siehe unten).

Das Makro ist unter **mult.sas** abgelegt. Es kann in den Editor geladen werden. Durch "abschicken" des Editorinhaltes wird das Makro dann verfügbar gemacht.

Anwendung auf Hafer-Daten (Beispiel 4.3, **alpha.dat**):

```
→ ods output diff=diffs;
→ ods output lsmeans=lsmeans;
proc mixed data=alpha;
class rep block trt;
model y=rep trt/ddfm=kenwardroger;
random block(rep);
lsmeans trt/adjust=sim pdiff cl;
run;

→ %mult(trt=trt, alpha=0.05, p=adjp);
```

Drei zusätzliche Programmzeilen sind im Vergleich zu den "normalen" Anweisungen erforderlich, um die Buchstabendarstellung zu erhalten. Beim hier verwendeten gemischten Modell wird die Inter-Block-Information genutzt. Adjustierte p-Werte werden mit der Simulations-Option von Edwards und Berry berechnet.

Output:

LABEL	LSMEAN	G
-------	--------	---

1	5.1076995	a .
2	4.4785321	a b
3	3.4991996	. b
4	4.4900945	a b
5	5.0372103	a .
6	4.5366622	a b
7	4.1111362	a b
8	4.5276337	a b
9	3.5021811	. b
10	4.3731995	a b
11	4.2832642	a b
12	4.7552764	a .
13	4.7579132	a .
14	4.7756621	a .
15	4.9691115	a .
16	4.7301311	a .
17	4.6026124	a b
18	4.3616924	a b
19	4.8403279	a .
20	4.0399851	a b
21	4.7950074	a .
22	4.5275448	a b
23	4.2524488	a b
24	4.153874	a b

Anwendung auf Reis-Daten (Beispiel 5.2, Strip-plot, **reis strip plot.dat**): Der Versuch hat zwei Faktoren: N (Stufen: 0, 60, 120) und SORTE (Stufen: 1, 2, 3, 4, 5, 6). Die Wechselwirkungen sind signifikant, also vergleichen wir z.B. die Sorten getrennt für die N-Stufen. Die SAS Anweisungen sind wie folgt:

```
ods output diffs=diffs;
ods output lsmeans=lsmeans;

proc mixed;
class block n sorte;
model y=block n sorte n*sorte/ddfm=kr;
random n sorte/sub=block;
lsmeans sorte*n/pdiff;
run;

%mult(trt=sorte, by=n, level=0);
%mult(trt=sorte, by=n, level=60);
%mult(trt=sorte, by=n, level=120);
```

Die BY-Option spezifiziert die BY-Variable (Faktor, für dessen Stufen getrennt Vergleiche durchzuführen sind). Die LEVEL-Option gibt die Stufe der BY-Variable an, für die die Vergleiche durchzuführen sind. Da der Faktor N drei Stufen hat, sind drei Aufrufe des Makros notwendig.

Ergebnis:

TRT	BY	LEVEL	BY2	LEVEL2	BY3	LEVEL3	LABEL	LSMEAN	G
sorte n	0						1	3571.6667	a b
							2	4934.3333	. b
							3	4249.6667	a b
							4	4059	a b
							5	4101.6667	a b
							6	3207.3333	a .

TRT	BY	LEVEL	BY2	LEVEL2	BY3	LEVEL3	LABEL	LSMEAN	G
sorte n	60						1	5132	a . c
							2	6713.6667	. b .
							3	6122.3333	. b c
							4	5553.6667	. b c
							5	5633.3333	. b c
							6	3714.3333	a . .

TRT	BY	LEVEL	BY2	LEVEL2	BY3	LEVEL3	LABEL	LSMEAN	G
sorte n	120						1	7548	. b .
							2	7211.3333	. b c
							3	7868.3333	. b .
							4	7094.3333	. b c
							5	6012	. . c
							6	2492	a . .

Die Variablen BY2, BY3, LEVEL2 und LEVEL3 werden hier nicht benötigt, da der Versuch nur 2 Faktoren hat.

Makro 2 (Daten-Transformation): In vielen Versuchen und Erhebungen werden Daten erhoben, bei denen zu erwarten ist, dass die Voraussetzungen der Varianzanalyse nicht zutreffen. Ein gängiger Ansatz besteht hier in der Suche nach geeigneten Datentransformationen. Für beschränkte Zählwerte bzw. für Prozentzahlen/Anteile wird oft die Wurzel-Transformation oder die Winkel-Transformation verwendet. Bei unbeschränkten Zählwerten sowie bei stetigen Variablen (Ertrag etc.) kommen oft die logarithmische Transformation und die Wurzel-Transformation zur Anwendung.

In der Praxis besteht das Problem, die geeignete Transformation zu wählen. Anstatt nun verschiedene Transformationen auszuprobieren, kann man eine Familie von Transformationen verwenden, die einen Transformationsparameter ϕ hat und dann mit der Maximum Likelihood Methode den besten Wert des Transformationsparameters bestimmen. Die populärste Familie von Transformationen ist die Box-Cox Familie:

$$y = \begin{cases} (x^\phi - 1)/\phi, & \phi \neq 0 \\ \log_e(x) & \phi = 0 \end{cases}$$

Für $\phi = 1/2$ erhält man die Wurzel-Transformation, für $\phi = 0$ the Log-Transformation. Im Fall $\phi = 1$ wird nicht transformiert. Die Box-Cox-Transformation is sehr flexibel, hat jedoch den Nachteil, dass alle untransformierten Werte positiv sein müssen. Dies macht insbesondere dann Probleme, wenn der Datensatz Nullen umfasst, was leicht bei Prozentzahlen oder nach oben unbeschränkten Zählwerten vorkommt. Eine Familie von Transformationen, die negative Werte zulässt, ist die Manly-Familie:

$$y = \begin{cases} (\exp(\phi x) - 1)/\phi, & \phi \neq 0 \\ x & \phi = 0 \end{cases}$$

Diese Familie wird in der Praxis bisher kaum eingesetzt, scheint nach meiner Erfahrung jedoch oft ähnlich gut zu funktionieren wie die Box-Cox Familie.

Theorie: Im folgenden wird der theoretische Hintergrund der ML-Schätzung von ϕ erläutert. Dieser Abschnitt kann ohne Probleme übersprungen werden, falls technische Details nicht von Interesse sind. Es sei $\mathbf{x}$ der Vektor der untransformierten Daten, der einer multivariaten Verteilung mit Dichtefunktion (p.d.f.) $f(\mathbf{x})$ folgt.

Weiterhin sei $\mathbf{y} = \mathbf{y}(\mathbf{x}; \phi)$, wobei ϕ ein Transformationsparameter ist, so dass $\mathbf{y}$ eine multivariate Verteilung mit Dichtefunktion $g(\mathbf{y})$ hat. Hier nehmen wir eine gemischtes lineares Modell mit multivariater Normalverteilung der Effekte für $g(\mathbf{y})$ an. Es folgt aus Standardresultaten, dass

$$\log[f(\mathbf{x})] = \log[g(\mathbf{y})] + \sum_i \log \left(\frac{\partial y_i}{\partial x_i} \right) \quad (\text{M2})$$

wobei die Summe auf der rechten Seite des Logarithmus der Jacobischen Determinante der Transformation von $\mathbf{x}$ nach $\mathbf{y}$ ist sowie $\mathbf{x}_i$ und $\mathbf{y}_i$ die i -ten Elemente der Vektoren $\mathbf{x}$ und $\mathbf{y}$. Für gegebenes ϕ , kann das Maximum von $\log[f(\mathbf{x})]$ mit der Maximum Likelihood Methode gefunden werden. Hierzu passt man das Modell für die transformierten Daten $\mathbf{y}$ mit PROC MIXED an, wobei die ML Methode durch METHOD=ML spezifiziert wird. Hierbei werden systematisch verschiedene Werte von ϕ ausprobiert. Für jeden Wert von ϕ wird der Logarithmus der Jacobischen Determinante berechnet und zur maximierten log-likelihood $\log[g(\mathbf{y})]$ hinzugezogen, um das Maximum der log-likelihood in Gl. (M2) für gegebenes ϕ zu erhalten. Sodann wird das globale Maximum der log-likelihood graphisch bestimmt (ATKINSON, 1985, p. 86).

Beschreibung der Makros %boxcox und %manly:

```

/*****/
/*
/*  phimin   = smallest phi
/*  phimax   = largest phi
/*  steps    = number of steps in grid search
/*  class    = list of variables for class statement
/*  model    = list of terms in model statement
/*

```

```

/* stmts      = %str(other mixed statements, incl. random) */
/* data       = dataset with original data                */
/* response = name of response variable in dataset        */
/*                                                     */
/*****/

```

*Anwendung auf die Radieschen-Daten (Beispiel 13, S. 64, **radieschen.dat**):*

```

data s;
input block stamm m n;
x=m/n;
datalines;
1 1 18 41
2 1 19 41
1 2 18 35
2 2 19 37
1 3 22 42
2 3 28 47
1 4 9 32
2 4 12 41
1 5 13 45
2 5 14 44
1 6 6 46
2 6 8 40
1 7 11 38
2 7 8 39
1 8 8 37
2 8 17 41
1 9 2 40
2 9 5 45
1 10 10 37
2 10 7 46
1 11 21 37
2 11 17 33
1 12 3 34
2 12 8 40
1 13 19 38
2 13 18 44
1 14 12 44
2 14 25 50
1 15 12 40
2 15 18 37
1 16 8 44
2 16 16 45
1 17 12 47
2 17 12 45
1 18 14 44
2 18 21 38
1 19 24 50
2 19 27 45

```

```

1 20 7 43
2 20 5 39
1 21 33 45
2 21 19 32
1 22 12 44
2 22 24 40
1 23 17 36
2 23 29 42
1 24 6 43
2 24 17 47
1 25 7 33
2 25 8 36
1 26 5 40
2 26 12 45
;

```

```

%boxcox(phimin=0.4,phimax=0.6, steps=20, model=block, class=block stamm,
        stmts=%str(random stamm;), data=s, response=x );
%manly( phimin=0.4,phimax=0.6, steps=20, model=block, class=block stamm,
        stmts=%str(random stamm;), data=s, response=x );

```

Die optimalen Wertebereiche der Suche für ϕ findet man durch mehrmaliges Probieren. Für die Box-Cox-Transformation ergibt sich (siehe auch Abb. M1):

Optimal value of phi

Obs	phi	loglik
1	0.51	31.6197

Dies entspricht etwa der Quadratwurzel-Transformation. Für die Manly-Transformation finden wir (siehe auch Abb. M2):

optimal value for phi

Obs	phi	loglik
1	-1.15	30.4448




Abb. M1: Log-Likelihood Profil für die Box-Cox-Transformation.




Abb. M2: Log-Likelihood Profil für die Manly-Transformation.

Wir können nun die in Beispiel 13 durchgeführten Analysen mit den transformierten Daten wiederholen, was hier der Kürze halber nicht getan wird. Um zu entscheiden, ob die Transformation notwendig ist, kann ein Likelihood-Quotienten-Test durchgeführt werden. Hierzu bildet man die Differenz der log-Likelihoods beim geschätzten Wert für ϕ und bei demjenigen Wert für ϕ , der den untransformierten Daten entspricht. Ist diese Differenz größer als $1/2$ mal der kritische Wert einer χ^2 Verteilung mit einem Freiheitsgrad, so liegt eine signifikante Abweichung der Original-Daten von der Normalverteilung vor. Für $\alpha = 5\%$ muss die kritische

Schranke von $0.5 \cdot 3.84 = 1.92$ überschritten werden. Für die Box-Cox-Transformation wird gerade Signifikanz erreicht, nicht jedoch für die Manly-Transformation.

Literatur

- Bos I, Caligari P (1995) Selection methods in plant breeding. Chapman and Hall, London.
- Dean A, Voss D (1999) Design and analysis of experiments. Springer, New York.
- Hand DJ, Crowder M (1996) Practical longitudinal data analysis. Chapman and Hall, London.
- John JA, Quenouille MH (1977) Experiments: Design and analysis. Charles Griffin, London.
- Kenward MG, Roger JH (1997) Small sample inference for fixed effects from restricted maximum likelihood. *Biometrics* 53, 983-997.
- Piepho HP (1997) Analysis of a randomized complete block design with unequal subclass numbers. *Agronomy Journal* 89, 718-723.
- Piepho HP, Spilke J (1999) Anmerkungen zur Analyse balancierter gemischter Modelle mit der SAS Prozedur MIXED. *Zeitschrift für Agrarinformatik* 7, 39-46.
- Piepho H P (2002) A graphical representation of all pairwise comparisons. *Journal of Computational and Graphical Statistics* (submitted)
- Searle SR, Casella G, McCulloch CE (1992) Variance components. Wiley, New York.
- Verbeke G, Molenberghs G (2000) Linear mixed models for longitudinal data. Springer, Berlin.

Anhang 1: Allgemeine Resultate für das lineare gemischte Modell

Jedes lineare gemischte Modell kann in der Form

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \mathbf{e}$$

geschrieben werden, wobei $\mathbf{y}$ ein Datenvektor mit n Beobachtungen, $\mathbf{X}$ und $\mathbf{Z}$ Designmatrizen, $\boldsymbol{\beta}$ ein Parametervektor mit festen Effekten, $\mathbf{u}$ ein Vektor mit zufälligen Effekten, und $\mathbf{e}$ ein Vektor mit Fehlern ist. Im linearen Modell mit ausschließlich festen Effekten (LM) wird angenommen, dass die Fehler in $\mathbf{e}$ stochastisch unabhängig sind und normalverteilt sind mit Mittelwert 0 und Varianz σ^2 , was wie folgt formuliert werden kann:

$$\mathbf{e} \sim \text{MNV}(\mathbf{0}, I\sigma^2).$$

wobei MVN für die multivariate Normalverteilung steht. Im linearen gemischten Modell (LMM) wird die allgemeinere Annahme getroffen, dass

$$\mathbf{e} \sim \text{MNV}(\mathbf{0}, \mathbf{R}).$$

wobei $\mathbf{R}$ eine Varianz-Kovarianz-Matrix ist. Außerdem sind die zufälligen Effekte in $\mathbf{u}$ zufällig normalverteilt mit Mittelwert $\mathbf{0}$ und Varianz-Kovarianzmatrix $\mathbf{G}$:

$$\mathbf{u} \sim \text{MNV}(\mathbf{0}, \mathbf{G})$$

Die Verteilung des Beobachtungsvektors ist damit

$$\mathbf{y} \sim \text{MNV}(\mathbf{X}\boldsymbol{\beta}, \mathbf{V})$$

wobei

$$\mathbf{V} = \mathbf{Z}\mathbf{G}\mathbf{Z}' + \mathbf{R}$$

Beispiel: Für den Sorghumversuch (Beispiel 12) haben wir

$$\begin{pmatrix} y_{111} \\ y_{112} \\ \vdots \\ y_{11n_{11}} \\ y_{121} \\ \vdots \\ y_{34n_{34}} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ \vdots & 1 & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & 1 & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & 1 & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & 1 & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & 1 & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \end{pmatrix} \times \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} + \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 0 & \cdot & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & \cdot & 0 & 0 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \times \begin{pmatrix} u_{11} \\ u_{12} \\ \vdots \\ u_{21} \\ u_{22} \\ \vdots \\ u_{23} \\ \vdots \\ u_{31} \\ \vdots \\ u_{32} \\ \vdots \\ u_{33} \\ u_{34} \end{pmatrix} + \begin{pmatrix} e_{111} \\ e_{112} \\ \vdots \\ e_{11n_{11}} \\ e_{121} \\ \vdots \\ \vdots \\ \vdots \\ \vdots \\ \vdots \\ \vdots \\ \vdots \\ \vdots \\ e_{34n_{34}} \end{pmatrix}$$

$\mathbf{y} = \mathbf{X} \times \boldsymbol{\beta} + \mathbf{Z} \times \mathbf{u} + \mathbf{e}$

Bei der Auswertung eines LM wird die Summe der Fehlerquadrate,

$SQ_{Fehler} = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$, minimiert. Bei einem LMM wird dagegen die gewichtete

Summe der Fehlerquadrate, $SQ_{Fehler} = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})' \mathbf{V}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$, minimiert. Diese Zielfunktion ergibt sich aus einer Maximierung der Likelihoodfunktion bei multivariate normalverteilten Daten. Falls die Varianzkomponenten in $\mathbf{V}$ bekannt sind, ist die gewichtete Kleinstquadratschätzung

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}\mathbf{V}^{-1}\mathbf{X})^{-1} \mathbf{X}\mathbf{V}^{-1}\mathbf{y}$$

wobei $\mathbf{M}^{-}$ eine g-Inverse von $\mathbf{M}$ ist. Zum Vergleich die einfache Kleinstquadratschätzung beim LM:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}\mathbf{X})^{-} \mathbf{X}\mathbf{y}$$

Der einzige Unterschied ist die Einbeziehung der Inversen der Varianz-Kovarianz-Matrix $\mathbf{V}$. Die Matrix $\mathbf{V}$ bewirkt eine Gewichtung bei der Parameterschätzung. Bei unabhängigen Daten bewirkt $\mathbf{V}$ beispielsweise, dass Beobachtungen mit großer Varianz ein kleineres Gewicht erhalten als Beobachtungen mit kleiner Varianz (also größerer Genauigkeit). Es gelten für LMM im Prinzip dieselben Resultate wie für das LM, falls $\mathbf{V}$ bekannt ist. In der Regel muss $\mathbf{V}$ aber geschätzt werden. Dies kann mit verschiedenen Methoden geschehen. Die in MIXED implementierten Methoden sind:

ML	Maximum Likelihood
REML	Restricted Maximum Likelihood
MINQUE	Minimum Norm Quadratic Unbiased Estimation

Numerische Methoden zur ML- und REML-Schätzung verwenden einen iterativen Algorithmus zur Maximierung der Likelihood-Funktion. Für diesen Algorithmus müssen Startwerte für die Parameter vorgegeben werden, die dann iterativ aktualisiert werden, bis Konvergenz erreicht ist. Die MIXED Prozedur gibt automatisch Startwerte vor, diese können aber auch modifiziert werden, um die Konvergenz zu beschleunigen oder erst zu ermöglichen.

Falls $\mathbf{V}$ geschätzt wird, sind die Resultate für LM im allgemeinen nur noch näherungsweise gültig. Ausnahmen ergeben sich für balancierte Daten (Piepho und Spilke, 1999).

Betrachten wir nun den Test von Hypothesen. In allgemeiner Form können wir diese formulieren als

$$H_0: \mathbf{K}\boldsymbol{\beta} = \mathbf{0}$$

Beispiel: Im Sorghum-Beispiel (Beispiel 13) können wir die globale Nullhypothese, dass alle drei Behandlungen gleich sind, wie folgt schreiben:

$$\tau_1 - \tau_2 = 0 \text{ und } \tau_1 - \tau_3 = 0$$

Man beachte, dass dies $\tau_2 - \tau_3 = 0$ impliziert, und somit $\tau_1 = \tau_2 = \tau_3$. In Matritzen-schreibweise ist dies gleichbedeutend mit

$$H_0 : \begin{pmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \\ \tau_3 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\mathbf{K} \times \boldsymbol{\beta} = \mathbf{0}$$

Zur Prüfung von $H_0: \mathbf{K}\boldsymbol{\beta} = \mathbf{0}$ berechnet man die Wald-Statistik

$$\chi^2 = \mathbf{K}'\hat{\boldsymbol{\beta}}'(\mathbf{K}(\mathbf{X}\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{K}')^{-1}\mathbf{K}\hat{\boldsymbol{\beta}}$$

Diese folgt einer χ^2 -Verteilung mit $\text{Rang}(\mathbf{K})$ Freiheitsgraden, falls die Varianzen in $\mathbf{V}$ bekannt sind. Falls $\mathbf{V}$ geschätzt wird, ist es generell besser, mit der Wald-F-Statistik

$$F = \frac{\mathbf{K}'\hat{\boldsymbol{\beta}}'(\mathbf{K}(\mathbf{X}\hat{\mathbf{V}}^{-1}\mathbf{X})^{-1}\mathbf{K}')^{-1}\mathbf{K}\hat{\boldsymbol{\beta}}}{\text{Rang}(\mathbf{K})}$$

zu arbeiten, wobei $\text{Rang}(\mathbf{K})$ der Rang der Matrix $\mathbf{K}$ ist. Bei einem F-Tests auf Gleichheit von I Behandlungseffekten ist $\text{Rang}(\mathbf{K}) = (t - 1)$, also gleich den üblichen "Behandlungsfreiheitsgraden". Die Wald-F-Statistik kann gegen eine F-Verteilung mit $\text{Rang}(\mathbf{K})$ Nenner-Freiheitsgraden geprüft werden. Falls im LMM $\text{Rang}(\mathbf{K}) = 1$ ist, beispielsweise beim Vergleich von 2 Mittelwerten, entspricht $\sqrt{F}$ einer t -Statistik. Es ist dann

$$t = \frac{\mathbf{K}'\hat{\boldsymbol{\beta}}'}{\sqrt{\mathbf{K}(\mathbf{X}\hat{\mathbf{V}}^{-1}\mathbf{X})^{-1}\mathbf{K}'}}$$

Man beachte die Analogie der Wald-F-Statistik für das LMM zur F-Statistik für das LM, welche wie folgt geschrieben werden kann:

$$F = \frac{\mathbf{K}'\hat{\boldsymbol{\beta}}'(\mathbf{K}(\mathbf{X}\mathbf{X})^{-1}\mathbf{K}')^{-1}\mathbf{K}\hat{\boldsymbol{\beta}}}{\hat{\sigma}^2 \text{Rang}(\mathbf{K})}$$

wobei $\hat{\sigma}^2$ die Fehlervarianz ist. Für das LMM wird also im wesentlichen $\hat{\sigma}^2$ durch $\mathbf{V}$ ersetzt.

Für die Bestimmung der Zählerfreiheitsgrade für die Wald-F-Statistik und t-Statistik im gemischten Modell gibt es verschiedene Methoden, von denen in MIXED einige implementiert sind (DDFM= Option der MODEL Anweisung). Im allgemeinen sind diese Wald-t-Tests und F-Tests nur näherungsweise gültig. Für unbalancierte Daten sind die Satterthwaite-Approximationen von Giesbrecht und Burns (1985) und Fai und Cornelius (1996) zu empfehlen. Außerdem kann die Methode von Kenward und Roger (1997) verwendet werden, welche die Verteilung der F-Statistik über eine gestreckte F-Verteilung approximiert und zusätzlich die Unterschätzung der Varianzen bei einfachem Einsetzen von Schätzwerten für unbekannte Varianzen. Ersetzung unbekannter Varianzen berücksichtigt. Im balancierten Fall liefern diese beiden Verfahren den exakten F-Test bzw. t-Test (Piepho und Spilke, 1999). Die Verfahren wurden durch Simulationen für die REML Methode geprüft und sollten daher nur mit dieser Methode zur Schätzung der Varianzkomponenten verwendet werden.

Test	Approximation	MIXED Option DDFM=
t-Test	Satterthwaite-Methode von Giesbrecht und Burns (1985)	SATTERTH
F-Test	Satterthwaite-Methode von Fai und Cornelius (1996)	SATTERTH
t-Test, F-Test	Approximation von Kenward und Roger (1997)	KENWARDROGER (Version 8)

Die **Vorhersage zufälliger Effekte u (Best Linear Unbiased Prediction - BLUP)** ergibt sich nach der Formel

$$\hat{u} = \hat{G}\hat{V}^{-1}(y - X\hat{\beta})$$

Hieraus ergibt sich z.B. die Zuchtwertschätzung in Beispiel 7.1.

Anhang 2: Hinweise zur Nutzung von SAS

SAS ist ein Statistikpaket, welches im Gegensatz zu anderen Paketen eine **zeilenorientierte** Eingabe erfordert. Verschiedene Verfahren sind in sog. **Prozeduren** (PROC) verfügbar. Außerdem können Datenmanagement sowie sehr vielseitige Verrechnungen innerhalb sog. **Datenschritte** (**datasteps**) durchgeführt werden.

Es gibt drei wichtige **Fenster**:

Editor: Hier werden die Anweisungen eingegeben

Output: Ausgabe der Ergebnisse

Log: Hier wird Buch geführt über abgearbeitete Befehle. Es erscheinen Fehlermeldungen bei fehlerhafter Syntax.

Online-Hilfe: Markieren eines Prozedurnamens im Editor und Drücken der F1-Taste ruft die Online-Hilfe auf. Hier wird die Syntax der Prozedur beschrieben.

Handbücher: Es gibt umfangreiche Handbücher, die z.B. in der Bibliothek und im Fachgebiet Bioinformatik zur Verfügung stehen. Außerdem sind die Handbücher elektronisch verfügbar unter

<http://www.rz.uni-hohenheim.de/SASOnlineDocV8/sasdoc/sashtml/onldoc.htm>


Der Inhalt ist weitgehend identisch mit der "normalen" Online-Hilfe.

1. Grundstruktur eines SAS-Programms

Jedes SAS-Programm hat folgende **Grundstruktur**:

1. Datenschnitt
2. Daten
3. Prozedurschritt

Beispiel: Die folgenden Anweisungen berechnen den Mittelwert aus den Werten 1, 2, 3 und 4:



Das Programm wird in den Editor eingegeben. Durch Anklicken des Männchens auf der oberen Symbolleiste wird das Programm gestartet.

Ergebnis (Output-Fenster):

The MEANS Procedure				
Analysis Variable : y				
N	Mean	Std Dev	Minimum	Maximum
5	3.0000000	1.5811388	1.0000000	5.0000000

Ein Programm hat im allgemeinen die folgende Minimal-Struktur:

```
data <Datensatz-Name>;
input <Variablenliste>;
datalines;
.
.
<Datenblock>
.
.
proc <prozedurname> <optionen>;
<Anweisungen>;
run;
```

Häufige (Anfänger-) Fehler: Semikolon vergessen, Variablen-Namen falsch geschrieben.

Im Datenschrift werden nach der INPUT-Anweisung die Variablen in der Reihenfolge aufgeführt, in der sie auch im Datenblock stehen.

Die Grundstruktur des Datenblocks ist so, dass die **Variablen** in den **Spalten** stehen und die **Beobachtungen** (Records, Fälle) in den **Zeilen**.

Beispiel: In einem Versuch wurden bei drei Sorten (1, 2, 3) in jeweils zwei Parzellen die Erträge ermittelt. Es gibt insgesamt sechs Beobachtungen (3 Sorten × 2 Parzellen), also hat der Datenblock sechs Zeilen. Außerdem gibt es drei Variablen: Sorte, Parzelle und Ertrag. Der Datenblock kann z.B. wie folgt aussehen:

Sorte	Parzelle	Ertrag
1	1	54
3	2	26
2	3	41
3	4	36
2	5	55
1	6	82

SAS-Anweisungen zu Einlesen und Berechnung der Mittelwerte:

```
data;  
input Sorte Parzelle Ertrag;  
datalines;  
1      1      54  
3      2      26  
2      3      41  
3      4      36  
2      5      55  
1      6      82  
;  
proc means;  
var ertrag;  
class sorte;  
run;
```

Ausgabe:

The MEANS Procedure							
Analysis Variable : Ertrag							
Sorte	N Obs	N	Mean	Std Dev	Minimum	Maximum	
1	2	2	68.0000000	19.7989899	54.0000000	82.0000000	
2	2	2	48.0000000	9.8994949	41.0000000	55.0000000	
3	2	2	31.0000000	7.0710678	26.0000000	36.0000000	

2. Numerische und alphanumerische Variablen

Numerische Variablen sind Zahlenwerte. Alphanumerische Variablen können dagegen Buchstaben enthalten.

Beispiele:

numerisch: 1, 2, 3, 4
 100, 443, 731

alphanumerisch: a, b, c
 otto, helga, tina
 t1, t2, t4

Die Unterscheidung zwischen numerischen und alphanumerischen Variablen ist wichtig beim Einlesen von Daten. Bei alphanumerischen Variablen muss in der Input-Anweisung ein \$-Zeichen nachgestellt werden, sonst gibt es eine Fehlermeldung.

```

data;
input y z$;
datalines;
1 a
2 c
3 e
4 d
5 b
;

data;
input Rinderrasse$;
datalines;
Schwarzbunt
Rotbunt
Fleckvieh
Braunvieh
;

```

Die Variablen im letzten Beispiel werden nach 8 Zeichen abgeschnitten. Um Variablen größerer Länge vollständig einzulesen, muss das Format nach dem \$-Zeichen angegeben werden. Die folgende Anweisung lässt Variablennamen mit bis zu 11 Zeichen zu:

```

data;
input Rinderrasse$11.;
datalines;
Schwarzbunt
Rotbunt
Fleckvieh
Braunvieh
;

```

3. SAS-Datensätze

Mittels des Daten-Schrittes wird ein temporärer Datensatz (data set) erzeugt. Hinter der DATA Anweisung kann ein Datensatz-Name vereinbart werden, unter dem der Datensatz später aufgerufen wird. Die Vergabe von Datensatz-Namen ist vor allem dann wichtig, wenn mehr als ein Datensatz im Rahmen einer Sitzung verwendet werden.

Beispiel: Ein Datensatz wird unter der Bezeichnung "a" gespeichert und soll in das Output-Fenster ausgegeben werden. Hierzu wird der Datensatz durch den Zusatz "data=a" im Aufruf der Prozedur PRINT spezifiziert.

```

data a;
input y;
datalines;
3
1

```

```

5
4
2
;
proc print data=a;
run;

```

Ausgabe:

Obs	y
1	3
2	1
3	5
4	4
5	2

4. Einlesen von EXCEL-Dateien

Syntax:

```

proc import out=<SAS-Ausgabe-Datensatz>
            datafile="<Laufwerk:\<Pfad>\<Excel-Datei-Name>"
            DBMS=EXCEL2000 replace;
getname=yes;
run;

```

Die Excel-Datei muss wie üblich strukturiert sein, d.h. Variablen in Spalten und Beobachtungen in Zeilen.

Beispiel: Im Verzeichnis c:\kurs\ liege eine Excel-Datei mit dem Namen **weizen.xls**, die in den SAS-Datensatz "a" eingelesen werden soll:

```

proc import out= a datafile="c:\kurs\weizen.xls"
            DBMS=EXCEL2000 replace;
getnames=yes;
run;

```

Eine weitere Möglichkeit des Einlesens ist über den Import-Wizard, der über die Menü-Leiste anzusteuern ist (File ⇒ Import Data).

5. Wichtige Prozeduren

Im folgenden werden Hinweise zu einigen Prozeduren gegeben, die im Rahmen der Vorlesung genutzt werden.

5.1 PROC PRINT

Die PRINT Prozedur gibt einen SAS-Datensatz in das Output-Fenster aus.

Syntax:

```
proc print data=<SAS-Quell-Datensatz>;  
var <Variablen-Name(n)>;  
run;
```

Beispiel:

```
data a;  
input Rinderrasse$11. Anzahl;  
datalines;  
Schwarzbunt 120  
Rotbunt      284  
Fleckvieh    93  
Braunvieh    761  
;  
proc print data=a;  
var rinderrasse;  
run;
```

Ausgabe:

Obs	Rinderrasse
1	Schwarzbunt
2	Rotbunt
3	Fleckvieh
4	Braunvieh

Wichtige Nutzung der PRINT Prozedur: Nach jedem neuen Datenschritt sollte man sich das Ergebnis ausgeben lassen und sich vergewissern, dass die gewünschten Ergebnisse ohne Fehler berechnet wurden.

5.2 PROC SORT

Die SORT Prozedur sortiert Beobachtungen in einem SAS Datensatz nach einer oder mehreren Variablen und speichert die sortierten Daten in einem neuen Datensatz, der den alten ersetzt, es sei denn, ein spezifischer Ausgabe-Datensatz wird explizit angegeben (über die OUT= Option).

Syntax:

```
proc sort data=<SAS-Quell-Datensatz> out=<SAS-Ausgabe-Datensatz>;  
by <By-Variablen>;  
run;
```

By-Variablen: Nach diesen Variablen wird sortiert. Falls mehrere Variablen aufgeführt werden, wird zuerst nach der ersten sortiert, dann nach der zweiten innerhalb der ersten, usw.

Beispiel: Die folgenden Anweisungen lesen die Werte 3, 1, 5, 9 und 7 in einen Datensatz a, sortieren ihn der Größe nach und legen das Ergebnis in einem Datensatz b ab. Schließlich wird der sortierte Datensatz ausgegeben.

```
data a;
input y;
datalines;
3
1
5
9
7
;
proc sort data=a out=b;
by y;
run;

proc print data=b;
run;
```

Ausgabe:

Obs	y
1	1
2	3
3	5
4	7
5	9

5.3 PROC MEANS

Die MEANS Prozedur berechnet einfache beschreibende Maßzahlen für numerische Variablen.

Syntax (Ausschnitt):

```
proc means data=<SAS-Quell-Datensatz>;
var <Variablen-Liste>;
output out=<SAS-Ausgabe-Datensatz> mean=<Namen>;
by <By-Variable>;
run;
```

In der Output-Anweisung wird mit der Option mean= der Name angegeben, unter dem der Mittelwert abgespeichert werden soll. Es können weitere Maßzahlen berechnet werden (siehe online-Hilfe). Die By-Variable ist zu verwenden, wenn für

verschiedene Gruppen der Mittelwert berechnet werden soll. Der Datensatz muss zuvor nach der By-Variable sortiert sein.

Beispiel: Berechnung des Mittelwertes der Zahlen 3, 1, 5, 4, 2, 8, 7, 9, 10 und 6 und Ausgabe in einen Datensatz "mittelwert".

```
data a;
input y gruppe;
datalines;
3 a
1 b
5 a
4 b
2 a
8 b
7 a
9 b
10 a
6 b
;
proc means data=a;
var y;
output out=mittelwert mean=mittel;

proc print data=mittelwert;
run;
```

Ausgabe:

Obs	_TYPE_	_FREQ_	mittel
1	0	10	5.5

Beispiel: Berechnung für Mittelwerte für die Gruppen a und b.

```
data a;
input y gruppe$;
datalines;
3 a
1 b
5 a
4 b
2 a
8 b
7 a
9 b
10 a
6 b
;
```

```
proc sort data=a out=b;
by gruppe;

proc means data=b;
var y;
output out=mittelwert mean=mittel;
by gruppe;
run;
```

Ausgabe:

Obs	gruppe	_TYPE_	_FREQ_	mittel
1	a	0	5	5.4
2	b	0	5	5.6

5.4 PROC GLM

Die GLM Prozedur kann für gemischte Modelle eine Varianzanalyse berechnen. F-Tests werden basierend auf den Erwartungswerten der MQ konstruiert. GLM berechnet im allgemeinen keine adäquaten Standardfehler. Zahlreiche Beispiele finden sich im Skript.

Syntax (Ausschnitt):

```
proc glm data=<SAS-Quell-Datensatz>;
class <Variablen-Liste>;
model <Zielvariable>=<Liste der zufälligen und festen Effekte>;
random <Liste der zufälligen Effekte>/test;
run;
```

5.5 PROC MIXED

Die MIXED Prozedur kann für gemischte Modelle eine REML-Analyse durchführen. F-Tests werden basierend auf Wald-Statistiken berechnet. MIXED berechnet im allgemeinen adäquate Standardfehler. Die Prozedur umfasst die "State-of-the-art" Methoden für gemischte Modelle. Im Unterschied zu GLM werden die zufälligen Effekte lediglich in der RANDOM-Anweisung angegeben, und nicht in der MODEL-Anweisung. Beispiele finden sich vielfach im Skript.

Syntax (Ausschnitt):

```
proc glm data=<SAS-Quell-Datensatz>;
class <Variablen-Liste>;
model <Zielvariable>=<Liste festen Effekte>;
random <Liste der zufälligen Effekte>/test;
run;
```

6. Das Output-Delivery-System

Bei fast allen Prozeduren, die Output erzeugen, werden die Ergebnisse in verschiedenen Tabellen intern als Datensatz abgelegt. Auf diese Datensätze kann über das Output-Delivery-System (ODS) zugegriffen werden. Das ODS ist ein sehr vielseitiges Tool. Wir verwenden es hier lediglich zum Auslesen von Ergebnistabellen in SAS-Datensätze.

Syntax (vor dem Aufruf der Prozedur anzugeben):

```
ods output <Name der Tabelle>=<Ausgabe-SAS-Datensatz>;
```

Die Bezeichnungen der verschiedenen Tabellen ist in der Online-Hilfe für die betreffende Prozedur unter "Additional Topics".

Beispiel: Es soll eine Varianzanalyse durchgeführt werden (2 Gruppen, je 5 Werte) und die Mittelwerte in einen Datensatz "mittelwerte" ausgegeben werden. In der Online-Hilfe findet man die Tabelle LSMEANS.

```
data a;
input y gruppe$;
datalines;
3 a
1 b
5 a
4 b
2 a
8 b
7 a
9 b
10 a
6 b
;
ods output lsmeans=mittelwerte;
proc mixed;
class gruppe;
model y=gruppe;
lsmeans gruppe;
run;

proc print data=mittelwerte;
run;
```

Ergebnis:

Obs	Effect	gruppe	Estimate	StdErr	DF	tValue	Probt
1	gruppe	a	5.4000	1.4353	8	3.76	0.0055
2	gruppe	b	5.6000	1.4353	8	3.90	0.0045

7. SAS-Datensätze in einem Datenschnitt verfügbar machen

Oft ist es notwendig, einen bestehenden SAS-Datensatz im Rahmen eines SAS-Datenschritts weiterzubearbeiten. Hierzu kann die SET-Anweisung innerhalb eines Datenschrittes verwendet werden.

Syntax:

```
data <Ausgabe-SAS-Datensatz>;  
set <Quell-SAS-Datensatz>;  
<Rechenschritte>;
```

Beispiel: Es wird eine einfache Varianzanalyse durchgeführt. Mit ODS werden die Mittelwerte in einen Datensatz "mittelwerte" geschrieben. Dieser wird dann in einem neuen Datenschnitt "a_mittelwerte" verfügbar gemacht, um den Mittelwert der Gruppe "a" auszuwählen. Hierzu wird eine IF-Anweisung verwendet.

```
data a;  
input y gruppe$;  
datalines;  
3 a  
1 b  
5 a  
4 b  
2 a  
8 b  
7 a  
9 b  
10 a  
6 b  
;  
ods output lsmeans=mittelwerte;  
proc mixed data=a;  
class gruppe;  
model y=gruppe;  
lsmeans gruppe;  
run;  
  
data a_mittelwert;  
set mittelwerte;  
if gruppe='a';  
  
proc print data=a_mittelwert;  
run;
```

Ergebnis:

Obs	Effect	gruppe	Estimate	StdErr	DF	tValue	Probt
1	gruppe	a	5.4000	1.4353	8	3.76	0.0055