

Einführung in die Teststatistik

Bevor wir uns einige wesentliche Tests anschauen, möchte ich zunächst ein paar Grundlagen behandeln, ohne die die Vorgehensweise der Tests nicht richtig verstanden werden kann.


Ich beginne mit den statistischen Fehlermöglichkeiten:

Fehler 1. Art oder auch α -Fehler genannt

Fehler 2. Art oder auch β -Fehler genannt.

Zur Erläuterung soll folgendes Szenario dienen:

Angenommen, Sie verfügen über ein riesiges Silo, das gefüllt ist mit den Körnern der Erbsensorte A. Dieses Silo sei so groß, dass es sozusagen die Grundgesamtheit aller Erbsenkörner der Sorte A darstellt. Angenommen, wir würden nun in dieses Silo greifen und zufällig 100 Körner entnehmen. Wir könnten jedes einzelne Korn wiegen und aus den 100 Einzelkorngewichten den Stichprobenmittelwert berechnen. Wenn wir diesen Vorgang ganz häufig wiederholen würden (sagen wir mal unendlich oft), bekämen wir unendlich viele Stichprobenmittelwerte, die wir in einer Häufigkeitsverteilung darstellen könnten (X-Achse ist in g skaliert) :



Da die Stichproben ja alle aus derselben Grundgesamtheit gezogen wurden (Sorte A), kann es sich bei den Unterschieden zwischen den Mittelwerten nur um Zufallsstreuung (Zufallsfehler) handeln. Jede Stichprobe enthält andere Körner und jedes Korn ist unterschiedlich. Wenn das betrachtete Merkmal (hier Einzelkorngewicht) normalverteilt ist (das ist der Fall), dann ist auch die Verteilung von Stichprobenmittelwerten normalverteilt. Die meisten Mittelwerte finden sich in der Mitte der Verteilung, einige wenige Mittelwerte sind sehr groß oder sehr klein.

Angenommen, neben unserem großen Silo mit bekanntem Inhalt (Sorte A), befände sich ein weiteres großes Silo, das mit Erbsenkörnern einer Sorte gefüllt sei, wir aber vergessen hätten, um welche Sorte es sich handelt. Wenn wir unterstellen, dass jede Erbsensorte dieser Welt ein ganz spezifisches

mittleres Einzelkorngewicht hat (was auch tatsächlich so ist), könnten wir die obige Häufigkeitsverteilung der Sorte A nutzen, um zu einer belastbaren Aussage zu kommen.

Wir können in der uns bekannten Verteilung von Stichprobenmittelwerten der Sorte A im Umfang von $n=100$ (die Stichprobenmittelwerte wurden aus jeweils 100 Körnern berechnet) eine obere und untere Grenze setzen, sagen wir beim 2,5% Perzentil und beim 97,5% Perzentil (d. h. dass außerhalb dieser Grenzen größenordnungsmäßig 5% aller beobachteten (möglichen) Stichprobenmittelwerte des Umfangs $n=100$ der Sorte A liegen).

Nun könnten wir aus dem anderen Silo mit unbekannter Sorte eine Stichprobe im Umfang von $n=100$ Körnern ziehen, den Stichprobenmittelwert bezüglich des Einzelkorngewichts ermitteln und dann folgende Entscheidungsregel formulieren:

Wenn der Stichprobenmittelwert der Körner aus Silo B größenordnungsmäßig außerhalb der gesetzten Grenzen der Häufigkeitsverteilung der Mittelwerte von Sorte A liegt, dann behaupten wir, dass es sich in Silo B um eine andere Sorte handelt. Warum? Weil dieser Stichprobenmittelwert aus Silo B so ungewöhnlich groß bzw. klein für Sorte A ist, vermutet man, dass dieser Stichprobenmittelwert nicht mehr zur Familie der Stichprobenmittelwerte von Sorte A gehört.

Die zweite Entscheidungsregel, die man formulieren kann, lautet: wenn der Stichprobenmittelwert aus Silo B größenordnungsmäßig innerhalb der gesetzten Grenzen der Mittelwertverteilung von Sorte A liegt, dann behauptet man, dass im Silo B ebenfalls die Sorte A liegt, weil der Stichprobenmittelwert für die Verteilung der Sorte A ziemlich normal ist.

Jetzt sind zwei Szenarien denkbar:

1. Angenommen, in Silo B liegen in Wirklichkeit auch Körner der Sorte A. Wenn wir nun bei der Stichprobenziehung aus Silo B rein zufällig einen sehr großen oder kleinen Wert erzielen, der außerhalb der von uns gesetzten Grenze liegt, dann würden wir ja nach der oben von uns formulierten Entscheidungsregel behaupten, dass im Silo B eine andere Sorte, also nicht die Sorte A liegt. Und wir würden in diesem Fall mit unserer Behauptung irren, denn in Wirklichkeit liegt ja die Sorte A drin. Wir würden also irrtümlich von Unterschiedlichkeit sprechen und damit einen Fehler begehen. Dieser Fehler wird als α -Fehler bezeichnet. Das Risiko wäre bei unserer Grenzsetzung aber auf 5% begrenzt. Das bedeutet, dass in maximal 5% aller denkbaren Fälle ein solcher Fehler begangen werden kann. In dem Fall, dass es in Wirklichkeit keinen Unterschied gibt (in beiden Silos liegt die Sorte A), besteht bei der Grenzsetzung beim 2,5% und 97,5% Perzentil also ein Risiko von 5%, irrtümlich von Unterschiedlichkeit zu sprechen.

Wenn es in Wahrheit keinen Unterschied gibt, dann wird das von den Statistikern als H_0 =wahr bezeichnet. H_0 wird als Nullhypothese bezeichnet und lautet umgangssprachlich: „es gibt in Wirklichkeit keinen Unterschied“.

Das Risiko, einen Fehler 1. Art (α -Fehler) zu begehen, ist nur gegeben, wenn es in Wirklichkeit keinen Unterschied gibt. Die Höhe des Risikos hat man in der eigenen Hand: wenn einem 5% Irrtumswahrscheinlichkeit zu hoch ist, dann kann man die Grenzen in der Verteilung nach außen schieben, z. B. auf das 1% Niveau.

2. Angenommen, im Silo B liegt eine andere Sorte, also nicht die Sorte A. Wenn wir nun einen Stichprobenmittelwert aus Silo B erhalten, der größenordnungsmäßig außerhalb unserer gesetzten Grenzen liegt, dann würde unsere Entscheidungsregel ja lauten: es sieht so aus, als ob im Silo B eine andere Sorte liegt und wir hätten damit die Wahrheit erkannt. Es könnte aber auch sein, dass wir einen Stichprobenmittelwert aus Silo B erhalten, der innerhalb der von uns gesetzten Grenzen liegt. Nun würden wir nach unserer Entscheidungsregel folgendes sagen: es sieht so aus, als ob im Silo B auch die Sorte A liegt und wir würden mit unserer

Aussage irren. Wir würden jetzt einen β -Fehler begehen. Einen β -Fehler begeht man, wenn man irrtümlich von Gleichheit spricht. Dem Risiko eines β -Fehlers unterliegt man nur, wenn es in Wirklichkeit einen Unterschied gibt. Der β -Fehler ist leider nicht eindeutig zu quantifizieren. Er kann ja nur begangen werden, wenn es in Wirklichkeit Unterschiede gibt. Da wir aber die Wirklichkeit ja nicht kennen, wissen wir ja eben nicht, ob im Silo B auch die Sorte A oder eine andere Sorte liegt und wenn eine andere Sorte darin liegen würde, hätten wir ja eben auch keine Ahnung, wie groß der Unterschied zwischen dieser Sorte und der Sorte A ist.

Es gibt also zwei Möglichkeiten, richtig zu entscheiden und zwei Möglichkeiten, zu irren:

Entscheidung	Wahrheit	
	H_0 stimmt	H_0 stimmt nicht
H_0 nicht verworfen	richtig	Fehler 2. Art: „ β “
H_0 verworfen	Fehler 1. Art: „ α “	richtig

Wenn H_0 stimmt (bedeutet in unserem Beispiel: in beiden Silos liegt dieselbe Sorte), dann kann es sein, dass man zur richtigen Entscheidung kommt (wenn der Stichprobenmittelwert innerhalb der gesetzten Grenzen liegt) oder man begeht einen Fehler 1. Art (wenn man zufällig einen Wert ermittelt, der außerhalb der Grenzen liegt).

Wenn H_0 nicht stimmt (bedeutet in unserem Beispiel: in Silo B liegt eine andere Sorte), dann besteht die Möglichkeit zur richtigen Entscheidung (wenn der ermittelte Wert außerhalb der gesetzten Grenzen liegt) oder man begeht einen Fehler 2. Art (wenn der ermittelte Wert innerhalb der gesetzten Grenzen liegt).

Dieses Silobeispiel hat alle Zutaten eines **statistischen Tests**. Bei einem Test wird ein Prüfwert berechnet (hier der Stichprobenmittelwert aus Silo B). Ein Test benötigt eine vorliegende Prüfverteilung (hier die Verteilung der vielen, vielen Stichprobenmittelwerte aus der Grundgesamtheit der Sorte A). Die Prüfverteilungen der vielen unterschiedlichen statistischen Tests, die es gibt, sind von Mathematikern erarbeitet worden und liegen vor. Dann werden in der Prüfverteilung Grenzen gesetzt und Entscheidungsregeln formuliert (im Silobeispiel ist die Entscheidungsregel: wenn der Prüfwert außerhalb des Grenzwerts ist, dann sprechen wir von Unterschiedlichkeit. Wenn der Prüfwert innerhalb der Grenzwerte liegt, dann sprechen wir von Gleichheit (hier der Sorten)).


Einseitige und zweiseitige Fragestellung

Im Silobeispiel haben wir eine untere und eine obere Grenze in der Prüfverteilung gesetzt. Wenn es Sorten gibt, die ein kleineres mittleres Einzelkorngewicht haben und Sorten gibt die ein größeres mittleres Einzelkorngewicht als die Sorte A haben, dann muss man das in unserer Prüfverteilung auch tun, denn wir wissen ja nicht, welche Sorte im Silo B liegt. Wenn eine Sorte darin liegt, die ein kleineres mittleres Einzelkorngewicht hat, dann wird der Prüfwert (der Stichprobenmittelwert aus Silo B) tendenziell unterhalb der unteren Grenze zu finden sein und umgedreht.

Angenommen, wir wüssten, dass die Sorte A das kleinste mittlere Einzelkorngewicht aller existierenden Sorten hat. Dann könnte ja nur folgendes vorliegen: entweder liegt im Silo B auch die Sorte A oder es liegt eine andere Sorte darin. Wenn eine andere Sorte darin liegen sollte, dann


müsste aber der Mittelwert tendenziell oberhalb der oberen Grenze liegen. Eine untere Grenzsetzung wäre dann nicht nötig. Man könnte also einseitig testen:

Alternative einseitig ($\mu > \mu_0$ oder je nach Fragestellung auch $\mu < \mu_0$):



Angenommen, in Silo B läge eine andere Sorte und wir nehmen mal an, dass wir für diese andere Sorte ebenfalls wie bei Sorte A ganz viele Stichproben in einem bestimmten Umfang n gezogen hätten. Dann hätten wir für Sorte A (wir unterstellen, dass die Sorte A das kleinstmögliche mittlere Einzelkorngewicht aller Erbsensorten hat, also einseitige Testsituation) und Sorte XY eine entsprechende Häufigkeitsverteilung von Stichprobenmittelwerten eines bestimmten Umfangs n :

Alternative einseitig (in der Graphik $\mu > \mu_0$):



In dieser Abbildung kann man nun sehen, wie das Fehlerrisiko 1. und 2. Art miteinander zusammenhängen. Angenommen, die linke Häufigkeitsverteilung bezieht sich auf die Sorte A und die rechte Häufigkeitsverteilung auf die Sorte XY mit einem größeren mittleren Einzelkorngewicht. Angenommen, uns wäre nur die Häufigkeitsverteilung der Sorte A (die Prüfverteilung unseres obigen Beispiels) bekannt und wir würden aus dem Silo B mit Sorte XY eine Stichprobe ziehen (also einen Stichprobenmittelwert der rechten Verteilung). Nach unserer Teststrategie setzen wir in unserer vorliegenden Prüfverteilung (der Verteilung der Sorte A) eine obere Grenze (wir können ja einseitig testen) bei, sagen wir, dem 95% Perzentil, bedeutet, dass 5% aller denkbaren Stichprobenmittelwerte der Sorte A oberhalb dieser Grenze liegen. Wenn nun im Silo B die Sorte XY läge, und als Prüfverteilung die Häufigkeitsverteilung der Sorte A dient, dann wäre hier das Risiko, fälschlich von Gleichheit zu sprechen (β -Fehler) bei über 50%, also sehr hoch. Man könnte den β -Fehler kleiner machen, wenn man unseren Grenzwert in der Verteilung der Sorte A nach links

schieben würde (also das Risiko einen α -Fehler zu begehen vergrößern würde). Wenn wir nur die Verteilung der Sorte A kennen und nicht wissen, welche Sorte in Silo B liegt, es also nicht ausgeschlossen ist, dass in Silo B auch die Sorte A liegt, dann würde man durch die Linksverschiebung des Grenzwerts in der Verteilung der Sorte A den α -Fehler vergrößern, wenn im Silo B die Sorte A läge. Den α -Fehler kann man ja nur begehen, wenn in beiden Silos dieselbe Sorte liegt, den β -Fehler kann man nur begehen, wenn im Silo B eine andere Sorte liegt. Also umso kleiner das Fehlerrisiko bezüglich α -Fehler gemacht wird (Grenze nach rechts verschieben), umso größer wird das Risiko, einem β -Fehler zu unterliegen. Wenn wir keine Ahnung haben, welche Sorte in Silo B liegt, dann muss man beide Fehlermöglichkeiten einkalkulieren. Den α -Fehler können wir über die bekannte Prüfverteilung quantifizieren (wir können die Grenzen setzen), den β -Fehler leider nicht. Das Risiko, einen β -Fehler zu begehen, hängt von der Unterschiedlichkeit der beiden Sorten ab. Wenn im Silo B eine Sorte liegt, deren Stichprobenmittelwertverteilung meilenweit oberhalb der Verteilung der Sorte A liegt, also die beiden Verteilungen sich gar nicht überlappen, dann geht der β -Fehler gegen 0. Umso ähnlicher sich die Sorten sind, umso mehr würden die beiden Verteilungen der Sorten überlappen, umso größer wäre das β -Fehler Risiko.

Statistische Tests


Übersicht ausgewählter wichtiger statistischer Tests:

Tests für univariable Betrachtungen

	Nominalskala, auch Ordinalskala mit wenigen Kategorien bei großer Stichprobe	Ordinalskala, auch Intervallskala, Normalverteilung nicht erforderlich	Intervallskala und Normalverteilung
Einstichprobentests	Chi-Quadrat- Anpassungstest		Vertrauensbereiche
Zweistichprobentests	Chi-Quadrat-Test (unabhängige Stichproben)	U-Test (unabhängige Stichproben) Wilcoxon-Test (verbundene Stichproben)	t-Test - bei unabhängigen Stichproben und gleichen, unbekannten Varianzen - bei ungleichen Varianzen - bei verbundenen Stichproben
> 2 Stichproben	Chi-Quadrat-Test (unabhängige Stichproben)	Kruskal-Wallis-Test (unabhängige Stichproben) Friedman-Test (abhängige Stichproben)	Varianzanalyse -einfaktoriell -mehrfaktoriell

120

Angenommen, Sie hätten eine Untersuchung durchgeführt, in der die Wirkung dreier antibiotischer Wirkstoffe auf das Wachstum der Bakterienart *Hafnia* untersucht werden sollte.



Sie hätten insgesamt 12 Agarplatten mit *Hafnia* ausgestrichen. Jedem Antibiotikum hätten Sie vier Platten zugeordnet. Bei jeder Platte wäre eine gleich große Wirkstoffmenge in das Zentrum der Platte geträufelt worden. Dann hätten wir 4 Wiederholungen für jedes Antibiotikum, wir hätten für jedes Antibiotikum eine Stichprobe im Umfang $n=4$ erzeugt. Die Platten würde man zufällig verteilt auf einem Labortisch platzieren. Als Untersuchungsmerkmal könnte man hier den Durchmesser des Hofes (des bakterienfreien Bereichs um den applizierten Wirkstofftropfen) in mm wählen. Die Frage, die es zu beantworten galt, lautete: unterscheiden sich die 3 Antibiotika bezüglich des Untersuchungsmerkmals (Hofdurchmesser in mm) voneinander oder sind die Unterschiede zwischen

den Stichproben noch als zufällig zu bezeichnen. Das ist die klassische Aufgabe eines statistischen Tests. Welcher der vielen verfügbaren Tests wäre passend?

Um den passenden Test zu finden, müssen 3 Dinge geklärt werden:

1. Skalenniveau des Untersuchungsmerkmals, also der Werte, mit denen auf Unterschiedlichkeit geprüft werden soll
2. Wie viele Stichproben liegen vor
3. Sind die Stichproben unabhängig oder verbunden

In unserem Fall ist das Untersuchungsmerkmal intervallskaliert(durch Messung entstanden). Jetzt könnte man in der Übersichtstabelle schon mal nachschauen, in welche Spalte man zu gehen hat. Die rechte Spalte ist überschrieben mit: Intervallskala und Normalverteilung. Hier wäre jetzt die Frage, ist das Merkmal Hofdurchmesser normalverteilt. Aus Erfahrung ist dies tatsächlich gegeben. Also wäre man ganz rechts schon mal in der richtigen Spalte. Als nächstes ist zu klären, welche Stichprobenanzahl vorliegt: hier sind es 3 Stichproben. Somit hätte man auch die passende Zeile gefunden. Nun schaut man in der entsprechenden Schublade nach und findet dort als Testvorschlag die Varianzanalyse. Auf diesem Weg gelangt man zum passenden Test. In der oben eingefügten Testübersicht finden sich wie gesagt nur einige sehr gebräuchliche Tests, es gibt noch viel mehr im Angebot (siehe entsprechende Lehrbücher).

Vorstellung einiger wichtiger Tests

Vertrauensbereich des arithmetischen Mittels (in der Übersichtstabelle der Kasten ganz oben rechts).

Angenommen, Sie wären Eigentümer einer ackerbaulich genutzten Fläche und die zuständige Bodenschutzbehörde würde sich bei Ihnen melden und mitteilen, dass der Verdacht bestünde, diese Fläche sei mit Cadmium belastet. Die Behörde würde nun eine Untersuchung durchführen, um zu ermitteln, ob die Cd-Belastung der Verdachtsfläche bereits oberhalb des amtlichen Grenzwerts von 1,5 mg Cd /kg Boden (lufttrocken) liege. Dazu würden Bodenproben genommen: an 10 zufällig ausgewählten Stellen der Fläche würde man mit einem Bohrstock Oberbodenmaterial entnehmen und im Labor separat untersuchen. Man hätte am Ende somit 10 Untersuchungswerte (die Ergebnisse der 10 Entnahmestellen) aus dem Labor. Man kann nun aus diesen 10 Einzelwerten einen Mittelwert berechnen. Angenommen, der Mittelwert läge bei 1,6 mg Cd/kg Boden. Wenn jetzt die Behörde zu Ihnen käme und sagen würde, sie müsse eine Nutzungsbeschränkung aussprechen, weil der Stichprobenmittelwert oberhalb des Grenzwerts liege, könnten Sie mit Recht sagen, dass es sich bei dem Stichprobenmittelwert doch nur um eine Schätzung des wahren Mittelwerts handle und der Stichprobenmittelwert doch zufallsfehlerbehaftet sei. Würde man die ganze Probennahme wiederholen bekäme man einen etwas anderen Stichprobenmittelwert. Jeder Stichprobenmittelwert unterscheidet sich von anderen Stichprobenmittelwerten durch die zufällige Zusammensetzung der Entnahmestellen in den Stichproben (Zufallsfehler). Sie könnten jetzt mit Fug und Recht eine Auskunft verlangen, wie verlässlich die Schätzung des wahren Mittelwerts (der wahren Belastung) durch diesen Stichprobenmittelwert ist. Damit sind Sie beim Vertrauensbereich des Mittelwerts.


(die Schritte zur Auswahl des richtigen Tests: 1. Welches Skalenniveau unterliegt den Werten, mit denen gerechnet werden soll: Cd-Gehalt in g ist intervallskaliert; ist dieses Merkmal normalverteilt: erfahrungsgemäß ja 2. Stichprobenanzahl: eine Stichprobe wurde aus dem großen Acker gezogen. Somit gelangt man in der Übersichtstabelle der Tests in den Kasten ganz rechts oben).

Man könnte nun den Vertrauensbereich berechnen, der den Bereich angibt, in dem mit einer bestimmten Wahrscheinlichkeit der wahre Mittelwert (die wahre Belastung) liegt. Z. B. könnte das Ergebnis folgendermaßen aussehen: Stichprobenmittelwert = 1,6 mg Cd/kg Boden; 95% Vertrauensbereich = $1,6 \pm 0,093$; untere Grenze des Vertrauensbereichs: 1,47; obere Grenze des Vertrauensbereichs: 1,65. Die Aussage wäre dann: mit 95%iger Wahrscheinlichkeit befindet sich der wahre Mittelwert (die wahre Belastung der Fläche) zwischen 1,47 mg Cd/kg Boden und 1,65 mg Cd/kg Boden.


Vor diesem Hintergrund könnten Sie sich als Eigentümer gegen eine Nutzungsbeschränkung wehren, weil ja nicht ausgeschlossen ist, dass die tatsächliche Belastung der Fläche unterhalb des amtlichen Grenzwerts liegt. Ein Gericht würde Ihnen vermutlich Recht geben. Die Behörde würde deshalb auch nur eine Nutzungsbeschränkung aussprechen, wenn der komplette Vertrauensbereich oberhalb des amtlichen Grenzwerts angesiedelt wäre. Dann wäre das Risiko, unberechtigt eine Nutzungsbeschränkung auszusprechen ja unter 5% gesunken.

Nun kommt die Frage: wie kann der Vertrauensbereich berechnet werden?

Hierzu folgender Vorspann:




Verteilung der Einzelwerte x einer Grundgesamtheit



Verteilung der Mittelwerte von Stichproben des Umfangs n einer Grundgesamtheit

In der oberen rechten Abbildung soll die Häufigkeitsverteilung von Einzelwerten einer normalverteilten Grundgesamtheit dargestellt sein, z. B. die Pflanzenhöhe der Pflanzen eines sehr großen Maisackers (sozusagen unendlich viele Pflanzen). Aus diesem Meer an Pflanzen könnte man wiederholt eine Stichprobe ziehen, sagen wir mal im Umfang von $n=10$. Sie könnten für diese Stichproben jeweils einen Stichprobenmittelwert berechnen. Nachdem Sie auf diesem Weg ganz viele Stichprobenmittelwerte berechnet hätten (sozusagen unendlich viele), könnten Sie auch diese in einer Häufigkeitsverteilung darstellen. Die Verteilung der Stichprobenmittelwerte ist in der oberen rechten Abbildung zu sehen. Es gibt nun eine Beziehung zwischen der Standardabweichung der Verteilung der Einzelwerte und der Verteilung der Stichprobenmittelwerte: wenn man die Standardabweichung der Einzelwerte (hier mit σ symbolisiert, was die Standardabweichung einer Grundgesamtheit, also die wahre Standardabweichung symbolisiert) durch die Wurzel aus der Stichprobengröße teilt, die man gewählt hat, um die Stichprobenmittelwerte zu berechnen (hier $n=10$), erhält man die Standardabweichung der Häufigkeitsverteilung der Stichprobenmittelwerte: $\sigma/\sqrt{n}$.

$\sigma/\sqrt{n}$ wird auch als Standardfehler bezeichnet.



Verteilung der Mittelwerte von Stichproben des Umfangs n einer Grundgesamtheit

Obige Abbildung soll die Häufigkeitsverteilung der Stichprobenmittelwerte darstellen. Bei einer normalverteilten Grundgesamtheit gilt folgendes: wenn man den Standardfehler mit 1,96 multipliziert und dieses Produkt dem Mittelwert μ dazu addiert bzw. davon abzieht, dann gelangt man zum 2,5 % und 97,5% Perzentil. In dem Bereich Mittelwert $\pm 1,96 \cdot \text{Standardfehler}$ finden sich somit 95% aller beobachteten Stichprobenmittelwerte, die übrigen außerhalb dieser beiden Grenzen.

Im Umkehrschluss gilt jetzt folgendes: wenn man diesen Bereich von $\pm 1,96 \cdot \text{Standardfehler}$ um die einzelnen Stichprobenmittelwerte aufspannt, die in dieser Häufigkeitsverteilung enthalten sind, dann wird bei 95% aller Stichprobenmittelwerte (der Stichprobenmittelwerte, die größenordnungsmäßig zwischen dem 2,5% und dem 97,5% Perzentil liegen) der wahre Mittelwert μ (also der Mittelwert der Grundgesamtheit) von diesem Intervall umschlossen. Das soll in der obigen Abbildung exemplarisch dargestellt sein für einen dieser Stichprobenmittelwerte, der hier mit $\bar{x}_1$ symbolisiert ist: wenn wir um diesen Stichprobenmittelwert dieses Intervall von $\bar{x}_1 \pm 1,96 \cdot \text{Standardfehler}$ aufspannen, dann liegt der wahre Mittelwert μ in diesem Intervall. Bei den Mittelwerten, die unterhalb des 2,5% Perzentils und oberhalb des 97,5% Perzentils liegen, gilt das nicht. Man kann also sagen, dass in 95% aller Stichprobenmittelwerte (Fälle) zutrifft, dass das Intervall Stichprobenmittelwert $\pm 1,96 \cdot \text{Standardfehler}$ den wahren Mittelwert umschließt, bei 5% der Mittelwerte aber nicht.

Somit hätten wir hierüber den 95% -Vertrauensbereich (auch Konfidenzintervall) gefunden. Wenn Sie um einer der Stichprobenmittelwerte diesen Vertrauensbereich legen, dann ist die Wahrscheinlichkeit, dass dieses Intervall den wahren Mittelwert umschließt, 95%.

In der Realität haben wir nun aber noch ein Problem:

Im praktischen Leben wird so vorgegangen, wie in dem eingangs vorgestellten Beispiel mit der Cd-Kontamination: man kennt die Grundgesamtheit nicht, alles was man hat, sind die Ergebnisse einer einzigen Stichprobenziehung. Somit ist die wahre Standardabweichung σ nicht bekannt.

Alles was man hat, sind die wenigen Einzelwerte der Stichprobe. Es gibt aber einen Ausweg: man schätzt die wahre Standardabweichung σ über die Stichprobenstandardabweichung s .

Man berechnet also aus der Stichprobe heraus den Stichprobenmittelwert und die Stichprobenstandardabweichung. Nun kann man aus s den geschätzten Standardfehler berechnen:

$s/\sqrt{n}$ n =Stichprobengröße (im Beispiel der Cadmiumuntersuchung wäre dann $n=10$).

Jetzt gibt es aber noch ein Problem: der Faktor 1,96 darf nur benutzt werden in Zusammenhang mit der wahren Standardabweichung σ . Die Schätzung der wahren Standardabweichung durch die Stichprobenstandardabweichung s ist ja auch mit einem Schätzfehler behaftet. Was ist nun zu tun?

Der Ausweg ist folgender: statt mit dem Faktor 1,96 arbeitet man jetzt mit dem sogenannten t-Wert aus einer t-Tabelle. Diese t-Tabellen finden Sie im Internet und im Anhang eines jeden Statistiklehrbuchs. In OSCA finden Sie im Dateibereich dieser Veranstaltung ein Dokument mit dem Namen Biostatistik-Skript, in dem Sie ebenfalls die t-Tabelle finden.

Zur Berechnung des Vertrauensbereichs aus einer Stichprobe heraus, müssen Sie in der t-Tabelle für den zweiseitigen Test nachschauen (weil wir ja eine untere und eine obere Grenze setzen). Wenn Sie den 95%-Vertrauensbereich berechnen wollen, dann müssen Sie in der t-Tabelle in der Spalte 5% (oder 0,05) nachschauen. Um den passenden Ersatzfaktor für 1,96 in der t-Tabelle zu finden, brauchen Sie jetzt noch die Freiheitsgrade (FG). Die Freiheitsgrade ergeben sich aus Stichprobengröße $- 1$. Bezogen auf unser Cd-Beispiel hätten wir dann $10-1 = 9$ FG. Nun kann man in der Tabelle nachschauen (5%, 9 FG): der passende t-Wert ist 2,26. Um den 95%-Vertrauensbereich in dem oben erwähnten Cd-Beispiel zu berechnen, muss man zum Stichprobenmittelwert $\pm 2,26 \cdot$

$s/\sqrt{10}$ dazurechnen und erhält die untere und obere Grenze des 95%-Vertrauensbereichs, also des Bereichs, der mit 95%iger Wahrscheinlichkeit den wahren Mittelwert enthält.

Werte von t

FG	P%									FG
	60	40	20	10	5	2	1	0,2	0,1	
1	0,73	1,38	3,08	6,31	12,71	31,82	63,66	318,3	632,6	1
2	0,62	1,06	1,87	2,92	4,30	6,97	9,92	22,33	31,60	2
3	0,58	0,98	1,64	2,35	3,18	4,54	5,84	10,22	12,92	3
4	0,57	0,94	1,53	2,13	2,78	3,75	4,60	7,17	8,61	4
5	0,56	0,92	1,48	2,02	2,57	3,37	4,03	5,89	6,87	5
6	0,55	0,91	1,44	1,94	2,45	3,14	3,71	5,21	5,96	6
7	0,55	0,90	1,42	1,90	2,36	3,00	3,50	4,79	5,41	7
8	0,55	0,89	1,40	1,86	2,31	2,90	3,36	4,50	5,04	8
9	0,54	0,88	1,38	1,83	2,26	2,82	3,25	4,30	4,78	9
10	0,54	0,88	1,37	1,81	2,23	2,76	3,17	4,14	4,59	10