

Messen, Schätzen, Bonitieren: Konsequenzen des Skalenniveaus für die Auswertung und Interpretation von Versuchsdaten

Andreas BÜchse & Hans-Peter Piepho, Universität Hohenheim, Fachgebiet Bioinformatik, Fruwirthstr. 23, 70599 Stuttgart, buechse@uni-hohenheim.de

Einleitung

Ein landwirtschaftlicher Feldversuch ist ein Experiment. Ziel eines Experimentes ist die Gewinnung von Daten unter dem Einfluss von Prüffaktoren. Aus den Daten, die das Experiment liefert, werden Schätzwerte für die Effekte von Prüffaktoren gewonnen. Auf Basis dieser Schätzwerte werden dann Entscheidungen getroffen. Zum Beispiel eine Düngungsempfehlung für eine bestimmte Fruchtart oder die Selektionsentscheidung eines Züchters. Damit man möglichst häufig die richtige Entscheidung trifft, sollen die Schätzwerte (i) eine möglichst kleine Varianz aufweisen und (ii) unverzerrt sein.

Die Forderung nach kleiner Varianz bezieht sich auf zufällige Fehlereinflüsse. Da die Daten des Experiments lediglich eine Stichprobe aus einer Grundgesamtheit von möglichen Beobachtungen darstellen, unterliegen die Schätzwerte einem Stichprobenfehler. Dieser kann durch eine entsprechend exakte Versuchsanlage und –durchführung oder durch eine höhere Zahl an Messungen (=Wiederholungen) reduziert werden.

Mit unverzerrt ist gemeint, dass eine unendlich große Zahl von Wiederholungen des Experiments im Mittel einen Schätzwert liefern sollte, der dem Wert in der Grundgesamtheit, für die eine Aussage gemacht werden soll, entspricht. Weicht der aus den Experimenten gewonnene Schätzer von dem tatsächlichen Wert ab, so liegt eine Verzerrung vor. Eine gewisse Verzerrung müssen wir in Feldversuchen meist in Kauf nehmen. Ein Parzellenversuch kann eben nicht die Verhältnisse in einem mehrere Hektar großen Praxisschlag abbilden. Meist akzeptieren wir eine geringe Verzerrung, wenn wir dafür die zufälligen Fehler reduzieren können.

Die im Experiment gewonnenen Daten sollen am Ende in Interpretationen und Entscheidungen verwandelt werden. Für den Wissenschaftler stellt sich damit die Frage, wie belastbar seine Daten sind, also ob seine Ergebnisse präzise und unverzerrt sind. Während letzteres meist aus sachlichen Überlegungen heraus entschieden werden kann ist für eine Bewertung der Präzision eine statistische Analyse notwendig. Präzisionsmaße sind z.B. Standardfehler, Vertrauensintervalle und Grenzdifferenzen. Die hierfür angemessenen Methoden hängen stark von der Art der Daten, insbesondere ihrem Skalenniveau ab. Hiermit befasst sich der vorliegende Beitrag.

Skalen

In der statistischen Basis-Literatur (z.B. BORTZ 1999) werden im Allgemeinen vier Skalentypen unterschieden:

- (1) Nominalskala (z.B. Blütenfarben, krank/gesund)
- (2) Ordinalskala (z.B. Schulnoten, Stärke eines Krankheitsbefalls)
- (3) Intervallskala (z.B. Temperatur, Kalenderzeit)
- (4) Verhältnisskala (z.B. Längen, Gewichte)

In der EPPO-Richtlinie 1/152 (2) werden nominale Merkmale, die lediglich zwei Ausprägungsstufen aufweisen, gesondert behandelt (BBA 2001). Intervall- und Verhältnisskala werden dagegen zusammengefasst.

- (1) Binär skalierte Merkmale (z.B. krank/gesund)
- (2) Nominal skalierte Merkmale (z.B. Blütenfarben)

(3) Ordinal skalierte Merkmale (z.B. Schulnoten, Stärke eines Krankheitsbefalls)

(4) Quantitative Merkmale („alles was gemessen oder gezählt werden kann“)

Im Folgenden sollen einige der sich aus den Skalenniveaus ergebenden Konsequenzen anhand von Beispielen erläutert werden.

Beispiel 1 - Messwerte

Tab. 1: DON-Gehalt [$\mu\text{g kg}^{-1}$] von Winterweizen nach Körnermais in Abhängigkeit von unterschiedlicher Behandlung der Maisstoppel (Daten von Dr. Wilfried Hermann, Ihinger Hof, Univ. Hohenheim)

VG	Wdh 1	Wdh 2	Wdh 3	Mittel
1	206			206
2		1484	774	1129
3		3776	2420	3098
4		1653	1833	1743
5		1772	1120	1446
6	88			88
7	453	457	458	456
8		900	871	886
9	657	325	361	448
10	197	248	205	217
Mittel	320	1327	1005	965

Diese Daten wurden auf einer nach oben offenen stetigen Skala gemessen. Bei einigen Parzellen wurde der DON-Gehalt nicht gemessen. Das übliche Auswertungsverfahren ist die Varianzanalyse mit anschließendem multiplem Mittelwertvergleich. Aufgrund der Lückigkeit des Datensatzes sind einfache (arithmetische) Mittelwerte im Hinblick auf die spätere Interpretation nicht empfehlenswert. Der Versuch wurde als Blockanlage angelegt, deshalb sollten wir auch hier ein Modell zugrunde legen, das einen Blockeffekt enthält. Adjustierte Mittelwerte (LSMeans) können wir dann mit der Methode der kleinsten Quadrate schätzen. Für die Analyse legen wir folgendes Modell zu Grunde: $y_{ij} = \mu + \beta_j + \tau_i + e_{ij}$

Erwartungswert für den Mittelwert einer Behandlung: $= \mu + \bar{\beta}_{\bullet} + \tau_i$

y_{ij} = DON-Gehalt in Parzelle mit i -ter Behandlung in j -tem Block

β_j = Effekt des j -ten Blocks

τ_i = Effekt der i -ten Behandlung

e_{ij} = Restfehler der ij -ten Parzelle

Dieses Modell können wir mit einer Software für lineare Modelle auswerten und die Gesamtstreuung mittels Varianzanalyse in die verschiedenen Ursachen zerlegen. Für Prüfgliedmittelwerte und Mittelwertdifferenzen berechnen wir Standardfehler und Konfidenzintervalle.

Tab. 2: Varianzanalyse-Tabelle für DON-Gehalte

Ursache	FG	SQ	MQ	F-Wert	p-Wert
Wdh	2	431192.78	215596.39	1.87	0.2092
VG	9	12736232.1	1415136.9	12.28	0.0005
Fehler	9	1037295.05	115255.01		

Tab. 3: Mittelwerte und Standardfehler für DON-Gehalte

VG	1	2	3	4	5	6	7	8	9	10
DON LSMEAN	144	1160	3129	1774	1477	26	456	917	448	217
Standardfehler	375	253	253	253	253	375	196	253	196	196
Signifikanzgruppe*	ab	bcd	e	d	dc	a	ab	ac	ab	a

* Mittelwerte mit gleichen Buchstaben unterscheiden sich nicht signifikant

Die Varianzanalyse hat gezeigt, dass generell signifikante Variantenunterschiede bestehen, nun ist von Interesse, welche Varianten sich unterscheiden. Hierfür berechnen wir die Grenzdifferenz nach t-Test (LSD = least significant difference). Bei 9 Fehler-Freiheitsgraden und 5%-Irrtumswahrscheinlichkeit liegt der t-Tabellenwert bei 2.26. Wenn wir für n die maximale Anzahl Wiederholungen einsetzen erhalten wir:

$$LSD = t \cdot \sqrt{\frac{2 \cdot MQ_e}{n}} = 2.26 \cdot \sqrt{\frac{2 \cdot 115255}{3}} = 626$$

Wir müssen aber beachten, dass lediglich bei VG 7, 9 und 10 drei Beobachtungen vorliegen. Bei Vergleichen anderer Mittelwerte mit geringerer Wiederholungszahl ergeben sich andere Grenzdifferenzen. In diesem Datenbeispiel gibt es keine einheitliche Grenzdifferenz! Eine sinnvolle Alternative ist deshalb eine Darstellung mit Buchstaben, so wie in Tab. 3. Die Erstellung der Buchstaben bei unbalancierten Daten ist unter Umständen nicht trivial. Hierzu wurde ein SAS-Macro entwickelt (PIEPHO 2004, 2005).

Die Varianzanalyse hat unter anderem vier wesentliche Voraussetzungen: Unabhängigkeit der Fehler, Additivität der Effekte, Normalverteilung der Residuen und Varianzhomogenität. Die Unabhängigkeit kann dadurch sichergestellt werden, dass die Varianten den Versuchseinheiten zufällig (randomisiert) zugeteilt werden. Die letzten beiden Voraussetzungen bedeuten, dass die den Beobachtungen anhaftenden Fehler alle aus der gleichen normalverteilten Grundgesamtheit von Fehlereffekten stammen sollen und zwischen Mittelwert und Varianz soll keine Abhängigkeit bestehen. Dieses kann am besten mit einem Residuenplot überprüft werden. Während der Auswertung lässt man sich für jede Beobachtung den Erwartungswert berechnen. Die Residuen sind dann die Differenzen zwischen Beobachtung und dem aufgrund des Modells vorausgesagten Werts.




Abb. 1: Histogramm der Residuen (links) und Plot der Residuen (rDON) gegen die Erwartungswerte (pDON)

Die Plots zeigen, dass zwar die Normalverteilung halbwegs erfüllt ist, allerdings steigt die Varianz mit zunehmenden Erwartungswerten an. Bei Behandlungen mit hohem DON-Gehalt weichen die Residuen stärker von Null ab, d.h. die Einzelwerte streuen stärker um den Mittelwert.

Oftmals kann fehlende Normalverteilung und / oder Varianzheterogenität durch eine Transformation korrigiert werden. Dann führen wir erneut eine Varianzanalyse mit den transformierten Daten durch und schauen uns die Residuen an. Wir führen hier eine Log-Transformation durch.

Transformation mit natürlichem Logarithmus : $y' = \text{Log}(y)$

Transformation mit dekadischem Logarithmus : $y' = \text{Log}_{10}(y)$




Abb. 2: Histogramm der Residuen (links) und Plot der Residuen (rDON) gegen die Erwartungswerte (pDON), nach Log-Transformation

Nach der Transformation wird die Normalverteilung der Residuen noch besser erfüllt und der Plot der Residuen gegen die Erwartungswerte zeigt keine Beziehung mehr. Damit ist Varianzanalyse zulässig. Für die Darstellung der Ergebnisse gibt es nun drei Möglichkeiten:

- Ausschließlich die Mittelwerte aus der Auswertung der transformierten Daten darstellen, Buchstabendarstellung oder Grenzdifferenz auf transformierter Skala
- Mittelwerte aus den untransformierten Daten berechnen, Signifikanztests aber mit transformierten Daten durchführen, Buchstabendarstellung
- Auswertung über transformierte Daten, Signifikanztests mit transformierten Daten durchführen, Mittelwerte abschließend auf Originalskala rücktransformieren, Buchstabendarstellung; die rücktransformierten Mittelwerte sind dann Schätzwerte für den Median auf der Originalskala (siehe PIEPHO & BÜCHSE 2003)

Tab. 4: Adjustierte Mittelwerte auf Originalskala, Mittelwerte und Standardfehler auf Log₁₀-Skala und rücktransformierte Mittelwerte

VG	LSMean original	LSMean Log ₁₀ -trans	Standardfehler Log ₁₀	Rueck_10 (= Median)	Signifikanzgruppe
3	3129	3.505	0.079	3198	A
4	1774	3.265	0.079	1841	AB
5	1477	3.173	0.079	1490	AB
2	1160	3.055	0.079	1134	BC
8	917	2.972	0.079	937	BCD
7	456	2.659	0.061	456	CDE
9	448	2.629	0.061	426	DE
10	217	2.334	0.061	216	EF
1	144	2.265	0.117	184	EF
6	26	1.896	0.117	79	F

* Mittelwerte bzw. Mediane mit gleichen Buchstaben unterscheiden sich nicht signifikant

Fazit Beispiel 1

Für Messwerte, die auf einer stetigen Skala erhoben wurden, ist im allgemeinen die Formulierung eines linearen Modells, Varianzanalyse und Mittelwertvergleich mittels t-Test (oder z.B. Tukey-Test) adäquat. Bei Verletzung der Modellvoraussetzungen hilft oftmals eine Transformation, im gezeigten Beispiel eine Log-Transformation. Falls gewünscht können die Mittelwerte auf die Original-Skala rücktransformiert werden. Grenzdifferenzen sollten nicht rücktransformiert werden, da es dann auf der Originalskala keine einheitliche Grenzdifferenz mehr gibt. Besser ist in diesem Fall eine „Buchstabendarstellung“. Rücktransformierte Mittelwerte sollten dann als Mediane gekennzeichnet werden.

Beispiel 2 – Zählwerte

Daten von Prof. J. Petersen, FH Bingen: Feldversuch zur Bekämpfung der Tauben Trespe in Wintergerste. Der Versuch bestand aus einer randomisierten Blockanlage mit 8 Versuchsgliedern und 4 Wiederholungen. In jeder Parzelle wurden 5 markierte Zählstellen a 0,25 m² eingerichtet, die im Herbst und Frühjahr aufgesucht wurden, um die Anzahl der Trespenpflanzen in Abhängigkeit der Behandlungen zu bestimmen. Herbizidbehandlungen fanden im frühen Nachauflauf statt. Hier werden vier ausgewählte Versuchsglieder wiedergegeben.

Tab. 5: Dichte von Tauber Trespe (Pfl./m²) im Frühjahr in Abhängigkeit von Herbizidmaßnahme

Variante	Zählstelle	Block 1	Block 2	Block 3	Block 4
1	1	28	40	12	28
1	2	28	36	8	24
1	3	16	4	0	4
1	4	8	0	4	0
1	5	0	0	0	0
4	1	12	8	0	0
4	2	12	8	0	12
4	3	0	4	0	0
4	4	0	0	0	0
4	5	0	0	0	0
5	1	12	4	0	0
5	2	24	8	0	0
5	3	16	0	0	0
5	4	0	0	0	0
5	5	0	0	0	0
6	1	16	16	12	8
6	2	8	20	20	8
6	3	16	8	4	0
6	4	0	0	0	0
6	5	0	0	0	4

Um einen besseren Eindruck von den Daten zu erhalten, fertigen wir uns Boxplots an (Abb. 3). Die Varianzen sind nicht homogen. Die unbehandelte Variante 1 zeigt die größte Streuung. Auch zwischen den Blöcken bestehen Unterschiede im Mittelwert und in der Varianz. Da viele Nullen auftreten sind die Daten deutlich rechtsschief. Je Parzelle wurden fünf Zählstellen untersucht. Insgesamt stehen hier Daten von 80 Zählstellen zur Verfügung. Für die statistische Analyse ist jedoch zu beachten, dass die Varianten nicht auf die Zählstellen sondern auf die Parzel-

len randomisiert wurden. Es gibt lediglich 16 unabhängige Beobachtungen nicht 80. Es ist daher sinnvoll, die Daten auf Ebene der Parzellen zu aggregieren (Tab. 6). Das Problem der ungleichen Varianzen bleibt allerdings bestehen.




Abb. 3: Boxplots der Trespendichte gruppiert nach Varianten und Wiederholungen.

Tab. 6: Dichte von Tauber Trespe (Pfl./m²) im Frühjahr in Abhängigkeit von Herbizidmaßnahme, Daten auf Parzellenebene aggregiert

Variante	Block 1	Block 2	Block 3	Block 4	Mittel
VG 1 = Kontrolle, keine Herbizide	16.0	16.0	4.8	11.2	12.0
VG 4 = 400 g/ha Cadou + 3,0 l/ha Stomp	4.8	4.0	0.0	2.4	2.8
VG 5 = 600 g/ha Herold	10.4	2.4	0.0	0.0	3.2
VG 6 = 200 g/ha Sencor	8.0	8.8	7.2	4.0	7.0
Mittel	9.8	7.8	3.0	4.4	6.3

Auch bei diesen Daten ist zunächst an eine Varianzanalyse und ein lineares Modell zu denken:

$$y_{ij} = \alpha + \beta_j + \tau_i + e_{ij}$$

y_{ij} = Anzahl Trespe-Pflanzen in Parzelle mit i -ter Behandlung in j -tem Block

α = Konstante, β_j = Effekt des j -ten Blocks

τ_i = Effekt der i -ten Behandlung, e_{ij} = Restfehler der ij -ten Parzelle

Bei diesem Modell gehen wir davon aus, dass sich die Effekte additiv verhalten. Dieses ist hier jedoch nicht plausibel. Aus biologischen Erwägungen, ist es nicht sinnvoll anzunehmen, dass die Wirkung von Variante 4 in allen Blöcken gleich ist. Wir erwarten viel eher, dass die Behandlung mit dem Herbizid jeweils einen gewissen Anteil der Trespepflanzen abtötet (z.B. jeweils etwa 75%). Diese Annahme entspricht einem multiplikativen Modell. Wir haben verschiedene Möglichkeiten, diese Multiplikativität zu berücksichtigen. Die erste ist (wie in Beispiel 1) eine logarithmische Transformation, denn durch die Logarithmierung werden multiplikative Beziehungen in additive überführt. Problem bei den Daten von Beispiel 2 ist allerdings, dass viele Nullen auftreten. Und zu „0“ gibt es keinen Logarithmus! Mögliche Lösung wäre, jeweils eine „kleine Zahl“ z.B. 0.5 zu addieren. Die Wahl dieser Zahl ist aber relativ willkürlich und hat Einfluss auf das Endergebnis, was unbefriedigend ist. Eine andere Transformation, die manchmal gut passt ist die Wurzeltransformation. In vielen Fällen findet man allerdings überhaupt keine

Transformation, die sowohl Varianzhomogenität als auch Normalverteilung erreicht. In solchen Fällen, ist die Verwendung eines Generalisierten Linearen Modells (GLM) (McCULLAGH & NELDER 1989, AGRESTI 2002) zu überlegen.

Was ist ein Generalisiertes Lineares Modell?

Bei einem GLM ist die Transformation quasi Teil des Modells. Die Verbindung zwischen der Originalskala und der transformierten Skala wird als Link-Funktion bezeichnet. Bei einer logarithmischen Transformation spricht man von einem „Log-Link“. Die Transformation bezieht sich beim GLM nicht auf die Beobachtungen sondern auf die Erwartungswerte. Diese sind nicht gleich Null. Dass einzelne Beobachtungen gleich Null sind, stört daher bei der Auswertung nicht. Neben der Definition der Link-Funktion muss in einem GLM eine Verteilungsannahme getroffen werden. Zählwerte wie die Trespedaten sind häufig Poisson-verteilt.

Wir bezeichnen im Folgenden den Erwartungswert für die Anzahl Pflanzen in einem bestimmten Block bei einer bestimmten Behandlung mit μ_{ij} .

Für die Trespe-Daten ergibt sich: $E(y_{ij}) = \mu_{ij} = \alpha + \beta_j + \tau_i$

Wie bereits oben erwähnt ist die Additivitätsannahme hier nicht so sinnvoll. Vielmehr nehmen wir ja an, dass Multiplikativität herrscht. Das impliziert Additivität auf der Log-Skala.

$\log(\mu_{ij}) = \alpha + \beta_j + \tau_i$. Die Schätzwerte für Konstante, Block- und Behandlungseffekte werden dann auf der Log-Skala geschätzt. Wir ersetzen abschließend $\log(\mu_{ij})$ durch: η_{ij} .

Dieses wird in GLM-Terminologie als Linearer Prediktor bezeichnet: $\eta_{ij} = \alpha + \beta_j + \tau_i$

Wir haben nun ein so genanntes „Loglineares Modell“ vor uns. Es liegt weiterhin ein lineares Modell vor; allerdings gilt die lineare Beziehung nicht bezüglich μ_{ij} , sondern für eine Funktion von μ_{ij} . Diese Funktion ist die Link-Funktion: Sie stellt die Verbindung (den „Link“) her zwischen der Anzahl und dem linearen Prediktor. $\eta_{ij} = f(\mu_{ij})$

Viele marktübliche Software-Pakete (z.B. SAS, SPSS) sind mit Modulen zur Analyse von GLMs ausgestattet. Die Schätzung der Effekte erfolgt mit der Maximum-Likelihood-Methode. Anstelle von Summenquadraten werden Devianzen berechnet, die aber ähnlich zu interpretieren sind. Ob ein Effekt im Modell signifikant ist wird mittels Chi-Quadrat-Test geprüft. In Tab. 7 und 8 ist der Output der SAS-Prozedur GENMOD dargestellt (zugehöriger Programm-Code im Anhang). Die Behandlungseffekte sind bei einem p-Wert von 0.1% klar signifikant. Auch die Blockeffekte sind signifikant. Die erhaltenen Schätzwerte können wir zur besseren Interpretation wieder auf die Original-Skala zurücktransformieren. Hierzu müssen wir lediglich die Umkehrfunktion zur Link-Funktion einsetzen. Hier also $\mu_{ij} = \exp(\eta_{ij})$.

Tab. 7: Devianz-Tabelle für Dichte von Tauber Trespe in Abhängigkeit von Herbizidmaßnahme

Ursache	Devianz	Zähler-FG	Nenner-FG	Chi-Quadrat	p-Wert
Intercept	74.4315				
Block	55.3125	3	9	9.22	0.0265
Behandlung	21.4667	3	9	16.32	0.0010

Tab. 8: LSMeans für Dichte von Tauber Trespe (GLM mit Log-Link)

Behandlung	Erwartungswert	Standardfehler	Rücktransformiert [Pfl./m ²]
1	2.3815	0.2193	10.82
4	0.9262	0.4360	2.52
5	1.0598	0.4086	2.89
6	1.8425	0.2810	6.31

Wirkungsgrade

Eine andere Möglichkeit, Multiplikatивität abzubilden ist die Berechnung eines Wirkungsgrades.

Wirkungsgrad nach ABBOTT (1925): $WG = \left(1 - \frac{Y_n}{X_n}\right)$; Y_n = Anzahl Beh.; X_n = Anzahl Kontrolle

Wenn wir uns in Tab. 6 die Mittelwerte der Varianten über den Versuch anschauen, so erhalten wir folgende Wirkungsgrade:

Var. 4: $WG = (1 - 2.8/12) = 77\%$; Var. 5: $WG = (1 - 3.2/12) = 73\%$; Var. 6: $WG = (1 - 7/12) = 42\%$

Wir können die Wirkungsgrade aber auch in jedem Block separat berechnen (Bezugsbasis jeweils Kontrolle innerhalb des Blocks) und dann über die Blöcke mitteln. Hierdurch erhalten die Ergebnisse aus Block 3 allerdings ein höheres Gewicht als wenn die Auswertung zunächst über Absolutzahlen erfolgt.

Tab. 9: Wirkungsgrade, Bezugsbasis jeweils Kontrolle im gleichen Block

Variante	Block 1	Block 2	Block 3	Block 4	Mittel
VG 1 = Kontrolle, keine Herbizide	0%	0%	0%	0%	0%
VG 4 = 400 g/ha Cadou + 3,0 l/ha Stomp	70%	75%	100%	79%	81%
VG 5 = 600 g/ha Herold	35%	85%	100%	100%	80%
VG 6 = 200 g/ha Sencor	50%	45%	-50%	64%	27%
Mittel	39%	51%	38%	61%	47%

Ein extremes Beispiel, was dieses Problem verschärft:

Block A: Kontrolle = 10, Behandlung = 0, $WG = 100\%$

Block B: Kontrolle = 890, Behandlung = 0, $WG = 100\%$

Block C: Kontrolle = 50, Behandlung = 5, $WG = 90\%$

Block D: Kontrolle = 50, Behandlung = 5, $WG = 90\%$

Der mittlere Wirkungsgrad wäre hier 95%. Man kann allerdings die Auffassung vertreten, dass die Wirkung der Behandlung in Block B viel größer ist als in Block A, C und D und dass die Beobachtung aus Block B entsprechend Niederschlag im Gesamtergebnis finden soll. Immerhin haben auf dem Versuchsfeld lediglich 10 von 1000 Pflanzen überlebt. Ist der Wirkungsgrad dann also nicht vielmehr 99%?

Diese Überlegungen lassen vermuten, dass der WG vielleicht kein sinnvolles Kriterium für die Beurteilung eines Mittels ist und dass die Relativbetrachtung evtl. durch eine Absolutbetrachtung zu ersetzen ist. In diesem Fall würde man zur Beurteilung die absolute Differenz der Mittelwerte von Kontrolle und Behandlung betrachten, was aber wiederum aufgrund der fehlenden Additivität nicht optimal sein kann. Ein weiteres Problem ist, dass eine varianzanalytische Auswertung von Wirkungsgraden wie in Tab. 9 nicht unproblematisch ist. Zum einen sind die Werte innerhalb eines Blocks nicht mehr unabhängig sondern korreliert, da sie die gleiche Kontrolle als Bezugsbasis haben, zum anderen verletzen Prozentzahlen häufig die Annahmen der Normalverteilung und Varianzhomogenität. Man müsste also wiederum transformieren.

Die Lösung dieses Dilemmas ist die Auswertung als GLM. Schauen wir uns die Ergebnisse in Tab. 8 an. Hier wurden in einem loglinearen Modell die Erwartungswerte auf der Log-Skala geschätzt. In der letzten Spalte sind die rücktransformierten Schätzwerte dargestellt. Wir erhalten folgende Wirkungsgrade: Var. 4: $WG = (1 - 2.52/10.82) = 77\%$; Var. 5: $WG = (1 - 2.89/10.82) = 73\%$; Var. 6: $WG = (1 - 6.31/10.82) = 42\%$. Die gleichen Wirkungsgrade wie bei der Berechnung basierend auf Tab. 6! Bei Zählwerten ist die Berechnung von Wirkungsgraden über das Gesamt-

tmittel also der bessere Weg. Das GLM bietet uns nun noch einen weiteren Vorteil. Da wir ein lineares Modell formuliert haben, können wir sowohl Mittelwerte als auch Differenzen und die zugehörigen Standardfehler schätzen. Die Differenz zweier Behandlungen auf der Log-Skala entspricht dem Quotient der zugehörigen Werte auf der Originalskala. In Tab. 10 sind die Differenzen zwischen dem Mittelwert der Kontrolle (Variante 1) und den Mittelwerten der Varianten 4, 5 und 6 sowie die Standardfehler der Differenz und die 95%-Vertrauensintervalle für die Differenzen angegeben. Zwischen der Kontrolle und Behandlung 4 beträgt die Differenz $(2.3815 - 0.9262) = 1.4553$. Wir können diese Differenz rücktransformieren, um einen Quotienten zu erhalten: $\mu_1 / \mu_4 = \exp(\eta_1 - \eta_4) = \exp(1.4553) = 4.286$

In der Kontrolle ist die Tresse-Dichte 4.286 mal so hoch wie in der Behandlung 4. Hieraus ergibt sich ein Wirkungsgrad von $1 - (1 / 4.286) = 76.7\%$. Nach dem gleichen Schema können wir die Grenzen der Vertrauensintervalle in einen Wirkungsgrad transformieren.

Tab. 10: Differenzen auf der Log-Skala und entsprechende Wirkungsgrade

Beh	_Beh	Differenz	Standardfehler	Vertrauensintervall		WG [%]	Untere Grenze [%]	Obere Grenze [%]
1	4	1.4553	0.4779	0.5186	2.3919	76.7	40.5	90.9
1	5	1.3218	0.4530	0.4338	2.2097	73.3	35.2	89.0
1	6	0.5390	0.3425	-0.1322	1.2102	41.7	-14.1	70.2

Fazit Beispiel 2

Zählwerte für Individuendichten (z.B. Unkräuter, Insekten) sind häufig nicht normal- sondern Poisson-verteilt. Das impliziert, dass die Bildung von arithmetischen Mittelwerten auf der untransformierten Skala zu Fehlinterpretationen führen kann, wenn z.B. Versuche mit unterschiedlichem Befallsniveau gemeinsam ausgewertet werden. Vor varianzanalytischer Auswertung ist eine Transformation notwendig (z.B. Wurzel- oder Log-Transformation). Besser ist die Verwendung eines Generalisierten Linearen Modells (GLM) mit Log-Link und entsprechender Verteilungsannahme. Bei Mittelprüfungen ist die Anlage einer unbehandelten Kontrolle und eine Berechnung des Wirkungsgrades nach Abbott üblich. Dieser reagiert aber empfindlich bei heterogenen Befallssituationen innerhalb eines Versuchs, wenn jeweils unterschiedliche Parzellen als Bezugsbasis gewählt werden. Auch die hieraus entstehenden Probleme verschwinden bei Nutzung eines GLM.

Beispiel 3 – Bonituren vom Typ „Prozent Befall“

An verschiedenen Standorten im Rheinland wurden Feldversuche mit fünf Zuckerrübensorten angelegt. Vor der Ernte wurden im Bestand Bereiche festgelegt, in denen Rüben geerntet wurden. Hierbei wurden bewusst Bereiche mit schwachem, mittleren und starkem Befall ausgewählt. Zur Ernte wurden dann Rüben von Hand gerodet und der Befall mit Später Rübenfäule (*Rhizoctonia solani*) bonitiert. Je Sorte wurden innerhalb eines Blocks 20 bis 30 Rüben bonitiert. Am Standort Gangelt wurden im Jahre 2002 insgesamt 1899 Einzerrüben entsprechend dem Anteil verfaulter Rübenoberfläche in % bonitiert. Abb. 4 zeigt die Verteilung der Boniturergebnisse in einer anfälligen Sorte und in einer toleranten / teilresistenten Sorte.

Für die Auswertung wurde zunächst wieder das Modell einer Blockanlage verwendet. Wichtig ist hier, das Modell um einen zufälligen Parzellenfehler für jede Sorte*Block-Kombination zu erweitern.




Abb. 4: Verteilung von *Rhizoctonia*-Befall (% verfaulte Oberfläche) bei Einzerrüben

$$y_{ijk} = \mu + \beta_j + \tau_i + f_{ij} + e_{ijk}$$

y_{ijk} = Befall der k -ten Rübe in Parzelle mit i -ter Behandlung in j -tem Block in Prozent

β_j = Effekt des j -ten Blocks

τ_i = Effekt der i -ten Behandlung

f_{ij} = zufälliger „Parzellenfehler“ Sorte*Block

e_{ijk} = Restfehler k -ten Rübe in der ij -ten Parzelle

Wir schauen uns die Verteilung der Residuen (Restfehler) an (Abb. 5). Erwartungsgemäß folgen die Residuen nicht einer Normalverteilung. Die Verteilung ist zu schmalgipflig. Im Plot der Residuen gegen die Erwartungswerte erkennen wir folgende Charakteristika: Die Streuung der Residuen ist bei kleinen Erwartungswerten am geringsten. Je höher der Erwartungswert, desto mehr negative Residuen treten auf. Dieses ist verständlich. Die Skala der Bonituren ist auf Werte zwischen 0 und 100% begrenzt. Ebenso liegen die Erwartungswerte zwischen 0 und 100%. Ein Beobachtungswert von 10% kann also zwangsläufig nur Residuen zwischen –90% und 10% aufweisen. Um diese Probleme zu beseitigen, können wir uns wieder einer Transformation bedienen. Geeignete Transformation für Werte, die sich zwischen 0 und 100% bewegen, sind die Winkel- (Arcussinus) und die LOGIT-Transformation:

Arcussinus $x' = \sin^{-1}(x)$ $|x| \leq 1$ (Umkehrfunktion der Sinusfunktion)

Logit $x' = \log[x/(1-x)]$ $0 < x < 1$ Wichtig: x = Prozentwert / 100 !




Abb. 5: Histogramm der Residuen von Auswertung Einzerrüben (links) und Plot der Residuen gegen die Erwartungswerte

Leider ist die Winkeltransformation bei diesen Daten nicht hilfreich und die Logit-Transformation hat das Problem, dass sehr häufig ein Befall von 0 oder 100% auftritt, wodurch entweder der Logarithmus von 0 gebildet werden müsste oder eine Division durch 0 notwendig würde. Wir könnten uns nun wiederum damit behelfen, im Zähler und im Nenner jeweils einen kleinen Wert zu addieren. Ein besseres Verfahren ist die Verwendung eines GLM mit Logit-Link und Annahme einer Binomial-Verteilung (PIEPHO 1998).

Im vorliegenden Fall können wir noch eine weitere Alternative probieren. Da je Sorte und Befallsnest jeweils bis zu 30 Rüben bonitiert wurden, können wir den Mittelwert aus diesen 30 Einzelwerten berechnen und unsere statistische Analyse mit diesen Mittelwerten durchführen.




Abb. 6: Histogramm der Residuen von Auswertung über Mittelwerte (links) und Plot der Residuen gegen die Erwartungswerte

Die Verteilung der Residuen ist nun verbessert (näher an der Normalverteilung) (Abb. 6). Ein solches Phänomen kann häufig beobachtet werden und ergibt sich aus dem zentralen Grenzwertsatz: *Die Summe (bzw. der Mittelwert) einer großen Zahl von unabhängigen, identisch verteilten Zufallsvariablen ist annähernd normalverteilt.* (Als große Zahl wird gemeinhin $n > 30$ angesehen). Der Plot gegen die Erwartungswerte ist leider noch nicht befriedigend, wir sehen Varianzheterogenität (Abb. 6). Sehr unschön ist, dass Erwartungswerte $< 0\%$ Befall auftreten. Dieser Befund hat seine Ursache in fehlender Additivität und wird offensichtlich wenn wir uns die Mittelwerte der Sorten und Blöcke anschauen (Tab. 11). Wenn der Befall bei Sorte 2 9% unter dem Gesamt-Mittel liegt, so wird der Erwartungswert für Sorte 2 im Block 6702 mit -5% tatsächlich negativ! Ursache ist die fehlende Additivität! Die fehlende Additivität macht die Interpretation der Versuchsergebnisse sehr schwierig. Wenn wir die Differenz der arithmetischen Mittelwerte betrachten, so sehen wir, dass der mittlere Befall von Sorte 2 28% unter dem Befall der anfälligen Standardsorte 1 liegt. Diese Befallsdifferenz ist pflanzenbaulich jedoch nicht sinnvoll interpretierbar, denn wir wissen, dass der absolute Vorteil von Sorte 2 vom Befallsniveau abhängig ist. Die absolute Differenz ist in den Bereichen des Feldes, wo der Befall niedrig ist geringer und in den Befallsnestern höher. Um Additivität zu erreichen, können wir an dieser Stelle doch wieder eine Logit-Transformation verwenden. Auf der Logit-Skala sind unsere Residuen wunderbar normalverteilt. Die Varianzen sind homogen und von Additivität kann auch ausgegangen werden.

$$x' = \log((x+c) / (1-x+c))$$

x auf Bereich $[0;1]$ skalieren und für c einen kleinen Wert einsetzen (z.B. 0.001)

Tab. 11: Befall mit *R. solani* [% verfaulte Rübenoberfläche], Mittelwerte je Block und Sorte

Block	Sorte 1	Sorte 2	Sorte 3	Sorte 4	Sorte 5	Mittel
6701	28	3	30	3	13	15
6702	10	0.0	0.2	2	6	4
6703	14	4	23	0.4	7	10
6704	76	7	19	11	62	35
6705	10	0.0	0.2	0.0	4	3
6706	70	18	2	2	23	23
6707	60	1	1	0.0	19	16
6708	23	0.4	3	7	14	10
6709	39	5	2	12	36	19
6710	9	0.0	0.2	0.2	7	3
6711	17	0.3	0.4	0.1	2	4
6712	16	2	8	1	1	6
Mittel	31	3	7	3	16	12

Effekt Block 2 = 4 – 12 = -8

Effekt Sorte 2 = 3 – 12 = -9

Erwartungswert für Sorte 2 in Block 2 = 12 – 9 – 8 = -5

Tab. 12: Logits für Befall mit *R. solani* [% verfaulte Rübenoberfläche], Mittelwerte je Sorte

Signifikanzgruppe*	Logit-Mittelwert	N	SorteNr
A	-0.98	12	1
B	-2.15	12	5
C	-3.78	12	3
C	-4.44	12	4
C	-4.47	12	2

* Mittelwerte mit gleichen Buchstaben unterscheiden sich nicht signifikant

Sorte 1 ist die anfälligste, gefolgt von Sorte 5, die Sorten 2, 3 und 4 können nicht unterschieden werden. Wie sind die Mittelwerte der Sorten auf der Logit-Skala zu interpretieren? Um einen Logit zu berechnen, benötigt man zunächst den Quotienten aus der Befallswahrscheinlichkeit und der Gegenwahrscheinlichkeit. Angenommen der Befall liegt bei 10%. Dann ist die Wahrscheinlichkeit für einen bestimmten Teil der Oberfläche einer Rübe befallen zu werden, also verfault zu sein 10%. Die Wahrscheinlichkeit nicht verfault zu sein beträgt 90%. Der Quotient aus diesen beiden Wahrscheinlichkeiten beträgt $0.1 / 0.9 = 0.1111$. Dieser Quotient wird auch als Odds (Englisch für Chancenverhältnis) bezeichnet. Ein Logit ist ein logarithmierter Odds (=LogOdds). Die Differenz zwischen zwei Logits entspricht damit dem logarithmierten Quotienten zweier Odds. Man bezeichnet die Differenz auch als „LogOdds-Ratio“ (Log OR).

Die Differenz der Logits zwischen Sorte 3 und Sorte 1 beträgt z.B. $-3.78 - (-0.98) = -2.8$. Das ist also das LogOddsRatio. Die Umkehrfunktion zum Logarithmus ist die e-Funktion. Wir rechnen $OR = \exp(-2.8) = 0.061$. Das heißt der Quotient der Odds von Sorte 3 und Sorte 1 beträgt 0.061. Das kann jetzt folgendermaßen interpretiert werden:

Wenn der Befall der anfälligen Sorte 1 bei 10% liegt so ergibt sich ein odds von 0.1111. Wir wissen auf Basis unseres Versuches, dass das OddsRatio zwischen Sorte 3 und Sorte 1 $OR = 0.061$ beträgt. Für Sorte 3 erwarten wir dann ein Odds von $0.1111 * 0.061 = 0.0068$.

Wenn gewünscht können wir dieses Odds abschließend in eine absolute Befallswahrscheinlichkeit umrechnen:

$$0.0068 = p / (1 - p) \Leftrightarrow p = 0.0068 - (0.0068 p) \Leftrightarrow 1.0068 p = 0.0068 \Leftrightarrow p = 0.00675 = 0.675\%$$

Das relative Risiko für einen Befall beträgt damit bei Wahl von Sorte 3 im Vergleich zu Sorte 1 = $0.675\% / 10\% = 6.75\%$.

Wenn der Befall der anfälligen Sorte 1 bei 50% liegt so ergibt sich ein odds von 1. Das OddsRatio zwischen Sorte 3 und Sorte 1 beträgt $OR = 0.061$. Für Sorte 3 erwarten wir ein Odds von $1 * 0.061 = 0.061$. Hieraus ergibt sich eine absolute Befallswahrscheinlichkeit von:

$$0.061 = p / (1 - p) \Leftrightarrow p = 0.061 - (0.061 p) \Leftrightarrow 1.061 p = 0.061 \Leftrightarrow p = 0.0575 = 5.75\%$$

Das relative Risiko für einen Befall bei Wahl von Sorte 3 beträgt damit im Vergleich zu Sorte 1 = $5.75\% / 50\% = 11.5\%$.

Fazit Beispiel 3

Bonituren vom Typ „Prozent Befall“ bewegen sich in aller Regel in einem Wertebereich zwischen 0 und 1. Solche Daten sind im Allgemeinen nicht normalverteilt, weshalb wiederum die unkritische Anwendung der Varianzanalyse zu Fehlinterpretationen führen kann. Falls pro Parzelle mehrere Individuen bonitiert wurden so kann für die Mittelwerte Normalverteilung postuliert werden, wenn die Zahl der Individuen groß genug ist ($n > 30$). Oftmals kann jedoch keine Additivität und Varianzhomogenität erreicht werden. Für solche Daten wird daher eine Logit-Transformation oder die Verwendung eines GLM mit Logit-Link empfohlen. Die Differenz von Logits kann pflanzenbaulich im Sinne eines logarithmiertes Odds-Ratio interpretiert werden.

Beispiel 4 – Bonituren auf einer Notenskala 1-9

Noten basieren oft auf einer hinterlegten %-Skala. Anstatt die Note direkt zu schätzen, könnte man oftmals eine %-Zahl schätzen und dann einer Klasse zuordnen, was aber Informationsverlust bedeutet. Wenn möglich sollte die geschätzte %-Zahl direkt festgehalten werden. Man kann immer noch nachträglich die Note dazu ermitteln, wenn man es denn unbedingt will.

Als Argument für Boniturnoten wird häufig angeführt, dass die Bonitur dann schneller erfolgen kann. Das gilt allerdings nur solange die Zuordnung zu einer Note zweifelsfrei erfolgen kann. Bei Grenzfällen zwischen zwei Noten, kann der Entscheidungsprozess lange dauern und mit einer Prozentzahl würde man sich leichter tun. Boniturschemata sollten deshalb immer wieder mal kritisch hinterfragt werden.

Anstatt den *Rhizoctonia*-Befall von Beispiel 3 in Prozent zu erfassen, hätte man ebenfalls Noten verwenden können. Um diesen Fall zu simulieren, wurden die Prozentzahlen entsprechend einem Boniturschema nachträglich in Noten umgerechnet (Tab. 13).

Wie sollen wir diese Noten auswerten? Noten haben ordinales Niveau. Man kann lediglich sagen, dass eine Rübe mit Note 5 stärker befallen ist als eine Rübe mit Note 4, wir können aber keine Aussage darüber machen, um wie viel stärker. Die Differenz im Befall zwischen Note 4 und 5 hat außerdem eine andere Bedeutung wie die Differenz zwischen Note 1 und 2 oder zwischen Note 8 und 9.

Oftmals wird die Aussage gemacht, dass man bei ordinalen Daten anstatt des arithmetischen Mittels den Median darstellen sollte. Dieses wäre hier allerdings nicht sinnvoll. Ein Blick auf die Histogramme (Abb. 7) zeigt, dass der Median bei beiden Sorte die Note 1 wäre, denn jeweils mehr als 50% der Einzelrüben weisen keinen Befall auf. Eine varianzanalytische Auswertung der Noten verbietet sich allerdings ebenfalls. Die Noten sind nicht normalverteilt und auch Additivität kann *per se* nicht gegeben sein.

Tab. 13: Boniturschema für *Rhizoctonia*-Befall (Quelle IfZ Göttingen)

Befallsklasse	1	2	3	4	5	6	7	8	9
Oberfläche Rübe mit Fäule [%]	0	<1	>1-5	>5-10	>10-25	>25-50	>50-75	>75-99	100




Abb. 7: Verteilung von *Rhizoctonia*-Befall (Noten 1-9) bei Einzelrüben

Wenn wir wie im vorliegenden Beispiel viele Beobachtungen je Parzelle haben und viele Notenklassen besetzt sind, so sind wir in der komfortablen Situation, auf Parzellenebene den Mittelwert der Noten berechnen zu können. Entsprechend dem zentralen Grenzwertsatz können wir wieder erwarten, dass die Mittelwerte der Noten einer Normalverteilung zustreben. Dieses ist hier der Fall (Abb. 8). Die Mittelwerte der Noten werden dann wie eine stetige quantitative Variable behandelt und Mittels Varianzanalyse ausgewertet.




Abb. 8: Verteilung der Residuen von mittleren Noten, Auswertung über Mittelwerte

Tab. 14: Boniturnoten für *R. solani*, Mittelwerte je Sorte

SorteNr	Mittlere Note	N	Signifikanzgruppe*
1	3.76	12	A
5	2.93	12	B
3	1.83	12	C
4	1.45	12	C
2	1.44	12	C

* Mittelwerte mit gleichen Buchstaben unterscheiden sich nicht signifikant

Wenn nur wenige Noten vorliegen, z.B. nur eine Note je Parzelle, so sollte jedoch von Varianzanalyse Abstand genommen werden. Eingeführte Methoden für Ordinaldaten sind bei vollständig randomisierter Anlage der Kruskal-Wallis-Test, bei Blockanlage der Friedman-Test. Die Beobachtungen (z.B. Boniturnoten) werden der Größe nach sortiert. Jeder Beobachtung wird ein Rang zugeordnet. Dann werden mittlere Ränge berechnet. Die Signifikanz von Differenzen im mittleren Rang kann geprüft werden. Daneben existieren auf Permutationen basierende Verfahren (SCHUMACHER & FRISCH 1995, 1997). Für den mehrfaktoriellen Fall wurde von verschiedenen Autoren ein Datenalignment vorgeschlagen (BORTZ et al. 2000). Im vorliegenden Datenbeispiel könnte man in einem Schritt jeweils die mittlere Note je Block berechnen und diese Blockmittel von den Noten subtrahieren. Mittels Kruskal-Wallis-Test werten wir dann die um die Blockeffekte bereinigten Noten aus. Die Interpretation ist insofern unverändert, als dass die Reihenfolge der Sorten bei 1-5-3-(2,4) verbleibt. Der mittlere Rang gibt aber keine Auskunft darüber, um wie viel besser z.B. Sorte 3 gegenüber Sorte 1 ist. Hierfür ist wieder die mittlere Note heranzuziehen. Das Verfahren des Datenalignment ist aber nicht unumstritten und kann eigentlich nicht empfohlen werden.

Tab. 15: Rangsummen und mittlere Ränge für Boniturnoten für *R. solani*

SorteNr	N	Rangsumme	Erwartet unter H0	Standardabw. Unter H0	Mittlerer Rang
1	12	609.00	366.0	54.108742	50.75
2	12	215.00	366.0	54.108742	17.92
3	12	293.50	366.0	54.108742	24.46
4	12	215.50	366.0	54.108742	17.96
5	12	497.00	366.0	54.108742	41.42

Kruskal-Wallis-Test: Chi-Square 34.68; DF = 4; Pr>Chi-Square = <0.0001

Eine elegante „state of the art“-Methode zur Auswertung von Ordinaldaten ist das Schwellenwertmodell (PIEPHO 1997, PIEPHO & KALKA 2003, HARTUNG & PIEPHO 2005) und auf Rängen beruhende aktuelle Weiterentwicklungen der nichtparametrischen (verteilungsfreien) Verfahren (BRUNNER & LANGER 1999, BRUNNER & MUNZEL 2002). Das Schwellenwertmodell ist insbesondere dann effizient, wenn die Schwellen zwischen zwei Bonitурklassen bekannt sind. Das ist beispielsweise beim allgemeinen Boniturschema für landwirtschaftliche Sortenversuche erfüllt (Tab. 16).

Trotz aller Einschränkungen die für die Auswertung und Interpretation von Boniturnoten gelten mögen, erscheint die Berechnung von mittleren Noten als eine robuste Möglichkeit zentrale Tendenzen herauszuarbeiten. Genau so wird auch vom Bundessortenamt bei der Darstellung der Ergebnisse von Wertprüfungen verfahren (Tab. 17). Als Beispiel wurden aus dem Sortiment 2 der Wertprüfung Winterraps aus dem Jahr 1997 drei Sorten gewählt. Angegeben sind jeweils die Boniturnoten für Sclerotinia. Obwohl das Befallsniveau zwischen den Orten stark differiert, ist die Rangfolge und die Notendifferenz zwischen den drei Sorten sehr stabil.

Tab. 16: Boniturschema des Bundessortenamtes für Krankheiten und Schädlinge (BSA 2000).

Bonitur	Prozentskala	Schwellenwert	
		Prozent	Logit
1 = fehlend	0%	0%	nicht definiert
2 = sehr gering bis gering	> 0 - 2%	2%	-3.89182
3 = gering	> 2 - 5%	5%	-2.94444
4 = gering bis mittel	> 5 - 8%	8%	-2.44235
5 = mittel	> 8 - 14%	14%	-1.81529
6 = mittel bis stark	> 14 - 22%	22%	-1.26567
7 = stark	> 22 - 37%	37%	-0.53222
8 = stark bis sehr stark	> 37 - 61%	61%	0.44731
9 = sehr stark	> 61 - 100%	100%	nicht definiert

Tab. 17: Boniturnoten für Sclerotinia. Wertprüfung 2 Winterraps zur Körnernutzung 1997

	Ort 1	Ort 2	Ort 3	Ort 4	Ort 5	Ort 6	Ort 7	Ort 8	Ort 9	Ort 10	Mittel
Sorte 4	3.7	2.8	3.8	2.5	7.3	4.0	4.8	3.8	5.3	2.8	4.1
Sorte 5	2.7	2.5	3.5	2.0	6.3	2.8	3.8	2.8	3.5	2.0	3.2
Sorte 6	3.0	5.5	6.0	4.0	9.0	5.8	5.8	6.0	6.0	3.8	5.5
Mittel	3.1	3.6	4.4	2.8	7.5	4.2	4.8	4.2	4.9	2.9	4.3
Diff 6-5	0.3	3.0	2.5	2.0	2.7	3.0	2.0	3.2	2.5	1.8	2.3
Diff 4-5	1.0	0.3	0.3	0.5	1.0	1.2	1.0	1.0	1.8	0.8	0.9
Diff 6-4	-0.7	2.7	2.2	1.5	1.7	1.8	1.0	2.2	0.7	1.0	1.4

Fazit Beispiel 4

Falls möglich sollten Noten vermieden werden. Noten haben ordinales Niveau. Um eine Stichprobe zu charakterisieren ist eine Häufigkeitstabelle oder ein Histogramm sinnvoll. Falls die Verdichtung auf eine Maßzahl gewünscht ist, so kann die Berechnung einer mittleren Note erfolgen. Um Signifikanztests durchzuführen wird folgendes empfohlen: Wenn viele Einzelbonituren je Parzelle vorliegen, mittlere Note je Parzelle berechnen und diese wie normalverteilte stetige Variable behandeln, dann Varianzanalyse (evtl. zusätzlich Absicherung über nichtparametrischen Test, z.B. Kruskal-Wallis, Friedman-Test). Wenn nur wenige Einzelbonituren vorhanden (ein Wert je Parzelle), eher von Varianzanalyse absehen. Nichtparametrische Auswertung oder Schwellenwertmodell

Beispiel 5 – Nominale Daten mit mehr als zwei Klassen

In einem Laborversuch wurden drei Methoden (PDA, Wasser, Ethylen) zur Untersuchung von Lupinen-Saatgut verglichen. Mittels Keimtest in Petrischalen soll der Befallsgrad mit *Colletotrichum lupini* festgestellt werden. Die Lupinenkörner wurden unterschieden in „*Colletotrichum*-Befall“, „unbefallen“ und „unspezifischer Befall mit anderen Pathogenen“. Bei der Methode PDA wurden 20 Petrischalen à 10 Körner angesetzt, bei den Methoden Wasser und Ethylen jeweils 40 Petrischalen à 5 Körner. Insgesamt also 200 Körner je Methode. Von Interesse ist neben einem Vergleich des mittleren Befallsniveaus der Methoden die Häufigkeit von Sekundärinfektionen innerhalb einer Petrischale. Die klassische Darstellungsform für nominale Daten ist eine Häufigkeitstabelle, bzw. Kontingenztafel (Tab.18).

Tab. 18: Kontingenztafel für Pathogen-Befall von Lupinensamen in Abhängigkeit von der Untersuchungsmethode

Methode Frequency Row Pct Col Pct	Befall			Total
	Colletotrichum	andere	unbefallen	
Ethylen	20	180	0	200
	10.00	90.00	0.00	33.33
	16.67	38.38	0.00	
H ₂ O	20	169	11	200
	10.00	84.50	5.50	33.33
	16.67	36.03	100.00	
PDA	80	120	0	200
	40.00	60.00	0.00	33.33
	66.67	25.59	0.00	
Total	120	469	11	600
	20.00	78.17	1.83	100.00

Wir erkennen, dass der *Colletotrichum*-Befall bei der PDA-Methode am höchsten ist. Die Wahrscheinlichkeit für *Colletotrichum* liegt bei Ethylen und H₂O um den Faktor 4 niedriger (10% gegenüber 40%). Die H₂O-Methode ist die einzige, bei der auch gänzlich unbefallene Samen gefunden wurden. Die scheinbare Abhängigkeit zwischen Methode und Befall kann mit einem einfachen Chi-Quadrat-Test auf Signifikanz geprüft werden.

$$\chi^2 = \sum \frac{(n_{ij} - \mu_{ij})^2}{\mu_{ij}}$$

wobei n_{ij} der Zahl Beobachtungen in der i-ten Zeile und j-ten Spalte entspricht und μ_{ij} dem Erwartungswert für diese Zeilen-Spalten-Kombination. Da sich Wahrscheinlichkeiten für eine Kombination von Eigenschaften bekanntermaßen als Produkt der Einzelwahrscheinlichkeiten ergeben, können die Erwartungswerte als das Produkt von Zeilen- und Spaltensumme dividiert durch die Gesamtsumme berechnet werden. Der errechnete empirische Chi-Quadrat-Wert beträgt in unserem Fall 94.9

$$\chi^2 = \frac{(20 - 40)^2}{40} + \frac{(20 - 40)^2}{40} + \frac{(80 - 40)^2}{40} + \frac{(180 - 156.3)^2}{156.3} + \frac{(169 - 156.3)^2}{156.3} + \frac{(120 - 156.3)^2}{156.3} + \frac{(0 - 3.7)^2}{3.7} + \frac{(11 - 3.7)^2}{3.7} + \frac{(0 - 3.7)^2}{3.7} = 94.9$$

und wird mit einem Tabellenwert aus der χ^2 -Verteilung für (R-1)(C-1) Freiheitsgraden verglichen, wobei R und C für die Anzahl Zeilen bzw. Spalten stehen. In unserem Fall haben wir (3-1)(3-1)=4 Freiheitsgrade. Der Tabellenwert für 1% Irrtumswahrscheinlichkeit beträgt $\chi^2_{\text{Tab}}=13.28$. Da der berechnete Wert deutlich größer als der Tabellenwert ist, ist die Abweichung von den erwarteten Werten signifikant. Das heißt die Unabhängigkeitshypothese muss verworfen werden. Es scheint also einen Zusammenhang zwischen Methode und Befall zu geben. Dieser Test setzt allerdings voraus, dass die einzelnen Körner unabhängig voneinander befallen werden. Gerade das ist aber fraglich.

Um die Frage der Sekundärinfektionen innerhalb einer Petrischale zu untersuchen, können wir uns die Verteilung der Befallszahlen anschauen. Als Beispiel soll hier die Methode PDA untersucht werden. 80 von 200 Samen waren bei dieser Methode von *Colletotrichum* befallen, 120 Samen von anderen Pathogenen. Falls der Befall der Samen innerhalb einer Petrischale unabhängig voneinander ist, so müsste die Verteilung der Anzahl befallener Samen einer Binomial-

verteilung folgen. Falls Abhängigkeiten bestehen (Sekundärinfektion!) so sollte die Verteilung dagegen von der Binomialverteilung abweichen. Ob die empirische mit der theoretisch erwarteten Verteilung übereinstimmt können wir mit einem Chi-Quadrat-Anpassungstest prüfen.

Die Formel für Binomialwahrscheinlichkeiten lautet $P(X = k | n; p) = \binom{n}{k} p^k q^{n-k}$

n = Stichprobenumfang

X = Zahl der Stichprobenelemente mit Eigenschaft

k = möglicher Wert für die Realisation von X

p = Wahrscheinlichkeit, dass einzelnes Element Eigenschaft aufweist

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Bei n=10 und p=0.4 ergeben sich folgende Wahrscheinlichkeiten für die Anzahl befallene Samen in einer Petrischale mit 10 Samen:

$$\text{z.B.: 5 befallene Samen} = P(X=5|10;0.4) = \frac{n!}{k!(n-k)!} p^k q^{n-k} = \frac{10!}{5!(10-5)!} 0.4^5 0.6^{10-5} = 0.20$$

Tab. 19: Erwartete und beobachtete Verteilung der Anzahl mit *Colletotrichum lupini* befallener Samen bei 20 Petrischalen je 10 Samen

k	n über k	P	Erwartete Häufigkeit	Beobachtete Häufigkeit
0	1	0.00604662	0.12	0
1	10	0.04031078	0.81	3
2	45	0.12093235	2.42	2
3	120	0.21499085	4.30	2
4	210	0.25082266	5.02	6
5	252	0.20065812	4.01	1
6	210	0.11147674	2.23	4
7	120	0.04246733	0.85	2
8	45	0.01061683	0.21	0
9	10	0.00157286	0.03	0
10	1	0.00010486	0.00	0

Für den Chi-Quadrat-Anpassungstest sollten möglichst alle Klassen Erwartungswerte größer 1 haben. Wenn nötig werden benachbarte Klassen zusammengefasst. Wir fassen hier die Klassen 0, 1 und 2 sowie 7, 8, 9 und 10 zusammen. Für die verbleibenden sechs Klassen ergibt sich ein Chi-Quadrat-Wert von 6.66. Dieser ist bei (c-1-q) = 4 Freiheitsgraden nicht signifikant. Die Häufigkeiten scheinen also im Wesentlichen einer Binomialverteilung zu folgen. Dieses stützt die Annahme voneinander unabhängiger Samen und ist damit ein Argument gegen die Hypothese von Sekundärinfektionen innerhalb einer Petrischale. Allerdings ist der Stichprobenumfang relativ gering. Weshalb vielleicht doch signifikante Sekundärinfektionen auftreten, wir erkennen diese jedoch nicht (Fehler zweiter Art). Ein weiterer Nachteil der Auswertung über Kontingenztafeln und Chi-Quadrat-Verfahren ist die Tatsache, dass lediglich die Nullhypothese der Unabhängigkeit zwischen den Variablen geprüft wird. Es werden keine modellbasierten Schätzwerte für Effekte erhalten, geschweige denn Standardfehler berechnet. Im vorliegenden Fall weiß man lediglich, dass der Befall mit *Colletotrichum* bei Anzucht auf PDA etwa um den Faktor 4 erhöht ist und dass diese Erhöhung signifikant ist. Eine Alternative stellt deshalb einmal

mehr die Formulierung eines Generalisierten Linearen Modells dar. Bei mehr als zwei Klassen für den Befall, sollten wir als Link-Funktion einen kumulativen-Logit-Link und als Verteilung die Multinomialverteilung wählen. Falls wir uns auf zwei Klassen beschränken (z.B. *Colletotrichum*-Befall und kein *Colletotrichum*-Befall), so haben wir ein binäres Merkmal vor uns und können wieder wie bei Merkmalen vom Typ „Prozent Befall“ (Beispiel 3) einen Logit-Link und Binomialverteilung wählen. Dass sich die Samen innerhalb einer Petrischale beeinflussen, wird im Sinne eines GLM als „Überdispersion“ bezeichnet und kann unmittelbar modelliert werden. Im Rahmen von Generalisierten Linearen Gemischten Modellen (GLMM) können auch weitere zufällige Effekte in das Modell integriert werden (z.B. für Auswertung einer Spaltanlage).

Fazit Beispiel 5

Falls die abhängige Variable nominales Niveau mit mehr als zwei Klassen hat, so ist die Erstellung einer Häufigkeitstabelle / Kontingenztafel ein erster Schritt. Abhängigkeiten zwischen den Variablen können mittels Chi-Quadrat-Test auf Signifikanz geprüft werden. Der Chi-Quadrat-Test setzt allerdings voneinander unabhängige Beobachtungen voraus, was bei landwirtschaftlichen Versuchen infolge von Beeinflussungen zwischen Einzelpflanzen häufig nicht gegeben ist. Daneben können Parzellenfehler auftreten. Besser ist daher die Auswertung als GLM unter Annahme einer Multinomialverteilung und Cumulative-Logit-Link bzw. Binomialverteilung und Logit-Link.

Beispiel 6 – Nominale Daten oder Bonituren mit zwei Stufen (krank/gesund)

Es gibt Merkmale, bei denen nur das Auftreten oder die Abwesenheit bonitiert werden kann, bzw. eine Eigenschaft tritt lediglich in zwei Ausprägungsstufen auf. Falls mehrere Beobachtungen je Parzelle (bzw. Gefäß) vorliegen, so kann ein Wert vom Typ „Prozent Befall“ berechnet werden (siehe Beispiel 3). Die Auswertung kann dann entweder über Transformation und Varianzanalyse oder wiederum mit einem Generalisierten Linearen Modell erfolgen (PIEPHO 1998). Falls nur eine Beobachtung pro Parzelle vorliegt, so muss zwangsläufig eine Auswertung über Logistische Regression oder ein GLM mit Logit-Link erfolgen. Eine einfache aber nicht effiziente Alternative ist die Auswertung über Kontingenztafeln (siehe Beispiel 5).

Zusammenfassung

In Feldversuchen werden Daten unterschiedlicher Skalierung erhoben. Durch Berechnung von Mittelwerten und Varianzen und Erstellen von Box-Plots, Häufigkeitstabellen und Histogrammen kann ein Eindruck von zentraler Tendenz und Variation der Daten gewonnen werden. Um die Präzision der ermittelten Schätzwerte bewerten zu können und um Signifikanztests zu erhalten werden häufig Varianzanalyse und parametrische Mittelwerttests eingesetzt. Die Varianzanalyse hat aber Voraussetzungen, die überprüft werden müssen. Falls Voraussetzungen wie Normalverteilung der Residuen, Varianzhomogenität oder Additivität verletzt sind, so sollte eine Transformation der Daten probiert werden. Falls das Ergebnis dieser Transformation nicht befriedigend ist, so sollte die Auswertung über ein Generalisiertes Lineares Modell (GLM) in Erwägung gezogen werden. Besonders problematisch ist die Auswertung von nominalen oder ordinalen Daten wie z.B. Boniturnoten, diese Daten können allein aufgrund ihres Skalenniveaus die Voraussetzungen der Varianzanalyse nicht erfüllen. Hier kann ebenfalls ein GLM helfen. Boniturnoten sollten wenn möglich durch eine Prozentskala ersetzt werden.

Literatur

- ABBOTT, W.S. (1925): A method of computing the effectiveness of an insecticide: J. Econ. Entomol. 18, 265-267.
- AGRESTI, A. (2002): Categorical Data Analysis. 2nd Ed., Wiley.
- BBA (2001): EPPO-Richtlinie PP 1/152 (2), Anlage und Auswertung von Wirksamkeitsprüfungen. Biologische Bundesanstalt für Land- und Forstwirtschaft.
- BORTZ, J. (1999): Statistik für Sozialwissenschaftler. 5. Auflage, Springer.
- BORTZ, J., LIENERT, G.A., BOEHNKE, K. (2000): Verteilungsfreie Methoden in der Biostatistik. 2. Auflage, Springer.
- BRUNNER, E., LANGER, F. (1999): Nichtparam. Analyse longitudinaler Daten. Oldenbourg.
- BRUNNER, E., MUNZEL, U. (2002): Nichtparametrische Datenanalyse. Unverbundene Stichproben. Springer.
- BUNDESSORTENAMT (2000): Richtlinien für die Durchführung von landwirtschaftlichen Wertprüfungen und Sortenversuchen. Landbuch Verlag, Hannover.
- HARTUNG, K., PIEPHO, H.P. (2005): A threshold model for multi-year genebank data based on different rating scales. Crop Science, 45, 1045-1051.
- KEMPTON, R.A., FOX, P.N. (1997): Statistical methods for plant variety evaluation. Chapman and Hall, London.
- McCULLAGH, P., NELDER, J. (1989): Generalized linear models. Chapman & Hall, London.
- PIEPHO, H.P. (1997): Schwellenwertmodelle mit festen und zufälligen Effekten für Boniturdaten aus landwirtschaftlichen Versuchen. Informatik, Biometrie und Epidemiologie in Medizin und Biologie 28: 185-197.
- PIEPHO, H.P. (1998): Auswertung von Bonituren des Typs "Prozent Befall" mit Hilfe von SAS Prozeduren für Generalisierte Lineare Modelle. Zeitschrift für Agrarinformatik, 6, 26-37.
- PIEPHO, H.P. (2004): An algorithm for a letter-based representation of all-pairwise comparisons. Journal of Computational and Graphical Statistics 13, 456-466.
- PIEPHO, H.P. (2005): Zur Durchführung von Mittelwertvergleichen in unbalancierten Versuchen. Mitteilungen der Gesellschaft für Pflanzenbauwissenschaften, Band 17, 373-374.
- PIEPHO, H.P., BÜCHSE, A. (2003): Spaltanlage - Messwiederholung - Dauerversuch: Hinweise zur Auswertung komplexer pflanzenbaulicher Versuche mit gemischten Modellen. Mitteilungen der Gesellschaft für Pflanzenbauwissenschaften, Band 15, 362-367. siehe auch: „<http://www.uni-hohenheim.de/bioinformatik/veroeffentlichung/vortrag/Skript.doc>“
- PIEPHO, H.P., KALKA, E. (2003): Threshold models with fixed and random effects for ordered categorical data. Food Quality and Preference, 14, 343-357.
- SCHUMACHER, E., FRISCH, M. (1995) : Permutationstests zur Analyse von Boniturdaten in einfachen Versuchsanlagen. Zeitschrift für Agrarinformatik, 5, 107-113.
- SCHUMACHER, E., FRISCH, M. (1997): Ein SAS-Macro zur Durchführung von Permutationstests in vollständigen und unvollständigen Blockanlagen. Zeitschrift für Agrarinformatik, 6, 125-130.
- SCHUMACHER, E., THÖNI, H. (1990): Auswertung von Bonitурwerten. Agrarinformatik, 18, 51-62.
- THÖNI, H. (1985): Auswertung von Bonituren: Ein empirischer Methodenvergleich. EDV in Medizin und Biologie, 16, 108-114.
- THÖNI, H. (1992): Auswertung von Bonitурdaten: Ein empirischer Methodenvergleich. II. Signifikanzprüfung von Prüfgliedeffekten. Biometrie und Informatik in Medizin und Biologie 23: 144-156.

Anhang: SAS-Code zur Auswertung von Beispiel 2 mittels Log-linearem Modell

```
data b;
do Beh=1, 4, 5, 6;
  do Block=1 to 4;
    input y@; output;
  end;
end;
datalines;
16.0  16.0  4.8  11.2
4.8   4.0   0.0  2.4
10.4  2.4   0.0  0.0
8.0   8.8   7.2  4.0
;
run;

proc genmod data = b ;
ods output lsmeandiffs = diffs;
class Beh Block;
model y = Block Beh / dist=poisson scale=pearson link=log type1;
lsmeans Beh / pdiff cl;
run;

data diffs;
set diffs;
if Beh = 1;
WG = ( 1-exp(-estimate) )*100;
Lower_WG = ( 1-exp(-LowerCL) )*100;
Upper_WG = ( 1-exp(-UpperCL) )*100;

proc print data = diffs;
var _Beh WG Lower_WG Upper_WG;
run;
```