

Transformation von Daten

Es gibt Versuchsergebnisse, die intervallskaliert sind, aber keine Varianzhomogenität oder Normalverteilung aufweisen. Da die Varianzanalyse eine sehr flexible und mächtige Methode ist, möchte man sie aber trotzdem gerne einsetzen. Folgendes Beispiel dazu:

In einem Feldversuch (vollständig randomisiert; 4 Parzellen pro Variante) wurde die insektizide Wirkung von 3 neuen Wirkstoffen gegen Kohleulenlarven an Rotkohl im 6-Blattstadium untersucht. 2 Tage nach der Applikation wurde die Anzahl noch lebender Larven in jeder einzelnen Parzelle ermittelt.

Larvenzahl/Parzelle				
	Kontrolle	Mittel A	Mittel B	Mittel C
Wdh 1	56	8	32	14
Wdh 2	23	2	10	5
Wdh 3	45	6	21	12
Wdh 4	78	12	43	20
Varianz	524,33	17,33	201,67	38,25

Es fällt mit bloßem Auge auf, dass Mittel A offensichtlich sehr wirksam war, die Kontrolle demgegenüber viel höhere Werte aufweist. In einem solchen Fall sollte man unbedingt prüfen, ob die Varianzen der 4 Versuchsvarianten noch als homogen zu bezeichnen sind.

Die Berechnung der Varianzen ergibt sehr große Unterschiede. Die Varianz der Kontrolle (524,33) ist 30mal größer als die Varianz von Mittel A ($524,33/17,33 = 30,26$). Hier kann man wirklich nicht mehr von Varianzhomogenität sprechen. Eine einfache Faustformel besagt, dass Varianzen als homogen zu bezeichnen sind, wenn $s^2_{\max}/s^2_{\min} < 4$ ist.

Was könnte man tun? In diesem Fall wird empfohlen, die Originaldaten zu transformieren, z. B. zu logarithmieren. Bei der Auswahl der passenden Transformation gibt es einige Entscheidungshilfen. Man sollte für jede Versuchsvariante (hier die Insektizidbehandlungen) den Mittelwert, die Varianz und die Standardabweichung berechnen. Dann sollte man für jede Stichprobe die Quotienten Varianz/Mittelwert und Standardabweichung/Mittelwert berechnen. Wenn die Werte des Quotienten Varianz/Mittelwert mehr oder minder ähnlich groß sind, dann empfiehlt sich eine Wurzeltransformation (Quadratwurzel der Originalwerte). Wenn die Quotienten Standardabweichung/Mittelwert mehr oder minder gleich groß sind, dann empfiehlt sich eine Logarithmierung.

Hier sind die Quotienten Standardabweichung/Mittelwert größenordnungsmäßig sehr ähnlich:

Larvenzahl/Parzelle				
	Kontrolle	Mittel A	Mittel B	Mittel C
Wdh 1	56	8	32	14
Wdh 2	23	2	10	5
Wdh 3	45	6	21	12
Wdh 4	78	12	43	20

Mittelwert	50,5	7	26,5	12,75
Varianz	524,33	17,33	201,67	38,25
Standardabweichung	22,90	4,16	14,20	6,18
Varianz/Mittel	10,38	2,48	7,61	3,00
Stabw/Mittel	0,45	0,59	0,54	0,49

Also logarithmieren wir die Originalwerte ($\log x_{ij}$). **Bei der Logarithmierung muss eine Sache beachtet werden: wenn es Originalwerte gibt, die 0 sind, dann ist eine Logarithmierung dieser Werte mathematisch nicht möglich. Es wird dann empfohlen, bei allen Einzelwerten vor der Transformation einen im Verhältnis zu diesen Werten kleinen Wert dazu zu addieren!** Bei den vorliegenden Werten gibt es keine 0-Werte, also können die vorliegenden Werte ohne Veränderung logarithmiert werden:

log Anzahl	Kontrolle	Mittel A	Mittel B	Mittel C
	1,748	0,903	1,505	1,146
	1,362	0,301	1,000	0,699
	1,653	0,778	1,322	1,079
	1,892	1,079	1,633	1,301
Mittelwert	1,664	0,765	1,365	1,056
Varianz	0,050	0,111	0,076	0,065
Summe	6,655	3,061	5,461	4,225
Summe ²	44,292	9,372	29,821	17,853

Wenn wir nun die Stichprobenvarianzen aus den logarithmierten Werten berechnen, dann sieht man sofort, dass sie sich ziemlich ähnlich sind ($s^2_{\max} = 0,111$, $s^2_{\min} = 0,05$). Wir haben Varianzhomogenität erzielen können. Nun kann man die Varianzanalyse mit den logarithmierten Werten durchführen.

Händisches Rechnen der Varianzanalyse mit Hilfe des Subtraktionsglieds:

Subtraktionsglied: $(\text{Summe aller Einzelwerte})^2 / \text{Anzahl Einzelwerte} = 23,529$

SQ gesamt: Summe der quadrierten Einzelwerte - Subtraktionsglied

SQ zwischen (Varianten): $(6,655^2 + 3,061^2 + 5,461^2 + 4,225^2) / 4$ - Subtraktionsglied

SQ innerhalb (Rest): SQgesamt – SQ zwischen

Ursache	SQ	FG	MQ	Fvers	Ftab 5%
zwischen	1,805	3	0,602	7,96	3,49
innerhalb	0,907	12	0,076		
Gesamt	2,712	15			

Da die Varianzanalyse signifikante Unterschiede zwischen den Insektizidvarianten ausweist, fügt man noch einen multiplen Mittelwertvergleich an:

z. B. den Tukey-Test

Im balancierten Fall (d. h. Stichprobenumfänge gleich groß):

$$GV = q_{\alpha}(s;FG) * \sqrt{MQI/n}$$

$$GV = 4,2 (4; 12; 5\%) * 0,1378 = 0,579$$

GV = Grenzdifferenz; wenn Differenzen zwischen zwei Behandlungsmittelwerten > GV dann empfiehlt der Tukey-Test von Unterschiedlichkeit zu sprechen

	Kontrolle	Mittel B	Mittel C	Mittel A
	1,664	1,365	1,056	0,765
1,664		0,299	0,607	0,898
1,365			0,309	0,600
1,056				0,291
0,765				

Es gibt signifikante Unterschiede bei den fett hervorgehobenen Paardifferenzen. Mittel A und B haben z. B. signifikant niedrigere Larvenanzahlen als die Kontrolle.

Wichtig ist, dass die gesamte Datenanalyse (Varianzanalyse und multipler Mittelwertvergleich) mit den transformierten Werten gerechnet werden muss.

Ganz zum Schluss kann man die Mittelwerte der transformierten Werte detransformieren (hier 10 hoch log-Mittel), um sie in dieser Form in einem Bericht zu präsentieren. Für die Leser ist es schöner, Mittelwerte in der Originaldimension zu sehen zu bekommen:

	log-Mittel	delogarithmierte Anzahl Larven
Kontrolle	1,664	46,1
Mittel B	1,365	23,2
Mittel C	1,056	11,4
Mittel A	0,765	5,8